

FUNDAMENTOS ALGEBRAICOS PARA LA IA

Juan Perán Mazón
Departamento de Matemática Aplicada de la UNED ¹

28 de septiembre de 2026

¹ Este material se ha beneficiado significativamente de las revisiones, comentarios y sugerencias didácticas de los profesores Estibalitz Durand Cartagena y Fernando Jiménez Alburquerque, a quienes agradezco sinceramente su colaboración.

Aviso legal y de propiedad intelectual

- © 2026 [Juan Perán Mazón]. Todos los derechos reservados.
 - **Licencia de uso:** Esta obra se distribuye bajo los términos de la licencia *Creative Commons Atribución-NoComercial-SinDerivadas 4.0 Internacional (CC BY-NC-ND 4.0)*. Se permite su descarga y compartición gratuita siempre que se reconozca la autoría original, no se destine a fines comerciales y no se modifique ni se use para crear obras derivadas.
 - **Registro y prueba de autoría:** Obra inscrita en *Safe Creative* bajo huella digital con sello de tiempo criptográfico, garantizando la integridad y prioridad de la autoría sobre el texto base y sus versiones consolidadas.
-

ÍNDICE GENERAL

Tema I. ESCALARES	15
1. Conjuntos, tuplas, producto cartesiano	15
1.1. Lógica y teoría axiomática de conjuntos.	15
1.2. Teoría ingenua de conjuntos.	16
1.3. Tuplas y producto cartesiano.	19
1.4. Funciones.	21
1.5. Familias o conjuntos indexados.	22
1.6. Conjuntos numéricos	24
2. Los números naturales y los enteros. Bases de numeración	24
2.1. Números naturales y enteros	24
2.2. Sistemas de numeración.	26
2.3. El sistema posicional	28
3. Los números racionales.	30
3.1. El cuerpo $\mathbb{Q}$ de los números racionales.	30
3.2. Fracción y desarrollo de un racional	32
4. Los números reales	36
4.1. El cuerpo $\mathbb{R}$ de los números reales	36
4.2. Redondeo de números reales.	38
5. Números complejos	41
5.1. El cuerpo de los números complejos	41

5.2. Conjugado, módulo y argumento de un complejo	44
5.3. Representación gráfica de los números complejos	46
5.4. La función exponencial compleja	47
5.5. Teorema Fundamental del Álgebra	51
Tema II. TENSORES, MATRICES Y VECTORES	55
1. El espacio lineal $\mathbb{K}^I$	55
1.1. Introducción	55
1.2. Combinaciones lineales en $\mathbb{K}^I$	56
1.3. El teorema de la base	61
1.4. Espacios vectoriales «abstractos».	63
2. Los tensores como contenedores de datos indexados	64
2.1. Introducción	64
2.2. Definición de tensor	65
2.3. Notación de corchetes anidados	67
2.4. Construcción de matrices por bloques o cajas	70
2.5. Transposición de ejes. Matriz transpuesta	71
2.6. Algunas matrices importantes	74
2.7. Resumen de las identificaciones más importantes	81
2.8. ¿Qué es un vector?	82
3. Operaciones con tensores.	83
3.1. Combinaciones lineales de tensores	83
3.2. Producto de matrices.	84
3.3. Contracción de índices	87
3.4. Multiplicación por bloques	90
3.5. Propiedades del producto de matrices	94

3.6. Matrices normales	96
4. Matriz inversa.	97
4.1. Definición y propiedades	97
4.2. Cálculo de la matriz inversa	99
4.3. Cambio de base en $\mathbb{K}^n$	103
5. Distancias y ángulos.	104
5.1. Módulo de un vector.	104
5.2. Distancias y ángulos. Ortogonalidad	106
5.3. Distancia en $\mathbb{K}^n$	108
6. Ortogonalización.	110
6.1. Procedimiento de ortogonalización de Gram-Schmidt	110
6.2. Complemento ortogonal	112
6.3. Proyección ortogonal	113
6.4. Matrices ortogonales.	115
 Tema III. MATRICES Y TENSORES COMO APLICACIONES LINEALES O MULTILINEALES	 119
1. Los tensores como aplicaciones.	119
2. El determinante.	125
2.1. Definición y propiedades	125
2.2. Cálculo del determinante de matrices especiales.	128
2.3. Interpretación geométrica del determinante	131
3. Aplicaciones lineales entre espacios de vectores.	136
3.1. Subespacios de una matriz	136
3.2. Núcleo generalizado	137
3.3. Autovalores y autovectores.	138

4. Formas bilineales y formas cuadráticas	144
4.1. Formas bilineales.	144
4.2. Formas cuadráticas.	147
4.3. El producto escalar como forma cuadrática	149
Tema IV. PROCESOS DE TRIANGULACIÓN	153
1. Matrices triangulares	153
2. Factorización PLU.	154
2.1. Sistemas de ecuaciones lineales en forma matricial	154
2.2. El método de Gauss	156
2.3. Factorización PLU	164
3. Factorización QR	170
3.1. Ortogonalización de Gram-Schmidt y factorización QR	170
3.2. Aspectos computacionales de la factorización QR	174
3.3. Sistemas de ecuaciones y factorización QR.	175
4. Factorización triangular de Schur	179
Tema V. PROCESOS DE DIAGONALIZACIÓN	181
1. Diagonalización	181
2. Factorización LDU.	183
3. Diagonalización ortogonal	186
3.1. Teorema espectral	186
3.2. Ley de inercia de Sylvester.	189
3.3. Matrices definidas y semidefinidas	192
4. Diagonalización por similitud	196
4.1. Matrices diagonalizables	196

4.2. Forma canónica de Jordan	198
5. Descomposición en valores singulares (SVD)	201
TABLA DE MATRICES	207
ÍNDICE ALFABÉTICO DE TÉRMINOS	209
LISTA DE SÍMBOLOS	221
BIBLIOGRAFÍA	223

TEMA I

ESCALARES

1. CONJUNTOS, TUPLAS, PRODUCTO CARTESIANO

1.1. Lógica y teoría axiomática de conjuntos.

Es un lugar común afirmar que la matemática moderna se erige sobre los cimientos de la lógica formal y la teoría axiomática de conjuntos. Sin embargo, una mirada atenta a la práctica matemática revela una realidad distinta: incluso en sus ramas más puras y abstractas, la matemática no se formula ni se comunica mediante cadenas de símbolos lógicos. Su verdadero sustrato es el lenguaje natural enriquecido con la notación de una teoría de conjuntos esencialmente «ingenua». La formalización estricta es, en el mejor de los casos, un horizonte teórico que garantiza la solidez del edificio.

Ya Descartes sostenía en su *Discurso del método* que las reglas de la lógica servían más para explicar a otros lo que uno ya sabe (o incluso para hablar sin juicio de lo que se ignora) que para aprender. Sin llegar a la radicalidad de L.E.J. Brouwer (uno de los fundadores de la topología algebraica), para quien «la lógica descansa sobre las matemáticas, y no las matemáticas sobre la lógica», en lo que sigue nos basaremos en una lógica y en una teoría de conjuntos esencialmente informales, intuitivas, podríamos decir.

Por eso, prescindimos de las notaciones y de la jerga formal de la lógica, reduciendo su uso prácticamente a los símbolos de implicación « $\implies$ » y « $\iff$ » (más por brevedad que por rigor) y prefiriendo siempre la claridad del lenguaje natural frente al formalismo.

Cualquier intento de explicar la implicación lógica a través de ejemplos cotidianos (los típicos casos ilustrativos del tipo «si llueve, me mojo») suele generar más confusión que claridad. El motivo es que en la vida real las implicaciones arrastran siempre un sentido de causalidad o conexión temporal que no existe en la implicación lógica matemática.

Por esta razón, los mejores ejemplos para comprender su verdadero significado deben extraerse necesariamente del propio terreno de las matemáticas: si P y Q son proposiciones con variables, entonces « $P \implies Q$ » significa que no se cumple « P y no Q » para ningún valor de esas variables.

1.2. Teoría ingenua de conjuntos.

Una vez descartado el enfoque axiomático riguroso, describimos brevemente las nociones intuitivas y las notaciones que emplearemos. Quien desee ampliar los contenidos puede consultar el texto clásico de Halmos, *Naive Set Theory* ([2]).

Al exponer la teoría de conjuntos de forma rigurosa, se simula la construcción de todo el universo matemático a partir de unos ingredientes mínimos. Como esto prohíbe utilizar conceptos que no hayan sido definidos previamente mediante los axiomas, resulta difícil ilustrar el avance con ejemplos. Nosotros, en cambio, nos conformaremos con una aproximación ingenua, lo que nos permite dar por sentados los números reales. Más adelante, revisaremos los conjuntos numéricos: naturales ($\mathbb{N}$), enteros ($\mathbb{Z}$), racionales ($\mathbb{Q}$), reales ($\mathbb{R}$) y complejos ($\mathbb{C}$).

Carece de sentido (incluso en una presentación informal como esta) definir los conceptos de *conjunto* y *elemento*. El término «conjunto» desempeña un papel similar a la palabra «algo»: en sentido estricto, todos los objetos de las matemáticas son conjuntos. Para no repetir la palabra «conjunto», se emplea a veces el sinónimo *colección*.

Lo relevante es la *relación de pertenencia* que se asume establecida entre los conjuntos. Es decir, no hay «conjuntos» y «elementos», como entes distintos, sino que unos conjuntos pertenecen a otros (los primeros *son elementos de* los segundos) y cada conjunto queda determinado por sus elementos. Pensar que unos objetos son «elementos» y que otros son «conjuntos» conduce a confusiones y bloqueos mentales. Nunca se debe decir « a es un elemento», sino « a es un elemento de».

La expresión $b \in A$, significa que b pertenece a A , es decir, que b es un elemento de A . El símbolo tachado, $\notin$, significa «no pertenece». Este criterio de «tachar para negar» se extiende al resto de los símbolos que veremos para denotar relaciones.

No hay ningún motivo especial para emplear en la expresión anterior minúscula para la b y mayúscula para la A . De igual manera podría haberse puesto $b \in a$ o $B \in A$, si eso fuera lo correcto. No obstante, para facilitar la lectura y aunque no hay ninguna norma que lo prescriba, se suele utilizar una jerarquía *creciente* en la tipografía. Por ejemplo, las minúsculas suelen indicar un nivel inferior frente a las mayúsculas ($b \in B$), al igual que las primeras letras del alfabeto frente a las últimas ($B \in X$) o las fuentes más simples frente a las más historiadas ($X \in \mathfrak{B}$).

El conjunto que no tiene elementos se llama *conjunto vacío* y se denota por $\emptyset$. Solo hay un conjunto vacío, pues todo conjunto queda determinado por sus elementos.

Las *llaves*, $\{ \dots \}$, determinan conjuntos. Los elementos se pueden enumerar o deter-

minar por una condición. En el segundo caso, hay que referir la condición a un conjunto prefijado, salvo que la teoría añada un axioma que garantice la existencia de tal conjunto.

Aunque procuraremos evitar el fanatismo de las notaciones, hay ocasiones para ser inflexibles y esta es una de ellas: las llaves y solo las llaves describen por extensión los elementos de un conjunto y no se deben emplear las llaves con ningún otro fin.

Ejemplo 1. ■ $b \in \{a, b\}$, $a \in \{a\}$, $\{a, b\} = \{b, a\}$, $\{a, a\} = \{a\}$.

- $\{x \in \{a, b, u\} : x \text{ está denotado por una vocal}\} = \{a, u\}$.
- $\{n \in \mathbb{N} : n < 7\} = \{0, 1, 2, 3, 4, 5, 6\}$.
- $A = \{B : B \text{ tiene más de un elemento}\}$ no está bien formado, porque no se fija el conjunto al que se refiere la condición.
- La *intersección* de dos conjuntos A y B es el conjunto $A \cap B = \{x \in A : x \in B\}$. Observemos que $A \cap B = B \cap A$.
- El *complementario relativo* de B en A , es el conjunto $A \setminus B = \{x \in A : x \notin B\}$, es decir, el conjunto formado por los elementos de A que no pertenecen a B .

Cuando A y B son subconjuntos de un conjunto X en que se ha definido una operación *resta* (como, por ejemplo, en $X = \mathbb{R}$), se denota por $A - B$ al conjunto $A - B = \{a - b : a \in A, b \in B\}$, ¡no se debe confundir con $A \setminus B$!

Por ejemplo: $\{1, 2, 5\} \setminus \{1, 2\} = \{5\}$, mientras $\{1, 2, 5\} - \{1, 2\} = \{0, -1, 1, 4, 3\}$.

□

Si la intersección es un simple ejemplo de definición de un conjunto por extensión, la *unión* requiere un axioma propio: dada una colección $\mathfrak{B}$, existe un conjunto $\bigcup \mathfrak{B}$ formado por los x tales que $x \in X$ para algún $X \in \mathfrak{B}$. En particular, se pone $A \cup B = \bigcup \{A, B\}$, es decir, $A \cup B$ está formado por los x tales que $x \in A$ o $x \in B$.

Se dice que A es un *subconjunto* de B , escrito como $A \subset B$, o también, como $A \subseteq B$, si todos los elementos de A son elementos de B , es decir, si $A \cap B = A$ o, equivalentemente, si $A \cup B = B$.

También se necesita un axioma para garantizar la existencia del conjunto formado por los subconjuntos de un conjunto X , que se denomina *conjunto de las partes* de X o *conjunto potencia* de X y se denota por $\wp(X)$, es decir, $\wp(X) = \{A : A \subset X\}$.

Ejemplo 2. Sean cuales sean los conjuntos A, a, b y c , las siguientes expresiones son verdaderas, $\{a, b\} \subset \{a, b, c\}$, $\{a\} \subset \{a, b\}$, $a \in \{a, b\}$, $\wp(\{a, b\}) = \{\emptyset, \{a\}, \{b\}, \{a, b\}\}$, $\emptyset \subset A$, $\emptyset \in \wp(A)$, $A \subset A$, $A \in \wp(A)$. □




Figura 1. Representación «ingenua» de la unión, la intersección y el complementario relativo.

¿Cuántos pisos tiene el edificio de las matemáticas? Puede llegar a producir vértigo observar que, según la teoría de conjuntos formal, la jerarquía de potencias A , $\wp(A)$, $\wp(\wp(A))$, ... de un conjunto A es ilimitada. Y no solo hacia arriba: ¡también es ilimitada hacia abajo!, ya que los elementos de A distintos del vacío son, a su vez, conjuntos que contienen otros elementos.

Sin embargo, la práctica real de las matemáticas es mucho más acotada. Normalmente, un texto matemático se mueve dentro de un único conjunto U (el *universo*), que a menudo ni siquiera se menciona explícitamente. Los elementos $x \in U$ formarían la planta baja. Si subimos la escalera, los elementos de $\wp(U)$ estarían en la primera planta, los de $\wp(\wp(U))$ en la segunda, y así sucesivamente. En cambio, si bajáramos, los elementos que pertenecen a esos objetos de la planta baja estarían en el primer sótano.

Pues bien, la regla implícita en la matemática cotidiana es tajante: jamás se baja al sótano y rara vez se pasa de la tercera planta.

Ejemplo 3. Si el universo es $U = \mathbb{R}$, un número real a habita en la planta baja; en la práctica, nos conformamos con su valor y nunca nos preguntamos qué hay «dentro» de él. Un intervalo cerrado $I = [a, b]$, al ser un conjunto de números, sube a la primera planta $\wp(\mathbb{R})$. Dando un paso más en la abstracción, la colección $\mathcal{U}_a$ de todos los intervalos que contienen al número a es un conjunto de conjuntos, por lo que se sitúa en la segunda planta $\wp(\wp(\mathbb{R}))$. Y así sucesivamente.

Cada piso que subimos no representa objetos más grandes, sino un nuevo nivel de empaquetamiento: elementos, conjuntos de elementos y colecciones de conjuntos. $\square$

1.3. Tuplas y producto cartesiano.

Hemos visto que el par $\{a, b\}$ no está ordenado, esto es, que $\{a, b\} = \{b, a\}$. Resulta crucial definir la noción de par ordenado pero, aunque intuitivamente tenemos claro lo que pretendemos, no es fácil proporcionar una construcción racional, porque no sabemos qué significa «ordenar conjuntos».

El *par ordenado* (a, b) se define como

$$(a, b) = \{\{a\}, \{a, b\}\}.$$

Por enrevesada que parezca, esta es la manera más simple e ingeniosa de conseguir lo que queríamos: si $a \neq b$, entonces $(a, b) \neq (b, a)$. Además, la definición permite «repetir coordenadas», como en (a, a) , sin incurrir en ambigüedad ni contradicción.

Denominamos *producto cartesiano* de los conjuntos A y B al conjunto

$$A \times B = \{(a, b) : a \in A, b \in B\}.$$

En lugar de $A \times A$ se pone A^2 .

 El significado de los superíndices en matemáticas es estrictamente contextual. Frecuentemente denotan la repetición de una operación (como en el producto de números, matrices u otros objetos); en este caso, la reiteración del producto cartesiano. Los diferentes significados del superíndice pueden combinarse una misma frase sin confusión posible; por ejemplo: «si A tiene n elementos, entonces A^2 tiene n^2 elementos». $\square$

Ejemplo 4. ■ $\{a, b\} \times \{a, b, c\} = \{(a, a), (a, b), (a, c), (b, a), (b, b), (b, c)\}.$

■ Si $A = \{a, b\}$, entonces $A^2 = \{(a, a), (a, b), (b, a), (b, b)\}.$

■ $\mathbb{R}^2 = \{(x, y) : x, y \in \mathbb{R}\}.$

■ $[1, 5] \times [-2, 7] = \{(x, y) \in \mathbb{R}^2 : 1 \leq x \leq 5, -2 \leq y < 7\}.$ $\square$

Razonando por inducción se pueden definir *ternas ordenadas*, (a_1, a_2, a_3) , *cuaternas ordenadas*, (a_1, a_2, a_3, a_4) y, en general, n -tuplas, $(a_1, a_2, \dots, a_n)$. En efecto, una vez definida la tupla $(a_1, a_2, \dots, a_{n-1})$, se define la n -tupla $(a_1, a_2, \dots, a_n)$ como

$$(a_1, a_2, \dots, a_n) = ((a_1, a_2, \dots, a_{n-1}), a_n).$$

Después de conseguir una definición de tupla sólida (aunque artificiosa), se olvidan los detalles técnicos (tal y como se hace frecuentemente en matemáticas), para recordar solamente las propiedades características del concepto: una n -tupla es una ristra de n elementos, posiblemente repetidos, en la que se tiene en cuenta el orden en el que figuran.

La propiedad característica fundamental es:

$$(a_1, a_2, \dots, a_n) = (b_1, b_2, \dots, b_m) \text{ si y solo si } n = m, a_1 = b_1, a_2 = b_2, \dots, a_n = b_n.$$

Ejemplo 5. $(1, 1, 2) \neq (1, 2, 1) \neq (1, 2), (0, 0, 0) \neq (0, 0).$ □

No es necesario que las componentes de una tupla sean números. El par ordenado (P, Q) , por ejemplo, puede estar formado por dos puntos, dos rectas o dos planos; incluso permite combinar objetos de distinta naturaleza, siendo P un plano y Q un punto.

Ya hemos dicho que el conjunto cuyos elementos son los pares ordenados (a_1, a_2) con $a_1 \in A_1, a_2 \in A_2$ es el producto cartesiano $A_1 \times A_2$ y que el producto cartesiano de un conjunto por sí mismo se denota por $A^2 = A \times A$. Análogamente, con más factores, así $A_1 \times A_2 \times A_3$ es el conjunto formado por las ternas de la forma (a_1, a_2, a_3) con $a_1 \in A_1, a_2 \in A_2, a_3 \in A_3$ o, con n factores, $A^n = A \times \dots \times A$, es el conjunto formado por las n -tuplas $(a_1, a_2, \dots, a_n)$, con $a_1, a_2, \dots, a_n \in A$.

Una **relación** en un conjunto X es un subconjunto $\mathcal{R}$ de $X \times X$. En lugar de escribir $(x_1, x_2) \in \mathcal{R}$, se suele poner $x_1 \mathcal{R} x_2$. Las relaciones más importantes son las de **orden**, para las que se emplea genéricamente el símbolo « $\leq$ », que se lee «menor que» o «estrictamente menor que», en vez de una letra como $\mathcal{R}$. Las relaciones de orden se caracterizan por dos propiedades básicas: i) ningún elemento es estrictamente menor que sí mismo, ii) si un elemento es menor que otro y éste es menor que un tercero, entonces el primero es menor que el tercero.

Decimos que un orden es **total** en el conjunto dado cuando cualesquiera dos de sus elementos están relacionados (uno es menor que el otro); en otro caso, se dice que el orden es **parcial**. El símbolo « $\leq$ » se lee «menor o igual que», y significa precisamente eso.

 En este manual, al hablar de «orden», nos referiremos a un «orden estricto y total», salvo que se indique otra cosa. □

Ejemplo 6. Las palabras del diccionario están totalmente ordenadas alfabéticamente. La relación «ser descendiente de» es de orden parcial entre las personas de una ciudad. □

Se dice que un conjunto X está **ordenado** cuando se ha fijado sobre él una relación de orden total. Denominamos **cota** (superior) de un subconjunto no vacío $M \subset X$ a cualquier elemento de X que sea mayor o igual que todos los elementos de M .

Ejemplo 7. Con el orden del alfabético, la palabra «abuela» es mayor que «abeja» (va después en el diccionario). La palabra «bota» es una cota superior del conjunto M de las

palabras que empiezan por «a».

□

Todos los conjuntos pueden ordenarse, aunque puede no existir ninguna relación de orden compatible con otras relaciones previamente definidas en ese conjunto.

1.4. Funciones.

Para definir el concepto de función o aplicación (términos que consideraremos equivalentes), recurriremos primero a su definición matemática formal, como relación o gráfica. Hacemos esto porque la gráfica es un objeto matemáticamente preciso y menos «resbaladizo» que la noción intuitiva de función que veremos más adelante.

Una función o aplicación $f: X \rightarrow Y$ es un subconjunto del producto cartesiano $X \times Y$ que cumple la siguiente propiedad: para cada $x \in X$ existe un único $y \in Y$ tal que $(x, y) \in f$. Como es habitual, esta relación se denota simplemente como $y = f(x)$.

Una vez asentado este concepto de forma rigurosa, podemos permitirnos dejar a un lado la formalización de los pares ordenados y trabajar directamente con la idea intuitiva de asignación o regla de correspondencia.

Una *función* o *aplicación* $f: X \rightarrow Y$ es una regla que asigna a cada elemento de su *dominio* X un solo elemento del conjunto final Y . La *imagen* de un subconjunto $A \subset X$ mediante una función $f: X \rightarrow Y$ es el subconjunto de Y dado por $f(A) = \{y \in Y : \text{existe } x \in A \text{ tal que } f(x) = y\}$. La imagen, $f(X)$, del dominio de f se denomina *recorrido* de f .

Recíprocamente, la *imagen inversa* de $B \subset Y$ es el subconjunto de X dado por $f^{-1}(B) = \{x \in X : f(x) \in B\}$. Observemos que, en general, f^{-1} no es una función de $f(X)$ en X (es una multifunción); cuando $f^{-1}: f(X) \rightarrow X$ es una función, decimos f es *inyectiva*. Si, además, $f(X) = Y$, entonces se dice que f es *biyectiva*, en cuyo caso, obviamente $f^{-1}: Y \rightarrow X$ también es biyectiva.

El *conjunto de todas las aplicaciones* $f: X \rightarrow Y$ se denota por Y^X .

En la práctica, las funciones se pueden describir bien mediante una «fórmula» o bien enumerando los valores, cuando el dominio tiene pocos elementos. No siempre se dispondrá de una fórmula explícita ni tampoco siempre se podrán enumerar todas las imágenes.

Ejemplo 8. La función $f: I = \{2, 3, 4, 5\} \rightarrow \mathbb{N}$ dada por la fórmula $f(x) = (x - 3)^2$ se puede describir también enumerando sus cuatro valores $f(2) = 1, f(3) = 0, f(4) = 1, f(5) = 4$. En este caso, $f \in \mathbb{N}^I$. □

Entre las funciones que estudiaremos, revisten especial importancia las denominadas *operaciones internas p-arias*: las que tienen imagen en un conjunto X y dominio en el producto cartesiano X^p de ese mismo conjunto. Las más frecuentes, con diferencia, son las *binarias* (en las que $p = 2$). Salvo que se especifique otra cosa, por *operación* en un conjunto X entenderemos una con dominio en todo $X \times X$ e imagen en X .

Ejemplo 9. La adición y la multiplicación de números naturales:

$$\begin{array}{llll} \text{Adición} & + : & \mathbb{N} \times \mathbb{N} & \rightarrow \mathbb{N} \\ & & (n, m) & \rightarrow n + m \end{array}$$

$$\begin{array}{llll} \text{Multiplicación} & \cdot : & \mathbb{N} \times \mathbb{N} & \rightarrow \mathbb{N} \\ & & (n, m) & \rightarrow n \cdot m = nm \end{array}$$

son operaciones binarias en el conjunto $\mathbb{N}$ de los números naturales. □

Observemos que las operaciones son funciones que no se suelen representar mediante una letra, como en $z = f(x, y)$, sino con un símbolo como «+», «·», etc. En ocasiones, el dominio de una operación no abarca todo el producto cartesiano, como, por ejemplo, la división (no se puede dividir entre cero).

Decimos que un subconjunto $M \subset X$ es *cerrado para una operación* definida en X si el resultado de operar elementos de M siempre está en M .

Ejemplo 10. El conjunto de los números impares es cerrado para la multiplicación, pero no para la adición de números naturales, porque el producto de impares es impar, pero la suma de impares no lo es. □

En esta asignatura estudiaremos algunas operaciones con más de dos «entradas» o «variables» (3-arias, 4-arias, etc.), como el determinante, pero estamos adelantándonos a los acontecimientos.

1.5. Familias o conjuntos indexados.

Cuando el dominio I de una aplicación $u: I \rightarrow X$ carece de estructura adicional (más allá de ser un mero conjunto) o se decide ignorar cualquier estructura adicional que tenga, la aplicación se conoce habitualmente como *familia*. En este contexto, es costumbre denotar las imágenes o *componentes* como u_i en lugar de $u(i)$ para cada $i \in I$, así como referirse a la propia función como $(u_i)_{i \in I}$ en vez de u . Incluso, se puede relajar la notación para poner $u = u_i$. Estas convenciones no son reglas estrictas.

A veces, el concepto de familia se interpreta de manera similar al de un conjunto, con

la salvedad de que sus miembros están indexados (etiquetados, podríamos decir) por un conjunto de *índices* I . Por ello, también suelen recibir el nombre de *conjuntos indexados*. Los elementos u_i de dicha familia pueden ser de diversa naturaleza, tales como números, subconjuntos o funciones.

Los conjuntos de índices no tienen por qué estar formados por números: cualquier conjunto puede funcionar como conjunto de índices de una familia.

Ejemplo 11. Si quisiéramos formalizar el contenido de una frase del tipo:

«... para estudiar las decisiones de consumo en cultura de cada hogar, estudiamos las cantidades u_{libros} , u_{entradas} o $u_{\text{suscripciones}}$ que se refieren al número de unidades adquiridas de cada producto por cada hogar en un año ...»

podríamos definir tres funciones $u_i: H \rightarrow \mathbb{N}$, en donde H es el conjunto de los hogares e $i \in I = \{\text{libros, entradas, suscripciones}\}$. De esta manera, $u_i(h)$ representaría el número de unidades del objeto i adquirido por la familia $h \in X$. Podemos decir que tenemos una familia de funciones $(u_i)_{i \in I}$, mas concretamente, una familia $(u_i)_{i \in I}$ de elementos de $X = \mathbb{N}^H$. Si damos un paso más en la abstracción (imprescindible para programar, por ejemplo), podemos considerar la familia $u: I \rightarrow X$, formalizando así el modelo con una sola función.

No es la única manera de modelar nuestra frase: según el caso, alternativamente se puede considerar $u: I \times H \rightarrow \mathbb{N}$, de manera que $u(i, h)$ representaría la cantidad de unidades del producto i adquiridas por la familia h . $\square$

Los índices son variables mudas. Una variable muda es un símbolo matemático utilizado temporalmente para definir una operación o una función, cuyo nombre específico es irrelevante porque no afecta al resultado final ni existe fuera de ese contexto. Emplear la letra k , por ejemplo, en vez de la i como índice no altera la definición de $u: I \rightarrow X$.

Para profundizar. En un contexto formal, una *variable muda* (o *ligada*) es aquella que está bajo el alcance de un cuantificador o un operador lógico/matemático que la define, por lo que su identidad es puramente local; por el contrario, una *variable libre* no está sujeta a ningún operador, mantiene su identidad en todo el argumento y su valor determina el resultado o la veracidad de la expresión. $\square$

1.6. Conjuntos numéricos

En lo que resta de este primer tema se presentan los principales conjuntos de números: naturales, enteros, racionales, reales y complejos, y se repasan sus operaciones y propiedades. También se introducen las bases de numeración, la notación científica y las cifras significativas, conceptos relacionados con la forma en que los números se representan y se manejan en un ordenador.

No todos los contenidos del tema tienen el mismo papel en la asignatura. Los conjuntos numéricos, sus operaciones y sus propiedades ya se habrán estudiado en algún momento; aquí se presentan fundamentalmente como un repaso, para asegurar una base común antes de avanzar. Los números complejos tendrán una especial importancia más adelante por su papel en la factorización de polinomios con coeficientes complejos, una herramienta fundamental para la diagonalización de matrices.

Las bases de numeración, el redondeo y las cifras significativas tienen un papel diferente. Estos conceptos no volverán a aparecer de forma explícita en los temas siguientes, pero se incluyen porque son necesarios para las prácticas de la asignatura. En ellas trabajaremos con números representados por un ordenador y es importante comprender que, al utilizar un número limitado de cifras, la aproximación obtenida depende de la base de numeración empleada. Esto es especialmente relevante porque los ordenadores representan internamente los números utilizando el sistema binario.

2. LOS NÚMEROS NATURALES Y LOS ENTEROS. BASES DE NUMERACIÓN

2.1. Números naturales y enteros

El conjunto de los *números naturales*, $\mathbb{N} = \{0, 1, 2, \dots\}$, está dotado de dos operaciones, adición y multiplicación,

$$\begin{array}{llll} \text{Adición} & + : & \mathbb{N} \times \mathbb{N} & \rightarrow \mathbb{N} \\ & & (n, m) & \rightarrow n + m \end{array}$$

$$\begin{array}{llll} \text{Multiplicación} & \cdot : & \mathbb{N} \times \mathbb{N} & \rightarrow \mathbb{N} \\ & & (n, m) & \rightarrow n \cdot m = nm \end{array}$$

y de una relación de orden: $0 < 1 < 2 < 3 < \dots$

Las operaciones de resta y división de naturales no están definidas en todo $\mathbb{N} \times \mathbb{N}$: por ejemplo, no existe un número natural que sumado a 5 dé 3 ni tampoco existe un número natural que multiplicado por 5 dé 3.

Un conjunto A es *infinito* si tiene infinitos elementos, es decir, si a cada número natural se le puede asignar un elemento diferente de A . Los conjuntos que no son infinitos se denominan *finitos*. Un conjunto es *numerable* si a cada uno de sus elementos se le puede asignar un número natural diferente, es decir, si se pueden enumerar sus elementos. Obviamente, $\mathbb{N}$ es infinito numerable. Estas «asignaciones» son aplicaciones de $\mathbb{N}$ en A y de A en $\mathbb{N}$, respectivamente. En la Figura 2 podemos ver dos ejemplos.

Al ampliar $\mathbb{N}$ con los números negativos se forma el conjunto de los *números enteros*, que contiene a los naturales y a sus opuestos, $\mathbb{Z} = \{0, \pm 1, \pm 2, \dots\}$, y está dotado de la única relación de orden compatible con la adición extendida desde $\mathbb{N}$ («compatible» significa que $k + 1$ sea mayor que k para todo entero k):

$$\dots < -3 < -2 < -1 < 0 < 1 < 2 < 3 < \dots$$

Al igual que el de los números naturales, los enteros son un conjunto numerable, aunque para enumerarlos es necesario hacerlo en un orden distinto del orden anterior, por ejemplo:

$\mathbb{N}$	0	1	2	3	4	5	6	...
$\mathbb{Z}$	0	1	-1	2	-2	3	-3	...

(ver figura 3)



Figura 2. Los números pares son un conjunto infinito numerable mientras que los días de la semana son un conjunto finito.

Los números enteros se pueden sumar, se pueden *restar*, y se pueden *multiplicar*, dando siempre como resultado otro número entero. Al igual que sucedía con los números naturales, la división de enteros no siempre devuelve un número entero.

Nota 1. Aunque en algunos textos el cero no se considera un número natural, su incorporación al sistema de numeración supuso uno de los avances más importantes de la historia de las matemáticas. El cero no solo representa la ausencia de cantidad, sino que es imprescindible en los sistemas de numeración posicional, donde actúa como marcador de posición y permite distinguir, por ejemplo, entre 35, 305 y 3005. Gracias a él fue posible desarrollar algoritmos de cálculo mucho más eficientes y construir el sistema de numeración que utilizamos en la actualidad. $\square$




Figura 3. Los números enteros son un conjunto infinito numerable.

2.2. Sistemas de numeración

Conviene distinguir desde el principio entre un *número* (una entidad abstracta) y su representación mediante un determinado *sistema de numeración*, es decir, la manera concreta de escribirlo. Por ejemplo, en nuestro sistema escribimos «19» y en el romano se pone «XIX», pero el número es el mismo.

Una estructura matemática, como un conjunto numérico, se define por unas propiedades básicas que la caracterizan; cualquier otra propiedad se deduce de las básicas y jamás puede depender de la notación empleada ni de la construcción concreta con la que se haya demostrado la existencia de una estructura que verifique esas propiedades básicas.

Nota 2. Por supuesto, al hablar de sistemas de numeración nos referimos únicamente a los números naturales. Los números negativos solo requieren una marca delante o un color («números rojo»), algo que no afecta para nada al sistema de numeración. $\square$

Los sistemas de numeración no dejan de ser un tipo de escritura. A diferencia de los sistemas de escritura logográficos o jeroglíficos (donde cada símbolo representa una palabra, morfema o idea completa), los sistemas fonográficos emplean un repertorio finito de símbolos (letras o grafemas) que representan sonidos abstractos que se combinan secuencialmente siguiendo un orden lineal para construir las palabras. Cualquier sistema de este tipo es inherentemente *posicional*. En todos ellos, si se sustituye una letra por otra diferente, la palabra cambia de significado, se vuelve impronunciable o deja de pertenecer al léxico de la lengua. Como sabemos, ese carácter posicional se refleja al ordenar alfabéticamente (lexicográficamente) las palabras en un diccionario.

Al adaptar estos sistemas a la notación numérica, aparecen otros sistemas también *secuenciales* que emplean un repertorio de b símbolos (correspondientes a los primeros b números naturales) que se combinan secuencialmente, de manera que, al añadir al final de una secuencia el símbolo del cero, no cambia el número representado.

I.1: Sistema de numeración posicional

Decimos que un sistema de numeración secuencial con b símbolos es *posicional* si cualesquiera dos secuencias de igual longitud se ordenan lexicográficamente en el mismo orden que los números que representan.

El natural $b > 1$ se denomina *base* del sistema y los b símbolos, dígitos o cifras.

Todos los sistemas posicionales son esencialmente iguales al que empleamos nosotros. El romano, por ejemplo, solo es parcialmente posicional: XIX (diecinueve) es un número diferente de XXI (veintiuno), pero IXX no es un número diferente de XIX (según el convenio, IXX coincide con XIX o no pertenece al sistema).

El sistema posicional es uno de los mayores descubrimientos de la humanidad, ideado al menos tres veces: en Mesopotamia, en Mesoamérica y en la India. Por haber desplazado a los demás sistemas, cuesta separar la noción de «número» de su representación.

Desde el punto de vista matemático, la base por excelencia es $b = 2$ (sistema posicional binario o simplemente *sistema binario*), pues todo el edificio de las matemáticas se fundamenta en una lógica binaria: «verdadero/falso», «pertenece/no pertenece», etc.

Emplear bases mayores que dos solo complica los razonamientos matemáticos sin ofrecer ninguna ventaja. Incluso desde el punto de vista operacional, el sistema binario es superior, pues facilita las operaciones aritméticas.

El inconveniente del sistema binario reside en la extensión de las secuencias de ceros y unos correspondientes a los números en los cálculos de la vida cotidiana. Por ese motivo, se han empleado históricamente bases mayores: $b = 10$, en nuestro caso (sistema posicional decimal o simplemente *sistema decimal*); $b = 20$, en el caso maya; etc. En esas elecciones de las bases parecen haber influido cuestiones anatómicas, como la de tener los humanos diez dedos en las manos o veinte, sumando los de las manos y los pies.

Aplicación a la informática. En informática, donde los datos se almacenan internamente en binario (la base natural), se recurre a menudo a la base 16, o *sistema hexadecimal*, y a la base 8, o *sistema octal*. Por un lado, son mucho más compactas que el binario y, a la vez, se convierten en él de forma inmediata, como vamos a ver. La unidad básica de memoria es el *byte* u *octeto*, formado por 8 bits. Como cada bit puede tomar dos valores, 0 o 1, un byte puede representar $2^8 = 256$ valores diferentes. Cada dígito hexadecimal puede representar $16 = 2^4$ valores, es decir, la información contenida en 4 bits, de modo que dos dígitos hexadecimales representan $2^4 \cdot 2^4 = 2^8 = 256$ valores, exactamente los mismos que un byte. Por ello, es habitual expresar el contenido de un byte mediante dos cifras hexadecimales; por ejemplo, el byte 11111111_2 se escribe como FF_{16} . El sistema

octal, por su parte, emplea las ocho cifras $0, 1, 2, \dots, 7$; aunque en la actualidad su uso es menos frecuente que el del sistema hexadecimal, sigue siendo útil en informática, ya que cada cifra octal representa exactamente 3 bits ($2^3 = 8$), lo que permite convertir fácilmente un número binario en octal agrupando sus bits de tres en tres. $\square$

Para profundizar. La definición I.1 de sistema posicional es bastante precisa, para estar formulada en lenguaje natural. Quien tenga inclinación por el rigor de las notaciones matemáticas (por el ejemplo, quien quiera programar), tal vez eche de menos una formulación aún más precisa. Aunque el rigor innecesario conduce frecuentemente a la pedantería, nos arriesgamos a facilitar una definición «rigurosa».

Sea X el conjunto de b símbolos ordenado según su correspondencia con los primeros b naturales. El conjunto de todas las secuencias finitas con esos b símbolos es $Z = \bigcup_{n=1}^{\infty} X^n$. Para modelar la equivalencia de secuencias, definimos $\varphi: X^n \rightarrow X^{\mathbb{N}}$ por

$$\mathbf{v} = \varphi(\mathbf{u}) \iff v_i = \begin{cases} u_i, & \text{para } i \leq n \\ 0, & \text{para } i > n. \end{cases}$$

Al considerar cualquier $n \geq 1$, tenemos definida $\varphi: Z \rightarrow X^{\mathbb{N}}$.

El *orden lexicográfico* se define para $\mathbf{x}, \mathbf{y} \in \varphi(Z)$ por

$$\mathbf{x} <_{\text{lex}} \mathbf{y} \iff x_r < y_r, \text{ donde } r = \max\{i \in \mathbb{N} : x_i \neq y_i\}.$$

Un sistema de numeración secuencial basado en X es una aplicación $q: \varphi(Z) \rightarrow \mathbb{N}$. El sistema q es *posicional* si $q(\mathbf{x}) < q(\mathbf{y})$ para todos los $\mathbf{x}, \mathbf{y} \in \varphi(Z)$ tales que $\mathbf{x} <_{\text{lex}} \mathbf{y}$. $\square$

2.3. El sistema posicional

Como se ha señalado ya, un sistema de numeración posicional en base b utiliza un conjunto de b símbolos, que representan a los primeros b naturales, $0, 1, \dots, b-1$, de manera que quedan perfectamente definidas las operaciones aritméticas con esos símbolos. Todo número natural n se representa en ese sistema por la única secuencia de símbolos $n = a_k a_{k-1} \dots a_1 a_0$ que verifica

$$n = a_k b^k + a_{k-1} b^{k-1} + \dots + a_2 b^2 + a_1 b + a_0, \quad (1)$$

en donde $a_k \neq 0$. Se dice que n tiene $k+1$ cifras en base b .

Ejemplo 12. El conjunto de símbolos del sistema hexadecimal es $(0, 1, \dots, 9, A, B, C, D, E, F)$, que representa ordenadamente a los naturales del cero al quince.

El número $n = F3A_{16}$ se representa en el sistema decimal como

$$n = F \cdot b^2 + 3 \cdot b + A \cdot b^0 = [16 \cdot 16^2 + 3 \cdot 16^2 + 10 \cdot 1]_{10} = 3898_{10}.$$

Seguramente este ejemplo también ilustra cómo nos cuesta separar la noción abstracta de «número» de su representación decimal. $\square$

Notación y terminología. Solo se emplean subíndices para indicar la base cuando en el contexto aparecen números de distintos sistemas. En caso contrario, como ocurre habitualmente con el sistema decimal, los números se escriben como siempre, sin subíndice. $\square$

Para convertir un número de una base a otra, lo habitual es pasar por el sistema decimal. No existe una razón matemática para ello, sino la mera costumbre de operar en base diez.

Ejemplo 13. Vamos a convertir el número $n = 11101_2$ a base $b = 3$ sin pasar por el sistema decimal. Para ello, comenzamos expresando en base tres las potencias de dos: $2^0 = 1_3$, $2^1 = 2_3$, $2^2 = 11_3$, $2^3 = 22_3$, $2^4 = 121_3$ de manera que

$$n = 1 \cdot 2^4 + 1 \cdot 2^3 + 1 \cdot 2^2 + 0 \cdot 2^1 + 1 \cdot 2^0 = 121_3 + 22_3 + 11_3 + 1_3 = 1002_3.$$

Hemos efectuado la suma mediante acarreo de cifras (*llevadas*) en base tres, tal como aprendimos en el colegio con la base diez. $\square$

Para convertir un número escrito en base b al sistema decimal basta desarrollarlo según el valor posicional de sus cifras, como hemos visto en el ejemplo 12. El proceso inverso, escribir un número decimal en una base b se deduce directamente de (1):

$$a_k b^k + \cdots + a_1 b + a_0 = b (a_k b^{k-1} + \cdots + a_1) + a_0,$$

de modo que, al dividir el número entre b , el resto es exactamente la última cifra a_0 , y el cociente es el número que forman las cifras restantes. Repitiendo la división sobre ese cociente se obtienen, uno a uno, cada dígito, empezando por el de las unidades. Así, el algoritmo consiste en dividir sucesivamente entre b , anotar el resto en cada paso, y continuar con el cociente hasta que este sea cero; la representación buscada se lee entonces desde el último resto obtenido hasta el primero.

Ejemplo 14. Para escribir 45 en base 4 realizamos las divisiones

$$\begin{aligned} 45 &= 4 \cdot 11 + 1, \\ 11 &= 4 \cdot 2 + 3, \\ 2 &= 4 \cdot 0 + 2. \end{aligned}$$

leyendo los restos de abajo hacia arriba obtenemos $45 = 231_4$. $\square$

Reto Python 15. Escriba un programa que, dado un número representado en una base b , calcule su representación en una base b' . $\square$

Ejemplo 16. Para transformar un número decimal a binario, octal o hexadecimal, Python incluye las funciones `bin()`, `oct()`, `hex()`, que devuelven el resultado como una

cadena. Para el proceso inverso, convertir una cadena que representa un número en otra base a un entero en base 10, se usa `int (cadena, base)`:

Ejemplo de Python

```
# Ejemplo: conversion de binario a entero
resultado_binario = int('1010', 2)
print(resultado_binario)
# 10
```

□

Notación y terminología. para representar los números negativos, simplemente se antepone el signo al valor absoluto: $-13_2 = -1101_2$ o $-255_{16} = -FF_{16}$. □

3. LOS NÚMEROS RACIONALES

3.1. El cuerpo $\mathbb{Q}$ de los números racionales.

Cuando intentamos dividir dos números naturales, p entre q , y el primero no es múltiplo del segundo, sabemos que tenemos dos opciones, que conducen a construcciones equivalentes: bien hacer la división entera para hallar un cociente y un resto, $p = qc + r$ (procedimiento que, al repetirse, proporciona una representación en secuencia de dígitos), o bien expresar simbólicamente el resultado como una fracción $\frac{p}{q}$. Tras establecer la equivalencia entre fracciones y definir las operaciones y el orden tal y como aprendimos en el colegio, se obtienen los *números racionales*

$$\mathbb{Q} = \left\{ \frac{p}{q} : p, q \in \mathbb{Z}, q \neq 0 \right\}.$$

Los racionales se pueden sumar, restar, multiplicar y *dividir* (salvo entre 0), dando siempre como resultado otro número racional y verificando todas las propiedades que aprendimos en la enseñanza obligatoria: su estructura algebraica sirve de modelo para definir el concepto de *cuerpo*, que formulamos a continuación.

Supongamos que, al igual que en $\mathbb{Q}$, tenemos definidas sobre un cierto conjunto $\mathbb{K}$ (con más de un elemento) cuatro operaciones internas: *adición*, *sustracción*, *multiplicación* y *división* por un elemento no nulo (un elemento $e \in \mathbb{K}$ es nulo si $e + a = a$ para todo $a \in \mathbb{K}$), denotadas respectivamente por «+», «-», «·» y «/».

Denominamos *identidad algebraica en $\mathbb{K}$* a una igualdad (que solamente puede conte-

ner letras, los símbolos de esas cuatro operaciones y paréntesis para indicar la jerarquía de las operaciones) que es verdadera para cualquier sustitución de las letras por elementos de $\mathbb{K}$ que no anulen ningún divisor.

Ejemplo 17. La igualdad $(b - c) \cdot (a/(b - c)) = a$ es una identidad algebraica en $\mathbb{Q}$. $\square$

Se dice que $\mathbb{K}$ es un *cuerpo* si todas las identidades algebraicas de $\mathbb{Q}$ son válidas en $\mathbb{K}$.

Ejemplo 18. Obviamente, todas las identidades algebraicas de $\mathbb{Q}$ son válidas cuando las variables se sustituyen por elementos de $\mathbb{Z}$ (¡porque $\mathbb{Z} \subset \mathbb{Q}$!). Para que $\mathbb{Z}$ fuera candidato a que se le aplicara la definición de cuerpo, habría que añadir a la adición y el producto, las operaciones de sustracción y división por no nulos en $\mathbb{Z}$ de manera que verificaran todas las identidades algebraicas de $\mathbb{Q}$, lo cual es imposible (¿cómo definir $1/2$ en $\mathbb{Z}$?). $\square$

Decimos que un cuerpo $\mathbb{K}$ es un *cuerpo ordenado* si está definida sobre él una relación de orden total para la que el conjunto de los elementos mayores que 0 es cerrado por la adición y la multiplicación (página 22).

Un cuerpo ordenado es *completo* si el conjunto de las cotas (superiores) de cualquiera de sus subconjuntos es vacío o posee un elemento menor que el resto de las cotas.

Ejemplo 19. Como $3^2 = 9 > 2$, es evidente que el número 3 es una cota (superior) en $\mathbb{Q}$ del conjunto $M = \{r \in \mathbb{Q} : r^2 < 2\}$, por lo que el conjunto de las cotas de M no es vacío. Veamos que no existe una cota de M que sea menor que todas las demás.

Para cada $r \in \mathbb{Q}$ hay, en principio, tres posibilidades:

- $r^2 < 2$. Podemos encontrar un natural n suficientemente grande como para que $(r + \frac{1}{n})^2 < 2$, de manera que $r + \frac{1}{n} \in M$ y r no es una cota de M .
- $r^2 > 2$. Podemos encontrar un natural n suficientemente grande como para que $(r - \frac{1}{n})^2 > 2$, de manera que r no es la menor de las cotas de M .
- $r^2 = 2$. El racional r se puede expresar como una fracción irreducible, $r = \frac{p}{q}$, de manera que $p^2 = 2q^2$. De esta igualdad se deduce que p es par y que, por tanto, $2q^2$ es múltiplo de 4, lo cual implica que q también sería par. Sin embargo, esto contradice que la fracción fuera irreducible, por lo que la igualdad $r^2 = 2$ no puede verificarse para ningún racional r .

En conclusión, no existe una cota mínima de M , con lo que se demuestra que el cuerpo ordenado $\mathbb{Q}$ no es completo. $\square$




Figura 4. Una manera de enumerar los números racionales (saltándose repeticiones).

En conjunto $\mathbb{Q}$ es numerable, aunque los racionales se enumeran en un orden distinto del suyo (véase la figura 4).

El *valor absoluto* de un elemento x de un cuerpo ordenado $\mathbb{K}$ se define como el máximo de los valores de x y $-x$, es decir, $|x| = \max\{x, -x\}$. Por ejemplo, $|4| = 4$ y $|-3| = 3$. Las principales propiedades del valor absoluto son:

$$|x + y| \leq |x| + |y|; \quad |xy| = |x| |y|; \quad |x| > 0, \text{ si } x \neq 0.$$

3.2. Fracción y desarrollo de un racional

Sabemos de la enseñanza elemental que la división entera, $p = cq + r$, de dos naturales p y q , para obtener un cociente c y un resto r menor que q , puede continuarse extrayendo decimales. Cada vez que en la escuela «bajamos un cero» para calcular la nueva cifra, en realidad en multiplicamos el resto por 10 (la base del sistema) y volvemos a repetir la división entera de $10r$ entre q .

Ejemplo 20. Dividimos $p = 3$ entre $q = 8$ para obtener $\frac{3}{8} = 0.375$. En efecto,

$$3 \cdot 10 = 30 = 3 \cdot 8 + 6,$$

$$6 \cdot 10 = 60 = 7 \cdot 8 + 4,$$

$$4 \cdot 10 = 40 = 5 \cdot 8 + 0.$$

Los cocientes sucesivos, 3, 7 y 5, son las cifras decimales. Véase la figura 5. □

El procedimiento anterior es válido en cualquier base $b \geq 2$: en cada paso se multiplica el resto por b y se divide entre el denominador.

Lo importante es que solo hay una cantidad finita de posibles restos: $0, 1, \dots, q - 1$, los naturales menores que el divisor q . Por tanto, al continuar el algoritmo, necesariamente llegará un momento en que se obtenga un resto repetido. A partir de ahí, el procedimiento

$$\begin{array}{r} 3000 \overline{) 8} \\ \underline{24} \\ 60 \\ \underline{56} \\ 40 \\ \underline{40} \\ 0 \end{array}$$

Figura 5. La división escolar del ejemplo 20.

se repite cíclicamente, con lo que se obtiene en el cociente un desarrollo periódico a partir de ese punto. Decimos que el desarrollo es *eventualmente periódico*.

Ejemplo 21. En la figura 6 vemos una división escolar completa con dividendo $p = 2297$ y divisor $q = 990$. Las divisiones enteras sucesivas van dando los siguientes cocientes y restos: $c_1 = 2, r_1 = 317$; $c_2 = 3, r_2 = 200$; $c_3 = 2; r_3 = 20$; $c_4 = 0; r_4 = 200$. En este momento se repite el resto, $r_4 = r_2$, con lo que ha terminado la división completa con el cociente exacto $\frac{2297}{990} = 2.\overline{320}$. $\square$

$$\begin{array}{r} 2297 \overline{) 990} \\ \underline{1980} \\ 3170 \\ \underline{2970} \\ 2000 \\ \underline{1980} \\ 2000 \\ \underline{1980} \\ 2000 \\ \underline{1980} \\ 2000 \end{array}$$

Figura 6. División escolar completa del ejemplo 21.

$\triangle$ Obsérvese que una misma secuencia eventualmente periódica se puede escribir con diferente parte periódica (con las cifras permutadas). Por ejemplo, $0.\overline{34} = 0.\overline{343}$. Además, la parte periódica $\hat{9}$ nunca se obtiene en el proceso de la división, porque $r = 0.\hat{9}$ es exactamente 1. En efecto, $10r - r = 9.\hat{9} - 0.\hat{9} = 9$, luego $r = 1$. Lo mismo ocurre en cualquier base con el periodo formado por su mayor símbolo. $\square$

El razonamiento anterior demuestra que al dividir dos números enteros siempre se obtiene un desarrollo eventualmente periódico. Recíprocamente, todo desarrollo de este tipo corresponde a un número racional. En efecto, si r es un número con un desarrollo cuya parte periódica tiene longitud k y comienza inmediatamente después de la cifra m -ésima de los decimales, entonces $b^{m+k}r$ y $b^m r$ comparten la misma parte decimal (precisamente, la periódica). Al restarlos, se obtiene un número entero $p = b^{m+k}r - b^m r$, de modo que $p = b^m(b^k - 1)r$, lo que implica finalmente que $r = \frac{p}{b^m(b^k - 1)}$.

Ejemplo 22. Si $r = 2.3\widehat{20}$ es el desarrollo del ejemplo 21, entonces, $10^3 r = 2320.\widehat{20}$, $10r = 23.\widehat{20}$. Al restar resulta $990r = 2320 - 23 = 2297$, luego $r = \frac{2297}{990}$. $\square$

I.2: Caracterización de los números racionales

En cualquier base de numeración, todo número racional posee un desarrollo eventualmente periódico y, recíprocamente, toda secuencia con este comportamiento representa a un número racional.

Decimos que un racional es *exacto en base b* o que tiene *desarrollo finito en base b* si la parte periódica de su desarrollo es $\widehat{0}$. El conjunto de los racionales exactos en base b se puede representar como

$$\mathbb{Z}[b] = \{p b^q \in \mathbb{Q} : p, q \in \mathbb{Z}\} = \{p b^q \in \mathbb{Q} : p, q \in \mathbb{Z}, \text{ con } p \text{ no divisible entre } b\}. \quad (2)$$

Decimos que un racional exacto $r = p b^q$ tiene *n cifras significativas (c.s) en base b* si $b^{n-1} \leq |p| < b^n$, con p no es divisible entre b . Por convenio, $r = 0$ tiene cero c.s.

Ejemplo 23. El racional $\frac{3}{8} = 0.375\widehat{0} = 0.375$ es exacto en base 10, porque su parte periódica es $\widehat{0}$. Observemos que $\frac{3}{8} = p b^q \in \mathbb{Z}[10]$ para $b = 10$, $p = 375$, $q = -3$. El número $\frac{3}{8}$ tiene 3 c.s en base 10, pues $10^2 \leq 375 < 10^3$. $\square$

 Mientras que la periodicidad eventual de la expansión de un número racional es independiente de la base, el carácter finito de su desarrollo depende esencialmente de ella.

En consecuencia, la expresión «número racional exacto» resulta imprecisa si no se acompaña de la base de numeración correspondiente. Por ejemplo, $\frac{1}{3}$ es exacto en base tres, $\frac{1}{3} = 0.1_3 = 0.1\widehat{0}_3$, pero no en base diez, $\frac{1}{3} = 0.\widehat{3}_{10}$. $\square$

Ejemplo 24. Calculemos las cifras significativas de los siguientes números:

$$5.67 = 567 \cdot 10^{-2}, \quad 10^2 \leq 567 < 10^3 \implies 5.67 \text{ tiene 3 c.s. en base 10,}$$

$$40\,000 = 4 \cdot 10^4, \quad 10^0 \leq 4 < 10^1 \implies 40\,000 \text{ tiene 1 c.s. en base 10,}$$

$$-0.010405 = -10\,405 \cdot 10^{-6}, \quad 10^4 \leq 10\,405 < 10^5 \implies -0.010405 \text{ tiene 5 c.s. en base 10,}$$

$$1.011_2 = 1011_2 \cdot 2^{-3}, \quad 2^3 \leq 1011_2 < 2^4) \implies 1.011_2 \text{ tiene 4 c.s. en base 2.} \quad \square$$

Reto Python 25. Escriba un programa que determine las partes entera, no periódica y periódica del desarrollo un número racional en una base cualquiera. $\square$

Reto Python 26. Escriba un programa que determine el número de cifras significativas en base 2 y en base 10 de un número exacto en esas bases. $\square$

Denotemos por $\mathbb{Q}_{b,n}$ al conjunto de los racionales exactos con menos de $n + 1$ cifras significativas en base b . Los números de $\mathbb{Q}_{b,n}$ no suelen presentarse en el formato de la expresión (2), lo que dificultaría establecer comparaciones directas. Lo habitual es emplear la notación de *coma flotante*, en la que se permite aumentar o disminuir el exponente q de (2), reemplazando el entero p por una expresión decimal, si es preciso.

Ejemplo 27. El número $r = 463 \cdot 10^{-2}$, exacto en base 10, se escribe de diversas maneras en notación de coma flotante: $r = 0.463 \cdot 10^{-5}$, $r = 46.3 \cdot 10^{-3}$, $r = 4630 \cdot 10^{-1}$, etc. $\square$

Un caso particular de notación de coma flotante es la *notación científica*, en la que se ajusta el exponente q hasta conseguir una única cifra entera antes del punto decimal.

Ejemplo 28. Escribamos los siguientes números en notación científica (a la derecha):

$$\begin{aligned} 23.567 &= 23567 \cdot 10^{-3} = 2.3567 \cdot 10^1, \\ 0.0497 &= 497 \cdot 10^{-4} = 4.97 \cdot 10^{-2}, \\ -3.0768 &= -30768 \cdot 10^{-4} = -3.0768 \cdot 10^0, \\ 101.1_2 &= 1011_2 \cdot 2^{-1} = 1.011_2 \cdot 2^2. \end{aligned}$$

Cuando la base de numeración se sobrentiende, en lugar de escribir un símbolo para la multiplicación de números (lo que procura evitarse fuera de las matemáticas escolares) se escribe $4.97\text{E}-2$, en vez de las notaciones habituales como $4.97 \cdot 10^{-2}$ o 4.97×10^{-2} . $\square$

Al representar los números de $\mathbb{Q}_{b,n}$ en notación científica, es costumbre rellenar con ceros las posiciones decimales. Por supuesto, esto no significa que 5.200, 5.20 y 5.2 sean números diferentes (sostenerlo constituiría un disparate). Se trata de tres representaciones de un mismo número racional: con la primera enfatizamos que operamos en $\mathbb{Q}_{10,4}$; con la segunda destacamos la pertenencia a $\mathbb{Q}_{10,3}$, y con la tercera señalamos que se encuentra en $\mathbb{Q}_{10,2}$. Obviamente, $\mathbb{Q}_{10,2} \subset \mathbb{Q}_{10,3} \subset \mathbb{Q}_{10,4}$.

Aplicación a la informática. El concepto de notación de coma flotante cristaliza en el estándar **IEEE 754**, ideado fundamentalmente por el matemático William Kahan, que es hoy la especificación técnica que rige de manera casi universal la aritmética en el hardware

informático. Por supuesto, el estándar utiliza la numeración en base 2, de manera que cada dígito corresponde a un bit, como vemos a continuación.

En su formato de precisión simple, que dedica 32 bits de memoria a cada número representable, se distribuye el espacio asignando un único bit para el signo del número, un bloque de 8 bits para el *exponente* y 23 bits dedicados a la *fracción* del *significando*. Al operar en base dos, los 23 dígitos que constituyen la fracción permiten representar los 24 dígitos binarios del significando (el número decimal que multiplica a la potencia en coma flotante). En efecto, la condición de normalización en base dos exige que el único dígito entero posible antes de la coma sea inexorablemente un uno. Lejos de constituir un mero artificio de ingeniería para aprovechar memoria, la omisión explícita de este bit inicial es una consecuencia directa de la notación posicional en base dos y proporciona un ejemplo más del carácter natural de esta base.

Cuando se requiere mayor precisión, entra en juego el formato de precisión doble, que duplica la capacidad empleando sesenta y cuatro bits distribuidos en un bit para el signo, once para el exponente y cincuenta y dos para la fracción.

La vieja costumbre de llamar *mantisa* a la parte que multiplica a la potencia revela un pequeño anacronismo histórico. Dicho término, heredado de las antiguas tablas impresas de logaritmos decimales, donde designaba estrictamente la parte fraccionaria del logaritmo, resulta técnicamente impreciso para describir el coeficiente completo de un número en coma flotante. Por esta razón, la terminología formal contemporánea ha desplazado aquel concepto hacia los términos de significando y fracción.

El sistema también contempla los márgenes más delicados de la escala numérica mediante los llamados números subnormales o desnormalizados. Cuando un cálculo se aproxima peligrosamente al cero y el exponente alcanza su límite inferior de representación, el sistema flexibiliza su exigencia de normalización para permitir que el bit inicial pase a ser cero. Esto evita un colapso conocido como desbordamiento por debajo y suaviza la transición numérica para que la representación en el ordenador mantenga una continuidad más fiel al comportamiento continuo de las matemáticas reales. $\square$

4. LOS NÚMEROS REALES

4.1. El cuerpo $\mathbb{R}$ de los números reales

Hemos visto anteriormente que el cuerpo $\mathbb{Q}$ de los números racionales no es completo. Denotamos por $\mathbb{R}$ al menor cuerpo ordenado completo que extiende a los racionales. Los

elementos de $\mathbb{R}$ se conocen como *números reales*.

En sentido estricto, habría que demostrar que existe algún cuerpo ordenado completo que extienda a los racionales; a esto se le llama «construir» el cuerpo de los reales. La construcción rigurosa de este cuerpo requiere de una precisión técnica que no vamos a abordar en esta asignatura. Hay que tener en cuenta que cualquier resultado en el que participen los números reales debe deducirse exclusivamente de su condición de extensión completa de los racionales, por lo que resulta ilegítimo emplear propiedades de una construcción particular. Es decir, una vez lograda una construcción, esta se olvida para siempre.

Aunque no alcancemos el nivel de rigor necesario como para denominarlo «construcción», podemos identificar los números reales con todas las posibles secuencias de los símbolos del sistema que posean un número entero como parte entera y cualquier secuencia infinita como parte decimal. La base de numeración empleada es aquí irrelevante.

Esta representación de los números reales como «todos los desarrollos posibles» se ajusta de manera natural a la intuición del «continuum», es decir, a la identificación de los reales con los puntos de una recta geométrica.

Los números reales que no son racionales se llaman *números irracionales*. Se caracterizan porque su desarrollo no es eventualmente periódico. Por ejemplo, el desarrollo

$$1.01\ 001\ 0001\ 00001\ 000001\ \dots$$

corresponde a un número irracional, porque, al aumentar la cantidad de ceros que hay entre cada dos unos, nunca se puede alcanzar una parte periódica. De hecho, en el ejemplo 19 ya probamos implícitamente que el número $\sqrt{2}$ es irracional. También lo son algunos importantes números de las matemáticas como π y e , aunque es difícil demostrarlo.

A diferencia del de los racionales, el cuerpo de los reales no es numerable. Vamos a probar por reducción al absurdo que el intervalo $[0, 1]$ no es numerable, de manera que $\mathbb{R}$ tampoco lo es. Si el intervalo $[0, 1]$ pudiera enumerarse:

$$\begin{aligned} x_1 &= 0.\textcolor{red}{a}_{11}a_{12}a_{13}a_{14}\dots \\ x_2 &= 0.a_{21}\textcolor{red}{a}_{22}a_{23}a_{24}\dots \\ x_3 &= 0.a_{31}a_{32}\textcolor{red}{a}_{33}a_{34}\dots \\ x_4 &= 0.a_{41}a_{42}a_{43}\textcolor{red}{a}_{44}\dots \\ &\vdots \end{aligned}$$

cualquier desarrollo $0.b_1b_2b_3\dots$ debería figurar en esa lista. Si escogemos:

$$b_n = \begin{cases} 1, & \text{si } a_{nn} \neq 1, \\ 2, & \text{si } a_{nn} = 1, \end{cases}$$

llegamos a una contradicción, ya que, difiere de x_n al menos en la n -ésima cifra decimal.

4.2. Redondeo de números reales

Al ser $\mathbb{R}$ la completación de $\mathbb{Q}$, entre dos números reales distintos existen infinitos números tanto racionales como irracionales. Es más, entre cualesquiera dos números reales siempre es posible hallar infinitos racionales exactos en cualquier base de representación.

Si definimos la *distancia entre dos números reales* x e y como $d(x, y) = |x - y|$, todo número real puede aproximarse mediante números racionales exactos con tanta precisión como se desee.

Aunque esta propiedad de densidad es teóricamente fundamental, la práctica efectiva del cálculo (desde el ábaco hasta las calculadoras mecánicas y los equipos informáticos contemporáneos) opera sobre un conjunto $\mathcal{R}$ de números *representables*. La garantía que ofrece esa densidad matemática es, precisamente, lo que permite escoger ese repertorio de números representables tan grande como se quiera para satisfacer la precisión deseada.

Hoy en día, el conjunto $\mathcal{R}$ de los números representables será normalmente uno formado por racionales exactos con el número de cifras significativas prefijado, es decir, del tipo $\mathcal{R} = \mathbb{Q}_{b,n}$ que hemos visto en la página 35. Este requerimiento de fijar el número de cifras significativas es necesario para controlar la propagación de errores en los cálculos.

De hecho, el conjunto de los números representables en el estándar IEEE 754 se define con ese mismo espíritu, aunque no formen exactamente un conjunto del tipo $\mathbb{Q}_{b,n}$. Existen diferencias notables, como la limitación del tamaño del exponente, la cual hace que dicho conjunto sea finito.

Apartarse del criterio de fijación del número de cifras significativas resulta un disparate cuando se van a encadenar numerosas operaciones aritméticas. Sin embargo, en contextos ajenos al ámbito científico-técnico, fijar el número de decimales en lugar de las cifras significativas puede ser más aconsejable. Por ejemplo, si pensamos en el saldo de una cuenta bancaria, parece más razonable prescindir de los céntimos de euro al redondear que eliminar euros o decenas de euros en los saldos más abultados (tampoco está claro qué resulta más injusto, por cierto). Volveremos a este asunto más adelante.

Dado un conjunto $\mathcal{R}$ de números representables, cualquier número real no representable tendrá un único elemento más cercano en $\mathcal{R}$, o bien dos, exclusivamente en el supuesto de hallarse equidistante entre dos números representables consecutivos.

I.3: Redondeo de números reales

Fijado un conjunto $\mathcal{R}$ de números representables exactos, redondear un número real consiste en sustituirlo por el elemento de $\mathcal{R}$ más próximo a él; si existiesen dos candidatos equidistantes, se adopta aquel cuya última cifra sea par.

El criterio anterior para resolver la equidistancia (adoptado por defecto en el estándar IEEE 754) recibe el nombre de *redondeo al par más cercano* (*round half to even*) y no es universal: algunos dispositivos redondean de modo unidireccional cuando hay equidistancia: siempre hacia arriba o siempre hacia abajo. El redondeo al par más cercano evita la acumulación sistemática de errores de redondeo en una misma dirección; mientras que un redondeo unidireccional sumaría constantemente desviaciones con idéntico signo a lo largo de numerosas operaciones, la alternancia hacia el par o el impar favorece su compensación mutua.

Ejemplo 29. Al redondear a 2 cifras significativas en base 10, tanto 1.2 como 1.3 están a la misma distancia de 1.25. Como 1.2 termina en cifra par y 1.3 en cifra impar, el redondeo al par más cercano da $1.25 \approx 1.2$ (hacia abajo). En cambio, $1.35 \approx 1.4$ (hacia arriba). $\square$

Cuando el conjunto de números representables es $\mathcal{R} = \mathbb{Q}_{b,n}$, decimos que estamos *redondeando a n cifras significativas en base b* . Si $\mathcal{R}$ fuera el conjunto de números representables de los saldos de las cuentas bancarias que comentábamos, estaríamos redondeando a dos decimales, por ejemplo.

Ejemplo 30. Redondeamos a 3 c.s. en base 10 unos cuantos números

$$\begin{array}{llll} 3.14159265 \approx 3.14; & 0.009865 \approx 0.00986; & 0.009835 \approx 0.00984 \\ 0.00012349 \approx 0.000123; & 999.5 \approx 1000; & 1.003 \approx 1. \end{array}$$

En la equidistancia, hemos aplicado el criterio de redondeo al par más cercano. $\square$

Las operaciones aritméticas realizadas en un conjunto finito de números representables exhiben propiedades diferentes a las del cuerpo de los reales.

Ejemplo 31. Consideremos el conjunto de números representables $R = \mathbb{Q}_{10}^2$ (dos c.s.). Los números $a = 1$ y $b = 0.04$ pertenecen a $\mathcal{R}$ pero su suma $a + b = 1.04$ no es un número representable (no pertenece a $\mathcal{R}$), por lo que se debe redondear, $1 + 0.04 \approx 1$, es decir, $a + b \approx b$, de donde no se puede deducir que $b \approx 0$. La aritmética en $\mathcal{R}$ quebranta otras reglas básicas de las operaciones en un cuerpo, como la asociatividad de la adición:

$$\begin{aligned} (1 + 0.04) + 0.04 &\approx 1 + 0.04 \approx 1 \\ 1 + (0.04 + 0.04) &\approx 1 + 0.08 \approx 1.1 \end{aligned}$$

Todas estas cuestiones, aunque suelen quedar en un segundo plano en el marco de esta asignatura, son analizadas y mitigadas por los diseñadores de hardware y los desarrolladores de software para garantizar la estabilidad numérica de los programas. $\square$

Ejemplo 32. Como ya vimos, el conjunto de números representables en el estándar IEEE 754 en doble precisión almacena los números en coma flotante de doble precisión, siempre en base 2. Sabemos que un número con desarrollo finito en base 10 puede tener desarrollo periódico infinito en base 2. Esto es justo lo que ocurre con 0.1 y 0.2:

$$\begin{aligned} 0.1_{10} &= 0.0001100110011 \dots_2 = 0.000\overline{11}_2, \\ 0.2_{10} &= 0.001100110011 \dots_2 = 0.001\overline{11}_2. \end{aligned}$$

Al no caber en los 53 bits de mantisa disponibles, el sistema debe redondear ambos desarrollos infinitos (que por supuesto, jamás almacena) al representable más cercano:

$$\begin{aligned} 0.1_{10} &\approx 0.00011001100110011001100110011001100110011001100110011001101_2, \\ 0.2_{10} &\approx 0.0011001100110011001100110011001100110011001100110011010_2. \end{aligned}$$

Al sumar estas dos aproximaciones se obtiene

$$0.010011001100110011001100110011001100110011001100110011011_2,$$

que, convertido de nuevo a base 10, es exactamente

$$0.3000000000000000444089209850062616169452667236328125,$$

un valor que se muestra recortado en Phytton:

Ejemplo de Python

```
resultado = 0.1 + 0.2
print(resultado)
# 0.30000000000000004
```

$\square$

Ejemplo 33. Si se trabaja en contabilidad o en alguna otra área semejante (jamás en aplicaciones científico tecnológicas), se puede utilizar un conjunto de representables con una extensión fija de la parte decimal. Por ejemplo, Python proporciona el módulo `decimal`, permite fijar explícitamente el número de dígitos decimales de precisión.

Ejemplo de Python

```
from decimal import Decimal
resultado = Decimal("0.1") + Decimal("0.2")
print(resultado)
# 0.3
```

El módulo decimal es fundamental en aplicaciones contables y financieras. En la contabilidad cotidiana se exige precisión absoluta hasta una unidad fija (como los céntimos de euro), por lo que acumular imprecisiones derivadas de la representación en coma flotante o del cambio de base resulta inaceptable.

Por el contrario, en las disciplinas científicas se trabaja con cifras significativas (a menudo presentadas de manera uniforme mediante ceros a la derecha para mantener la misma longitud decimal en tablas y textos), por ejemplo, mediante la notación científica o la ingenieril (que maneja exponentes múltiplos de 3). $\square$

5. NÚMEROS COMPLEJOS

5.1. El cuerpo de los números complejos

En el cuerpo $\mathbb{R}$ de los números reales la ecuación $x^2 = -1$ no tiene solución. Denotamos por $\mathbb{C}$ al menor cuerpo que, extendiendo a $\mathbb{R}$, contenga una solución de esa ecuación. Los elementos de $\mathbb{C}$ se denominan *números complejos*.

Más adelante veremos que, al añadir a $\mathbb{R}$ una solución para esa ecuación, automáticamente estamos añadiendo soluciones para todas las ecuaciones polinómicas, es decir, toda ecuación polinómica en $\mathbb{C}$ tiene solución, lo que se resume afirmando que el cuerpo $\mathbb{C}$ es algebraicamente cerrado.

Recordemos que, cuando se define una estructura algebraica por sus propiedades (como acabamos de hacer con el cuerpo complejo), es necesario construir un objeto matemático que satisfaga dichos axiomas. Mientras que la construcción del cuerpo de los números reales a partir de los racionales es un proceso arduo que requiere un alto nivel de abstracción, la de los números complejos a partir de los reales resulta bastante sencilla.

Si denotamos por i a uno de los complejos que resuelve la ecuación anterior, es decir, $i^2 = -1$, la otra solución será $-i$, pues $(-i)^2 = (-1)^2(i^2) = -1$. El número i se denomina *unidad imaginaria*.

El resto de los números complejos se obtiene operando reiteradamente con las propiedades de cualquier cuerpo, teniendo en cuenta que $i^2 = -1$. Es decir, operamos como si i «fuera una variable», pero reemplazando i^2 por -1 . De esta manera, tras las oportunas simplificaciones, cualquier número complejo se escribe como $a + bi$, con $a, b \in \mathbb{R}$.

Así, hemos «construido» el cuerpo de los números complejos

$$\mathbb{C} = \{a + bi : a, b \in \mathbb{R}\},$$

con lo que concluimos la extensión de los conjuntos numéricos.

I.4: Conjuntos de números

Los conjuntos numéricos son:

$$\mathbb{N} \subset \mathbb{Z} \subset \mathbb{Q} \subset \mathbb{R} \subset \mathbb{C}.$$

Denominaremos a los dos últimos, $\mathbb{R}$ y $\mathbb{C}$, *cuerpos de escalares*.

El conjunto de los números complejos puede ordenarse, como cualquier conjunto, pero no existe ninguna relación de orden en $\mathbb{C}$ compatible con su estructura de cuerpo. En efecto, si existiera un orden compatible, se tendría $-1 = i^2 > 0$, lo que no es posible en un cuerpo. Por lo tanto, $\mathbb{C}$ *no* es un cuerpo ordenado.

Los números reales $a, b \in \mathbb{R}$ se denominan respectivamente la *parte real*, $a = \operatorname{Re}(z)$, y la *parte imaginaria*, $b = \operatorname{Im}(z)$, del complejo $z = a + bi \in \mathbb{C}$. A esta representación de un número complejo se le llama *forma binómica*. Si $\operatorname{Re}(z) = 0$, decimos que z es un *imaginario puro*. Observemos que z se reduce a un número real si $\operatorname{Im}(z) = 0$, algo lógico porque el cuerpo complejo es una extensión del real, $\mathbb{R} \subset \mathbb{C}$.

 La parte imaginaria de un complejo es un número real, al igual que su parte real. $\square$

Nota 3. En física e ingeniería se emplea la letra j para denotar a la unidad imaginaria, porque la letra i suele estar reservada para la intensidad de corriente. Esta convención se ha extendido a otras áreas aplicadas, de manera que, por ejemplo, en Python, la unidad imaginaria se representa mediante la letra j . $\square$

En el resto del tema, salvo que expresamente se diga otra cosa, la letra i representa la unidad imaginaria, mientras que z y w se reservan para variables complejas, las demás letras representan números reales.

Las operaciones propias de la estructura de cuerpo no requieren ninguna explicación ni definición suplementaria para el cuerpo complejo. Como hemos señalado antes, lo único que hay que hacer es operar como si la unidad imaginaria i fuera una variable para sustituir

$i^2 = -1$ cuando corresponda.

Aunque vamos a proporcionar ejemplos, es imprescindible realizarlos por cuenta propia (estos y muchos más) hasta adquirir soltura. Leer operaciones resueltas es tan útil como pretender ponerse en forma mirando cómo trabaja en el gimnasio otra persona.

Ejemplo 34.

$$(5 + 7i) + (-1 + 2i) = 5 + (-1) + 7i + 2i = 5 - 1 + (7 + 2)i = 4 + 9i.$$

$$\begin{aligned}(5 + 7i)(-1 + 2i) &= 5(-1 + 2i) + 7i(-1 + 2i) \\ &= 5(-1) + 5(2i) + 7i(-1) + (7i)(2i) = -5 + 10i - 7i + 14i^2 \\ &= -5 + 10i - 7i + 14(-1) = -19 + 3i.\end{aligned}$$

$$\begin{aligned}\frac{5 + 7i}{-1 + 2i} &= \frac{(5 + 7i)}{(-1 + 2i)} \frac{(-1 - 2i)}{(-1 - 2i)} = \frac{(5 + 7i)(-1 - 2i)}{(-1 + 2i)(-1 - 2i)} \\ &= \frac{9 - 17i}{(-1)^2 - (2i)^2} = \frac{9 - 17i}{1 - 4(-1)} = \frac{9}{5} - \frac{17}{5}i.\end{aligned}$$

El «truco» para dividir está en obtener una fracción equivalente donde el denominador sea un número real, para así obtener como resultado de la división una expresión del tipo $a + bi$. Para ello multiplicamos numerador y denominador por el conjugado del denominador. $\square$

Ejemplo 35. Las potencias de la unidad imaginaria siempre valen ± 1 o $\pm i$:

$$\begin{aligned}i & & ; & i^2 = -1 & ; & i^3 = i^2 i = -i & ; & i^4 = i^2 i^2 = (-1)(-1) = 1 \\ i^5 = i^4 i = i & ; & i^6 = -1 & ; & i^7 = -i & ; & i^8 = 1, \dots\end{aligned}$$

Los valores de las potencias de i se repiten cíclicamente, por lo que, para calcular i^k , dividimos el exponente $k \in \mathbb{Z}$ entre 4 y empleamos el resto r de la división, $k = 4c + r$, con $r \in \{0, 1, 2, 3\}$, $c \in \mathbb{Z}$, para obtener $i^k = i^{4c+r} = i^{4c} i^r = i^r$. $\square$

Ejemplo 36. Veamos algunas operaciones con complejos en Phyton:

Ejemplo de Python

```
# Ejemplo: Suma de complejos
z1 = 5 + 7j
z2 = -1 + 2j
print(z1 + z2)
# (4+9j)
```

Ejemplo de Python

```
# Ejemplo: Producto de complejos
z1 = 5 + 7j
z2 = -1 + 2j
print(z1 * z2)
# (-19+3j)
```

Ejemplo de Python

```
# Ejemplo: Divisi\ '{o}n de complejos
z1 = 5 + 7j
z2 = -1 + 2j
print(z1 / z2)
# (1.8-3.4j)
```

□

5.2. Conjugado, módulo y argumento de un complejo

Las operaciones de la estructura de cuerpo (la adición, la sustracción, la multiplicación y la división) no revisten ninguna particularidad al operar con números complejos. La verdadera operación característica del cuerpo complejo, la más importante, es la *conjugación*.

El *conjugado* de un número complejo $z = a + bi$ es el número complejo

$$\bar{z} = a - bi.$$

Las propiedades básicas de la conjugación son las siguientes. Si $z, w \in \mathbb{C}$:

- $\overline{\bar{z}} = z.$
- $z = \bar{z}$ si y solo si $z \in \mathbb{R}.$
- $\overline{z + w} = \bar{z} + \bar{w}.$
- $\overline{zw} = \bar{z} \bar{w}.$

Las tres primeras propiedades se demuestran muy fácilmente, solo la cuarta requiere una justificación algo más extensa:

$$\overline{zw} - \bar{z} \bar{w} = \overline{(a + bi)(c + di)} - \overline{a + bi} \overline{c + di}$$

$$\begin{aligned}
 &= \overline{((ac - bd) + (ad + bc)i)} - (a - bi)(c - di) \\
 &= ((ac - bd) - (ad + bc)i) - ((ac - bd) - (ad + bc)i) = 0.
 \end{aligned}$$

El **módulo** de un número complejo $z = a + bi$ es el número real no negativo

$$|z| = \sqrt{z\bar{z}} = \sqrt{a^2 + b^2}.$$

El módulo de un número real, considerado como complejo, es precisamente su valor absoluto, de ahí la notación coincidente $|a + 0i| = \sqrt{a^2} = |a|$. Además, el módulo satisface propiedades análogas a las del valor absoluto. Para todos $z, w \in \mathbb{C}$ se verifica:

- $|\operatorname{Re}(z)| \leq |z|$; $|\operatorname{Im}(z)| \leq |z|$.
- Si $z \neq 0$, entonces $|z| > 0$ y $\frac{1}{z} = \frac{\bar{z}}{|z|^2}$.
- $|zw| = |z| |w|$.
- $|z + w| \leq |z| + |w|$.

La dos primeras propiedades son casi evidentes. Las demostraciones de las otras dos resultan más aparatosas:

$$|zw|^2 = (zw)(\overline{zw}) = zw\bar{z}\bar{w} = (z\bar{z})(w\bar{w}) = |z|^2|w|^2 \implies |zw| = |z| |w|.$$

$$\begin{aligned}
 |z + w|^2 &= (z + w)(\overline{z + w}) = (z + w)(\bar{z} + \bar{w}) = z\bar{z} + z\bar{w} + w\bar{z} + w\bar{w} \\
 &\leq |z|^2 + z\bar{w} + \overline{z\bar{w}} + |w|^2 = |z|^2 + 2\operatorname{Re}(z\bar{w}) + |w|^2 \leq |z|^2 + 2|z\bar{w}| + |w|^2 \\
 &= |z|^2 + 2|z||w| + |w|^2 = (|z| + |w|)^2 \implies |z + w| \leq |z| + |w|.
 \end{aligned}$$

Ejemplo 37. En Python, el módulo y el valor absoluto también se denotan igual

Ejemplo de Python

```
# Ejemplo: M\{'o}dulo de de un complejo
z = 3 + 4j
print(abs(z))
# 5.0
```

□

5.3. Representación gráfica de los números complejos

Para representar los números complejos $a + bi$ los identificamos con el par ordenado (a, b) , es decir, con un punto en el plano $\mathbb{R}^2$:

$$\begin{aligned}\mathbb{C} &\longleftrightarrow \mathbb{R}^2 \\ a + bi &\longleftrightarrow (a, b)\end{aligned}$$

En la figura 7 se observa que las partes real e imaginaria de un complejo z corresponden




Figura 7. Representación gráfica de un número complejo

a los catetos de un triángulo rectángulo, de manera que

$$z = r(\cos \theta + i \operatorname{sen} \theta),$$

expresión que se denomina *forma trigonométrica* del complejo z . Como las funciones seno y coseno son periódicas, $\cos(\theta + 2\pi) = \cos(\theta)$ y $\operatorname{sen}(\theta + 2\pi) = \operatorname{sen}(\theta)$, hay infinitos ángulos θ que satisfacen la expresión anterior, todos lo que resultan de ir sumando o restando 2π al ángulo inicial, es decir, todos los del conjunto:

$$\operatorname{Arg}(z) = \{\theta \in \mathbb{R} : a = r \cos \theta, b = r \operatorname{sen} \theta\},$$

que se denomina *argumento* del número complejo z . Obsérvese que en cada intervalo $[a, 2\pi)$ hay exactamente un elemento de $\operatorname{Arg}(z)$, que se denomina *determinación del argumento* correspondiente al número real a . Cuando se elige una de ellas, se le suele llamar *determinación principal del argumento*. Lo más frecuente es escoger $a = -\pi$, de manera que los argumentos se miden en el intervalo $[-\pi, \pi)$ (hay alguna ventaja en que el intervalo sea simétrico; es el criterio que se seguirá aquí, de ser necesario). También hay quien escoge $a = 0$, con lo que el intervalo sería $[0, 2\pi)$.

⚠ Este criterio de fijar el intervalo en el que se miden los argumentos facilita la computación. Fijarlo rígidamente en los razonamientos, creyendo que así se ahorran las complicaciones de considerar infinitos argumentos, es una decisión que puede bloquear la comprensión. Se trata de lo que el matemático Roger Penrose ha denominado «mutilación brutal de una estructura matemática sublime». □

Ejemplo 38. El módulo del número complejo $z = 1 - \sqrt{3}i$ es

$$|z| = \sqrt{1^2 + (\sqrt{3})^2} = \sqrt{4} = 2,$$

mientras que su argumento verifica $\cos \theta = \frac{1}{2}$, $\sin \theta = -\frac{\sqrt{3}}{2}$, de manera que

$$\text{Arg}(z) = \left\{ \frac{5\pi}{3} + 2k\pi : k \in \mathbb{Z} \right\}$$

y la determinación principal del argumento es $\arg(z) = -\frac{\pi}{3}$. □

Ejemplo 39. En Python, el módulo y el argumento principal se obtienen con `cmath`:

Ejemplo de Python

```
import cmath
import math
z = 1 - math.sqrt(3)*1j
print(abs(z))
# 2.0
print(cmath.phase(z))
# -1.0471975511965976
print(cmath.phase(z) == -math.pi/3)
# True
```

□

5.4. La función exponencial compleja

La exponencial ($y = e^x$) y las trigonométricas ($y = \sin x$, $y = \cos x$) son las funciones trascendentes más importantes en el cálculo de variable real. Su extensión al campo complejo no reviste mayor dificultad que su correcta definición en el campo real. Existen diversas formas de introducirlas formalmente, ya sea mediante límites o series de potencias. No importa si estas construcciones se estudiaron en su día o si no se recuerdan; lo

fundamental es comprender que la auténtica dificultad radica en el paso de los racionales a los reales, mientras que su extensión al caso complejo es directa.

Dado que la definición rigurosa de estas funciones suele establecerse a través de sus series de Taylor (insistimos en que no importa no saber o no recordar qué son dichas series), esta extensión es inmediata: basta con utilizar las mismas series de potencias con sus mismos coeficientes, interpretando la variable como compleja:

$$\begin{aligned}
 e^x &= \sum_{n=1}^{\infty} \frac{1}{n!} x^n, \text{ para } x \in \mathbb{R} & \dashrightarrow & e^z = \sum_{n=1}^{\infty} \frac{1}{n!} z^n, \text{ para } z \in \mathbb{C}. \\
 \cos x &= \sum_{n=1}^{\infty} \frac{(-1)^n}{(2n)!} x^{2n}, \text{ para } x \in \mathbb{R} & \dashrightarrow & \cos z = \sum_{n=1}^{\infty} \frac{(-1)^n}{(2n)!} z^{2n}, \text{ para } z \in \mathbb{C}. \\
 \sin x &= \sum_{n=1}^{\infty} \frac{(-1)^n}{(2n+1)!} x^{2n+1}, \text{ para } x \in \mathbb{R} & \dashrightarrow & \sin z = \sum_{n=1}^{\infty} \frac{(-1)^n}{(2n+1)!} z^{2n+1}, \text{ para } z \in \mathbb{C}.
 \end{aligned}$$

Definida de esta manera, la función exponencial compleja conserva la propiedad fundamental de la exponencial real:

$$e^{z+w} = e^z e^w, \text{ para todo } z \in \mathbb{C}. \quad (3)$$

Al sustituir el imaginario puro $z = i\theta$ en la variable de la exponencial y simplificar resulta

$$e^{i\theta} = \sum_{n=0}^{\infty} i^n \frac{\theta^n}{n!} = \sum_{k=0}^{\infty} \frac{(-1)^k}{(2k)!} \theta^{2k} + i \sum_{k=0}^{\infty} \frac{(-1)^k}{(2k+1)!} \theta^{2k+1} = \cos \theta + i \sin \theta,$$

lo que revela una inesperada relación entre las funciones exponencial y trigonométricas que se denomina *fórmula de Euler*.

I.5: Fórmula de Euler

Para todo número real $\theta \in \mathbb{R}$ se verifica:

$$e^{i\theta} = \cos \theta + i \sin \theta. \quad (4)$$

Como consecuencia, todo número complejo $z \neq 0$ se puede expresar como

$$z = r e^{i\theta},$$

en donde $r = |z|$ y $\theta \in \text{Arg}(z)$ (*forma exponencial* del número complejo z).

Nota 4. La sustitución $\theta = \pi$ en la fórmula de Euler nos da la conocida *identidad de Euler*

$$e^{i\pi} + 1 = 0,$$

publicada por Euler en 1748 en el libro “*Introductio in analysis infinitorum*”, relaciona los cuatro números más importantes de las matemáticas: el número e , la unidad imaginaria i , el número π , el 0 y el 1. $\square$

Nota 5. La fórmula de Euler (4) se utiliza con frecuencia para *definir* la exponencial compleja y evitar así la aparición de las series de Taylor (aunque las series de potencias están en la base del análisis matemático desde su gestación). Este enfoque es correcto siempre que se hayan definido previamente las funciones trigonométricas. Sin embargo, desde el punto de vista didáctico, introducir la igualdad $e^{i\theta} = \cos \theta + i \sin \theta$ como una definición sin motivación previa puede desconcertar: «¿Por qué se define la exponencial mediante funciones trigonométricas si son conceptos completamente diferentes en variable real?» $\square$

La propiedad fundamental (3) de la exponencial nos proporciona una interpretación geométrica de esta función. Aplicada con $z = i\alpha$, $w = i\theta$, muestra que multiplicar complejos de módulo 1 equivale a sumar sus exponentes, es decir, los complejos de módulo 1 operan como rotaciones por la multiplicación.

En particular, multiplicar repetidamente por la unidad imaginaria $i = e^{\pi i/2}$ produce sucesivas rotaciones de un cuarto de vuelta alrededor del origen (véase la figura 8).




Figura 8. Interpretación geométrica de la multiplicación por la unidad imaginaria.

Dedicamos el resto de la sección a exponer algunos importantes ejemplos de aplicación de la función exponencial; no hay, en realidad, nuevos conceptos.

La *potencia n -ésima* ($n \in \mathbb{Z}$) de un número complejo $z = re^{i\theta}$ es

$$z^n = (re^{i\theta})^n = r^n e^{i\theta n},$$

un número complejo de módulo r^n y argumento $n\theta + 2k\pi$. Esta igualdad escrita en forma trigonométrica se conoce con el nombre de *Fórmula de Moivre*. Para cualquier $n \in \mathbb{Z}$,

$$(\cos \theta + i \sin \theta)^n = \cos n\theta + i \sin n\theta \quad (5)$$

⚠ Todavía pervive la obsesión por poner nombres a todo, por crear una taxonomía exhaustiva similar a la de la botánica de Linneo. Los nombres «forma trigonométrica», «fórmula de Euler», «identidad de Euler» y «fórmula de Moivre», tuvieron pleno sentido en su momento, pero hoy representan simples aplicaciones de la función exponencial. □

Ejemplo 40. Calcular $(1 + i)^{12}$ en forma binómica sería muy tedioso. Lo hacemos en forma trigonométrica, $1 + i = \sqrt{2}(\cos \frac{\pi}{4} + i \sin \frac{\pi}{4})$, mediante la fórmula de Moivre (5)

$$\begin{aligned}(1 + i)^{12} &= \left(\sqrt{2} \left(\cos \frac{\pi}{4} + i \sin \frac{\pi}{4} \right) \right)^{12} = (\sqrt{2})^{12} \left(\cos \left(12 \frac{\pi}{4} \right) + i \sin \left(12 \frac{\pi}{4} \right) \right) \\ &= 64 (\cos (3\pi) + i \sin (3\pi)) = -64.\end{aligned}$$

Por supuesto, no hacía falta recordar la forma trigonométrica ni la fórmula de Moivre, solo las propiedades de la exponencial compleja, que son idénticas a las de la exponencial real:

$$(1 + i)^{12} = (\sqrt{2} e^{\pi i/4})^{12} = 2^6 e^{3\pi i} = -64.$$

□

Ejemplo 41. De nuevo, empleando la forma exponencial $1 + i = \sqrt{2} e^{\pi i/4}$, calculamos

$$(1 + i)^{1000} = (\sqrt{2} e^{\pi i/4})^{1000} = 2^{500} e^{250\pi i} = 2^{500}.$$

□

Para hallar las raíces n -ésimas de un número complejo $w = r e^{i\theta}$, es decir, las soluciones de la ecuación $z^n = w$, aplicamos de nuevo la forma exponencial:

$$z^{1/n} = (r e^{i\theta})^{1/n} = (r e^{i\theta+2k\pi i})^{1/n} = r^{1/n} e^{i \frac{\theta+2k\pi}{n}},$$

de manera que las *raíces n -ésimas de un número complejo* de z son n números complejos, todos ellos de módulo $\sqrt[n]{r}$, y argumentos

$$\alpha_0 = \frac{\theta}{n}, \quad \alpha_1 = \frac{\theta+2\pi}{n}, \quad \alpha_2 = \frac{\theta+4\pi}{n}, \quad \dots, \quad \alpha_{n-1} = \frac{\theta+2(n-1)\pi}{n}.$$

Observemos que para $k < 0$ y para $k \geq n$ se obtienen ángulos que difieren de $\alpha_0, \dots, \alpha_{n-1}$ en 2π radianes y por tanto vuelven a repetirse secuencialmente, de manera que las raíces n -ésimas de un número complejo se encuentran en una circunferencia de radio $\sqrt[n]{r}$ y forman un polígono regular de n lados.

Ejemplo 42. Para obtener las raíces quintas del número real $w = 32$, solo hay que calcular $32^{1/5}$, pues $r = 32$ y $\theta = 0$. La solución está formada por 5 números complejos de radio $r = \sqrt[5]{32} = 2$ y argumentos

$$\alpha_0 = \frac{0}{5}, \quad \alpha_1 = \frac{0+2\pi}{5}, \quad \alpha_2 = \frac{0+4\pi}{5}, \quad \alpha_3 = \frac{0+6\pi}{5}, \quad \alpha_4 = \frac{0+8\pi}{5},$$

es decir, $32^{1/5} = \{2, 2e^{i\frac{2\pi}{5}}, 2e^{i\frac{4\pi}{5}}, 2e^{i\frac{6\pi}{5}}, 2e^{i\frac{8\pi}{5}}\}$. Véase la figura 9. □




Figura 9. Raíces de un número complejo

5.5. Teorema Fundamental del Álgebra

Recordemos que, al resolver una ecuación de segundo grado $ax^2 + bx + c = 0$ en $\mathbb{R}$ mediante la conocida solución algebraica (válida en cualquier cuerpo),

$$x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a},$$

podemos obtener dos raíces diferentes, una sola raíz doble o ninguna raíz, dependiendo de que el discriminante $b^2 - 4ac$ sea positivo, nulo o negativo, pues los números negativos no tienen raíz cuadrada en $\mathbb{R}$. La situación cambia en $\mathbb{C}$, donde todos los números complejos no nulos tienen exactamente dos raíces cuadradas.

Ejemplo 43. La ecuación $z^2 - 2z + 10 = 0$ no tiene soluciones en $\mathbb{R}$, pero sí en $\mathbb{C}$:

$$z = \frac{-(-2) \pm \sqrt{(-2)^2 - 4 \cdot 1 \cdot 10}}{2} = \frac{2 \pm \sqrt{-36}}{2} = \frac{2 \pm 6i}{2} = 1 \pm 3i.$$

Obtenemos dos soluciones conjugadas, $z = 1 + 3i$ y $z = 1 - 3i$, algo que siempre ocurre en las ecuaciones con coeficientes en $\mathbb{R} \subset \mathbb{C}$ cuando se buscan soluciones en $\mathbb{C}$. $\square$

Los polinomios son las funciones que se obtienen sumando y multiplicando números y variables. Tras simplificarlo, cualquier polinomio de grado n se expresa en la forma

$$P(z) = a_n z^n + a_{n-1} z^{n-1} + \cdots + a_1 z + a_0,$$

en donde $a_i \in \mathbb{C}$ para cada $0 \leq i \leq n$ y $a_n \neq 0$. Un número $z_0 \in \mathbb{C}$ es una **raíz** del polinomio P si es una solución de la ecuación $P(z) = 0$, es decir, si $P(z_0) = 0$.

Es natural preguntarse si, al igual que ocurre con las ecuaciones de segundo grado, también las de grado superior tendrán siempre alguna solución en $\mathbb{C}$. Si el término inde-

pendiente a_0 es nulo, evidentemente el polinomio tiene a $z = 0$ como raíz. Centrémonos, por lo tanto, en el caso $a_0 \neq 0$.




Figura 10. En azul, la curva $w(\theta) = P(re^{i\theta})$ para $r \approx 0$; en rojo, para $r \gg 0$.

Podemos investigar la cuestión escribiendo la variable en forma exponencial $z = re^{i\theta}$. Para cada r fijo, si dejamos variar el parámetro θ , obtenemos una curva $w(\theta) = P(re^{i\theta})$ en el plano complejo. Por supuesto, esa curva puede ser muy complicada y tener autointersecciones, pero, si la constante r es lo suficientemente pequeña, la curva entera estará tan cerca del punto a_0 que no rodeará al origen $w = 0$, ya que $P(z) \approx a_0$ cuando $r = |z| \approx 0$.

Por otro lado, si escogemos una constante r suficientemente grande, la curva correspondiente se aproximará a una circunferencia centrada en el origen, con radio r^n mayor que la distancia de a_0 a ese origen, ya que $P(z) \approx a_n z^n$ cuando $r = |z| \approx \infty$. En efecto, si r es muy grande, el módulo del término $a_n z^n$ de grado n será mucho mayor que el mayor de los otros términos $|a_k z^k|$:

$$|a_n z^n| = |a_n| r^n = r^{n-k} \frac{|a_n|}{|a_k|} |a_k| r^k \gg |a_k| r^k = |a_k z^k|.$$

Resumiendo: al escoger r muy grande, la curva rodea al origen, mientras que, al escogerlo muy pequeño, la curva no lo rodea. Véase la figura 10.

Si hacemos ahora variar la constante r de forma continua, desde el valor $r = 0$ hasta un valor muy grande, obtenemos una curva que se mueve por el plano también de forma continua, de manera que, al principio, no rodea al origen pero, al final, sí lo hace. Por lo tanto, en algún momento la curva tendrá que pasar por encima del origen; es decir, existirá un r_0 para el que la curva pasará por el punto $w = 0$, lo que significa que para algún θ_0 se tendrá $P(r_0 e^{i\theta_0}) = 0$, con lo que $z = r_0 e^{i\theta_0}$ será una raíz del polinomio $P(z)$.

Para profundizar. Si el razonamiento anterior no constituye una auténtica demostración, es porque de la proximidad de una curva a una circunferencia no se sigue necesariamente que aquella rodee su centro. Podría darse el caso, por ejemplo, de que diera una vuelta en un sentido y otra en el opuesto sin llegar a rodearlo. El motivo por el cual esto no ocurre es que $e^{i\theta}$ siempre gira en la misma dirección al aumentar θ ; sin embargo, demostrar rigurosamente que este hecho subsana el «agujero» de nuestro razonamiento requiere matemáticas más avanzadas que las empleadas aquí. $\square$

Si admitimos entonces que todo polinomio tiene alguna raíz en $\mathbb{C}$, es fácil comprobar que debe tener tantas como indica su grado, contando la multiplicidad. En efecto, si $z = z_1$ es una raíz de $P(z)$, este polinomio debe ser divisible entre $z - z_1$,

$$P(z) = (z - z_1)P_1(z),$$

con cociente $P_1(z)$ de grado $n - 1$, que tendrá, a su vez, alguna raíz $z = z_2$, de modo que

$$P(z) = (z - z_1)(z - z_2)P_2(z).$$

Repitiendo el proceso, llegamos a

$$P(z) = a_n(z - z_1)(z - z_2) \cdots (z - z_n).$$

Agrupando las raíces repetidas, expresamos la factorización de $P(z)$ en su forma definitiva

$$P(z) = a_n(z - z_1)^{m_1}(z - z_2)^{m_2} \cdots (z - z_p)^{m_p},$$

en donde $z_1, z_2, \dots, z_p$ son las distintas raíces del polinomio $P(z)$ y $m_1, m_2, \dots, m_p$ son las correspondientes **multiplicidades**, que verifican $m_1 + m_2 + \cdots + m_p = n$.

I.6: Teorema Fundamental del Álgebra

Todos los polinomios no constantes tienen al menos una raíz en $\mathbb{C}$.

En consecuencia, un polinomio de grado $n > 1$

$$P(z) = a_n z^n + a_{n-1} z^{n-1} + \cdots + a_1 z + a_0$$

tiene n raíces, contando la multiplicidad, y se factoriza como

$$P(z) = a_n(z - z_1)^{m_1}(z - z_2)^{m_2} \cdots (z - z_p)^{m_p},$$

en donde $z_1, z_2, \dots, z_p$ son las distintas raíces del polinomio P y $m_1, m_2, \dots, m_p$ son las correspondientes **multiplicidades**, que verifican $m_1 + m_2 + \cdots + m_p = n$.

Ejemplo 44. Descompongamos en factores sobre $\mathbb{C}$ el polinomio:

$$P(z) = z^4 - 6z^3 + 14z^2 - 14z + 5.$$

Encontrar las raíces exactas de un polinomio de grado elevado suele ser una tarea extremadamente difícil (o incluso imposible mediante fórmulas con radicales, para grado mayor o igual a 5), por lo que habitualmente se emplean métodos numéricos para obtener aproximaciones.

Sin embargo, en ejemplos preparados como este, podemos apreciar una de ellas, $z = 1$, por simple inspección, lo que garantiza que el polinomio $P(z)$ es divisible entre $z - 1$.

Da igual qué procedimiento sigamos para dividir polinomios: podemos hacer la división mediante el mismo algoritmo con el que dividimos números naturales (colocando $z - 1$ en la «caja» como divisor), o podemos aplicar la versión escolar (regla de Ruffini) de la división sintética de polinomios (a veces conocida como esquema de Horner):

$$\begin{array}{r|rrrrr} & 1 & -6 & 14 & -14 & 5 \\ 1 & & 1 & -5 & 9 & -5 \\ \hline & 1 & -5 & 9 & -5 & 0 \end{array}$$

lo que nos permite factorizar el polinomio como:

$$P(z) = z^4 - 6z^3 + 14z^2 - 14z + 5 = (z - 1)(z^3 - 5z^2 + 9z - 5).$$

Una vez más, comprobamos por inspección que $z = 1$ anula el cociente:

$$\begin{array}{r|rrrr} & 1 & -5 & 9 & -5 \\ 1 & & 1 & -4 & 5 \\ \hline & 1 & -4 & 5 & 0 \end{array}$$

lo que permite factorizarlo a su vez

$$P(z) = (z - 1)(z^3 - 5z^2 + 9z - 5) = (z - 1)^2(z^2 - 4z + 5),$$

que es la factorización completa de $P(z)$ en $\mathbb{R}$.

Para hallar las dos raíces complejas restantes, se aplica la fórmula de la ecuación de segundo grado al segundo factor:

$$z = \frac{4 \pm \sqrt{16 - 20}}{2} = \frac{4 \pm \sqrt{-4}}{2} = \frac{4 \pm 2i}{2} = 2 \pm i.$$

Por lo tanto, la factorización completa en $\mathbb{C}$ de $P(z)$ es:

$$P(z) = z^4 - 6z^3 + 14z^2 - 14z + 5 = (z - 1)^2(z - (2 + i))(z - (2 - i)).$$

Las raíces del polinomio $P(z)$ son $z_1 = 1$, $z_2 = 2 + i$ y $z_3 = 2 - i$, con multiplicidades $m_1 = 2$, $m_2 = 1$ y $m_3 = 1$, respectivamente.

Ruffini publicó su procedimiento en 1804. Hoy, es un caso particular del esquema de Horner para la división sintética de polinomios, un importante algoritmo en cálculo numérico y ciencias de la computación, que permite dividir polinomios de cualquier grado de manera eficiente. $\square$

TEMA II

TENSORES, MATRICES Y VECTORES

1. EL ESPACIO LINEAL $\mathbb{K}^I$

1.1. Introducción

El conjunto $\mathbb{K}^I$ formado por todas las familias o funciones $u: I \rightarrow \mathbb{K}$, en donde I es un conjunto arbitrario y $\mathbb{K}$ representa el cuerpo de los escalares elegido, bien sea $\mathbb{K} = \mathbb{R}$ o $\mathbb{K} = \mathbb{C}$, va a desempeñar un papel esencial en la asignatura. Su estudio en esta sección requiere un cierto esfuerzo de abstracción, lo que debe contemplarse más como un reto que como una dificultad o un inconveniente.

Debemos oponernos al prejuicio que muchas veces se nos quiere imponer de que «abstracto» equivale a «difícil» y «concreto», a «fácil». Al contrario, la abstracción en las matemáticas y en las disciplinas científicas tiene el propósito de simplificar, de eliminar todos los rasgos superfluos que complican el análisis de un objeto.

Conceptos como los de *punto* o *plano*, en geometría, *punto material* o *sólido rígido*, en física, o *máquina de Turing*, en ciencias de la computación, son nociones abstractas sin un referente concreto que las materialice exactamente en la realidad.

Incluso dentro de las matemáticas, podemos comparar el concepto «abstracto», simple y elegante, de *número racional* (cociente de dos enteros) con el caso «concreto» de decidir si un determinado número es o no racional, por ejemplo, $\alpha = \cos(20^\circ) \cos(40^\circ) \cos(80^\circ)$.

No obstante, para poner ejemplos concretos mientras se avanza en el estudio de la sección, podemos recurrir a uno los conjuntos de tipo $\mathbb{K}^I$ más sencillos: el que se obtiene al considerar $\mathbb{K} = \mathbb{R}$, $I = \{1, 2\}$, que se puede identificar con $\mathbb{R}^2$, al denotar la función $u: \{1, 2\} \rightarrow \mathbb{R}$ mediante el par ordenado (u_1, u_2) .

La particularidad de $\mathbb{R}^2$ (conjunto de los pares (x, y) con $x, y \in \mathbb{R}$) es que se puede «visualizar» como una hoja de papel de extensión infinita en la que se puede dibujar, para lo que es imprescindible marcar siempre el origen $(0, 0)$ en el dibujo.

Los dibujos pueden ser palancas de comprensión o trampas conceptuales que lleven al error y a la confusión permanente. En cualquier caso conviene tener siempre presente que

una palabra vale más que mil imágenes.

Notación y terminología. En lo sucesivo, se podrá denotar los escalares mediante letras griegas minúsculas siempre que multipliquen a elementos de $\mathbb{K}^I$. Estos últimos se representarán con letras latinas (mayúsculas o minúsculas), tanto en negrita como en cursiva, o con letras griegas mayúsculas.

Cuando se emplee mayúscula o negrita, se procurará mantener las componentes en cursiva minúscula, como en $A = (a_i)_{i \in I}$, $u = (u_i)_{i \in I}$ o $\mathbf{v} = (v_i)_{i \in I}$. Asimismo, se podrá relajar la notación escribiendo simplemente $A = (a_i)$, $u = (u_i)$ o $\mathbf{v} = (v_i)$.

En particular, resulta conveniente emplear la negrita al indexar los propios elementos de $\mathbb{K}^I$, por ejemplo, $\mathbf{u}_1, \mathbf{u}_2, \mathbf{u}_3 \in \mathbb{K}^I$. De este modo se minimiza el riesgo de confusión con las componentes de un elemento $u = u_i \in \mathbb{K}^I$. Bajo este criterio, la componente i de $\mathbf{u}_j$ se expresaría por $(\mathbf{u}_j)_i$.

En general, el uso de la negrita advierte de que el objeto posee componentes, aunque no todo elemento con componentes deba ir necesariamente en negrita. $\square$

1.2. Combinaciones lineales en $\mathbb{K}^I$

Sean I un conjunto arbitrario, $\mathbb{K}$ el campo de escalares elegido ($\mathbb{K} = \mathbb{R}$ o $\mathbb{K} = \mathbb{C}$) y $\mathbb{K}^I$ el conjunto formado por todas las familias $\mathbf{u}: I \rightarrow \mathbb{K}$.

Puesto que ya sabemos operar con escalares, la extensión de esas operaciones a $\mathbb{K}^I$ es inmediata si trabajamos componente a componente: si para $\mathbf{u}, \mathbf{v} \in \mathbb{K}^I$, $\alpha, \beta \in \mathbb{K}$ se tiene $\mathbf{w} = \alpha\mathbf{u} + \beta\mathbf{v}$ si y solo si $w_i = \alpha u_i + \beta v_i$, para todo $i \in I$.

Ejemplo 45. Consideremos $I = \{1, 2\}$, $\mathbb{K} = \mathbb{R}$, los números reales $\alpha = 4$ y $\beta = 2$ y dos elementos $\mathbf{u}$ y $\mathbf{v}$ de $\mathbb{K}^I$ dados respectivametne por $u_1 = 3$, $u_2 = -5$ y $v_1 = 6$, $v_2 = 8$.

Obtenemos $\mathbf{w} = \alpha\mathbf{u} + \beta\mathbf{v} \in \mathbb{K}^I$ componente a componente. La primera componente es $w_1 = 4u_1 + 2v_1 = 12 + 12 = 24$ y la segunda, $w_2 = 4u_2 + 2v_2 = -20 + 16 = -4$. Cuando se identifica $\mathbb{R}^I$ con $\mathbb{R}^2$, se escribe así: $\mathbf{w} = 4(3, -5) + 2(6, 8) = (24, -4)$. $\square$

Ejemplo 46. Si $I = \mathbb{N}$, $\mathbb{K} = \mathbb{R}$, $u_k = k^2$, $v_k = \sqrt{k}$, entonces $w = 2u - 5v \in \mathbb{R}^I$ viene dada por $w_k = 2k^2 - 5\sqrt{k}$. En este caso, es mejor emplear la letra k como índice para evitar que se confunda el índice i con la unidad imaginaria. $\square$

La expresión $\alpha\mathbf{u} + \beta\mathbf{v}$ se denomina *combinación lineal* de $\mathbf{u}, \mathbf{v} \in \mathbb{K}^I$ con *pesos* o *coeficientes* $\alpha, \beta \in \mathbb{K}$. Se pueden formar combinaciones lineales con cualquier núme-

ro de sumandos. Por ejemplo, $\sum_{j=1}^m \alpha_j \mathbf{u}_j$ es una combinación lineal de m elementos, $\mathbf{u}_1, \dots, \mathbf{u}_m \in \mathbb{K}^I$ con pesos $\alpha_1, \dots, \alpha_m \in \mathbb{K}$. La combinación lineal que tiene todos los pesos iguales a cero se denomina *combinación trivial*.

Al introducir las combinaciones en el conjunto $\mathbb{K}^I$, decimos que lo hemos dotamos de una estructura de *espacio lineal*.

En español es más frecuente el término *espacio vectorial*, pero procuraremos evitarlo porque, como veremos más adelante, vamos a reservar el término «vector» para los elementos de un espacio lineal concreto. Podremos referirnos a $\mathbb{K}^I$ como «espacio», más que como «conjunto».

Las operaciones de $\mathbb{K}^I$ se extienden a sus subconjuntos: si $A, B \subset \mathbb{K}^I$, $\Lambda, \Gamma \subset \mathbb{K}$,

$$\Lambda A + \Gamma B = \{\lambda \mathbf{a} + \gamma \mathbf{b} : \mathbf{a} \in A, \mathbf{b} \in B, \lambda \in \Lambda, \gamma \in \Gamma\}. \quad (6)$$

Si alguno de los conjuntos es unitario, se suelen omitir las llaves; por ejemplo, si $B = \{\mathbf{b}\}$, se pone $A + \mathbf{b}$ en vez de $A + \{\mathbf{b}\}$.

Ejemplo 47. La expresión (6) representa todas las posibles combinaciones lineales que se pueden formar con los elementos de los conjuntos en cuestión. Aunque no está claro que unos dibujos en el plano ayuden a comprender mejor esa idea abstracta de «todas las combinaciones posibles», lo hacemos en $\mathbb{R}^2$ (identificado con $\mathbb{R}^{\{1,2\}}$).

Sean $\Lambda = [1, 2]$, $\Gamma = [0, 1]$, intervalos de la recta real, A , el segmento de extremos $(0, 2)$, $(2, 2)$ y B , la circunferencia de centro $(0, 0)$ y radio 1. En la figura 11 se representan: el segmento A , la circunferencia B , el trapecio ΛA , el círculo ΓB y la suma $\Lambda A + \Gamma B$, que se visualiza colocando una copia del círculo ΓB en cada punto del trapecio ΛA . $\square$




Figura 11. Dibujos correspondientes al ejemplo 47.

Se dice que un conjunto $V \subset \mathbb{K}^I$ es un *subespacio lineal* de $\mathbb{K}^I$ si $\alpha \mathbf{u} + \beta \mathbf{v} \in V$ para

todos $\mathbf{u}, \mathbf{v} \in V, \alpha, \beta \in \mathbb{K}$, lo que equivale a afirmar que $\mathbb{K}V + \mathbb{K}V \subset V$.

Se dice que $B \subset \mathbb{K}^I$ es un *subespacio afín* de $\mathbb{K}^I$ si $B - \mathbf{b}$ es un subespacio lineal para algún $\mathbf{b} \in B$. Si $B - \mathbf{b}$ es subespacio lineal, entonces $B - \mathbf{b}' = (B - \mathbf{b}) - (\mathbf{b}' - \mathbf{b}) = B - \mathbf{b}$ para todo $\mathbf{b}' \in B$.

Ejemplo 48. Los subespacios lineales de $\mathbb{R}^{\{1,2\}} \approx \mathbb{R}^2$ son: el origen $V = \{0\}$, todas las «rectas» que pasan por el origen y el espacio total $V = \mathbb{R}^{\{1,2\}}$.

Los subespacios afines de $\mathbb{R}^{\{1,2\}} \approx \mathbb{R}^2$ son: los «puntos» (conjuntos con un solo elemento), todas las «rectas» del plano y el espacio total (el propio plano). $\square$

El conjunto de todas las combinaciones lineales de los elementos de un conjunto $B \subset \mathbb{K}^I$ forma un subespacio lineal de $\mathbb{K}^I$, pues las combinaciones de combinaciones son también combinaciones. Este subespacio lineal se denomina *subespacio generado* por B y se denota por $\langle B \rangle = \mathbb{K}B + \mathbb{K}B$.

La familia $\mathbf{0} \in \mathbb{K}^I$ que vale siempre cero, es decir, $0_i = 0$ para todo $i \in I$, se denomina *elemento nulo* o *elemento cero* de $\mathbb{K}^I$.

Decimos que un conjunto $B \subset \mathbb{K}^I$ es *linealmente dependiente* si podemos encontrar una combinación lineal no trivial de sus elementos que dé como resultado el elemento cero ($\mathbf{0} \in \mathbb{K}^I$). En caso contrario, decimos que B es *linealmente independiente* o, lo que es lo mismo, que B es una *base* del subespacio $\langle B \rangle$ que genera.

 Decir que un subconjunto B es linealmente dependiente significa que *alguno* de sus elementos se puede expresar como combinación lineal de los demás elementos de B (es, en cierto sentido, «redundante»). Pero no significa que *cualquier* elemento de B se pueda expresar como combinación lineal de los demás elementos de B .

Por ejemplo, $B = \{(1, 0), (2, 0), (0, 1)\}$ es linealmente dependiente en $\mathbb{R}^2$, porque existen combinaciones nulas no triviales, como $2(1, 0) - (2, 0) + 0(0, 1) = (0, 0)$, pero $(0, 1)$ no es combinación lineal de $(1, 0)$ y $(2, 0)$. $\square$

Cuando los elementos de una base B siguen un orden concreto (están indexados), la llamamos *base ordenada*. De hecho, muchas veces cuando hablemos simplemente de una «base», estaremos dando por hecho que está ordenada.

Denominamos *elementos básicos* de $\mathbb{K}^I$ a las funciones $\mathbf{e}_j \in \mathbb{K}^I$ (una por cada índice $j \in I$) definidas como sigue:

$$\mathbf{e}_j : I \rightarrow \mathbb{K}, \quad (\mathbf{e}_j)_i = \begin{cases} 1, & \text{si } i = j \\ 0, & \text{si } i \neq j \end{cases}.$$

El valor $\delta_{ij} = (\mathbf{e}_j)_i$ se conoce habitualmente como la *delta de Kronecker*.

⚠ Es necesario prestar atención a la notación $\mathbf{e}_j$, porque nos estamos refiriendo de la misma manera a los elementos básicos correspondientes a distintos conjuntos de índices. Una notación más precisa, como $\mathbf{e}_j^I$, resultaría excesivamente recargada. Resolveremos las posibles ambigüedades con las explicaciones convenientes. $\square$

El subespacio generado por todos los elementos básicos $\{\mathbf{e}_j\}_{j \in I}$ de $\mathbb{K}^I$ se denomina *espacio lineal libre* sobre I y se denota por $\mathcal{F}(I)$. Es decir, $\mathcal{F}(I) = \langle \{\mathbf{e}_j\}_{j \in I} \rangle \subset \mathbb{K}^I$.

La familia de elementos básicos $\{\mathbf{e}_j\}_{j \in I}$ de $\mathbb{K}^I$ es linealmente independiente, por lo que es una base del espacio lineal libre $\mathcal{F}(I)$, que se denomina *base canónica* de $\mathcal{F}(I)$.

Cualquier elemento u de $\mathcal{F}(I)$ se expresa como

$$u = \sum_{j \in I} u_j \mathbf{e}_j.$$

Para comprobar la expresión anterior, basta evaluar las componentes del miembro derecho $v = \sum_{j \in I} u_j \mathbf{e}_j$ y comprobar que se obtienen las componentes de u :

$$v_i = \sum_{j \in I} u_j (\mathbf{e}_j)_i = u_i,$$

pues $(\mathbf{e}_j)_i = 0$ cuando $i \neq j$, mientras que $(\mathbf{e}_i)_i = 1$.

Si el conjunto I tiene un número finito de elementos, entonces los elementos básicos generan todo el espacio, esto es, $\mathcal{F}(I) = \mathbb{K}^I$. En ese caso, la familia $\{\mathbf{e}_j\}_{j \in I}$ es la *base canónica* de $\mathbb{K}^I$ y cualquier elemento u de $\mathbb{K}^I$ se expresa como

$$u = \sum_{j \in I} u_j \mathbf{e}_j.$$

Casi todos los conjuntos de índices que estudiaremos serán conjuntos finitos.

Si el conjunto I tiene infinitos elementos, entonces $\mathcal{F}(I) \neq \mathbb{K}^I$, es decir, $\mathcal{F}(I)$ es un *subespacio propio* de $\mathbb{K}^I$. Véanse los ejemplos 51 y 52, más adelante.

Aplicación a la informática. El espacio lineal libre sobre un conjunto es una herramienta matemática fundamental para la IA: permite transformar elementos abstractos, como palabras, categorías o nodos de un grafo, en objetos con los que se puede operar algebraicamente. Esta construcción es la que sostiene desde las técnicas esenciales de procesamiento del lenguaje natural hasta el funcionamiento de las redes neuronales avanzadas. $\square$

Ejemplo 49. Si $I = \{a, b\}$, entonces hay dos elementos básicos en $\mathbb{R}^I$, que son las funciones $\mathbf{e}_a, \mathbf{e}_b: I \rightarrow \mathbb{R}$ definidas mediante: $(\mathbf{e}_a)_a = 1, (\mathbf{e}_a)_b = 0, (\mathbf{e}_b)_a = 0, (\mathbf{e}_b)_b = 1$.

El conjunto $B = \{\mathbf{e}_a, \mathbf{e}_b\}$ es linealmente independiente y genera todo $\mathbb{R}^I$ (compruébese como ejercicio que, efectivamente, $\langle B \rangle = \mathbb{R}^I$). Es decir, B es una base de $\mathcal{F}(I) = \mathbb{R}^I$. Todos los elementos de $\mathbb{K}^I$ son de la forma $u = u_a \mathbf{e}_a + u_b \mathbf{e}_b$. $\square$

Ejemplo 50. Si $I = \{1, 2, 3\}$, entonces hay tres elementos básicos en $\mathbb{R}^I$, que son las funciones $\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3: I \rightarrow \mathbb{R}$ definidas mediante: $(\mathbf{e}_1)_1 = 1, (\mathbf{e}_1)_2 = 0, (\mathbf{e}_1)_3 = 0, (\mathbf{e}_2)_1 = 0, (\mathbf{e}_2)_2 = 1, (\mathbf{e}_2)_3 = 0, (\mathbf{e}_3)_1 = 0, (\mathbf{e}_3)_2 = 0, (\mathbf{e}_3)_3 = 1$.

El conjunto $B = \{\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3\}$ es una base de $\mathcal{F}(I) = \mathbb{R}^I$. Los elementos $u \in \mathbb{K}^I$ se expresan como $u = u_1 \mathbf{e}_1 + u_2 \mathbf{e}_2 + u_3 \mathbf{e}_3$. $\square$

Ejemplo 51. Si $I = \mathbb{N}$, entonces hay infinitos elementos básicos en $\mathbb{K}^{\mathbb{N}}$, que son las funciones $\mathbf{e}_m: \mathbb{N} \rightarrow \{0, 1\} \subset \mathbb{K}$ (una función para cada $m \in \mathbb{N}$) definidas mediante $(\mathbf{e}_m)_n = 1$ si y solo si $n = m$.

El conjunto $B = \{\mathbf{e}_m\}_{m \in \mathbb{N}}$ no genera todo $\mathbb{K}^{\mathbb{N}}$. Por ejemplo, la función $v \in \mathbb{K}^{\mathbb{N}}$ dada por $v_n = 1$ para todo $n \in \mathbb{N}$ no se puede expresar como combinación lineal de los elementos de B , porque en cada una de esas combinaciones aparece un número finito de unos.

El espacio $\mathbb{K}^{\mathbb{N}}$ este formado por todas las sucesiones de escalares, mientras que el espacio libre $\mathcal{F}(\mathbb{N})$ está formado por las sucesiones de escalares que tienen todos sus términos iguales a cero, excepto un número finito de ellos, es decir, sucesiones a_n para las que existe un $n_0 \in \mathbb{N}$ tal que $a_n = 0$ para todo $n \geq n_0$. $\square$

Ejemplo 52. Cuando $I = \mathbb{R}$, se suele emplear la notación de paréntesis combinada con la de subíndices. Hay infinitos elementos básicos en $\mathbb{R}^{\mathbb{R}}$: las funciones $\mathbf{e}_x: \mathbb{R} \rightarrow \{0, 1\} \subset \mathbb{R}$ definidas mediante $\mathbf{e}_x(y) = 1$ si y solo si $x = y$ (una función por cada $x \in \mathbb{R}$).

El conjunto $B = \{\mathbf{e}_x\}_{x \in \mathbb{R}}$ no genera todo el espacio de funciones reales de variable real $\mathbb{R}^{\mathbb{R}}$, sino solo el subespacio $\mathcal{F}(\mathbb{R})$ formado por las funciones $f: \mathbb{R} \rightarrow \mathbb{R}$ que valen en cero en todo punto, excepto en un número finito de ellos (funciones características de conjuntos finitos). $\square$

1.3. El teorema de la base

II.1: Teorema de la base

Sea $B \subset \mathbb{K}^I$ un conjunto linealmente independiente con n elementos y $A \subset \langle B \rangle$.

- i) Si A tiene más de n elementos, entonces A es linealmente dependiente.
- ii) Si A es linealmente independiente y tiene n elementos, entonces $\langle A \rangle = \langle B \rangle$.
- iii) Todas las bases del subespacio $\langle B \rangle$ tienen n elementos.

Demostración.

- i) Cualquier $\mathbf{v} \in A$ se puede expresar como combinación lineal $\mathbf{v} = \sum_{k=1}^n \alpha_k \mathbf{u}_k$ de los elementos de la base $B = \{\mathbf{u}_1, \dots, \mathbf{u}_n\}$, de donde es posible despejar uno de los $\mathbf{u}_j$ (cuyo coeficiente sea no nulo) y reemplazarlo en B por $\mathbf{v}$. El conjunto resultante seguirá generando todo el espacio $\langle B \rangle$.

Este proceso de sustitución se repite sucesivamente. Si en algún paso intermedio no se puede despejar en la combinación lineal, es porque dicho elemento ya era combinación lineal de los elementos de A previamente introducidos, con lo que A sería linealmente dependiente.

En caso contrario, si el proceso logra completarse hasta reemplazar los n elementos de B , el nuevo conjunto formado por n elementos de A pasará a generar todo $\langle B \rangle$, por lo que cualquier elemento restante de A será combinación lineal de los anteriores y, también este caso, A sería linealmente dependiente.

- ii) Si A no generara todo $\langle B \rangle$, existiría un $\mathbf{v} \in \langle B \rangle \setminus \langle A \rangle$. Pero, entonces el conjunto $A \cup \{\mathbf{v}\}$ sería linealmente independiente y tendría $n + 1$ elementos, en contradicción con el apartado i).
- iii) Supongamos que B' un subconjunto linealmente independiente que genera el mismo espacio, es decir $\langle B' \rangle = \langle B \rangle$. Si B' tuviera más elementos que B , aplicaríamos el resultado anterior con $A = B'$ para llegar a una contradicción. Si B' tuviera menos elementos que B , aplicaríamos el apartado i), cambiando A por B y B por B' . $\square$

Denominamos *dimensión* de un subespacio V , denotado por $\dim(V)$, al número de elementos de cualquiera de sus bases, pues todas tienen el mismo número de ellos.

Como hemos visto, si el conjunto de índices I tiene n elementos, entonces el espacio $\mathbb{K}^I = \mathcal{F}(I)$ tiene dimensión n .

La **suma** de dos subespacios $U, V \subset \mathbb{K}^I$ es el subespacio generado por su unión:

$$U + V = \langle U \cup V \rangle = \{\mathbf{u} + \mathbf{v} \in \mathbb{K}^I : \mathbf{u} \in U, \mathbf{v} \in V\}$$

Si unimos una base de U con otra de V , la familia resultante no tiene por qué ser base de $U + V$, porque U y V pueden tener vectores comunes no nulos.

Si los subespacios $U, V \subset \mathbb{K}^I$ verifican $U \cap V = \{\mathbf{0}\}$, el subespacio suma se denomina **suma directa** y se denota, en este caso, mediante $U \oplus V$.

En estas condiciones sí que es cierto que, al unir una base U con una base de V , se obtiene una base de $U \oplus V$.

Ejemplo 53. Consideremos el conjunto de índices $I = \{1, 2, 3, 4, 5, 6\}$ y los subespacios $U = \langle \mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3 \rangle$ y $V = \langle \mathbf{e}_3, \mathbf{e}_5, \mathbf{e}_6 \rangle$ de $\mathbb{K}^I$.

El subespacio suma $U + V$ está generado por la familia

$$\{\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3\} \cup \{\mathbf{e}_3, \mathbf{e}_5, \mathbf{e}_6\} = \{\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3, \mathbf{e}_5, \mathbf{e}_6\},$$

es decir,

$$U + V = \langle \mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3, \mathbf{e}_5, \mathbf{e}_6 \rangle = \left\{ \sum_{i=1, i \neq 4}^6 \alpha_i \mathbf{e}_i \in \mathbb{K}^I : \alpha_1, \alpha_2, \alpha_3, \alpha_5, \alpha_6 \in \mathbb{K} \right\}$$

La suma no es directa, porque $U \cap V \neq \mathbf{0}$, ya que $\mathbf{e}_3 \in U \cap V$.

Si consideramos ahora el subespacio $W = \langle \mathbf{e}_5, \mathbf{e}_6 \rangle$, entonces su suma con U sí es directa, pues $U \cap W = \mathbf{0}$:

$$U \oplus W = \langle \mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3, \mathbf{e}_5, \mathbf{e}_6 \rangle = U + V.$$

Al quitar los vectores «repetidos», hemos expresado el subespacio $U + V$ como suma directa de U y W . El símbolo $\oplus$ sirve para resaltar que lo sumandos U y W solo tienen en común el vector cero $\mathbf{0}$. $\square$

No todos los espacios son de dimensión finita, como se ha visto en los ejemplos 51 y 51. En esta asignatura estudiaremos espacios de dimensión finita.

Para profundizar. El **producto de Hadamard** en $\mathbb{K}^I$ consiste en multiplicar componente a componente, con la misma filosofía que la adición en $\mathbb{K}^I$:

$$w = u \odot v \text{ si y solo si } w_i = u_i v_i \text{ para todo } i \in I.$$

El producto de Hadamard es una mera curiosidad en los cursos introductorios de álgebra lineal, si es que llega a aparecer. La razón es que esta disciplina se dedica al estudio de las transformaciones que conservan la estructura lineal y el producto de Hadamard no lo hace. No obstante, esta operación es importante en el ámbito de la inteligencia artificial. $\square$

1.4. Espacios vectoriales «abstractos».

Las siguientes propiedades del espacio $\mathbb{K}^I$ son tan evidentes que escribirlas prácticamente equivale a demostrarlas: solo hay que poner el subíndice a $\mathbf{u}, \mathbf{v}, \mathbf{w}$ y se convierten en propiedades conocidas de los escalares. Para todos $\mathbf{u}, \mathbf{v}, \mathbf{w} \in \mathbb{K}^I$, $\alpha, \beta \in \mathbb{K}$ se verifica:

$$(EV1) \quad (\mathbf{u} + \mathbf{v}) + \mathbf{w} = \mathbf{u} + (\mathbf{v} + \mathbf{w}),$$

$$(EV2) \quad \mathbf{u} + \mathbf{v} = \mathbf{v} + \mathbf{u},$$

$$(EV3) \quad \mathbf{u} + \mathbf{0} = \mathbf{u},$$

$$(EV4) \quad \mathbf{u} - \mathbf{u} = \mathbf{0},$$

$$(EV5) \quad \alpha(\mathbf{u} + \mathbf{v}) = \alpha\mathbf{u} + \alpha\mathbf{v},$$

$$(EV6) \quad (\alpha + \beta)\mathbf{u} = \alpha\mathbf{u} + \beta\mathbf{u},$$

$$(EV7) \quad (\alpha\beta)\mathbf{u} = \alpha(\beta\mathbf{u}),$$

$$(EV8) \quad 1\mathbf{u} = \mathbf{u},$$

Los manuales que prefieren un enfoque axiomático denominan *espacio vectorial* o *espacio lineal* sobre el cuerpo $\mathbb{K}$ (en español es más frecuente el término *espacio vectorial*) a los conjuntos dotados de dos operaciones (la adición y la multiplicación por escalares) que satisfacen las propiedades (EV1) a (EV8).

En realidad, cualquier espacio vectorial abstracto V de este tipo se puede identificar con el espacio lineal libre $\mathcal{F}(B) \subset \mathbb{K}^B$ sobre una base B de V .

No obstante lo anterior, es imposible ignorar la enorme trascendencia de la axiomatización del concepto de espacio vectorial. Sin necesidad de profundizar, resulta mucho más práctico demostrar un teorema una sola vez para todos los espacios vectoriales en abstracto, que tener que demostrarlo repetidamente para distintos espacios funcionales particulares. Sin embargo, en esta asignatura (y, muy probablemente, durante el resto de la carrera) solo trabajaremos con espacios vectoriales del tipo $\mathbb{K}^I$.



Se puede consultar en este punto el capítulo *Espacios vectoriales* del libro *Álgebra para ingenieros* [1], páginas 53 a 98, en donde se exponen conceptos revisados en esta sección, pero desde el punto de vista de los espacios vectoriales abstractos. Se comprobará que no hay gran diferencia en la presentación y se podrán consultar ejemplos y ejercicios de comprobación.

2. LOS TENSORES COMO CONTENEDORES DE DATOS INDEXADOS

2.1. Introducción

Si miramos una pantalla Full HD (1080p) de cerca, veremos que la imagen se divide en una cuadrícula de 1920 filas y 1080 columnas llena de puntos llamados píxeles. Así que, para empezar, necesitamos dos índices para localizar un píxel concreto: su fila ($1 \leq i \leq 1920$) y su columna ($1 \leq j \leq 1080$). Como la imagen es en color (por ejemplo, en el formato estándar RGB), cada uno de esos píxeles contiene una mezcla de tres colores básicos: rojo (red), verde (green) y azul (blue). Para saber cuánta cantidad hay de cada color, añadimos un tercer índice ($1 \leq k \leq 3$).

Por ejemplo, en el píxel de la fila 10, columna 5 ($i = 10, j = 5$), podríamos tener $a_{10,5,1} = 255$, que indicaría máxima contribución de rojo; $a_{10,5,2} = 0$, nada de verde, $a_{10,5,3} = 125$, mitad de la capacidad de azul, aproximadamente, lo que representaría un rosa fucsia intenso o magenta para el píxel (10, 5).

De esta manera, una imagen digital estándar en color se almacena matemáticamente como un conjunto de indexado de datos con tres índices o ejes (lo que se puede entender como un solo índice cuyos valores son ternas ordenadas). Diremos que su formato (*shape*) es $1920 \times 1080 \times 3$, porque 1920, 1080 y 3 son los tamaños o longitudes del primer índice, del segundo y del tercero, respectivamente.




Figura 12. Una imagen RGB como conjunto de números indexado por tres índices.

Vamos a denominar *tensores* a los conjuntos numéricos indexados mediante tuplas de

números naturales. Estos objetos pueden contemplarse desde varios puntos de vista:

- (a) Como simples contenedores de datos organizados por determinados rasgos o características. Esta perspectiva tiene escaso interés desde el punto de vista del álgebra, aunque constituye un procedimiento de almacenamiento muy eficiente desde el punto de vista informático.
- (b) Como objetos algebraicos que se operan entre sí y con escalares. Los tensores heredan las propiedades de los vectores de la enseñanza secundaria. Esto permite que toda la maquinaria del álgebra lineal (combinaciones lineales, subespacios, optimización) se aplique a datos complejos. Que el objeto sea algebraico permite calcular «distancias» o «similitudes» entre conceptos complejos.
- (c) Como operadores, es decir, como «máquinas» que reciben vectores como argumentos y devuelven un resultado (un escalar u otro vector), de manera que la transformación preserva la estructura algebraica respecto de cada argumento por separado, cuando se consideran fijos los otros.

Por ejemplo, una capa de una red neuronal es, en esencia, un tensor actuando como operador sobre los datos de entrada para transformarlos en una nueva representación.

Cuando escuchamos la palabra «tensor», es normal que pensemos en matemáticas abstractas y difíciles o en física matemática. Sin embargo, en el mundo de la IA, los tensores constituyen un marco de referencia; de hecho, son la estructura de datos fundamental sobre la que se construye todo el aprendizaje profundo (*Deep Learning*).

Una de las librerías de IA más famosas y utilizadas (desarrollada por Google) se denomina *TensorFlow*. Su propio nombre lo dice todo: *Flujo de tensores*. En una red neuronal, los datos (ya sean imágenes, textos o audio) se transforman en tensores que «fluyen» a través de las distintas capas del algoritmo, operando y transformándose a gran velocidad.

2.2. Definición de tensor

Para cada número natural $n \geq 1$, denotaremos $\mathbb{N}_n = \{1, 2, \dots, n\}$. Si tenemos m números naturales $n_1, n_2, \dots, n_m > 0$, con $m > 1$, utilizaremos la expresión abreviada $n_1 \times n_2 \times \dots \times n_m$ para representar al producto cartesiano $\mathbb{N}_{n_1} \times \mathbb{N}_{n_2} \times \dots \times \mathbb{N}_{n_m}$. Esta notación simplificada resulta muy cómoda y no da lugar a confusión.

 Aunque optamos por la convención matemática de iniciar los índices en 1, en la mayoría de los lenguajes de programación se utiliza la indexación basada en 0. □

Diremos que el producto cartesiano $\mathcal{I} = n_1 \times n_2 \times \cdots \times n_m$ es un *formato* de *orden* m o con m índices. El primer índice, al que podemos llamar j_1 , toma valores en $\mathbb{N}_{n_1}$, por lo que decimos que tiene *tamaño* o *longitud* n_1 . Análogamente, los demás índices $j_2, \dots, j_m$ tienen tamaños $n_2, \dots, n_m$, respectivamente. Diremos que un eje o índice está *degenerado* si su tamaño es igual a 1.

Recordemos que denotamos mediante $\mathbb{K}$ a nuestro cuerpo de escalares, que en este contexto se refiere bien a los números reales ($\mathbb{K} = \mathbb{R}$) o bien a los complejos ($\mathbb{K} = \mathbb{C}$).

Denominamos *tensores* de formato $\mathcal{I}$ sobre $\mathbb{K}$ a los elementos de $\mathbb{K}^{\mathcal{I}}$.

Es decir, un tensor de formato $\mathcal{I}$ sobre $\mathbb{K}$ es un conjunto indexado $A: \mathcal{I} \rightarrow \mathbb{K}$, en donde $\mathcal{I} = n_1 \times n_2 \times \cdots \times n_m$ para ciertos $m, n_1, n_2, \dots, n_m \in \mathbb{N}$.

El espacio de tensores $\mathbb{K}^{\mathcal{I}}$ es un caso particular de los espacios estudiados en la sección II.1: el conjunto de índices es aquí un formato.

La dimensión del espacio lineal $\mathbb{K}^{\mathcal{I}}$ es el producto de los tamaños de todos los ejes de su formato $\mathcal{I}$, es decir, $\dim(\mathbb{K}^{\mathcal{I}}) = n_1 n_2 \cdots n_m$. El natural m es el *orden* del tensor. También se dice que m es el número de *ejes* o de índices del tensor.

Las imágenes $a_{(j_1, j_2, \dots, j_m)} \in \mathbb{K}$ se denominan *componentes* o elementos del tensor. Por simplicidad, se suele poner $a_{j_1 j_2 \dots j_m}$ en vez de $a_{(j_1, j_2, \dots, j_m)}$.

Los tensores de orden uno se denominan *vectores* y los de orden dos, *matrices*. Para ganar compatibilidad en las expresiones, podemos considerar a los propios elementos de $\mathbb{K}$ como tensores de orden cero e identificar esos elementos con los correspondientes tensores que tienen todos sus ejes degenerados, es decir,

$$\mathbb{K} = \mathbb{K}^1 = \mathbb{K}^{1 \times 1} = \dots = \mathbb{K}^{1 \times \cdots \times 1}.$$

Podremos emplear letras latinas (mayúsculas o minúsculas) tanto en negrita como en cursiva o con letras griegas mayúsculas para referirnos a los tensores, pero, procuraremos denotar las componentes mediante la minúscula correspondiente. Por ejemplo, $\mathbf{a} = a_{j_1 j_2 \dots j_m}$, $\mathbf{b} = b_{j_1 j_2 \dots j_m}$, $\mathbf{C} = c_{j_1 j_2 \dots j_m}$, $\mathbf{\Lambda} = \lambda_{j_1 j_2 \dots j_m} \dots$

Después de una cadena de definiciones como esta, toca poner ejemplos, pero, para hacerlo, necesitamos una buena notación.

2.3. Notación de corchetes anidados

La notación de corchetes anidados consiste en encapsular las componentes del tensor $A \in \mathbb{K}^{\mathcal{I}}$ dentro de corchetes $[\dots]$, donde cada par de ellos representa un eje o índice del tensor. Los elementos situados en el nivel más profundo son las componentes (elementos de $\mathbb{K}$), agrupados en listas; a su vez, estas listas se agrupan dentro de otras listas más externas, creando una estructura jerárquica de «cajas dentro de cajas». El número de corchetes que se abren de forma consecutiva al inicio de la expresión determina el orden del tensor, mientras que la cantidad de elementos contenidos en cada nivel define su formato.

Ejemplo 54. $v = [10, 20, 30, 40]$. Hay un solo corchete de apertura, por lo que el tensor es de orden 1 (un solo eje o, lo que es igual, un solo índice: v_j). Se trata de un vector. Los componentes de v son $v_1 = 10, v_2 = 20, v_3 = 30, v_4 = 40$, es decir, $v = \sum_{i=1}^4 v_i \mathbf{e}_i$.

Como el único índice j varía entre 1 y 4, el formato de v es $\mathbb{N}_4$, es decir $v \in \mathbb{K}^{\mathbb{N}_4}$. En principio, solo hemos convenido en simplificar la notación $\mathbb{N}_n$ por n al hacer productos cartesianos y aquí solo hay un factor. $\square$

Entre las muchas identificaciones necesarias, nos preguntamos si conviene identificar el vector $v = [10, 20, 30, 40] \in \mathbb{R}^{\mathbb{N}_4}$ con la tupla $v = (10, 20, 30, 40) \in \mathbb{R}^4$ (producto cartesiano). En matemáticas es habitual hacerlo, pero hay circunstancias en las que los conceptos deben diferenciarse.

Por ejemplo, en Python, la tupla $(2, 1, 4)$ puede interpretarse como una estructura para agrupar datos de forma inmutable. No entiende de álgebra. Para ella, el signo «+» significa «pegar» y el «*» significa «repetir». En cambio, el vector `np.array([2, 1, 4])` es un objeto matemático, entiende las reglas del álgebra lineal.

En esta asignatura, salvo que se indique lo contrario, identificamos tuplas y vectores,

$$[v_1, \dots, v_n] = (v_1, \dots, v_n),$$

de manera que $\mathbb{K}^{\mathbb{N}_n} = \mathbb{K}^n$, en donde $\mathbb{K}$ es nuestro conjunto de escalares ($\mathbb{K} = \mathbb{R}$ o $\mathbb{K} = \mathbb{C}$).

Cuando consideremos las matrices como operadores sobre espacios vectoriales, necesitaremos identificar algebraicamente los vectores bien como matrices fila de $\mathbb{K}^{1 \times n}$ o bien como matrices columna de $\mathbb{K}^{n \times 1}$.

Fijamos ya esta identificación siguiendo el criterio universal (según el cual los operadores reciben sus argumentos por la derecha): los vectores se identifican con sus respectivas matrices columna.

$$v = \sum_{i=1}^n v_i \mathbf{e}_i = [v_1, v_2, \dots, v_n] = (v_1, v_2, \dots, v_n) = \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix},$$

de manera que $\mathbb{K}^{\mathbb{N}_n} = \mathbb{K}^n = \mathbb{K}^{n \times 1}$.

⚠ No se debe confundir el vector $[v_1, v_2, \dots, v_n] = (v_1, v_2, \dots, v_n)$, un tensor de orden uno, con la matriz fila $[[v_1, v_2, \dots, v_n]]$, un tensor de orden dos, que se representa en la notación de tabla rectangular como $[v_1 \ v_2 \ \dots \ v_n]$ (¡obsérvense los espacios, en lugar de las comas!).

Estas matrices fila se denominan *covectores*, un término que refleja su complementariedad con los vectores (matrices columna): mientras que unos representan estados o posiciones, los otros actúan sobre ellos, como veremos. Aunque en esta asignatura no desempeñarán un papel esencial, su distinción permite entender geometría del espacio. $\square$

Disponemos, entonces, de dos notaciones para las matrices: corchetes anidados (componentes separados por comas) y tablas rectangulares (componentes separados por espacios, nunca por comas).

Ejemplo 55. $A = [[1, 2, 3], [4, 5, 6]]$. Se abren dos corchetes $[[\dots]$, lo que indica que A es un tensor de orden 2 (una matriz: a_{ij}). Si miramos de fuera hacia dentro: la caja principal contiene dos listas y cada una de esas listas contiene tres componentes. Su formato es 2×3 , es decir, $A \in \mathbb{R}^{2 \times 3}$. Los componentes de A son $a_{11} = 1, a_{12} = 2, a_{21} = 4$, etc. Las matrices se pueden representar tipográficamente mediante tablas rectangulares en las que las componentes (celdas) está separados por espacios, ¡nunca por comas!

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$$

$\square$

Ejemplo 56. $b = [[10, 20, 30, 40]]$. Se abren dos corchetes: es de orden 2 (matriz). Dentro, hay una sola lista de 4 números, luego el formato es 1×4 . Es una matriz fila o covector (el primer eje está degenerado), $b \in \mathbb{R}^{1 \times 4}$,

$$b = [10 \ 20 \ 30 \ 40]$$

$\square$

Ejemplo 57. $u = [[10], [20], [30], [40]]$. Se abren dos corchetes: es de orden 2 (matriz). Dentro, vemos 4 listas con un número cada una, luego el formato es 4×1 . Se trata de una

matriz columna (el segundo eje está degenerado), $u \in \mathbb{R}^{4 \times 1}$,

$$u = \begin{bmatrix} 10 \\ 20 \\ 30 \\ 40 \end{bmatrix}.$$

□

Ejemplo 58. $W = [[[9, 8], [\sqrt{7}, 6]], [[5, \pi], [3, 2]], [[1, 0], [1, 1]]]$. Se abren tres corchetes $[[[\dots]]$, por lo que se trata de un tensor de orden 3. El corchete exterior agrupa tres bloques; cada bloque es una matriz 2×2 :

$$W = [[[9, 8], [\sqrt{7}, 6]], [[5, \pi], [3, 2]], [[1, 0], [1, 1]]].$$

Por lo tanto, el formato de W es $3 \times 2 \times 2$, es decir, $W \in \mathbb{R}^{3 \times 2 \times 2}$. Se podría visualizar como tres matrices 2×2 convenientemente apiladas. Es habitual referirse a un tensor de este formato mediante w_{ijk} , de la misma manera que decimos «la función $f(x)$ » en vez de «la función f » (informalidad mucho más frecuente al tratar con sucesiones). □

Ejemplo 59. $x = [\sqrt{3}]$. Se abre un solo corchete: es un tensor de orden 1. El único eje o índice tiene tamaño 1 (está degenerado), luego $[\sqrt{3}] \in \mathbb{R}^1$. Recordemos que hemos convenido en identificar $\sqrt{3} = [\sqrt{3}]$, de manera que $\mathbb{R} = \mathbb{R}^1$, así que $x = [\sqrt{3}]$ es solo una manera de poner $x = \sqrt{3}$; □

Ejemplo 60. $x = [[\sqrt{3}]]$. Se abren dos corchetes: es un tensor de orden 2 (una matriz). Dentro, vemos un tensor de orden 1, luego $x \in \mathbb{R}^{1 \times 1}$ (los dos ejes están degenerados). Hemos convenido en identificar $\sqrt{3} = [[\sqrt{3}]]$, de manera que $\mathbb{R} = \mathbb{R}^{1 \times 1}$. Esta identificación desempeñará un importante papel más adelante, al multiplicar matrices, por ejemplo. ¡Atención! porque estos matices de notación pueden ser cruciales al programar (no siempre se establecen las mismas identificaciones). □

Ejemplo 61. $A = [[i, 0, 0], [1, -i, 0], [1, -i, 0]]$. Se abren dos corchetes: es un tensor de orden 2: en concreto, una matriz 3×3 con las componentes complejas: $A \in \mathbb{C}^{3 \times 3}$,

$$A = \begin{bmatrix} i & 0 & 0 \\ 1 & -i & 0 \\ 1 & -i & 0 \end{bmatrix}.$$

En el tema anterior se ha establecido una inclusión canónica de $\mathbb{R}$ en $\mathbb{C}$, de forma que $\mathbb{R} \subset \mathbb{C}$. En consecuencia, tenemos también $\mathbb{R}^{\mathcal{I}} \subset \mathbb{C}^{\mathcal{I}}$, para cualquier formato $\mathcal{I}$. □

2.4. Construcción de matrices por bloques o cajas

Podemos flexibilizar la notación de los corchetes anidados para definir nuevas matrices mediante *concatenación*. Por ejemplo, si $A = [[4, 0, 1], [3, 2, 6]] \in \mathbb{R}^{2 \times 3}$ y $B = [[3, 0], [7, 1]] \in \mathbb{R}^{2 \times 2}$, la matriz $C = [[A, B]] \in \mathbb{R}^{2 \times 5}$ sería:

$$A = \begin{bmatrix} 4 & 0 & 1 \\ 3 & 2 & 6 \end{bmatrix}, B = \begin{bmatrix} 3 & 0 \\ 7 & 1 \end{bmatrix} \rightarrow C = [A \ B] = \begin{bmatrix} 4 & 0 & 1 & 3 & 0 \\ 3 & 2 & 6 & 7 & 1 \end{bmatrix}.$$

También podemos concatenar verticalmente, si los formatos son compatibles. Por ejemplo, si $D = [9, 9, 2] \in \mathbb{R}^{1 \times 3}$, podríamos formar la siguiente matriz $E = [[A], [D]] \in \mathbb{R}^{3 \times 3}$:

$$A = \begin{bmatrix} 4 & 0 & 1 \\ 3 & 2 & 6 \end{bmatrix}, D = [9 \ 9 \ 2] \rightarrow E = \begin{bmatrix} A \\ D \end{bmatrix} = \begin{bmatrix} 4 & 0 & 1 \\ 3 & 2 & 6 \\ 9 & 9 & 2 \end{bmatrix}.$$

Se pueden aplicar las dos concatenaciones simultáneamente. Si $F = [[7], [8]] \in \mathbb{R}^{2 \times 1}$, la matriz $G = [[A, F], [D, 0]] \in \mathbb{R}^{3 \times 4}$ correspondería a:

$$A = \begin{bmatrix} 4 & 0 & 1 \\ 3 & 2 & 6 \end{bmatrix}, D = [9 \ 9 \ 2], F = \begin{bmatrix} 7 \\ 8 \end{bmatrix} \rightarrow G = \begin{bmatrix} A & F \\ D & 0 \end{bmatrix} = \begin{bmatrix} 4 & 0 & 1 & 7 \\ 3 & 2 & 6 & 8 \\ 9 & 9 & 2 & 0 \end{bmatrix}.$$

Aplicación a la informática. No siempre disfrutaremos de la coincidencia entre la sintaxis algebraica y la informática. Es inevitable que sean diferentes, pero, en esta ocasión, la correspondencia es cercana. Es la misma lógica que utiliza la librería fundamental de IA, NumPy, a través de su función `np.block()`. Para construir la matriz por bloques $G = [[A, F], [D, 0]]$ de antes, escribiríamos: `G = np.block([[A, F], [D, 0]])`. $\square$

Al definir una matriz por bloques, no siempre se indican explícitamente los formatos de cada bloque: para aligerar la presentación, se omiten los formatos redundantes. Por ejemplo, si $A \in \mathbb{K}^{n \times m}$, $D \in \mathbb{K}^{k \times r}$, se aprecia sin necesidad de señalarlo explícitamente que la matriz por bloques:

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix}$$

tiene formato $(n + k) \times (m + r)$, así como que $C \in \mathbb{K}^{k \times m}$ y $B \in \mathbb{K}^{n \times r}$.

 Es importante no confundir la concatenación (*concatenation* en inglés) con el *apilamiento* (*stacking* en inglés). Mientras que concatenar una matrices a lo largo de una dimensión existente (haciendo la matriz más ancha o más larga), el apilamiento añade un nuevo eje. Por ejemplo, si apilamos tres matrices de 2×5 , no obtenemos una matriz grande, sino un tensor de tres dimensiones de tamaño $3 \times 2 \times 5$ (como un «cubo» de datos).

En la literatura matemática avanzada, esto se suele denotar indexando las componentes mediante superíndices, formando una familia de matrices. En la librería NumPy de Python, por ejemplo, esta operación se realiza con la función `np.stack()`. $\square$

Hay que señalar que una misma matriz se puede representar por bloques de muchas maneras diferentes. Por ejemplo, si $A \in \mathbb{K}^{n \times m}$ es una matriz arbitraria y $k \leq \min\{n, m\}$, podemos considerar la submatriz cuadrada $A_k = (a_{ij})_{1 \leq i, j \leq k}$, que se denomina *submatriz principal líder* de formato $k \times k$ o simplemente *submatriz principal*, si se sobrentiende que está colocada en la esquina superior izquierda de A .

La matriz A se puede representar de la siguiente manera para cualquier $k < \min\{n, m\}$:

$$A = \begin{bmatrix} A_k & B_k \\ C_k & D_k \end{bmatrix},$$

en donde $A_k \in \mathbb{K}^{k \times k}$, $B_k \in \mathbb{K}^{k \times (m-k)}$, $C_k \in \mathbb{K}^{(n-k) \times k}$ y $D_k \in \mathbb{K}^{(n-k) \times (m-k)}$.

2.5. Transposición de ejes. Matriz transpuesta

Una operación básica para reorganizar tensores es la de transponer su índices: el resultado de intercambiar los ejes p -ésimo y q -ésimo en un tensor de r ejes $A = a_{k_1 \dots k_p \dots k_q \dots k_r}$ de formato $n_1 \times \dots \times n_p \times \dots \times n_q \times \dots \times n_r$ es otro tensor $A^{(p,q)} = a_{k_1 \dots k_q \dots k_p \dots k_r}$ con formato $n_1 \times \dots \times n_q \times \dots \times n_p \times \dots \times n_r$.

El caso más importante, con mucha diferencia, es el de las matrices. Como las matrices solo tienen dos ejes, no es necesario indicar qué índices se transponen: si $A \in \mathbb{K}^{n \times m}$, su transpuesta es la matriz $A^T = A^{(1,2)} \in \mathbb{K}^{m \times n}$ resultado de intercambiar filas y columnas:

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nm} \end{bmatrix} \mapsto A^T = \begin{bmatrix} a_{11} & a_{21} & \cdots & a_{n1} \\ a_{12} & a_{22} & \cdots & a_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1m} & a_{2m} & \cdots & a_{nm} \end{bmatrix}.$$

Aunque en la mayor parte de las aplicaciones se trabaja con el campo de escalares $\mathbb{K} = \mathbb{R}$, no hay ningún motivo para limitar al caso real el alcance de la exposición, cuando su generalización al campo complejo no presente dificultades añadidas.

Por ese motivo, denotamos por $A^\top = \overline{A^T} \in \mathbb{K}^{m \times n}$ a la *transpuesta conjugada* de la

matriz $A \in \mathbb{K}^{n \times m}$, es decir

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nm} \end{bmatrix} \mapsto A^\top = \begin{bmatrix} \overline{a_{11}} & \overline{a_{21}} & \cdots & \overline{a_{n1}} \\ \overline{a_{12}} & \overline{a_{22}} & \cdots & \overline{a_{n2}} \\ \vdots & \vdots & \ddots & \vdots \\ \overline{a_{1m}} & \overline{a_{2m}} & \cdots & \overline{a_{nm}} \end{bmatrix},$$

en donde $\overline{a_{kj}} = \alpha_{kj} - i\beta_{kj}$ es el conjugado del complejo $a_{kj} = \alpha_{kj} + i\beta_{kj}$.

⚠ Cuando A es una matriz real, $A \in \mathbb{R}^{n \times m}$, la transpuesta coincide con la transpuesta conjugada, $A^\top = A^T$, pues todo número real coincide con su conjugado. $\square$

Notación y terminología. Algunas notaciones usuales para el operador de transposición-conjugación (*transpuesta hermítica*) $A \rightarrow \overline{A^T}$ son A^* , A^H , $A^\dagger$ y A^+ , entre otras.

La primera puede generar confusión, porque algunos textos emplean el asterisco para denotar la conjugación, mientras que las dos últimas se confunden con la empleada para la pseudoinversa, como veremos.

Preferimos utilizar $A^\top = \overline{A^T}$ en vez de $A^H = \overline{A^T}$, porque la mayor parte de las aplicaciones se dan en el campo real, donde $A^\top = A^T$ y la notación $A^\top$ sugiere «algo relacionado con transposición», lo que, a nuestro juicio, puede facilitar la lectura.

De esta manera, cuando $A \in \mathbb{R}^{n \times m}$, emplearemos $A^\top$ en vez de la notación equivalente A^T ; en cambio, cuando $A \in \mathbb{C}^{n \times m}$, distinguiremos entre la transpuesta A^T y la transpuesta conjugada $A^\top$, siendo esta última de uso mucho más frecuente. $\square$

Ejemplo 62. Consideremos las matrices.

$$A = \begin{bmatrix} 1 & 2 & 0 \\ 8 & -1 & 3 \\ 5 & 6 & 7 \end{bmatrix}; \quad B = \begin{bmatrix} i & 2 & 1+i \\ -2i & -1+3i & 0 \\ 6 & 7 & 8 \end{bmatrix},$$

se tiene:

$$A^\top = A^T = \begin{bmatrix} 1 & 8 & 5 \\ 2 & -1 & 6 \\ 0 & 3 & 7 \end{bmatrix}; \quad B^T = \begin{bmatrix} i & -2i & 6 \\ 2 & -1+3i & 7 \\ 1+i & 0 & 8 \end{bmatrix}; \quad B^\top = \begin{bmatrix} -i & 2i & 6 \\ 2 & -1-3i & 7 \\ 1-i & 0 & 8 \end{bmatrix}.$$

$\square$

Se satisface la siguiente propiedad fundamental:

$$(\alpha A + \beta B)^\top = \overline{\alpha} A^\top + \overline{\beta} B^\top, \text{ para todos } \alpha, \beta \in \mathbb{K}, A, B \in \mathbb{K}^{n \times m}.$$

La comprobación es muy sencilla: basta observar que da lo mismo sumar primero y transponer después, que transponer primero las dos matrices y sumarlas después. Igual para el

producto por escalares. Veamos la justificación empleando índices:

$$\begin{aligned}(c_{kj}) &= (\alpha(a_{kj}) + \beta(b_{kj}))^\top \implies c_{jk} = \overline{\alpha a_{kj}} + \overline{\beta b_{kj}} \\ \implies c_{jk} &= \overline{\alpha} \overline{a_{jk}} + \overline{\beta} \overline{b_{jk}} \implies (c_{kj}) = \overline{\alpha} (a_{kj})^\top + \overline{\beta} (b_{kj})^\top.\end{aligned}$$

Decimos que un tensor es *cuadrado* si todos sus ejes tienen el mismo tamaño, es decir, si su formato es $\mathcal{I} = n \times \overset{(r)}{\cdots} \times n$, para ciertos $n, r \in \mathbb{N}$.

Un tensor cuadrado de r ejes, $A \in \mathbb{K}^{\mathcal{I}}$, con $\mathcal{I} = n \times \overset{(r)}{\cdots} \times n$, se denomina *simétrico* si $A^{(p,q)} = A$ para todos los ejes $1 \leq p < q \leq r$. Se dice que A es *antisimétrico* si $A^{(p,q)} = -A$ para todos los ejes $1 \leq p < q \leq r$.

En particular, decimos que una matriz cuadrada $A \in \mathbb{K}^{n \times n}$ (en las matrices, el número de ejes es $r = 2$) es *simétrica* si $A^T = A$ y decimos que es *antisimétrica*, si $A^T = -A$.

Por lo tanto, A es simétrica si y solo si $a_{ij} = a_{ji}$ para todos $1 \leq i, j \leq n$.

Análogamente, A es antisimétrica si y solo si $a_{ij} = -a_{ji}$ para todos $1 \leq i, j \leq n$, lo que implica $a_{ii} = 0$ para todo $1 \leq i \leq n$.

Decimos que $A \in \mathbb{K}^{n \times n}$ es *hermítica* si $A^\top = A$ y que es *antihermítica*, si $A^\top = -A$.

⚠ Si A es una matriz real, $A \in \mathbb{R}^{n \times n}$, los términos «simétrica» y «hermítica» coinciden y se utiliza el primero. Análogamente, los adjetivos «antisimétrica» y «antihermítica» significan lo mismo cuando se aplican a matrices reales y se emplea el primero. $\square$

Ejemplo 63. El *tensor de Levi-Civita* de formato $3 \times 3 \times 3$ se presenta mediante la notación de corchetes anidados como

$$H = [[[0, 0, 0], [0, 0, 1], [0, -1, 0]], [[0, 0, -1], [0, 0, 0], [1, 0, 0]], [[0, 1, 0], [-1, 0, 0], [0, 0, 0]]].$$

Es un poco pesado verificarlo directamente, pero se trata de un tensor antisimétrico, pues $H_{ijk} = -H_{jik} = -H_{ikj} = -H_{kji}$, para todos $i, j, k \in \{1, 2, 3\}$.

Obsérvese cómo funciona la notación de subíndices libres:

$$H = H_{ijk}, \quad H^{(1,2)} = H_{jik}, \quad H^{(2,3)} = H_{ikj}, \quad H^{(1,3)} = H_{kji}.$$

Una manera de comprobar visualmente la antisimetría consiste en *desplegar* el tensor a lo largo de cada uno de sus tres ejes:

Despliegue a lo largo del primer eje:

$$H_{1jk} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & -1 & 0 \end{bmatrix}, \quad H_{2jk} = \begin{bmatrix} 0 & 0 & -1 \\ 0 & 0 & 0 \\ 1 & 0 & 0 \end{bmatrix}, \quad H_{3jk} = \begin{bmatrix} 0 & 1 & 0 \\ -1 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}.$$

Despliegue a lo largo del segundo eje:

$$H_{i1k} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & -1 \\ 0 & 1 & 0 \end{bmatrix}, \quad H_{i2k} = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 0 & 0 \\ -1 & 0 & 0 \end{bmatrix}, \quad H_{i3k} = \begin{bmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}.$$

Despliegue a lo largo del tercer eje:

$$H_{ij1} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & -1 & 0 \end{bmatrix}, \quad H_{ij2} = \begin{bmatrix} 0 & 0 & -1 \\ 0 & 0 & 0 \\ 1 & 0 & 0 \end{bmatrix}, \quad H_{ij3} = \begin{bmatrix} 0 & 1 & 0 \\ -1 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}.$$

Observamos que las nueve matrices 3×3 son antisimétricas. □

2.6. Algunas matrices importantes

- Un matriz $n \times m$ genérica se desarrollaría así en la presentación como tabla:

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nm} \end{bmatrix}.$$

Los elementos a_{ii} , con $1 \leq i \leq \min\{n, m\}$, forman su *diagonal principal*, a la que denominamos simplemente *diagonal*, cuando no haya lugar a confusión.

- Decíamos que un tensor era cuadrado si todos sus ejes tenían el mismo tamaño. En particular, una matriz es *cuadrada* si sus dos ejes tienen el mismo tamaño, es decir, si su formato es $n \times n$:

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}.$$

Decimos que una matriz es *rectangular* para enfatizar que no es necesariamente cuadrada. En ocasiones se emplea el término «rectangular» en un sentido excluyente: señalando que la matriz no es cuadrada ($m \neq n$).

Si A tiene más filas que columnas, $m > n$, decimos que la matriz es *alta*, Cuando $m < n$, se dice que la matriz A es *ancha*

- La *matriz nula* de formato $n \times m$ es la que tiene todas las componentes iguales a

cero, $a_{ij} = 0$ para $1 \leq i \leq n, 1 \leq j \leq m$:

$$\mathbf{0}_{n \times m} = \begin{bmatrix} 0 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 0 \end{bmatrix}.$$

Cuando el formato se sobrentienda por el contexto, pondremos $\mathbf{0}$ en vez de $\mathbf{0}_{n \times m}$.

- La *matriz de unos* de formato $n \times m$ es la que tiene todas las componentes iguales a uno, $a_{ij} = 1$ para $1 \leq i \leq n, 1 \leq j \leq m$:

$$\mathbf{1}_{n \times m} = \begin{bmatrix} 1 & \cdots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \cdots & 1 \end{bmatrix}.$$

Cuando el formato se sobrentienda por el contexto, pondremos $\mathbf{1}$ en vez de $\mathbf{1}_{n \times m}$.

- Una matriz cuadrada D es *diagonal* si verifica $d_{ij} = 0$ para todos $i \neq j$:

$$D = \text{diag}(d_{11}, \dots, d_{nn}) = \begin{bmatrix} d_{11} & 0 & \cdots & 0 \\ 0 & d_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_{nn} \end{bmatrix}.$$

En general, si $\mathbf{a} \in \mathbb{K}^n$ es un vector, $\text{diag}(\mathbf{a}) \in \mathbb{K}^{n \times n}$ es la matriz diagonal:

$$\text{diag}(\mathbf{a}) = \begin{bmatrix} a_1 & 0 & \cdots & 0 \\ 0 & a_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_n \end{bmatrix}.$$

- Decimos que una matriz cuadrada $A \in \mathbb{K}^{n \times n}$ es *diagonal por bloques* si existen $k > 1$ matrices cuadradas $A_i \in \mathbb{K}^{n_i \times n_i}$ tales que:

$$A = \text{diag}(A_1, \dots, A_k) = \begin{bmatrix} A_1 & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & A_2 & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & A_k \end{bmatrix},$$

en donde $n_1 + n_2 + \cdots + n_k = n$. En la expresión anterior, los bloques se pueden escoger de manera que las matrices A_i no sean, a su vez, diagonales por bloques.

Ejemplo 64. La siguiente matriz no es diagonal, pero sí es diagonal por bloques:

$$A = \begin{bmatrix} 1 & 2 & 0 & 0 & 0 & 0 \\ 3 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 5 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 2 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 2 \end{bmatrix},$$

pues $A = \text{diag}(A_1, A_2, A_3)$ para

$$A_1 = \begin{bmatrix} 1 & 2 \\ 3 & 1 \end{bmatrix} \quad ; \quad A_2 = [5] \quad ; \quad A_3 = \begin{bmatrix} 1 & 0 & 2 \\ 0 & 1 & 0 \\ 0 & 0 & 2 \end{bmatrix}.$$

□

En general, se comprueba que $(\text{diag}(A_1, \dots, A_k))^T = \text{diag}(A_1^T, \dots, A_k^T)$, es decir

$$\begin{bmatrix} A_1 & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & A_2 & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & A_k \end{bmatrix}^T = \begin{bmatrix} A_1^T & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & A_2^T & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & A_k^T \end{bmatrix}.$$

- La matriz diagonal $I_n \in \mathbb{R}^{n \times n}$ que tiene unos en su diagonal se denomina *matriz identidad* de tamaño n :

$$I_n = \text{diag}(\mathbf{1}_n) = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix}.$$

Cuando el tamaño se sobreentienda por el contexto, pondremos I en vez de I_n .

- Se dice que una matriz A , no necesariamente cuadrada, es *diagonal-rectangular* si $a_{ij} = 0$ para todos $i \neq j$. Anteriormente, hemos denominado «diagonales» a las matrices que son cuadradas y diagonal-rectangulares.

Ejemplo 65. Las siguientes matrices son diagonal-rectangulares, pero no diagonales, ya que no son cuadradas:

$$\begin{bmatrix} 3 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 6 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} ; \quad \begin{bmatrix} 3 & 0 & 0 & 0 \\ 0 & -1 & 0 & 0 \\ 0 & 0 & 6 & 0 \end{bmatrix} ; \quad \begin{bmatrix} 3 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$



- Se denomina *matriz de permutación* al resultado de reordenar las columnas de la matriz identidad. Por ejemplo:

$$\begin{bmatrix} 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad y \quad \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}$$

son matrices de permutación de formato 4×4 .

- Los elementos básicos de $\mathbb{K}^n$ (ver pág. 59) forman una base de este espacio:

$$\begin{aligned} \mathbf{e}_1 &= (1, 0, \dots, 0) = [1, 0, \dots, 0] = [[1], [0], \dots, [0]] = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \\ \mathbf{e}_2 &= (0, 1, \dots, 0) = [0, 1, \dots, 0] = [[0], [1], \dots, [0]] = \begin{bmatrix} 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \\ &\dots \\ \mathbf{e}_n &= (0, \dots, 0, 1) = [0, \dots, 0, 1] = [[0], \dots, [0], [1]] = \begin{bmatrix} 0 \\ \vdots \\ 0 \\ 1 \end{bmatrix}. \end{aligned}$$

Cualquier vector $v \in \mathbb{K}^n$ se expresa como $v = \sum_{j=1}^m v_j \mathbf{e}_j$ (ver pág. 59).

- Los elementos básicos de $\mathbb{K}^{2 \times 2}$ (ver pág. 59) son:

$$\mathbf{e}_{11} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}; \mathbf{e}_{12} = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}; \mathbf{e}_{21} = \begin{bmatrix} 0 & 0 \\ 1 & 0 \end{bmatrix}; \mathbf{e}_{22} = \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}.$$

Toda matriz $A \in \mathbb{K}^{2 \times 2}$ se expresa como $A = \sum_{i,j=1}^2 a_{ij} \mathbf{e}_{ij}$. En general, una matriz $A \in \mathbb{K}^{n \times m}$ se representa como

$$A = \sum_{i=1}^n \sum_{j=1}^m a_{ij} \mathbf{e}_{ij}.$$

- **Matrices triangulares.** Una matriz cuadrada es *triangular superior* si todos los elementos por debajo de la diagonal principal son cero ($a_{ij} = 0$ para todo $i > j$).

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} & \dots & a_{1n} \\ 0 & a_{22} & a_{23} & \dots & a_{2n} \\ 0 & 0 & a_{33} & \dots & a_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & a_{nn} \end{bmatrix}$$

Una matriz cuadrada es *triangular inferior* si todos los elementos por encima de la diagonal principal son cero ($a_{ij} = 0$ para todo $i < j$).

$$\begin{bmatrix} a_{11} & 0 & 0 & \dots & 0 \\ a_{21} & a_{22} & 0 & \dots & 0 \\ a_{31} & a_{32} & a_{33} & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & a_{n3} & \dots & a_{nn} \end{bmatrix}$$

Una matriz triangular se denomina *unitriangular* (superior o inferior) si todos los elementos de su diagonal principal son iguales a 1, es decir, si $a_{ii} = 1$ para todo $i \in \{1, \dots, n\}$.

Decimos que una matriz unitriangular inferior $S \in \mathbb{K}^{n \times n}$ es *unitriangular inferior por bloques* si es de la forma

$$S = \begin{bmatrix} I_k & \mathbf{0} \\ A & I_{n-k} \end{bmatrix},$$

para algún $k < n$ y alguna matriz $A \in \mathbb{K}^{(n-k) \times k}$. En concreto, decimos que S es una matriz *unitriangular inferior con bloque A de k columnas*.

Asimismo, decimos que S está *concentrada* en alguna de las columnas de A , si todas las posiciones del resto de las columnas de A están ocupadas por ceros.

Por ejemplo, las siguientes matrices son unitriangulares inferiores por bloques:

$$S = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 2 & 3 & 6 & 1 & 0 \\ 4 & 1 & 5 & 0 & 1 \end{bmatrix} \quad ; \quad T = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 2 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 3 & 0 & 0 & 1 \end{bmatrix}.$$

En la matriz S , el bloque $A \in \mathbb{K}^{2 \times 3}$, con $k = 3$, es:

$$A = \begin{bmatrix} 2 & 3 & 6 \\ 4 & 1 & 5 \end{bmatrix},$$

mientras que en T , para $k = 2$, el bloque $A \in \mathbb{K}^{3 \times 2}$ es

$$A = \begin{bmatrix} 0 & 2 \\ 0 & 0 \\ 0 & 3 \end{bmatrix}.$$

La matriz unitriangular inferior T está concentrada en la segunda columna.

No todas las matrices unitriangulares son unitriangulares por bloques. Por ejemplo:

$$C = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 2 & 1 & 0 & 0 \\ 3 & 2 & 1 & 0 \\ 1 & 2 & 3 & 1 \end{bmatrix}$$

es unitriangular, pero no es unitriangular por bloques para ningún bloque A , es decir, no se puede expresar en la forma

$$S = \begin{bmatrix} I_k & \mathbf{0} \\ A & I_{3-k} \end{bmatrix},$$

para ningún valor de $k = 1, 2$.

Se definen análogamente las correspondientes matrices superiores (las transpuestas de las inferiores).

- **Matrices trapezoidales.** Una matriz $A \in \mathbb{R}^{m \times n}$ se dice *trapezoidal superior* si todos sus elementos por debajo de la diagonal principal son nulos; es decir, $a_{ij} = 0$ siempre que $i > j$.

Dependiendo de sus dimensiones, distinguimos dos configuraciones.

Matriz trapezoidal superior ancha, si $m < n$:

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} & \dots & a_{1m} & \dots & a_{1n} \\ 0 & a_{22} & a_{23} & \dots & a_{2m} & \dots & a_{2n} \\ 0 & 0 & a_{33} & \dots & a_{3m} & \dots & a_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots & & \vdots \\ 0 & 0 & 0 & \dots & a_{mm} & \dots & a_{mn} \end{bmatrix},$$

lo que se expresa mediante bloques como

$$A = \begin{bmatrix} U & B \end{bmatrix},$$

con $U \in \mathbb{K}^{m \times m}$ triangular superior y $B \in \mathbb{K}^{(n-m) \times m}$, una matriz arbitraria.

Matriz trapezoidal superior alta, si $m > n$:

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} & \dots & a_{1n} \\ 0 & a_{22} & a_{23} & \dots & a_{2n} \\ 0 & 0 & a_{33} & \dots & a_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & a_{nn} \\ \vdots & \vdots & \vdots & & \vdots \\ 0 & 0 & 0 & \dots & 0 \end{bmatrix},$$

lo que se expresa mediante bloques como

$$A = \begin{bmatrix} U \\ \mathbf{0} \end{bmatrix},$$

en donde $U \in \mathbb{K}^{n \times n}$ es triangular superior y $\mathbf{0}$ es la matriz nula $(m - n) \times n$.

Las matrices trapezoidales superiores que no son anchas ni altas son precisamente las triangulares superiores.

La terminología es análoga para las *matrices trapezoidales inferiores*. Una matriz es trapezoidal inferior si su transpuesta es trapezoidal superior.

⚠ Frecuentemente se denominan *triangulares* a las matrices que nosotros hemos llamado trapezoidales, sean o no cuadradas, de manera que, con esa terminología, nuestras matrices triangulares serían las cuadradas triangulares.

Por motivos puramente didácticos, preferimos marcar la diferencia entre «trapezoidal» y «triangular», aunque si aplicamos el adjetivo «triangular» a una matriz no cuadrada, querremos decir que es trapezoidal. □

- *Matrices escalonadas*. Se dice que una matriz trapezoidal superior es escalonada si la cadena de ceros con la que empieza cada fila no nula es más corta que la cadena de ceros con la que empieza la fila siguiente y, si una fila es nula, también lo es la siguiente. Por ejemplo, las matrices

$$A = \begin{bmatrix} 0 & 1 & 1 \\ 0 & 2 & 3 \\ 0 & 0 & 1 \end{bmatrix}, B = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, C = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix} \text{ y } D = \begin{bmatrix} 1 & 1 & 1 & 0 \\ 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 2 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

son trapezoidales (A , en particular, es triangular), pero solo B y C son escalonadas.

La forma escalonada de una matriz se conoce por sus siglas en inglés REF (*Row Echelon Form*).

Denominemos *pivote* de una fila de una matriz a la primera posición no nula de esa fila. Si una matriz escalonada tiene unos en todas las posiciones de pivote y, además, son nulas todas las posiciones por encima del pivote en cada columna, decimos que la matriz es *escalonada reducida* (RREF, *Reduced Row Echelon Form*).

Por ejemplo, la matriz C anterior es escalonada reducida, pero B no lo es, porque sobre el pivote de la segunda fila, $b_{23} = 3$, hay un elemento no nulo, $b_{13} = 1 \neq 0$.

Como veremos a lo largo del curso, las formas escalonada y escalonada reducida (sobre todo esta última) han ido perdiendo importancia tanto en el plano teórico como en el computacional, pero todavía es necesario saber reconocerlas.

2.7. Resumen de las identificaciones más importantes

II.2: Resumen de identificaciones

Los tensores que tienen todos sus ejes degenerados se identifican con los correspondientes escalares: $a = [a] = [[a]] = \dots$, para todo $a \in \mathbb{K}$, de manera que

$$\mathbb{K} = \mathbb{K}^1 = \mathbb{K}^{1 \times 1} = \dots = \mathbb{K}^{1 \times \dots \times 1}.$$

Se identifican las n -tuplas con los correspondientes vectores y matrices columna. Así, el vector $v = \sum_{j=1}^n v_j \mathbf{e}_j$ se puede expresar también como sigue:

$$v = (v_1, v_2, \dots, v_n) = [v_1, v_2, \dots, v_n] = [[v_1], [v_2], \dots, [v_n]] = \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix},$$

de manera que

$$\mathbb{K}^{\mathbb{N}_n} = \mathbb{K}^n = \mathbb{K}^{n \times 1}.$$

Un covector $w = [[w_1, \dots, w_n]] \in \mathbb{K}^{1 \times n}$ (matriz fila) se puede escribir como

$$w = \sum_{j=1}^n w_j \mathbf{e}_j^\top = \begin{bmatrix} w_1 & w_2 & \dots & w_n \end{bmatrix}.$$

Aquí, $\mathbf{e}_j^\top$ (transpuesta de $\mathbf{e}_j$) representa el elemento básico del formato $1 \times n$, mientras que $\mathbf{e}_j$ es el elemento básico del formato $n \times 1$.

Como vemos, tenemos dos tipos de notación para vectores y matrices: corchetes anidados (en línea, con la coma como separador) y la disposición tipográfica en tabla rectan-

gular (normalmente, en línea aparte y siempre con espacios como separadores). Además, disponemos de una tercera notación para los vectores, pues en esta asignatura los hemos identificado con las tuplas (entre paréntesis, con coma como separador).

Hay que prestar atención a la presencia de comas o espacios, pues, en la presentación como tabla (muy inadecuada para la programación) nunca se separan los elementos por comas, sino por espacios. En cambio, tanto en la notación de corchetes anidados, como en la de las tuplas (entre paréntesis), siempre se emplea la coma como separador.

Recordemos que no siempre se identifican vectores, tuplas y matrices columna. En determinados contextos, como en algunos lenguajes de programación, puede ser necesario distinguirlos.

2.8. ¿Qué es un vector?

Es habitual definir el término «vector» como un elemento cualquiera de un espacio vectorial. Aunque es un criterio formalmente correcto, resulta excesivamente laxo en nuestro contexto educativo: bajo esa definición, los números, las matrices, las funciones, los operadores y prácticamente cualquier objeto matemático serían vectores. Asegurar a estas alturas que un campo escalar es un «vector», por ejemplo, solo serviría para incrementar de forma artificial la dificultad de una materia.

Históricamente, el término «vector» (del latín *vector*, «el que conduce» o «el que transporta») procede de Hamilton, quien lo utilizó para designar lo que llamó la «parte vectorial», en oposición a la «parte escalar» de un cuaternión. La notación $\mathbf{i}, \mathbf{j}, \mathbf{k}$, que sigue empleándose en varias áreas de la física y la ingeniería para denotar vectores, es una huella directa de este origen.

Por su parte, la primera axiomatización del concepto de espacio vectorial suele atribuirse a Giuseppe Peano. Curiosamente, su propuesta no tuvo repercusión inmediata en la comunidad científica, hasta que el concepto fue redescubierto de forma independiente por matemáticos de la talla de Weyl, Banach, Hahn o Wiener. A lo largo de su carrera, el propio Peano abordó los vectores desde distintos enfoques: primero los consideró como tuplas (sin llamarlos «vectores»); después, como segmentos dirigidos; y, por último, proporcionó la axiomatización de lo que denominó «sistemas lineales», que se corresponde exactamente con nuestros actuales espacios vectoriales.

En la práctica, el uso del término «vector» depende estrechamente del contexto. En un desarrollo matemático concreto, se suelen fijar ciertos espacios vectoriales principales a cuyos elementos llamamos vectores, mientras que a los elementos de otros espacios

vectoriales involucrados en el mismo razonamiento se les asigna su nombre específico (como matrices o funciones) para evitar confusiones.

Por esta razón, en esta asignatura reservaremos la palabra «vector» estrictamente para los tensores de primer orden, identificados con las tuplas y las matrices columna. En este sentido, el término *espacio lineal* resulta, además de preciso, mucho más claro y menos propenso a malentendidos que el sinónimo *espacio vectorial*.

Asimismo, prescindiremos de la distinción formal entre *puntos* y *vectores*. En este contexto, unos y otros representan distintas interpretaciones de los elementos del espacio de coordenadas $\mathbb{R}^n$, es decir, de simples n -tuplas. Visualizaremos los puntos como posiciones en el espacio y los vectores como direcciones.

3. OPERACIONES CON TENSORES

3.1. Combinaciones lineales de tensores

Como se ha anticipado en la sección II.1, el espacio funcional $\mathbb{K}^I$ posee de forma implícita una estructura de espacio lineal (o vectorial) para cualquier conjunto de índices I . Esto es posible gracias a que las operaciones de adición y producto por escalares se heredan directamente del campo de escalares base.

Los tensores representan el caso particular en el que el conjunto de índices es un formato, es decir, $I = \mathcal{I}$ (ver pág. 66). Por lo tanto, el conjunto de tensores $\mathbb{K}^{\mathcal{I}}$ de formato $\mathcal{I}$ constituye un espacio lineal. Por este motivo, en adelante nos referiremos a $\mathbb{K}^{\mathcal{I}}$ como «espacio de tensores», abandonando el término más genérico de «conjunto de tensores».

Dado que la estructura de espacio lineal ya está definida (mediante la suma de tensores del mismo formato y el producto de un tensor por un escalar), el objetivo de este apartado se centrará exclusivamente en ilustrar estos conceptos a través de ejemplos.

Ejemplo 66. Vamos a combinar linealmente los vectores $u = (1, 0, 0, 3), v = (3, 1, 1, 0) \in \mathbb{R}^4$ con pesos $\alpha = -2, \beta = 1$, respectivamente

$$\alpha u + \beta v = -2 \begin{bmatrix} 1 \\ 0 \\ 0 \\ 3 \end{bmatrix} + 1 \begin{bmatrix} 3 \\ 1 \\ 1 \\ 0 \end{bmatrix} = \begin{bmatrix} -2 \cdot 1 + 1 \cdot 3 \\ -2 \cdot 0 + 1 \cdot 1 \\ -2 \cdot 0 + 1 \cdot 1 \\ -2 \cdot 3 + 1 \cdot 0 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \\ -6 \end{bmatrix}.$$

Por lo tanto, $\alpha u + \beta v = (1, 1, 1, -6) \in \mathbb{R}^4$. □

Ejemplo 67. Consideremos los escalares $\alpha = 3$ y $\beta = -2$, y las matrices A y B de

formato 3×2 definidas como:

$$A = \begin{bmatrix} 1 & 2 \\ 0 & 3 \\ 1 & 1 \end{bmatrix}, \quad B = \begin{bmatrix} -2 & 1 \\ -1 & 0 \\ 0 & 2 \end{bmatrix}.$$

Para calcular la combinación lineal $\alpha A + \beta B$, procedemos en dos pasos:

$$\alpha A + \beta B = 3 \begin{bmatrix} 1 & 2 \\ 0 & 3 \\ 1 & 1 \end{bmatrix} + (-2) \begin{bmatrix} -2 & 1 \\ -1 & 0 \\ 0 & 2 \end{bmatrix} = \begin{bmatrix} 3 & 6 \\ 0 & 9 \\ 3 & 3 \end{bmatrix} + \begin{bmatrix} 4 & 2 \\ 2 & 0 \\ 0 & -4 \end{bmatrix} = \begin{bmatrix} 7 & 8 \\ 2 & 9 \\ 3 & -1 \end{bmatrix}.$$

□

Ejemplo 68. Consideremos los escalares $\alpha = 2$ y $\beta = 3$, junto con los tensores S y T de formato $2 \times 2 \times 3$ definidos en notación de corchetes anidados como sigue:

$$S = [[[1, 0], [1, 1]], [[0, 1], [0, 0]], [[1, 1], [0, 1]]]$$

$$T = [[[0, 1], [1, 0]], [[1, 1], [1, 0]], [[0, 0], [1, 1]]].$$

La combinación lineal $\alpha T_1 + \beta T_2$ se calcula operando directamente componente a componente, lo que resulta en el siguiente tensor de mismo formato $2 \times 2 \times 3$:

$$\alpha S + \beta T = [[[2, 3], [5, 2]], [[3, 5], [3, 0]], [[2, 2], [3, 5]]].$$

□

3.2. Producto de matrices

Para multiplicar dos matrices necesitamos que el número de columnas de la primera matriz coincida con el número de filas de segunda.

Si $A \in \mathbb{K}^{n \times k}$ y $B \in \mathbb{K}^{k \times m}$, definimos el *producto de matrices* $C = AB \in \mathbb{K}^{n \times m}$ por

$$c_{ij} = \sum_{s=1}^k a_{is} b_{sj}.$$

Ejemplo 69.

$$A = \begin{bmatrix} 1 & 0 & -2 & 3 \\ 2 & -1 & 4 & 0 \end{bmatrix} \in \mathbb{R}^{2 \times 4}, \quad B = \begin{bmatrix} 2 & 1 & 0 \\ -1 & 3 & 4 \\ 0 & -2 & 1 \\ 3 & 0 & -1 \end{bmatrix} \in \mathbb{R}^{4 \times 3}$$

$$AB = \begin{bmatrix} 1(2) + 0(-1) + (-2)(0) + 3(3) & 1(1) + 0(3) + (-2)(-2) + 3(0) & 1(0) + 0(4) + (-2)(1) + 3(-1) \\ 2(2) + (-1)(-1) + 4(0) + 0(3) & 2(1) + (-1)(3) + 4(-2) + 0(0) & 2(0) + (-1)(4) + 4(1) + 0(-1) \end{bmatrix}$$




Figura 13. Producto de matrices del ejemplo 69.

$$= \begin{bmatrix} 11 & 5 & -5 \\ 5 & -9 & 0 \end{bmatrix} \in \mathbb{R}^{2 \times 3}.$$

□

Ejemplo 70.

$$A = \begin{bmatrix} 2 & 1 & 3 \\ 4 & 5 & 1 \end{bmatrix} \in \mathbb{R}^{2 \times 3}, \quad B = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 2 & 1 \end{bmatrix} \in \mathbb{R}^{3 \times 2}$$

$$AB = \begin{bmatrix} 2 & 1 & 3 \\ 4 & 5 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 2 & 1 \end{bmatrix}$$

$$= \begin{bmatrix} 2(1) + 1(3) + 3(2) & 2(2) + 1(4) + 3(1) \\ 4(1) + 5(3) + 1(2) & 4(2) + 5(4) + 1(1) \end{bmatrix} = \begin{bmatrix} 11 & 11 \\ 21 & 29 \end{bmatrix} \in \mathbb{R}^{2 \times 2}$$

$$BA = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} 2 & 1 & 3 \\ 4 & 5 & 1 \end{bmatrix}$$

$$= \begin{bmatrix} 1(2) + 2(4) & 1(1) + 2(5) & 1(3) + 2(1) \\ 3(2) + 4(4) & 3(1) + 4(5) & 3(3) + 4(1) \\ 2(2) + 1(4) & 2(1) + 1(5) & 2(3) + 1(1) \end{bmatrix} = \begin{bmatrix} 10 & 11 & 5 \\ 22 & 23 & 13 \\ 8 & 7 & 7 \end{bmatrix} \in \mathbb{R}^{3 \times 3}.$$

□

Ejemplo 71.

$$a = \begin{bmatrix} 3 \\ -1 \\ 2 \end{bmatrix} \in \mathbb{R}^{3 \times 1}, \quad a^T = [3 \quad -1 \quad 2] \in \mathbb{R}^{1 \times 3}.$$

$$a^T a = [3 \quad -1 \quad 2] \begin{bmatrix} 3 \\ -1 \\ 2 \end{bmatrix} = [3(3) + (-1)(-1) + 2(2)] = [9 + 1 + 4] = [14] = 14.$$

$$aa^T = \begin{bmatrix} 3 \\ -1 \\ 2 \end{bmatrix} [3 \quad -1 \quad 2] = \begin{bmatrix} 3(3) & 3(-1) & 3(2) \\ -1(3) & -1(-1) & -1(2) \\ 2(3) & 2(-1) & 2(2) \end{bmatrix} = \begin{bmatrix} 9 & -3 & 6 \\ -3 & 1 & -2 \\ 6 & -2 & 4 \end{bmatrix} \in \mathbb{R}^{3 \times 3}.$$

□

Ejemplo 72.

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \in \mathbb{R}^{2 \times 2}, \quad B = \begin{bmatrix} 5 & 6 \\ 0 & 7 \end{bmatrix} \in \mathbb{R}^{2 \times 2}$$

$$AB = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} 5 & 6 \\ 0 & 7 \end{bmatrix} = \begin{bmatrix} 1(5) + 2(0) & 1(6) + 2(7) \\ 3(5) + 4(0) & 3(6) + 4(7) \end{bmatrix} = \begin{bmatrix} 5 & 20 \\ 15 & 46 \end{bmatrix} \in \mathbb{R}^{2 \times 2}$$

$$BA = \begin{bmatrix} 5 & 6 \\ 0 & 7 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 5(1) + 6(3) & 5(2) + 6(4) \\ 0(1) + 7(3) & 0(2) + 7(4) \end{bmatrix} = \begin{bmatrix} 23 & 34 \\ 21 & 28 \end{bmatrix} \in \mathbb{R}^{2 \times 2}.$$

□

Ejemplo 73. Las matrices de permutación (página 77) se llaman así porque su efecto al multiplicar desde la izquierda a otra matriz es reordenar las filas de esta. En efecto, si $P \in \mathbb{R}^{n \times n}$ es una matriz de permutación y $A \in \mathbb{R}^{n \times m}$, el producto resulta

$$B = PA = \begin{bmatrix} \mathbf{e}_{k_1}^T \\ \mathbf{e}_{k_2}^T \\ \vdots \\ \mathbf{e}_{k_n}^T \end{bmatrix} [\mathbf{a}_1 \quad \mathbf{a}_2 \quad \dots \quad \mathbf{a}_m] \implies b_{ij} = \mathbf{e}_{k_i}^T \mathbf{a}_j = a_{k_i j}.$$

Vemos que las filas del producto $B = PA$ quedan reordenadas exactamente igual que están reordenadas las filas de P respecto de las de la identidad I_n .

Un ejemplo numérico con $n = 4$ y $m = 3$:

$$B = PA = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \\ a_{41} & a_{42} & a_{43} \end{bmatrix} = \begin{bmatrix} a_{21} & a_{22} & a_{23} \\ a_{41} & a_{42} & a_{43} \\ a_{11} & a_{12} & a_{13} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}.$$

□

Identificar las componentes de una matriz parece una tarea trivial: para saber cuál es la componente a_{ij} de una matriz A , solo tenemos que recorrer con el dedo la fila i hasta llegar a la columna j . Sin embargo, esto no es tan fácil cuando la matriz tiene miles de filas y miles de columnas. Obtenemos expresiones casi evidentes para estas componentes multiplicando por los vectores de la base canónica.

II.3: Identificación de filas, columnas y componentes de una matriz

Las columnas de una matriz $A \in \mathbb{K}^{n \times m}$ se obtienen multiplicando desde derecha por los vectores de la base canónica:

$$A = [\mathbf{a}_1 \ \mathbf{a}_2 \ \dots \ \mathbf{a}_m] \iff \mathbf{a}_j = A\mathbf{e}_j, \text{ para } j = 1, \dots, m.$$

Las filas de A son las columnas de A^T , luego las filas de A se obtienen multiplicando desde derecha por los vectores de la base canónica:

$$A = \begin{bmatrix} \mathbf{f}_1^T \\ \mathbf{f}_2^T \\ \vdots \\ \mathbf{f}_n^T \end{bmatrix} \iff A^T = [\mathbf{f}_1 \ \mathbf{f}_2 \ \dots \ \mathbf{f}_n] \iff \mathbf{f}_i^T = \mathbf{e}_i^T A, \text{ para } i = 1, \dots, n.$$

Las componentes de la matriz se obtienen multiplicando desde los dos lados:

$$A = (a_{ij}) \iff a_{ij} = \mathbf{e}_i^T A \mathbf{e}_j, \text{ para } i = 1, \dots, n; j = 1, \dots, m.$$

3.3. Contracción de índices

El producto de matrices es un caso particular de contracción de un índice en un tensor: en este caso, tensores de orden 2 en los que se contrae el segundo eje del primer factor con el primero del segundo. Veamos cómo es esto.

Si nos limitáramos a considerar únicamente la estructura de espacio lineal en cada espacio de tensores del mismo formato (es decir, a realizar combinaciones lineales), no

estaríamos haciendo otra cosa que estudiar tuplas bajo una notación más compleja.

Por ejemplo, considerado como espacio lineal, el espacio de las matrices $\mathbb{K}^{4 \times 3}$ no deja de ser prácticamente lo mismo que $\mathbb{K}^{12}$ o que $\mathbb{K}^{2 \times 6}$. Todos estos espacios constan de 12 componentes organizadas de distinta manera, lo cual carece de trascendencia desde el punto de vista de la teoría de los espacios lineales (aunque sí la tenga desde la perspectiva del almacenamiento de datos).

Si los espacios de tensores (y, en particular, los de matrices) revisten tanta importancia para el álgebra, es porque en ellos se pueden definir operaciones como la contracción de índices (en particular, el producto de matrices).

Para poder operar mediante una contracción dos tensores, A y B (el primero, con p ejes no degenerados y el segundo, con q), el único requisito es encontrar un eje i en A que tenga el mismo tamaño que un eje j en B .

La operación consiste en fusionar ambos tensores a lo largo de esos dos ejes mediante una combinación lineal: cada componente del eje i de A se multiplica por su homóloga en el eje j de B , y se suman todos los productos resultantes.

Por ejemplo, si $p = 3$ y $q = 2$ y contraemos el segundo eje, $i = 2$, de A con el primero, $j = 1$, de B , saldría algo como $c_{rst} = \sum_{l=1}^n a_{rls} b_{lt}$.

Al efectuar la combinación, los dos ejes seleccionados desaparecen (se contraen). El tensor resultante, $\mathfrak{C}_{i,j}(A, B)$, hereda, en el mismo orden en que estaban, todos los ejes restantes de A seguidos de todos los ejes restantes de B , por lo que $\mathfrak{C}_{i,j}(A, B)$ tiene $p + q - 2$ ejes.

Ejemplo 74. Consideremos el tensor $A = [[[1, 2], [3, 4]], [[5, 6], [7, 8]]] \in \mathbb{R}^{2 \times 2 \times 2}$ y el vector $v = (1, 2) = [[1], [2]] \in \mathbb{R}^{2 \times 1}$. Tenemos, $p = 3, q = 1$ (el segundo eje de v está degenerado).

$$C = \mathfrak{C}_{3,1}(A, v) \dashrightarrow c_{rs} = \sum_{l=1}^2 a_{rsl} v_l$$

$$C = \mathfrak{C}_{3,1}(A, v) = \begin{bmatrix} 1(1) + 2(2) & 3(1) + 4(2) \\ 5(1) + 6(2) & 7(1) + 8(2) \end{bmatrix} = \begin{bmatrix} 1 + 4 & 3 + 8 \\ 5 + 12 & 7 + 16 \end{bmatrix} = \begin{bmatrix} 5 & 11 \\ 17 & 23 \end{bmatrix} \in \mathbb{R}^{2 \times 2}$$

$$D = \mathfrak{C}_{2,1}(A, v) \dashrightarrow d_{rs} = \sum_{l=1}^2 a_{rls} v_l$$

$$D = \mathfrak{C}_{2,1}(A, v) = \begin{bmatrix} 1(1) + 3(2) & 2(1) + 4(2) \\ 5(1) + 7(2) & 6(1) + 8(2) \end{bmatrix} = \begin{bmatrix} 1 + 6 & 2 + 8 \\ 5 + 14 & 6 + 16 \end{bmatrix} = \begin{bmatrix} 7 & 10 \\ 19 & 22 \end{bmatrix} \in \mathbb{R}^{2 \times 2}.$$

Observemos que $p + q - 2 = 2$, que es el número de ejes de C y de D . $\square$

El producto de matrices es un caso particular para $p = q = 2$: si $A \in \mathbb{K}^{n+k}$, $B \in \mathbb{K}^{k \times m}$ el producto corresponde $C = AB = \mathfrak{C}_{2,1}(A, B) \in \mathbb{K}^{n \times m}$, es decir, se fusiona el segundo eje de A con el primero de B , para obtener $c_{ij} = \sum_{s=1}^k a_{is}b_{sj}$.

Ejemplo 75. El *producto vectorial* de dos vectores $\mathbf{u}, \mathbf{v} \in \mathbb{R}^3$, se define por

$$\mathbf{u} \times \mathbf{v} = \mathfrak{C}_{2,1}(\mathfrak{C}_{2,1}(H, \mathbf{u}), \mathbf{v})$$

en donde $H \in \mathbb{R}^{3 \times 3 \times 3}$ es el *tensor de Levi-Civita* (página 73):

$$H = [[[0, 0, 0], [0, 0, 1], [0, -1, 0]], [[0, 0, -1], [0, 0, 0], [1, 0, 0]], [[0, 1, 0], [-1, 0, 0], [0, 0, 0]]].$$

Si ponemos $A = \mathfrak{C}_{2,1}(H, \mathbf{u})$, de manera que $a_{ik} = \sum_{s=1}^3 h_{isk}u_s$, el producto vectorial $\mathbf{w} = \mathbf{u} \times \mathbf{v} = \mathfrak{C}_{2,1}(A, \mathbf{v})$, queda

$$w_i = \sum_{t=1}^3 a_{it}v_t = \sum_{t=1}^3 \sum_{s=1}^3 h_{ist}u_s v_t \implies \begin{cases} w_1 = u_2v_3 - u_3v_2, \\ w_2 = u_3v_1 - u_1v_3, \\ w_3 = u_1v_2 - u_2v_1. \end{cases}$$

Se emplea el mismo símbolo $\times$ que para el producto cartesiano, pero es imposible que la coincidencia provoque confusión. $\square$

Aplicación a la informática. Aunque este manual se dedica al álgebra y no a la programación, aprovechamos para señalar que la función matemática *suma de Einstein* de las librerías NumPy, PyTorch y TensorFlow de Python, proporciona un procedimiento práctico y elegante de referirse a la contracción de índices, incluso considerando composiciones de varias funciones del tipo $\mathfrak{C}_{i,j}(A, B)$ y, también, transposiciones de ejes. La sintaxis básica sería:

`einsum('índices  $A_1$ , índices  $A_2, \dots \rightarrow$  índices resultado',  $A_1, A_2, \dots$ )`
de acuerdo con las siguientes reglas:

1. Cualquier letra que aparezca en el lado de la entrada pero no aparezca en el lado de la salida, se va a contraer (se colapsa esa dimensión). La instrucción permite hacer varias contracciones de una vez, es decir, contraer varias dimensiones (precisamente las correspondientes a los índices que se repiten en las entradas). Los índices no tienen por qué repetirse, aunque es lo más normal.

Por ejemplo, `np.einsum('ij->i', A)` suma las filas de la matriz A .

2. El orden de las letras tras la flecha dictará el orden de los ejes del tensor resultante. $\square$

Ejemplo 76. Para la multiplicación de matrices de cualquier formato sería

$$AB = \mathfrak{C}_{2,1}(A, B) \rightarrow \text{np.einsum('ik, kj->ij', A, B)}.$$

$\square$

Ejemplo 77. Para la transposición de una matriz cualquiera

$$A^T \rightarrow \text{np.einsum}('ij \rightarrow ji', A).$$

□

Ejemplo 78. Si $A \in \mathbb{R}^{n \times n}$, $u \in \mathbb{R}^n = \mathbb{R}^{n \times 1}$, obtendríamos

$$Au \rightarrow \text{np.einsum}('ik, k \rightarrow i', A, u),$$

mientras que

$$u^T A \rightarrow \text{np.einsum}('ik, i \rightarrow k', A, u).$$

□

Ejemplo 79. Pueden participar varios tensores: si $A \in \mathbb{R}^{2 \times 3}$, $B \in \mathbb{R}^{3 \times 4}$, $C \in \mathbb{R}^{4 \times 5}$, entonces el producto ABC correspondería a

$$\mathfrak{C}_{2,1}(\mathfrak{C}_{2,1}(A, B), C) \in \mathbb{R}^{2 \times 5} \rightarrow \text{np.einsum}('ij, jk, kl \rightarrow il', A, B, C). \quad \square$$

Ejemplo 80. El producto vectorial del ejemplo 75 dispone de sus propia función en Python, pero también puede hacerse mediante `einsum`:

$$u \times v \rightarrow \text{np.einsum}('ijk, j, k \rightarrow i', \text{epsilon}, u, v)$$

en donde se ha llamado `epsilon` al tensor E del ejemplo 75.

□

3.4. Multiplicación por bloques

Aunque es fácil deducirlo a partir de la definición del producto de matrices, no siempre se presta la necesaria atención al hecho de que el producto da el mismo resultado al efectuarse por bloques compatibles.

Ejemplo 81. Por ejemplo, si $A \in \mathbb{K}^{n \times m}$, $D \in \mathbb{K}^{k \times r}$, $E \in \mathbb{K}^{m \times s}$ y $H \in \mathbb{K}^{r \times t}$, entonces

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix} \begin{bmatrix} E & F \\ G & H \end{bmatrix} = \begin{bmatrix} AE + BG & AF + BH \\ CE + DG & CF + DH \end{bmatrix}$$

es la multiplicación de una matriz $(n+k) \times (m+r)$ por otra de formato $(m+r) \times (s+t)$, obteniéndose una matriz $(n+k) \times (s+t)$. □

Ejemplo 82. A continuación se muestra un ejemplo numérico de multiplicación por bloques. Para $n = 1$, $m = 2$, $k = 3$, $r = 1$, $s = 2$ y $t = 3$, consideramos los bloques:

$$A = \begin{bmatrix} 1 & 0 \end{bmatrix}, \quad B = \begin{bmatrix} 2 \end{bmatrix}, \quad C = \begin{bmatrix} 0 & 0 \\ 3 & 1 \\ 0 & 0 \end{bmatrix}, \quad D = \begin{bmatrix} 0 \\ 0 \\ 4 \end{bmatrix},$$

$$E = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}, \quad F = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 3 \end{bmatrix}, \quad G = \begin{bmatrix} 0 & 0 \end{bmatrix}, \quad H = \begin{bmatrix} 0 & 2 & 1 \end{bmatrix}.$$

El producto de las matrices completas (sin particionar) es:

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix} \begin{bmatrix} E & F \\ G & H \end{bmatrix} = \begin{bmatrix} 1 & 0 & 2 \\ 0 & 0 & 0 \\ 3 & 1 & 0 \\ 0 & 0 & 4 \end{bmatrix} \begin{bmatrix} 2 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 & 3 \\ 0 & 0 & 0 & 2 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 0 & 1 & 4 & 2 \\ 0 & 0 & 0 & 0 & 0 \\ 6 & 1 & 3 & 0 & 3 \\ 0 & 0 & 0 & 8 & 4 \end{bmatrix}.$$

Repitamos el cálculo, pero operando por bloques:

$$\begin{aligned} AE + BG &= \begin{bmatrix} 2 & 0 \end{bmatrix} + \begin{bmatrix} 0 & 0 \end{bmatrix} = \begin{bmatrix} 2 & 0 \end{bmatrix} \\ AF + BH &= \begin{bmatrix} 1 & 0 & 0 \end{bmatrix} + \begin{bmatrix} 0 & 4 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 4 & 2 \end{bmatrix}, \\ CE + DG &= \begin{bmatrix} 0 & 0 \\ 6 & 1 \\ 0 & 0 \end{bmatrix} + \begin{bmatrix} 0 & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 6 & 1 \\ 0 & 0 \end{bmatrix}, \\ CF + DH &= \begin{bmatrix} 0 & 0 & 0 \\ 3 & 0 & 3 \\ 0 & 0 & 0 \end{bmatrix} + \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 8 & 4 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ 3 & 0 & 3 \\ 0 & 8 & 4 \end{bmatrix}. \end{aligned}$$

Recomponemos la matriz 4×5 y comprobamos que se obtiene el mismo resultado:

$$\begin{bmatrix} AE + BG & AF + BH \\ CE + DG & CF + DH \end{bmatrix} = \begin{bmatrix} 2 & 0 & 1 & 4 & 2 \\ 0 & 0 & 0 & 0 & 0 \\ 6 & 1 & 3 & 0 & 3 \\ 0 & 0 & 0 & 8 & 4 \end{bmatrix}.$$

□

Al aplicar la multiplicación por bloques a una matriz numérica concreta, como en el ejemplo 82, no suelen apreciarse las ventajas del procedimiento. Sin embargo, muchas propiedades se razonan con mayor claridad operando por bloques con matrices genéricas.

Por ejemplo, si $A, B \in \mathbb{K}^{m \times k}$, $Q \in \mathbb{K}^{m \times m}$ verifica $QQ^\top = I_m$ y $L \in \mathbb{K}^{k \times k}$ es unitriangular inferior, entonces:

$$\begin{bmatrix} L & \mathbf{0} \\ B & I_m \end{bmatrix} \begin{bmatrix} I_k & \mathbf{0} \\ A & I_m \end{bmatrix} = \begin{bmatrix} L & \mathbf{0} \\ A + B & I_m \end{bmatrix}, \quad (7)$$

$$\begin{bmatrix} I_k & \mathbf{0} \\ A & I_m \end{bmatrix} \begin{bmatrix} I_k & \mathbf{0} \\ \mathbf{0} & Q \end{bmatrix} = \begin{bmatrix} I_k & \mathbf{0} \\ A & Q \end{bmatrix} = \begin{bmatrix} I_k & \mathbf{0} \\ \mathbf{0} & Q \end{bmatrix} \begin{bmatrix} I_k & \mathbf{0} \\ Q^\top A & I_m \end{bmatrix}. \quad (8)$$

$$\begin{bmatrix} I_k & \mathbf{0} \\ \mathbf{0} & Q \end{bmatrix} \begin{bmatrix} I_k & \mathbf{0} \\ A & I_m \end{bmatrix} = \begin{bmatrix} I_k & \mathbf{0} \\ QA & Q \end{bmatrix} = \begin{bmatrix} I_k & \mathbf{0} \\ QA & I_m \end{bmatrix} \begin{bmatrix} I_k & \mathbf{0} \\ \mathbf{0} & Q \end{bmatrix}. \quad (9)$$

En particular, considerando $L = I_k$ en (7), se comprueba que el producto de matrices unitriangulares con bloques A y B del mismo formato es también unitriangular inferior, con bloque $A + B$ de ese formato.

La expresión (7) puede servir también para multiplicar matrices unitriangulares por bloques de distinto formato. Si $s < k$, $t = m + k - s$ y $C \in \mathbb{K}^{s \times t}$, entonces:

$$\begin{bmatrix} I_s & \mathbf{0} \\ C & I_t \end{bmatrix} \begin{bmatrix} I_k & \mathbf{0} \\ A & I_m \end{bmatrix} = \begin{bmatrix} L & \mathbf{0} \\ B & I_m \end{bmatrix} \begin{bmatrix} I_k & \mathbf{0} \\ A & I_m \end{bmatrix} = \begin{bmatrix} L & \mathbf{0} \\ A + B & I_m \end{bmatrix}, \quad (10)$$

en donde:

$$C = \begin{bmatrix} C_1 \\ C_2 \end{bmatrix} \in \mathbb{K}^{t \times s}, \quad L = \begin{bmatrix} I_s & \mathbf{0} \\ C_1 & I_{k-s} \end{bmatrix} \in \mathbb{K}^{k \times k}, \quad B = [C_2 \quad \mathbf{0}_{k-s}] \in \mathbb{K}^{m \times k}.$$

Ejemplo 83. Veamos un ejemplo numérico:

$$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 3 & 1 & 0 \\ 0 & 5 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 4 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 3 & 1 & 0 \\ 0 & 5 & 4 & 1 \end{bmatrix}.$$

Aquí $k = 3$, $m = 1$, $s = t = 2$,

$$C = \begin{bmatrix} 0 & 3 \\ 0 & 5 \end{bmatrix}, \quad C_1 = [0 \quad 3], \quad C_2 = [0 \quad 5], \quad A = [0 \quad 0 \quad 4],$$

$$B = [0 \quad 5 \quad 0], \quad L = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 3 & 1 \end{bmatrix}.$$

□

Un caso particular de (8) surge cuando Q es una matriz de permutación, de modo que

$$P = \begin{bmatrix} I_k & \mathbf{0} \\ \mathbf{0} & Q \end{bmatrix} \quad (11)$$

es otra matriz de permutación, que deja fijas las k primeras filas cuando opera desde la izquierda. Hemos probado que multiplicar a P desde la izquierda por la matriz unitriangular con bloque A equivale a multiplicar a P desde la derecha por la matriz unitriangular con bloque $Q^T A$.

Obsérvese que el bloque $Q^T A$ tiene el mismo formato que A , solo que con las filas reordenadas.

Ejemplo 84. Comprobamos la igualdad (8) con un ejemplo numérico para $k = 2, m = 3$,

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix} \quad \text{y} \quad Q = \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix},$$

de manera que

$$Q^\top = \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \quad QQ^\top = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = I_3, \quad Q^\top A = \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix} = \begin{bmatrix} 3 & 4 \\ 1 & 2 \\ 5 & 6 \end{bmatrix}$$

El miembro izquierdo de la igualdad (8) es

$$\begin{bmatrix} I_2 & \mathbf{0} \\ A & I_3 \end{bmatrix} \begin{bmatrix} I_2 & \mathbf{0} \\ \mathbf{0} & Q \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 1 & 2 & 1 & 0 & 0 \\ 3 & 4 & 0 & 1 & 0 \\ 5 & 6 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 1 & 2 & 0 & 1 & 0 \\ 3 & 4 & 1 & 0 & 0 \\ 5 & 6 & 0 & 0 & 1 \end{bmatrix},$$

mientras que el derecho se calcula como:

$$\begin{bmatrix} I_2 & \mathbf{0} \\ \mathbf{0} & Q \end{bmatrix} \begin{bmatrix} I_2 & \mathbf{0} \\ Q^\top A & I_3 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 3 & 4 & 1 & 0 & 0 \\ 1 & 2 & 0 & 1 & 0 \\ 5 & 6 & 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 1 & 2 & 0 & 1 & 0 \\ 3 & 4 & 1 & 0 & 0 \\ 5 & 6 & 0 & 0 & 1 \end{bmatrix}.$$

□

Multiplicar una matriz $C \in \mathbb{K}^{r \times n}$ desde la izquierda por una matriz unitriangular $D \in \mathbb{K}^{r \times r}$ con bloque de formato $m \times k$, en donde $m + k = r$, supone dejar las k primeras filas de C inalteradas y añadir a cada fila de C por debajo de la k -ésima una combinación lineal de las filas superiores. Comprobémoslo multiplicando por bloques.

Si $A \in \mathbb{K}^{m \times k}$, $C_1 \in \mathbb{K}^{k \times n}$, $C_2 \in \mathbb{K}^{m \times n}$ y $C = [[C_1], [C_2]]$, entonces,

$$DC = \begin{bmatrix} I_k & \mathbf{0} \\ A & I_m \end{bmatrix} \begin{bmatrix} C_1 \\ C_2 \end{bmatrix} = \begin{bmatrix} C_1 \\ AC_1 + C_2 \end{bmatrix}. \quad (12)$$

Ejemplo 85. Veamos un ejemplo numérico con $r = 5, n = 4, m = 3, k = 2$,

$$\begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & a_1 & 1 & 0 & 0 \\ 0 & a_2 & 0 & 1 & 0 \\ 0 & a_3 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 5 & 2 & 3 & 4 \\ 9 & 6 & 3 & 7 \\ 4 & 7 & 2 & 8 \\ 3 & 2 & 1 & 7 \\ 5 & 1 & 3 & 9 \end{bmatrix} = \begin{bmatrix} 5 & 2 & 3 & 4 \\ 9 & 6 & 3 & 7 \\ 9a_1 + 4 & 6a_1 + 7 & 3a_1 + 2 & 7a_1 + 8 \\ 9a_2 + 3 & 6a_2 + 2 & 3a_2 + 1 & 7a_2 + 7 \\ 9a_3 + 5 & 6a_3 + 1 & 3a_3 + 3 & 7a_3 + 9 \end{bmatrix}.$$

Obsérvese que en este ejemplo numérico

$$A = \begin{bmatrix} 0 & a_1 \\ 0 & a_2 \\ 0 & a_3 \end{bmatrix} \in \mathbb{K}^{3 \times 2}$$

está concentrada en la segunda columna. □

En general, si $\mathbf{a} \in \mathbb{K}^{n-k}$ y $\mathbf{v} = (0, \dots, 0, 1, \mathbf{a}) \in \mathbb{K}^n$, entonces

$$S = I_n + \mathbf{v} \mathbf{e}_k^\top = \begin{bmatrix} I_{k-1} & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & 1 & \mathbf{0} \\ \mathbf{0} & \mathbf{a} & I_{n-k} \end{bmatrix},$$

es una matriz unitriangular con bloque $A = [[\mathbf{0}, \mathbf{a}]] \in \mathbb{K}^{(n-k) \times k}$, que está concentrada en la columna k .

3.5. Propiedades del producto de matrices

Propiedad asociativa

El producto de matrices presenta algunas características análogas a las del producto ordinario de los números. La *propiedad asociativa* permite escribir sin ambigüedad productos con más de dos factores, como ABC :

$$(AB)C = A(BC), \quad \text{para } A \in \mathbb{K}^{n \times m}, B \in \mathbb{K}^{m \times k}, C \in \mathbb{K}^{k \times p}.$$

Para justificar esa igualdad, basta descender una vez más al nivel de las componentes y aplicar las propiedades de las operaciones con escalares:

$$\begin{aligned} D = AB &\implies d_{ij} = \sum_{s=1}^m a_{is} b_{sj} \\ F = (AB)C = DC &\implies f_{ij} = \sum_{t=1}^k d_{it} c_{tj} = \sum_{t=1}^k \sum_{s=1}^m a_{is} b_{st} c_{tj} \\ G = BC &\implies g_{ij} = \sum_{t=1}^k b_{it} c_{tj} \\ H = A(BC) = AG &\implies h_{ij} = \sum_{s=1}^m a_{is} g_{sj} = \sum_{s=1}^m a_{is} \sum_{t=1}^k b_{st} c_{tj} = \sum_{t=1}^k \sum_{s=1}^m a_{is} b_{st} c_{tj}. \end{aligned}$$

Propiedad distributiva

La *propiedad distributiva respecto de la suma* permite extraer factor común, bien por la izquierda o bien por la derecha.

$$AB + AC = A(B + C), \quad \text{para } A \in \mathbb{K}^{n \times m}, B, C \in \mathbb{K}^{m \times k}.$$

$$BA + CA = (B + C)A, \quad \text{para } A \in \mathbb{K}^{n \times m}, B, C \in \mathbb{K}^{k \times n}.$$

La demostración de la propiedad distributiva es análoga a la de la asociativa. La desarrollamos por la izquierda (se hace igual por la derecha):

$$F = A(B + C) \implies f_{ij} = \sum_{t=1}^m a_{it}(b_{tj} + c_{tj}) = \sum_{t=1}^m a_{it}b_{tj} + a_{it}c_{tj},$$

$$H = AB + AC \implies h_{ij} = \sum_{t=1}^m a_{it}b_{tj} + \sum_{t=1}^m a_{it}c_{tj} = \sum_{t=1}^m a_{it}b_{tj} + a_{it}c_{tj}.$$

El producto no es conmutativo

En los ejemplos 71 y 72 se observa que, incluso cuando están definidos los productos AB y BA , estas matrices no tienen por qué coincidir.

En el caso particular de las matrices cuadradas $n \times n$, ambos productos AB y BA son, en general, matrices diferentes de ese mismo formato. Es decir, el *producto de matrices es una operación interna no conmutativa* en $\mathbb{K}^{n \times n}$.

Cuando sí se verifica $AB = BA$, decimos que las matrices A y B *conmutan*.

Ejemplo 86. Comprobemos que las siguientes matrices conmutan:

$$A = \begin{bmatrix} 2 & 3 \\ 3 & 5 \end{bmatrix}, \quad B = \begin{bmatrix} 5 & 6 \\ 6 & 11 \end{bmatrix}$$

$$AB = \begin{bmatrix} 2 & 3 \\ 3 & 5 \end{bmatrix} \begin{bmatrix} 5 & 6 \\ 6 & 11 \end{bmatrix} = \begin{bmatrix} 2(5) + 3(6) & 2(6) + 3(11) \\ 3(5) + 5(6) & 3(6) + 5(11) \end{bmatrix} = \begin{bmatrix} 28 & 45 \\ 45 & 73 \end{bmatrix}$$

$$BA = \begin{bmatrix} 5 & 6 \\ 6 & 11 \end{bmatrix} \begin{bmatrix} 2 & 3 \\ 3 & 5 \end{bmatrix} = \begin{bmatrix} 5(2) + 6(3) & 5(3) + 6(5) \\ 6(2) + 11(3) & 6(3) + 11(5) \end{bmatrix} = \begin{bmatrix} 28 & 45 \\ 45 & 73 \end{bmatrix}.$$

□

Transpuesta del producto

Es interesante observar que $\mathfrak{C}_{1,2}(A, B) = \mathfrak{C}_{2,1}(B^T, A^T) = B^T A^T$, porque las columnas de B^T son la filas de B (lo mismo para A).

Por otra parte, es claro que $(\mathfrak{C}_{1,2}(A, B))^T = \mathfrak{C}_{2,1}(A, B) = AB$, porque los índices «libres» podrían haberse intercambiado desde el principio. Por lo tanto,

$$(AB)^T = B^T A^T.$$

Como $\overline{z + w} = \bar{z} + \bar{w}$ y $\overline{zw} = \bar{z}\bar{w}$, para todos $z, w \in \mathbb{C}$, también se cumple

$$(AB)^\top = B^\top A^\top,$$

para todas las matrices $A \in \mathbb{K}^{n \times m}$, $B \in \mathbb{K}^{m \times k}$.

3.6. Matrices normales

Una matriz A es *normal* si $AA^\top = A^\top A$. Las matrices hermíticas son normales, pues verifican $A^\top = A$. En particular, también lo son las matrices reales simétricas.

Una matriz normal es necesariamente cuadrada, pues $A^\top A \in \mathbb{K}^{m \times m}$ y $AA^\top \in \mathbb{K}^{n \times n}$ cuando $A \in \mathbb{K}^{n \times m}$. Además, la fila i -ésima de una matriz normal tiene el mismo módulo que su columna i -ésima:

$$\|Ae_i\|^2 = (Ae_i)^\top (Ae_i) = e_i^\top (A^\top A) e_i = e_i^\top (AA^\top) e_i = (A^\top e_i)^\top (A^\top e_i) = \|A^\top e_i\|^2.$$

Ejemplo 87. La siguiente matriz es normal:

$$A = \begin{bmatrix} 3 & 0 & 0 \\ 0 & 1 & -2 \\ 0 & 2 & 1 \end{bmatrix},$$

pues

$$AA^T = \begin{bmatrix} 9 & 0 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & 5 \end{bmatrix} = A^T A.$$

Los módulos de las filas y de las columnas de A son:

$$\text{Módulo de la fila 1} = \sqrt{3^2 + 0^2 + 0^2} = 3.$$

$$\text{Módulo de la fila 2} = \sqrt{0^2 + 1^2 + (-2)^2} = \sqrt{5}.$$

$$\text{Módulo de la fila 3} = \sqrt{0^2 + 2^2 + 1^2} = \sqrt{5}.$$

$$\text{Módulo de la columna 1} = \sqrt{3^2 + 0^2 + 0^2} = 3.$$

$$\text{Módulo de la columna 2} = \sqrt{0^2 + 1^2 + 2^2} = \sqrt{5}.$$

$$\text{Módulo de la columna 3} = \sqrt{0^2 + (-2)^2 + 1^2} = \sqrt{5}.$$

□

4. MATRIZ INVERSA

4.1. Definición y propiedades

Es fácil comprobar que la matriz identidad es elemento neutro de la multiplicación de matrices, es decir, si $A \in \mathbb{K}^{n \times m}$, entonces $I_n A = A I_m = A$.

Las propiedades asociativa, distributiva y de existencia de neutro son idénticas a las correspondientes de los escalares (el número 1 es el neutro de la multiplicación de escalares). Sin embargo, aunque todo escalar α no nulo tiene un inverso multiplicativo, $\frac{1}{\alpha}$, que verifica $\alpha \frac{1}{\alpha} = 1$, no toda matriz no nula tiene inversa.

Se llama *inversa por la derecha* de $A \in \mathbb{K}^{n \times m}$ a una matriz $R \in \mathbb{K}^{m \times n}$ que verifique $AR = I_n$. Del mismo modo, la *inversa por la izquierda* es una matriz $L \in \mathbb{K}^{m \times n}$ que cumple $LA = I_m$.

Ejemplo 88. La siguiente matriz $A \in \mathbb{K}^{3 \times 2}$ tiene inversa por la izquierda, pero no por la derecha.

$$A = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}, L = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \dashrightarrow LA = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = I_2$$

$$AR = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} r_{11} & r_{12} & r_{13} \\ r_{21} & r_{22} & r_{23} \end{bmatrix} = \begin{bmatrix} r_{11} & r_{12} & r_{13} \\ r_{21} & r_{22} & r_{23} \\ r_{11} + r_{21} & r_{12} + r_{22} & r_{13} + r_{23} \end{bmatrix} \neq \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

□

Ejemplo 89. La siguiente matriz $A \in \mathbb{R}^{2 \times 2}$ no tiene inversa por la izquierda ni por la derecha:

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}, L = \begin{bmatrix} l_{11} & l_{12} \\ l_{21} & l_{22} \end{bmatrix} \dashrightarrow$$

$$LA = \begin{bmatrix} l_{11} & l_{12} \\ l_{21} & l_{22} \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} = \begin{bmatrix} l_{11} + 2l_{12} & 2l_{11} + 4l_{12} \\ l_{21} + 2l_{22} & 2l_{21} + 4l_{22} \end{bmatrix} \neq \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$AR = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} r_{11} & r_{12} \\ r_{21} & r_{22} \end{bmatrix} = \begin{bmatrix} r_{11} + 2r_{21} & r_{12} + 2r_{22} \\ 2r_{11} + 4r_{21} & 2r_{12} + 4r_{22} \end{bmatrix} \neq \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

□

La condición necesaria y suficiente para que una matriz $A \in \mathbb{K}^{n \times m}$ tenga inversa por la izquierda es que entre sus n filas haya exactamente m linealmente independientes, para que puedan generar las m filas de I_m (elementos básicos de $\mathbb{K}^{1 \times m}$). En particular, esto implica $n \geq m$. Recuérdese el teorema de la base II.1.

La existencia de inversa por la derecha para la matriz $A \in \mathbb{K}^{n \times m}$ equivale a que $A^\top$ la tenga por la derecha, pues $LA = I$ si y solo si $A^\top L^\top = I$. Como acabamos de ver, esto corresponde a la existencia de n columnas linealmente independientes entre las m que tiene A , lo que implica que $n \leq m$.

Decimos que una matriz cuadrada es *singular* si sus filas o sus columnas son linealmente dependientes. En otro caso, decimos que es *regular* o *no singular*.

Acabamos de razonar que una matriz tiene inversas por ambos lados si y solo si es cuadrada no singular.

Decimos que la matriz A es *invertible* si tiene inversas por ambos lados, en cuyo caso, como sabemos, A debe ser cuadrada; además, ambas inversas deben coincidir. En efecto:

$$\left. \begin{array}{l} AR = I_n \implies LAR = L \\ LA = I_m \implies LAR = R \end{array} \right\} \implies L = R, n = m.$$

De hecho, si A es cuadrada y tiene inversa R por la derecha, entonces R también es inversa por la izquierda (y viceversa). Efectivamente, siendo $AR = I_n$, calculemos $D = RA$:

$D = RA \implies AD = ARA = A \implies A(D - I_n) = \mathbf{0} \implies D - I_n = \mathbf{0} \implies D = I_n$,
porque las columnas de A son linealmente independientes.

La *matriz inversa* (por la derecha y por la izquierda) de una matriz invertible $A \in \mathbb{K}^{n \times n}$ se denota por $A^{-1} \in \mathbb{K}^{n \times n}$. Esta matriz se caracteriza por verificar $A^{-1}A = I_n$, lo que equivale a $AA^{-1} = I_n$.

La inversa se comporta como cabía esperar respecto del producto y la transposición. Comprobemos que $(A^{-1})^\top$ es la inversa de A , si A es invertible:

$$A^\top (A^{-1})^\top = (A^{-1}A)^\top = I^\top = I.$$

Análogamente, comprobemos que $B^{-1}A^{-1}$ es la inversa de AB , si A y B son matrices invertibles del mismo formato:

$$AB(B^{-1}A^{-1}) = A(BB^{-1})A^{-1} = AA^{-1} = I.$$

Resumimos todos nuestros hallazgos sobre la matriz inversa

II.4: Resumen de propiedades de la matriz inversa

- i) Una matriz $n \times m$ tiene inversa por la izquierda (respectivamente, por la derecha) si y solo si tiene m filas (respectivamente, n columnas) linealmente independientes.
- ii) Una matriz $n \times m$ tiene inversa por la izquierda (respectivamente, por la derecha) si y solo si sus m columnas (respectivamente, sus n filas) son linealmente independientes.
- iii) Una matriz A es invertible si y solo si es cuadrada no singular, en cuyo caso, las inversas por ambos lados coinciden:

$$AA^{-1} = A^{-1}A = I.$$

- iv) Si A es una matriz invertible, también lo son A^T y $A^\top$, con inversas

$$(A^\top)^{-1} = (A^{-1})^\top ; \quad (A^T)^{-1} = (A^{-1})^T.$$

- v) Si A y B son matrices invertibles del mismo formato, entonces también lo es su producto AB , con inversa

$$(AB)^{-1} = B^{-1}A^{-1}.$$

4.2. Cálculo de la matriz inversa

Aunque la matriz inversa es una herramienta fundamental en el razonamiento matemático, su cálculo explícito es muy poco frecuente debido a su elevado coste computacional. No obstante, a continuación se describe brevemente cómo puede obtenerse.

Para hallar la inversa de una matriz invertible $A \in \mathbb{K}^{n \times n}$, construimos la matriz por bloques $[[A, I]] \in \mathbb{K}^{n \times (2n)}$ y observamos que reemplazar una fila por una combinación lineal de inferiores equivale a multiplicar desde la izquierda por una cierta matriz triangular inferior.

Decimos que $G \in \mathbb{K}^{n \times n}$ es una matriz de *transformación elemental correspondiente a la columna k* para este algoritmo si $g_{kk} = 1$, $g_{ii} \neq 0$ y $g_{ij} = 0$ para todos $j \neq k$, $i \neq j$.

Ejemplo 90. La siguiente es una matriz 5×5 de transformación elemental correspondientes a la columna $k = 2$:

$$\begin{bmatrix} 1 & 5 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & -1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 3 & 0 \\ 0 & 2 & 0 & 0 & 1 \end{bmatrix}.$$

□

De esta manera, sin conseguimos convertir el bloque izquierdo de $[[A, I]]$ en la identidad, mediante combinaciones lineales de las filas, el bloque derecho deberá presentar la matriz inversa A^{-1} , pues es la única matriz que, al multiplicarse por A , da la identidad.

Ejemplo 91. Calculemos la inversa de la matriz

$$A = \begin{bmatrix} 2 & 5 & 3 \\ 1 & 3 & 2 \\ 1 & 2 & 2 \end{bmatrix}.$$

Formamos la matriz por bloques $[[A, I]]$:

$$[A \quad I] = \begin{bmatrix} 2 & 5 & 3 & 1 & 0 & 0 \\ 1 & 3 & 2 & 0 & 1 & 0 \\ 1 & 2 & 2 & 0 & 0 & 1 \end{bmatrix}.$$

Anulamos las celdas $(2, 1)$ y $(3, 1)$ combinando cada fila con la primera, que se queda como estaba (decimos que empleamos la posición $(1, 1)$ como *pivote*):

$$\begin{bmatrix} 1 & 0 & 0 \\ -1 & 2 & 0 \\ -1 & 0 & 2 \end{bmatrix} \begin{bmatrix} 2 & 5 & 3 & 1 & 0 & 0 \\ 1 & 3 & 2 & 0 & 1 & 0 \\ 1 & 2 & 2 & 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 5 & 3 & 1 & 0 & 0 \\ 0 & 1 & 1 & -1 & 2 & 0 \\ 0 & -1 & 1 & -1 & 0 & 2 \end{bmatrix}.$$

Observemos cómo está formada la matriz que multiplica por la izquierda. La primera fila $[[1, 0, 0]]$ indica que estamos utilizando la primera fila de A como pivote (queda inalterada).

La segunda fila $[-1, 2, 0]$ de la matriz que multiplica por la izquierda indica que combinamos linealmente las filas de A con pesos $-1, 2$ y 0 , es decir

$$(-1) \times (\text{fila 1 de } A) + 2 \times (\text{fila 2 de } A) \rightarrow \text{nueva segunda fila de } A.$$

Análogamente, la tercera fila $[-1, 0, 2]$ de la matriz que multiplica por la izquierda nos dice que combinamos las filas de A con pesos $-1, 0$ y 2 .

Seguimos con la misma idea, utilizando ahora la segunda fila como pivote para anular

las celdas (1, 2) y (3, 2):

$$\begin{bmatrix} 1 & -5 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} 2 & 5 & 3 & 1 & 0 & 0 \\ 0 & 1 & 1 & -1 & 2 & 0 \\ 0 & -1 & 1 & -1 & 0 & 2 \end{bmatrix} = \begin{bmatrix} 2 & 0 & -2 & 6 & -10 & 0 \\ 0 & 1 & 1 & -1 & 2 & 0 \\ 0 & 0 & 2 & -2 & 2 & 2 \end{bmatrix}.$$

Anulamos ahora las celdas (1, 3) y (2, 3), utilizando la tercera fila como pivote.

$$\begin{bmatrix} 1 & 0 & 1 \\ 0 & 2 & -1 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 & -2 & 6 & -10 & 0 \\ 0 & 1 & 1 & -1 & 2 & 0 \\ 0 & 0 & 2 & -2 & 2 & 2 \end{bmatrix} = \begin{bmatrix} 2 & 0 & 0 & 4 & -8 & 2 \\ 0 & 2 & 0 & 0 & 2 & -2 \\ 0 & 0 & 2 & -2 & 2 & 2 \end{bmatrix}.$$

Solo nos queda dividir todas las filas entre 2 para obtener la identidad en el bloque de la izquierda, con lo que en el bloque de la derecha aparecerá la inversa buscada:

$$\begin{bmatrix} \frac{1}{2} & 0 & 0 \\ 0 & \frac{1}{2} & 0 \\ 0 & 0 & \frac{1}{2} \end{bmatrix} \begin{bmatrix} 2 & 0 & 0 & 4 & -8 & 2 \\ 0 & 2 & 0 & 0 & 2 & -2 \\ 0 & 0 & 2 & -2 & 2 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 2 & -4 & 1 \\ 0 & 1 & 0 & 0 & 1 & -1 \\ 0 & 0 & 1 & -1 & 1 & 1 \end{bmatrix} = [I \quad A^{-1}].$$

Ya tenemos la inversa

$$A^{-1} = \begin{bmatrix} 2 & -4 & 1 \\ 0 & 1 & -1 \\ -1 & 1 & 1 \end{bmatrix}.$$

□

Las matrices triangulares son de vital importancia en el álgebra lineal computacional debido a que pertenecen a una de las pocas familias de matrices cuya inversión es eficiente. En lugar de requerir algoritmos complejos, su inversa se calcula de forma directa mediante sustitución hacia atrás y conserva la misma estructura triangular.

Si denotamos por $A^{-1} = (b_{ij})$ a las componentes de la inversa de una matriz triangular superior A (suponiendo que todos los elementos de la diagonal $a_{ii} \neq 0$, pues, en otro caso, A no sería invertible), resulta:

$$A^{-1} = \begin{bmatrix} \frac{1}{a_{11}} & b_{12} & b_{13} & \dots & b_{1n} \\ 0 & \frac{1}{a_{22}} & b_{23} & \dots & b_{2n} \\ 0 & 0 & \frac{1}{a_{33}} & \dots & b_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & \frac{1}{a_{nn}} \end{bmatrix},$$

en donde los términos superiores b_{ij} (con $i < j$) vienen dados por la relación recurrente:

$$b_{ij} = -\frac{1}{a_{ii}} \sum_{k=i+1}^j a_{ik} b_{kj}. \quad (13)$$

Este sencillo algoritmo se denomina *sustitución hacia atrás* (*backward substitution*).

Ejemplo 92. Calculemos la inversa de la matriz triangular superior A :

$$A = \begin{bmatrix} 2 & 1 & 0 & 3 \\ 0 & -1 & 2 & 1 \\ 0 & 0 & 3 & -2 \\ 0 & 0 & 0 & 4 \end{bmatrix}, \quad A^{-1} = \begin{bmatrix} b_{11} & b_{12} & b_{13} & b_{14} \\ 0 & b_{22} & b_{23} & b_{24} \\ 0 & 0 & b_{33} & b_{34} \\ 0 & 0 & 0 & b_{44} \end{bmatrix}$$

Lo hacemos sustituyendo hacia atrás en la siguiente ecuación matricial:

$$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} = A A^{-1} = \begin{bmatrix} 2b_{11} & 2b_{12} + b_{22} & 2b_{13} + b_{23} & 2b_{14} + b_{24} + 3b_{44} \\ 0 & -b_{22} & -b_{23} + 2b_{33} & -b_{24} + 2b_{34} + b_{44} \\ 0 & 0 & 3b_{33} & 3b_{34} - 2b_{44} \\ 0 & 0 & 0 & 4b_{44} \end{bmatrix}.$$

Resulta:

$$\begin{aligned} 4b_{44} &= 1 \implies b_{44} = \frac{1}{4} \\ 3b_{34} - 2b_{44} &= 0 \implies b_{34} = \frac{2}{3}b_{44} = \frac{1}{6} \\ 3b_{33} &= 1 \implies b_{33} = \frac{1}{3} = \frac{1}{3} \\ -b_{24} + 2b_{34} + b_{44} &= 0 \implies b_{24} = 2b_{34} + b_{44} = \frac{7}{12} \\ -b_{23} + 2b_{33} &= 0 \implies b_{23} = 2b_{33} = \frac{2}{3} \\ -b_{22} &= 1 \implies b_{22} = -1 = -1 \\ 2b_{14} + b_{24} + 3b_{44} &= 0 \implies b_{14} = -\frac{1}{2}b_{24} - \frac{3}{2}b_{44} = -\frac{2}{3} \\ 2b_{13} + b_{23} &= 0 \implies b_{13} = -\frac{1}{2}b_{23} = -\frac{1}{3} \\ 2b_{12} + b_{22} &= 0 \implies b_{12} = -\frac{1}{2}b_{22} = \frac{1}{2} \\ 2b_{11} &= 1 \implies b_{11} = \frac{1}{2} = \frac{1}{2}. \end{aligned}$$

Hemos obtenido la inversa:

$$A^{-1} = \begin{bmatrix} \frac{1}{2} & \frac{1}{2} & -\frac{1}{3} & -\frac{2}{3} \\ 0 & -1 & \frac{2}{3} & \frac{7}{12} \\ 0 & 0 & \frac{1}{3} & \frac{1}{6} \\ 0 & 0 & 0 & \frac{1}{4} \end{bmatrix}$$

□

Notación y terminología. El procedimiento descrito en esta sección (hacer ceros por encima y por debajo de la diagonal) corresponde esencialmente al denominado *Método de Gauss-Jordan*.

Con unas pocas adaptaciones, el algoritmo permite transformar una matriz arbitraria en una escalonada reducida (RREF, página 80). Obsérvese que la identidad es una matriz escalonada reducida.

Aunque el procedimiento tiene una limitada utilidad computacional (y solo para calcular inversas en algunos casos concretos, casi nunca para obtener la forma RREF), es interesante desde el punto de vista didáctico, porque muestra cómo se codifican mediante factores matriciales las combinaciones lineales de las filas. $\square$

De la misma manera que podemos multiplicar matrices por bloques, en algunas ocasiones, también podremos hacer la inversión por bloques.

Ejemplo 93. Si aplicamos la expresión (7) a la matriz $A \in \mathbb{K}^{m \times k}$, resulta:

$$\begin{bmatrix} I_k & \mathbf{0} \\ A & I_m \end{bmatrix}^{-1} = \begin{bmatrix} I_k & \mathbf{0} \\ -A & I_m \end{bmatrix},$$

pues

$$\begin{bmatrix} I_k & \mathbf{0} \\ A & I_m \end{bmatrix} \begin{bmatrix} I_k & \mathbf{0} \\ -A & I_m \end{bmatrix} = \begin{bmatrix} I_k & \mathbf{0} \\ A - A & I_m \end{bmatrix} = \begin{bmatrix} I_k & \mathbf{0} \\ \mathbf{0} & I_m \end{bmatrix} = I_{k+m}.$$

$\square$

4.3. Cambio de base en $\mathbb{K}^n$

Según lo visto en el apartado II.1.2, una base de $\mathbb{K}^n$ está formada por n vectores linealmente independientes. Cuando los n vectores están indexados, como en $\mathbf{w}_1, \dots, \mathbf{w}_n \in \mathbb{K}^n$, podemos entender que forman una base ordenada.

En otros casos, principalmente en espacios con dimensión n baja, se asume (salvo que se indique otra cosa) que la base está ordenada alfabéticamente, como en $\mathbf{u}, \mathbf{v}, \mathbf{w} \in \mathbb{K}^3$.

En el caso general, o cuando queramos reforzar la idea de la que la base está ordenada, la presentaremos como una matriz fila: $W = [[\mathbf{w}_1, \dots, \mathbf{w}_n]] \in (\mathbb{K}^n)^{1 \times n} = \mathbb{K}^{n \times n}$, en donde la última identificación, $(\mathbb{K}^n)^{1 \times n} = \mathbb{K}^{n \times n}$, corresponde a la establecida al construir matrices por bloques.

Si $W = [[\mathbf{w}_1, \dots, \mathbf{w}_n]]$ es una base ordenada de $\mathbb{K}^n$ y $\mathbf{u} \in \mathbb{K}^n$ es un vector arbitrario,

$$\mathbf{u} = (WW^{-1})\mathbf{u} = W(W^{-1}\mathbf{u}) = \begin{bmatrix} \mathbf{w}_1 & \mathbf{w}_2 & \dots & \mathbf{w}_n \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{bmatrix} = \sum_{j=1}^n c_j \mathbf{w}_j,$$

en donde denotamos por $(c_1, \dots, c_n)$ a las componentes de $W^{-1}\mathbf{u} \in \mathbb{K}^n$.

Decimos que $(c_1, \dots, c_n) = W^{-1}\mathbf{u} \in \mathbb{K}^n$ son las *coordenadas de $\mathbf{u}$ respecto de la base W* . También se dice que W^{-1} es la *matriz de cambio de coordenadas* a la base W .

Conviene entender a $(c_1, \dots, c_n)$ más como una tupla que como un vector para evitar confusiones, si bien la diferencia entre ambos conceptos no es relevante en este contexto.

Ejemplo 94. Consideremos la base de $\mathbb{R}^3$ dada por los vectores $\mathbf{w}_1 = (1, 2, 3)$, $\mathbf{w}_2 = (2, 5, 7)$ y $\mathbf{w}_3 = (1, 2, 4)$, en ese orden. La matriz W es, en este caso,

$$W = [\mathbf{w}_1 \quad \mathbf{w}_2 \quad \mathbf{w}_3] = \begin{bmatrix} 1 & 2 & 1 \\ 2 & 5 & 2 \\ 3 & 7 & 4 \end{bmatrix},$$

con inversa

$$W^{-1} = \begin{bmatrix} 6 & -1 & -1 \\ -2 & 1 & 0 \\ -1 & -1 & 1 \end{bmatrix}.$$

Si $\mathbf{u} = (1, 0, 3) \in \mathbb{R}^3$, por ejemplo, tenemos

$$\mathbf{u} = WW^{-1}\mathbf{u} = [\mathbf{w}_1 \quad \mathbf{w}_2 \quad \mathbf{w}_3] \begin{bmatrix} 6 & -1 & -1 \\ -2 & 1 & 0 \\ -1 & -1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \\ 3 \end{bmatrix} = 3\mathbf{w}_1 - 2\mathbf{w}_2 + 2\mathbf{w}_3.$$

Decimos que $(3, -2, 2)$ son las coordenadas de $\mathbf{u}$ respecto de la base $[[\mathbf{w}_1, \mathbf{w}_2, \mathbf{w}_3]]$. $\square$

5. DISTANCIAS Y ÁNGULOS

Vamos a ver cómo la multiplicación de matrices permite introducir las nociones de «distancia» y «ángulo».

5.1. Módulo de un vector

La operación que asigna a cada par de vectores $\mathbf{u}, \mathbf{v} \in \mathbb{K}^n$ el escalar $\mathbf{u}^\top \mathbf{v} \in \mathbb{K}$ se denomina *producto escalar*.



Observemos que

$$\mathbf{u}^\top \mathbf{v} = \overline{\mathbf{u}}^T \mathbf{v} = (\overline{\mathbf{u}}^T \mathbf{v})^T = \mathbf{v}^T \overline{\mathbf{u}} = \overline{\mathbf{v}^\top \mathbf{u}},$$

de manera que la igualdad $\mathbf{u}^\top \mathbf{v} = \mathbf{v}^\top \mathbf{u}$ solo es cierta cuando este escalar es real. Como se ha señalado, la mayoría de las aplicaciones se dan para $\mathbb{K} = \mathbb{R}$. Cuando se considera $\mathbb{K} = \mathbb{C}$, tenemos dos opciones para definir el producto escalar: $\mathbf{u}^\top \mathbf{v}$ o $\mathbf{v}^\top \mathbf{u}$. En algunas áreas se escoge la primera opción y en otras, la segunda. $\square$

Por alta que sea la dimensión n del espacio $\mathbb{R}^n$, el espacio generado por un par de vectores linealmente independientes $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$ es «idéntico» a $\mathbb{R}^2$, espacio en el que podemos aplicar nuestra intuición espacial y nuestros conocimientos de geometría elemental.




Figura 14. Interpretación geométrica del módulo de un vector mediante el teorema de Pitágoras en $\mathbb{R}^2$.

El teorema de Pitágoras sugiere que la forma adecuada de definir la «longitud» o «módulo» de un vector $\mathbf{u} = u_1 \mathbf{e}_1 + u_2 \mathbf{e}_2 \in \mathbb{R}^2$ es $\|\mathbf{u}\| = \sqrt{u_1^2 + u_2^2}$ (figura 14). La misma idea se extiende al espacio tridimensional (figura 15) y a dimensiones superiores.




Figura 15. Interpretación geométrica del módulo de un vector mediante el teorema de Pitágoras en $\mathbb{R}^3$.

Denominamos *módulo* de un vector $u \in \mathbb{K}^n$ al número real

$$\|u\| = \sqrt{u^T u} = \sqrt{\sum_{i=1}^n |u_i|^2}.$$

La primera propiedad del módulo es su *homogeneidad absoluta*

$$\|\alpha \mathbf{u}\| = |\alpha| \|\mathbf{u}\|, \quad \text{para todos } \alpha \in \mathbb{K}, \mathbf{u} \in \mathbb{K}^n,$$

cuya comprobación es inmediata:

$$\|\alpha \mathbf{u}\| = \sqrt{(\alpha \mathbf{u}^\top)(\alpha \mathbf{u})} = \sqrt{|\alpha|^2} \sqrt{\mathbf{u}^\top \mathbf{u}} = |\alpha| \|\mathbf{u}\|.$$

Decimos que un vector $\mathbf{u} \in \mathbb{K}^n$ es *unitario* si $\|\mathbf{u}\| = 1$. También decimos que *normalizamos* un vector $\mathbf{v} \neq 0$ cuando lo dividimos entre su módulo $\|\mathbf{v}\|$, de manera que $\mathbf{u} = \frac{\mathbf{v}}{\|\mathbf{v}\|}$ sea un vector unitario,

$$\|\mathbf{u}\| = \left\| \frac{\mathbf{v}}{\|\mathbf{v}\|} \right\| = \frac{1}{\|\mathbf{v}\|} \|\mathbf{v}\| = 1.$$

5.2. Distancias y ángulos. Ortogonalidad

Si multiplicamos escalarmente dos vectores unitarios, $\mathbf{u}, \mathbf{v} \in \mathbb{K}^n$, el número real $|\mathbf{u}^\top \mathbf{v}|$ es menor que 1. Para comprobarlo, calculamos el cuadrado del módulo del vector $\mathbf{w} = \mathbf{v} - (\mathbf{u}^\top \mathbf{v}) \mathbf{u}$:

$$\begin{aligned} 0 \leq \|\mathbf{w}\|^2 &= \mathbf{w}^\top \mathbf{w} = (\mathbf{v}^\top - (\mathbf{u}^\top \mathbf{v}) \mathbf{u}^\top)(\mathbf{v} - (\mathbf{u}^\top \mathbf{v}) \mathbf{u}) \\ &= \|\mathbf{v}\|^2 - (\mathbf{u}^\top \mathbf{v})^2 - (\mathbf{u}^\top \mathbf{v})(\mathbf{v}^\top \mathbf{u}) + (\mathbf{u}^\top \mathbf{v})^2 \|\mathbf{u}\|^2 = 1 - (\mathbf{u}^\top \mathbf{v})(\mathbf{v}^\top \mathbf{u}) = 1 - |\mathbf{u}^\top \mathbf{v}|^2. \\ &\implies |\mathbf{u}^\top \mathbf{v}|^2 \leq 1 \implies |\mathbf{u}^\top \mathbf{v}| \leq 1. \end{aligned}$$

Al aplicar este resultado a los vectores normalizados $\frac{\mathbf{u}}{\|\mathbf{u}\|}$ y $\frac{\mathbf{v}}{\|\mathbf{v}\|}$, obtenemos la *desigualdad de Cauchy-Schwartz*:

$$|\mathbf{u}^\top \mathbf{v}| \leq \|\mathbf{u}\| \|\mathbf{v}\|, \text{ para todos } \mathbf{u}, \mathbf{v} \in \mathbb{K}^n.$$




Figura 16. Los vectores $\mathbf{u}$ y $\mathbf{v}$ son aquí unitarios.

En el caso particular de que $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$, el producto $\mathbf{u}^\top \mathbf{v}$ es un número real. En el razonamiento anterior se aprecia también que $\|\mathbf{w}\|^2 + (\mathbf{u}^\top \mathbf{v})^2 = 1$, por lo que el triángulo de la figura 16 es rectángulo y, por lo tanto, $\cos \theta = \mathbf{u}^\top \mathbf{v}$ (cateto contiguo, $\|(\mathbf{u}^\top \mathbf{v})\mathbf{u}\| = \mathbf{u}^\top \mathbf{v}$, partido por hipotenusa, $\|\mathbf{v}\| = 1$), de donde se obtiene la expresión del coseno del

ángulo formado por dos vectores no nulos $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$:

$$\cos \widehat{\mathbf{u}\mathbf{v}} = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|}.$$

Aplicación a la informática. En el ámbito de la IA, la expresión

$$\text{CosSim}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|}, \quad (\text{similitud coseno}),$$

para $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$, se utiliza para medir lo alineados que están dos vectores.

En IA, las palabras, textos o elementos se transforman en vectores de alta dimensión (denominados *embeddings*). Como la longitud de estos vectores suele depender de factores externos (como, por ejemplo, la cantidad de veces que se repite una palabra en un documento), la distancia euclídea puede resultar engañosa. Al calcular el coseno del ángulo que forman, se evalúa únicamente la dirección de los vectores: un coseno cercano a 1 indica que apuntan en la misma dirección (máxima similitud semántica), mientras que un coseno de 0 indica ortogonalidad (conceptos independientes). $\square$

En general, decimos que dos vectores no nulos $\mathbf{u}, \mathbf{v} \in \mathbb{K}^n$ son *ortogonales* si $\mathbf{u}^\top \mathbf{v} = 0$, lo que se denota por $\mathbf{u} \perp \mathbf{v}$.

Ejemplo 95. En el ejemplo 75 definimos el producto vectorial $\mathbf{u} \times \mathbf{v}$ como

$$(\mathbf{u} \times \mathbf{v})_i = \sum_{s,t=1}^3 h_{ist} u_s v_t,$$

en donde $\mathbf{u}, \mathbf{v} \in \mathbb{R}^3$ y $H \in \mathbb{R}^{3 \times 3 \times 3}$ es el tensor de Levi-Civita (ver ejemplo 63).

De la antisimetría del tensor H se deducen las propiedades del producto vectorial:

$$(\mathbf{v} \times \mathbf{u})_i = \sum_{s,t=1}^3 h_{ist} v_s u_t = \sum_{s,t=1}^3 h_{its} u_s v_t = - \sum_{s,t=1}^3 h_{ist} u_s v_t = -(\mathbf{u} \times \mathbf{v})_i,$$

luego, $\mathbf{u} \times \mathbf{v} = -\mathbf{v} \times \mathbf{u}$, para todos $\mathbf{u}, \mathbf{v} \in \mathbb{R}^3$.

De forma similar se comprueba que el producto vectorial de dos vectores no nulos es ortogonal a ambos factores, $\mathbf{u} \perp (\mathbf{u} \times \mathbf{v})$, $\mathbf{v} \perp (\mathbf{u} \times \mathbf{v})$.

$$\begin{aligned} \mathbf{u}^\top (\mathbf{u} \times \mathbf{v}) &= \sum_{i=1}^3 u_i (\mathbf{u} \times \mathbf{v})_i = \sum_{i=1}^3 u_i \sum_{s,t=1}^3 h_{ist} v_s u_t = \sum_{i,s,t=1}^3 h_{ist} v_s u_t u_i \\ &= \sum_{i,s,t=1}^3 h_{tsi} v_s u_i u_t = - \sum_{i,s,t=1}^3 h_{ist} v_s u_i u_t = -\mathbf{u}^\top (\mathbf{u} \times \mathbf{v}) \end{aligned}$$

$$\implies \mathbf{u}^\top (\mathbf{u} \times \mathbf{v}) = 0,$$

es decir, $\mathbf{u} \perp (\mathbf{u} \times \mathbf{v}) = 0$. Se haría igual con $\mathbf{v}$. $\square$

De forma más general, se dice que una familia de vectores no nulos $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_m \in \mathbb{K}^n$ es *ortogonal* si $\mathbf{u}_i \perp \mathbf{u}_j$ para todo $1 \leq i < j \leq m$. Una familia ortogonal formada por vectores unitarios se denomina *familia ortonormal*.

Una familia ortogonal siempre es linealmente independiente, es decir, es una base del espacio que genera, es decir, es una *base ortogonal* del espacio que genera.

En efecto, si una familia ortogonal $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_m \in \mathbb{K}^n$ no fuera linealmente independiente, existiría una combinación lineal no trivial nula: $\sum_{j=1}^m \alpha_j \mathbf{u}_j = 0$. Al ser no trivial la combinación, existiría un $k \in \{1, \dots, m\}$ tal que $\alpha_k \neq 0$ y entonces

$$0 = \mathbf{u}_k^\top \sum_{j=1}^m \alpha_j \mathbf{u}_j = \alpha_k \mathbf{u}_k^\top \mathbf{u}_k = \alpha_k \|\mathbf{u}_k\|^2,$$

con lo que llegaríamos a una conclusión absurda.

Ejemplo 96. Si $\mathbf{u}, \mathbf{v} \in \mathbb{K}^n$ son vectores unitarios y linealmente independientes, el vector $\mathbf{w} = \mathbf{v} - (\mathbf{u}^\top \mathbf{v}) \mathbf{u}$ (ver la figura 16) es ortogonal a $\mathbf{u}$. En efecto,:

$$\mathbf{u}^\top \mathbf{w} = \mathbf{u}^\top \mathbf{v} - (\mathbf{u}^\top \mathbf{v}) \mathbf{u}^\top \mathbf{u} = \mathbf{u}^\top \mathbf{v} - \mathbf{u}^\top \mathbf{v} = 0.$$

La familia $\{\mathbf{u}, \mathbf{w}\}$ es ortogonal; es una base ortogonal del subespacio $\langle \{\mathbf{u}, \mathbf{v}\} \rangle$ de $\mathbb{K}^n$. $\square$

5.3. Distancia en $\mathbb{K}^n$

De la desigualdad de Cauchy-Schwartz se deduce la *desigualdad triangular*:

$$\|\mathbf{u} + \mathbf{v}\| \leq \|\mathbf{u}\| + \|\mathbf{v}\|, \quad \text{para todos } \mathbf{u}, \mathbf{v} \in \mathbb{K}^n.$$

En efecto,

$$\begin{aligned} \|\mathbf{u} + \mathbf{v}\|^2 &= (\mathbf{u} + \mathbf{v})^\top (\mathbf{u} + \mathbf{v}) = (\mathbf{u}^\top + \mathbf{v}^\top)(\mathbf{u} + \mathbf{v}) = \mathbf{u}^\top \mathbf{u} + \mathbf{u}^\top \mathbf{v} + \mathbf{v}^\top \mathbf{u} + \mathbf{v}^\top \mathbf{v} \\ &= \|\mathbf{u}\|^2 + 2 \operatorname{Re}(\mathbf{u}^\top \mathbf{v}) + \|\mathbf{v}\|^2 \leq \|\mathbf{u}\|^2 + 2\|\mathbf{u}\|\|\mathbf{v}\| + \|\mathbf{v}\|^2 = (\|\mathbf{u}\| + \|\mathbf{v}\|)^2. \end{aligned}$$

Ejemplo 97. Comprobamos las desigualdades de Cauchy-Schwartz y triangular para los elementos $\mathbf{u} = (1, 2, 2), \mathbf{v} = (2, 6, 9) \in \mathbb{R}^3$. Se tiene:

$$\mathbf{u}^\top \mathbf{v} = 32, \quad \|\mathbf{u}\| = 3, \quad \|\mathbf{v}\| = 11, \quad \mathbf{u} + \mathbf{v} = (3, 8, 11), \quad \|\mathbf{u} + \mathbf{v}\| = \sqrt{194}.$$

Desigualdad de Cauchy-Schwarz:

$$\mathbf{u}^\top \mathbf{v} = 32 < 33 = \|\mathbf{u}\| \|\mathbf{v}\|.$$

Desigualdad triangular

$$\|\mathbf{u} + \mathbf{v}\| = \sqrt{194} < 14 = \|\mathbf{u}\| + \|\mathbf{v}\|.$$

□

Para profundizar. En muchas áreas de las matemáticas, y también en el ámbito del aprendizaje automático y la IA, es común trabajar con la familia de *normas* L_p :

$$\|\mathbf{u}\|_p = \sqrt[p]{\sum_{i=1}^n |u_i|^p}.$$

las cuales miden la magnitud de los vectores de diferentes maneras. Las más utilizadas son la norma L_1 ($\|\cdot\|_1$), que suma los valores absolutos de las componentes, y la norma L_2 ($\|\cdot\|_2$), que corresponde a la distancia euclídea clásica.

Dado que la norma L_2 es la geometría natural del espacio $\mathbb{R}^n$ y el pilar fundamental de la mayoría de los desarrollos analíticos, en esta asignatura adoptaremos la convención matemática estándar: salvo que se especifique lo contrario, la notación abreviada $\|\cdot\|$ se referirá exclusivamente a la norma L_2 (el módulo habitual). □

Cuando se interpretan los elementos de $\mathbb{K}^n$ como puntos (posiciones) más que como vectores (direcciones), conviene considerar la noción de distancia asociada al módulo.

Denotamos por $d: \mathbb{K}^n \times \mathbb{K}^n \rightarrow \mathbb{R}$ a la *distancia euclídea* $d(\mathbf{u}, \mathbf{v}) = \|\mathbf{u} - \mathbf{v}\|$. Las siguientes propiedades de la distancia euclídea se deducen directamente de las del módulo:

- (D1) $d(\mathbf{u}, \mathbf{v}) = 0$ si y solo si $\mathbf{u} = \mathbf{v}$.
- (D2) $d(\mathbf{u}, \mathbf{v}) = d(\mathbf{v}, \mathbf{u})$, para todos $\mathbf{u}, \mathbf{v} \in \mathbb{K}^n$.
- (D3) $d(\mathbf{u}, \mathbf{w}) \leq d(\mathbf{u}, \mathbf{v}) + d(\mathbf{v}, \mathbf{w})$, para todos $\mathbf{u}, \mathbf{v}, \mathbf{w} \in \mathbb{K}^n$.

En general, si E es un conjunto no vacío arbitrario y $d: E \times E \rightarrow \mathbb{R}_+$ es una aplicación que satisface las propiedades (D1) a (D3), se dice que d es un *métrica* o *distancia* y que el conjunto E dotado de esa métrica es un *espacio métrico*.

Ejemplo 98. Al considerar sobre $E = \mathbb{R}^2$ las métricas d_1 y d_2 asociadas a las normas L_1 y L_2 respectivamente, tenemos dos espacios métricos diferentes, $(\mathbb{R}^2, d_1)$ y $(\mathbb{R}^2, d_2)$ sobre un mismo conjunto base $E = \mathbb{R}^2$.

Calculemos la distancia entre los elementos $\mathbf{u} = (1, 2)$ y $\mathbf{v} = (4, 6)$ de $\mathbb{R}^2$ asociada a la norma L_2 (módulo):

$$d(\mathbf{u}, \mathbf{v}) = d_2(\mathbf{u}, \mathbf{v}) = \|\mathbf{u} - \mathbf{v}\|_2 = \sqrt{(-3)^2 + (-4)^2} = \sqrt{9 + 16} = \sqrt{25} = 5.$$

La distancia para la norma L_1 sería

$$d_1(\mathbf{u}, \mathbf{v}) = \|\mathbf{u} - \mathbf{v}\|_1 = |-3| + |-4| = 3 + 4 = 7.$$

□

6. ORTOGONALIZACIÓN

6.1. Procedimiento de ortogonalización de Gram-Schmidt

La misma idea geométrica que utilizamos para justificar la desigualdad de Cauchy-Schwarz (ver la figura 16 y el ejemplo 96) nos servirá ahora para desarrollar un algoritmo fundamental, tanto desde el punto de vista teórico como práctico: el procedimiento de ortogonalización de Gram-Schmidt, que sirve para construir una base ortonormal para el subespacio generado por una familia dada de vectores.

Dada una familia finita B de vectores no nulos de $\mathbb{K}^n$, escogemos un $\mathbf{v} \in B$ y lo normalizamos: $\mathbf{f}_1 = \frac{\mathbf{v}}{\|\mathbf{v}\|}$. A continuación, seleccionamos un nuevo $\mathbf{v} \in B$ (si no lo hubiera, habríamos terminado) y generamos un vector siguiendo la idea del ejemplo 96:

$$\mathbf{u} = \mathbf{v} - (\mathbf{f}_1^\top \mathbf{v}) \mathbf{f}_1.$$

Si $\mathbf{u} = \mathbf{0}$, es porque $\mathbf{v}$ es linealmente dependiente de $\mathbf{f}_1$, por lo que lo descartamos y vamos escogiendo vectores de B hasta que conseguir un $\mathbf{v}$ que genere un $\mathbf{u} \neq \mathbf{0}$ (si no lo conseguimos es porque el subespacio $\langle B \rangle$ tiene dimensión 1 y terminamos). Normalizando este vector, $\mathbf{f}_2 = \frac{\mathbf{u}}{\|\mathbf{u}\|}$, obtenemos una familia ortonormal de dos vectores $\{\mathbf{f}_1, \mathbf{f}_2\}$.

Supongamos que ya tenemos una familia ortonormal de k vectores $\{\mathbf{f}_1, \dots, \mathbf{f}_k\}$. Si no quedan vectores nuevos en B , es porque nuestra familia ortonormal es una base $\langle B \rangle$ y hemos terminado. Si hay un nuevo vector $\mathbf{v} \in B$, seguimos la misma idea de antes:

$$\mathbf{u} = \mathbf{v} - \sum_{j=1}^k (\mathbf{f}_j^\top \mathbf{v}) \mathbf{f}_j. \quad (14)$$

Una vez más, si $\mathbf{u} = \mathbf{0}$ es porque $\mathbf{v} = \sum_{j=1}^k (\mathbf{f}_j^\top \mathbf{v}) \mathbf{f}_j$ es combinación lineal de la familia $\{\mathbf{f}_1, \dots, \mathbf{f}_k\}$, por lo que lo descartamos y seguimos añadiendo vectores nuevos de B hasta conseguir un $\mathbf{u} \neq \mathbf{0}$ (si no es posible es porque $\{\mathbf{f}_1, \dots, \mathbf{f}_k\}$ genera todo $\langle B \rangle$ y

hemos terminado). Ese vector $\mathbf{u}$, tras su normalización, $\mathbf{f}_{k+1} = \frac{\mathbf{u}}{\|\mathbf{u}\|}$, se añadiría a nuestra familia ortonormal: $\{\mathbf{f}_1, \dots, \mathbf{f}_k, \mathbf{f}_{k+1}\}$.

Cuando este proceso termina, conseguimos una base ortonormal $\{\mathbf{f}_1, \dots, \mathbf{f}_m\}$ para el subespacio $\langle B \rangle$ generado por la familia B .

Ejemplo 99. Apliquemos el procedimiento de ortogonalización de Gram-Schmidt a la siguiente familia $B = \{\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3, \mathbf{v}_4\}$ de vectores de $\mathbb{R}^4$:

$$\mathbf{v}_1 = (1, 0, 3, 2), \quad \mathbf{v}_2 = (1, 3, 0, 1), \quad \mathbf{v}_3 = (1, -3, 6, 3), \quad \mathbf{v}_4 = (0, 2, 2, 1).$$

El primer elemento de nuestra base ortonormal es $\mathbf{f}_1 = \frac{\mathbf{v}_1}{\|\mathbf{v}_1\|} = \frac{1}{\sqrt{14}}(1, 0, 3, 2)$.

Seguidamente, escogemos $\mathbf{v} = \mathbf{v}_2$, para calcular

$$\mathbf{u} = \mathbf{v} - (\mathbf{f}_1^\top \mathbf{v}) \mathbf{f}_1 = (1, 3, 0, 1) - \frac{3}{14}(1, 0, 3, 2) = \frac{1}{14}(11, 42, -9, 8).$$

Como $\|\mathbf{u}\| = \frac{\sqrt{2030}}{14}$, normalizamos para obtener:

$$\mathbf{f}_2 = \frac{1}{\sqrt{2030}}(11, 42, -9, 8).$$

Escogemos a continuación $\mathbf{v} = \mathbf{v}_3$ y calculamos $\mathbf{u}$:

$$\begin{aligned} \mathbf{u} &= \mathbf{v} - (\mathbf{f}_1^\top \mathbf{v}) \mathbf{f}_1 - (\mathbf{f}_2^\top \mathbf{v}) \mathbf{f}_2 \\ &= (1, -3, 6, 3) - \frac{25}{14}(1, 0, 3, 2) - \frac{-145}{2030}(11, 42, -9, 8) = (0, 0, 0, 0). \end{aligned}$$

Al obtener $\mathbf{u} = \mathbf{0}$, el vector $\mathbf{v}_3$ es linealmente dependiente de los anteriores. Lo ignoramos, no genera ningún vector $\mathbf{f}_3$, y pasamos al siguiente elemento utilizando los mismos vectores de soporte $\{\mathbf{f}_1, \mathbf{f}_2\}$. Finalmente, para $\mathbf{v} = \mathbf{v}_4$:

$$\begin{aligned} \mathbf{u} &= \mathbf{v} - (\mathbf{f}_1^\top \mathbf{v}) \mathbf{f}_1 - (\mathbf{f}_2^\top \mathbf{v}) \mathbf{f}_2 \\ &= (0, 2, 2, 1) - \frac{8}{14}(1, 0, 3, 2) - \frac{96}{2030}(11, 42, -9, 8) = \frac{1}{145}(-15, -2, 7, 19) \end{aligned}$$

Como $\mathbf{u} \neq \mathbf{0}$, concluimos normalizando para obtener el último vector de la base ortogonal del subespacio generado por B :

$$\mathbf{f}_3 = \frac{1}{\sqrt{615}}(-15, -2, 7, 19).$$

Hemos obtenido una base ortonormal $\{\mathbf{f}_1, \mathbf{f}_2, \mathbf{f}_3\}$ para el subespacio $\langle B \rangle$ generado por B , que tiene, por lo tanto, dimensión 3. $\square$

Aplicación a la informática. La importancia de la ortogonalización de Gram-Schmidt en el campo de la IA radica en su capacidad para eliminar la redundancia y garantizar la estabilidad numérica en el procesamiento de datos a gran escala.

En los modelos de aprendizaje automático modernos, las variables de entrada suelen estar altamente correlacionadas, lo que satura y desestabiliza los algoritmos de entrenamiento. Gram-Schmidt proporciona el fundamento matemático para técnicas de reducción de dimensionalidad y factorización matricial, como la descomposición QR, que transforman datos correlacionados en componentes ortogonales independientes.

Asimismo, en el aprendizaje profundo (Deep Learning), este principio se utiliza para mantener la ortonormalidad en las matrices de pesos de las redes neuronales, lo que previene problemas críticos como la explosión o desvanecimiento del gradiente y asegura una propagación eficiente de la información.

En definitiva, el algoritmo actúa en IA como un filtro geométrico esencial para purificar la información y estabilizar el cálculo computacional. $\square$

6.2. Complemento ortogonal

Decimos que dos subconjuntos $A, B \subset \mathbb{K}^n$ son *ortogonales*, lo que denotaremos mediante $A \perp B$, si $\mathbf{a}^\top \mathbf{b} = 0$ para todos $\mathbf{a} \in A, \mathbf{b} \in B$. Se comprueba inmediatamente que $A \perp B$ si y solo si $\langle A \rangle \perp \langle B \rangle$.

El *complemento ortogonal* de un conjunto no vacío $B \subset \mathbb{K}^n$, es el subespacio

$$B^\perp = \{\mathbf{u} \in \mathbb{K}^n : \mathbf{u}^\top \mathbf{b} = 0, \text{ para todo } \mathbf{b} \in B\}.$$

El procedimiento de ortogonalización de Gram-Schmidt no solo sirve para hallar una base ortonormal del subespacio en cuestión. Una vez obtenida esa base ortonormal $\{\mathbf{f}_1, \dots, \mathbf{f}_m\}$ del subespacio $V = \langle B \rangle$, podemos seguir aplicando el algoritmo a la familia obtenida al añadir a B los vectores de la base canónica: $B \cup \{\mathbf{e}_1, \dots, \mathbf{e}_n\}$.

De esta manera, generaremos unos nuevos vectores $\mathbf{g}_1, \dots, \mathbf{g}_{n-m}$ que forman con $\{\mathbf{f}_1, \dots, \mathbf{f}_m\}$ una base ortonormal de todo el espacio $\mathbb{K}^n$.

La familia $\{\mathbf{g}_1, \dots, \mathbf{g}_{n-m}\}$ genera el complemento ortogonal $V^\perp$ del subespacio V .

En particular, el algoritmo demuestra que el espacio total $\mathbb{K}^n$ se puede descomponer ortogonalmente a partir de cualquier subespacio V de $\mathbb{K}^n$ (*descomposición ortogonal*)

$$V \oplus V^\perp = \mathbb{K}^n, \text{ para todo subespacio } V \subset \mathbb{K}^n. \quad (15)$$

Ejemplo 100. Retomamos los cálculos de ejemplo 99 para completar la base ortonormal del subespacio $V = \langle B \rangle$ hasta conseguir una base ortonormal del espacio completo $\mathbb{R}^4$.

Como, de momento, tenemos tres vectores en nuestra familia ortonormal $\{\mathbf{f}_1, \mathbf{f}_2, \mathbf{f}_3\}$ y la dimensión de $\mathbb{R}^4$ es 4, acabaremos cuando añadamos un cuarto vector $\mathbf{g}_1$ ortonormal a los anteriores.

Aplicamos el algoritmo Gram-Schmidt sobre los vectores de la base canónica de $\mathbb{R}^4$. Comenzamos con $\mathbf{v} = \mathbf{e}_1 = (1, 0, 0, 0)$:

$$\begin{aligned}\mathbf{u} &= \mathbf{v} - (\mathbf{f}_1^\top \mathbf{v}) \mathbf{f}_1 - (\mathbf{v}^\top \mathbf{f}_2) \mathbf{f}_2 - (\mathbf{f}_3^\top \mathbf{v}) \mathbf{f}_3 \\ &= (1, 0, 0, 0) - \frac{1}{14}(1, 0, 3, 2) - \frac{11}{2030}(11, 42, -9, 8) - \frac{-15}{615}(-15, -2, 7, 19) \\ &= \frac{1}{29}(-2, 3, 2, -2).\end{aligned}$$

Como $\mathbf{u} \neq \mathbf{0}$, el vector $\mathbf{e}_1$ era exterior al subespacio original. Normalizamos $\mathbf{u}$ para obtener el cuarto y último vector de nuestra base de $\mathbb{R}^4$:

$$\mathbf{g}_1 = \frac{1}{\sqrt{21}}(-2, 3, 2, -2).$$

Habiendo alcanzado el número máximo de vectores linealmente independientes para la dimensión del espacio, el proceso concluye. El conjunto $\{\mathbf{f}_1, \mathbf{f}_2, \mathbf{f}_3, \mathbf{g}_1\}$ constituye una base ortonormal de $\mathbb{R}^4$.

Es fundamental destacar que este nuevo vector $\mathbf{g}_1$, al haber sido construido ortogonal a todos los anteriores por el propio diseño del algoritmo, es el vector que genera el complemento ortogonal $V^\perp$ del subespacio inicial $V = \langle B \rangle$, es decir,

$$\mathbb{R}^4 = V \oplus V^\perp = \langle B \rangle \oplus \langle \mathbf{g}_1 \rangle.$$

Observemos que, como $\mathbb{R}^4$ tiene dimensión 4 y V tiene dimensión 3, el complemento ortogonal $V^\perp$ tiene dimensión $4 - 3 = 1$. $\square$

6.3. Proyección ortogonal

La descomposición ortogonal de la expresión (15) se denomina también *suma directa ortogonal* y significa que cualquier vector de $\mathbb{K}^n$ se representa de forma única como suma de un vector de V y otro de $V^\perp$: para todo $\mathbf{w} \in \mathbb{K}^n$ existen unos únicos $\mathbf{v} \in V, \mathbf{u} \in V^\perp$ tales que $\mathbf{w} = \mathbf{v} + \mathbf{u}$. El vector $\mathbf{v}$ se denomina *proyección ortogonal* del vector $\mathbf{w}$ sobre el subespacio V (revítese en la página 62 el concepto de suma directa).

El propio algoritmo de Gram-Schmidt nos da la expresión de la proyección ortogonal $\mathbf{v}$ de un vector $\mathbf{w}$ sobre el subespacio V generado por la base ortonormal $\{\mathbf{f}_1, \mathbf{f}_2, \dots, \mathbf{f}_m\}$, pues $\mathbf{u} = \mathbf{w} - \sum_{j=1}^m (\mathbf{f}_j^\top \mathbf{w}) \mathbf{f}_j$ pertenece a $V^\perp$, mientras que $\mathbf{v} = \sum_{j=1}^m (\mathbf{f}_j^\top \mathbf{w}) \mathbf{f}_j \in V$.

Por lo tanto, la proyección ortogonal de $\mathbf{w}$ sobre el subespacio V viene dada por:

$$\text{proj}_V(\mathbf{w}) = \sum_{j=1}^m (\mathbf{f}_j^\top \mathbf{w}) \mathbf{f}_j. \quad (16)$$

En ocasiones, se necesitará una expresión explícita de la proyección ortogonal $\text{proj}_V(\mathbf{w})$ sobre el subespacio V generado por una base que no sea ortonormal, sin tener que emplear el algoritmo de Gram-Schmidt.

Sea $A \in \mathbb{K}^{n \times m}$ la matriz que tiene por columnas a los elementos de la base de V . Como las columnas de A son linealmente independientes, también lo son las de la matriz cuadrada $A^\top A \in \mathbb{K}^{m \times m}$, por lo que ese trata de una matriz invertible. En efecto, si $(A^\top A)\mathbf{b} = \mathbf{0}$ para un $\mathbf{b} \in \mathbb{K}^m$, entonces $\mathbf{b}^\top A^\top (A\mathbf{b}) = 0$, lo que implica $(A\mathbf{b})^\top (A\mathbf{b}) = \|A\mathbf{b}\|^2 = 0$, es decir, $A\mathbf{b} = \mathbf{0}$. Pero esto solo ocurre si $\mathbf{b} = \mathbf{0}$, porque las columnas de A son linealmente independientes.

A continuación, veamos que el vector $\mathbf{u} = \mathbf{w} - A(A^\top A)^{-1}A^\top \mathbf{w}$ es ortogonal a V , es decir, que $A^\top \mathbf{u} = \mathbf{0}$:

$$A^\top \mathbf{u} = A^\top (\mathbf{w} - A(A^\top A)^{-1}A^\top \mathbf{w}) = A^\top \mathbf{w} - (A^\top A)(A^\top A)^{-1}A^\top \mathbf{w} = A^\top \mathbf{w} - A^\top \mathbf{w} = \mathbf{0}.$$

Como $\mathbf{v} = A(A^\top A)^{-1}A^\top \mathbf{w}$ pertenece a V (por ser una combinación lineal de las columnas de A), concluimos que la proyección ortogonal de $\mathbf{w}$ sobre el subespacio V generado por la base formada por las columnas de $A \in \mathbb{K}^{n \times m}$ viene dada por:

$$\text{proj}_V(\mathbf{w}) = A(A^\top A)^{-1}A^\top \mathbf{w}. \quad (17)$$

Ejemplo 101. Sean $\mathbf{w} \in \mathbb{R}^4$ y el subespacio $V = \langle \mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3 \rangle$ dados por:

$$\mathbf{w} = \begin{bmatrix} 1 \\ 2 \\ -1 \\ 3 \end{bmatrix}, \quad \mathbf{a}_1 = \begin{bmatrix} 1 \\ 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{a}_2 = \begin{bmatrix} 1 \\ 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{a}_3 = \begin{bmatrix} 0 \\ 1 \\ 1 \\ 1 \end{bmatrix}$$

Como $\{\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3\}$ no es una base ortonormal, aplicamos el procedimiento de Gram-Schmidt para obtener una base ortonormal $\{\mathbf{f}_1, \mathbf{f}_2, \mathbf{f}_3\}$ de V :

$$\mathbf{f}_1 = \frac{\mathbf{a}_1}{\|\mathbf{a}_1\|} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \\ 0 \end{bmatrix},$$

$$\mathbf{u}_2 = \mathbf{a}_2 - (\mathbf{f}_1^\top \mathbf{a}_2)\mathbf{f}_1 = \begin{bmatrix} \frac{1}{2} \\ 1 \\ -\frac{1}{2} \\ 0 \end{bmatrix} \Rightarrow \mathbf{f}_2 = \frac{\mathbf{u}_2}{\|\mathbf{u}_2\|} = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 \\ 2 \\ -1 \\ 0 \end{bmatrix},$$

$$\mathbf{u}_3 = \mathbf{a}_3 - (\mathbf{f}_1^\top \mathbf{a}_3)\mathbf{f}_1 - (\mathbf{f}_2^\top \mathbf{a}_3)\mathbf{f}_2 = \begin{bmatrix} -2/3 \\ 2/3 \\ 2/3 \\ 1 \end{bmatrix} \Rightarrow \mathbf{f}_3 = \frac{1}{\sqrt{21}} \begin{bmatrix} -2 \\ 2 \\ 2 \\ 3 \end{bmatrix}.$$

Ahora, calculamos la proyección ortogonal mediante la expresión (16)

$$\text{proj}_V(\mathbf{w}) = 0 + \begin{bmatrix} 1 \\ 2 \\ -1 \\ 0 \end{bmatrix} + \frac{9}{21} \begin{bmatrix} -2 \\ 2 \\ 2 \\ 3 \end{bmatrix} = \begin{bmatrix} 1/7 \\ 20/7 \\ -1/7 \\ 9/7 \end{bmatrix}.$$

□

Ejemplo 102. Calculemos de nuevo la proyección ortogonal del ejemplo 101 mediante la expresión matricial (17) para bases arbitrarias, $\text{proj}_V(\mathbf{w}) = A(A^\top A)^{-1}A^\top \mathbf{w}$:

$$\begin{aligned} \text{proj}_V(\mathbf{w}) &= \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 0 & 1 \\ 0 & 0 & 1 \end{bmatrix} \left[\begin{bmatrix} 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 0 & 1 \\ 0 & 0 & 1 \end{bmatrix} \right]^{-1} \begin{bmatrix} 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ -1 \\ 3 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 0 & 1 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 3 \end{bmatrix}^{-1} \begin{bmatrix} 0 \\ 3 \\ 4 \end{bmatrix} = \frac{1}{7} \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 0 & 1 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 5 & -2 & -1 \\ -2 & 5 & -1 \\ -1 & -1 & 3 \end{bmatrix} \begin{bmatrix} 0 \\ 3 \\ 4 \end{bmatrix} \\ &= \frac{1}{7} \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 0 & 1 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} -10 \\ 11 \\ 9 \end{bmatrix} = \begin{bmatrix} 1/7 \\ 20/7 \\ -1/7 \\ 9/7 \end{bmatrix}. \end{aligned}$$

□

6.4. Matrices ortogonales

Decimos que una matriz cuadrada $Q \in \mathbb{K}^{n \times n}$ es *ortogonal* si sus columnas forman una base ortonormal de $\mathbb{K}^n$, lo que equivale a la condición $Q^\top Q = I$, es decir, a que $Q^\top$ sea una inversa por la izquierda de Q . Pero, hemos visto que una inversa por la derecha de una matriz cuadrada también lo es por la izquierda, luego $QQ^\top = I$. Por lo tanto,

$$Q \in \mathbb{K}^{n \times n} \text{ es ortogonal} \iff Q^\top Q = QQ^\top = I \iff Q^{-1} = Q^\top.$$

Notación y terminología. Las matrices que hemos llamado «ortogonales» se denominan habitualmente *matrices unitarias* y se reserva el adjetivo «ortogonal» para las matrices

unitarias reales, que verifican $Q^\top = Q^T$. Como las aplicaciones más frecuentes se dan para $\mathbb{K} = \mathbb{R}$, preferimos emplear la palabra «ortogonal» también cuando $\mathbb{K} = \mathbb{C}$. $\square$

Ejemplo 103. Las matrices de permutación (página 77) son ortogonales, porque sus columnas corresponden a la base canónica reordenada y la base canónica es ortonormal. $\square$

Ejemplo 104. Comprobamos que la matriz:

$$Q = \frac{1}{7} \begin{bmatrix} 2 & 3 & 6 \\ 6 & 2 & -3 \\ -3 & 6 & -2 \end{bmatrix}$$

es ortogonal, para lo que multiplicamos $Q^\top Q$:

$$\begin{aligned} Q^\top Q &= \frac{1}{49} \begin{bmatrix} 2 & 6 & -3 \\ 3 & 2 & 6 \\ 6 & -3 & -2 \end{bmatrix} \begin{bmatrix} 2 & 3 & 6 \\ 6 & 2 & -3 \\ -3 & 6 & -2 \end{bmatrix} \\ &= \frac{1}{49} \begin{bmatrix} 4 + 36 + 9 & 6 + 12 - 18 & 12 - 18 + 6 \\ 6 + 12 - 18 & 9 + 4 + 36 & 18 - 6 - 12 \\ 12 - 18 + 6 & 18 - 6 - 12 & 36 + 9 + 4 \end{bmatrix} = \frac{1}{49} \begin{bmatrix} 49 & 0 & 0 \\ 0 & 49 & 0 \\ 0 & 0 & 49 \end{bmatrix} = I. \end{aligned}$$

$\square$

Nota 6. Como ya se ha anticipado, la inversión explícita de matrices es, por lo general, una operación computacionalmente prohibitiva. Muy pocas clases de matrices permiten obtener su inversa de forma eficiente; entre estas notables excepciones destacan las matrices triangulares (cuyo cálculo mediante sustitución ya hemos analizado) y, de manera sobresaliente, las matrices ortogonales, en las que el coste de la inversión es prácticamente nulo al reducirse a la conjugación y transposición: $Q^{-1} = Q^\top$. $\square$

Ejemplo 105. Consideremos la matriz particionada

$$M = \begin{bmatrix} A & B \\ \mathbf{0} & C \end{bmatrix},$$

en donde los bloques $A \in \mathbb{K}^{n \times n}$ y $C \in \mathbb{K}^{m \times m}$ son matrices ortogonales, mientras que $B \in \mathbb{K}^{n \times m}$ es una matriz arbitraria, de manera que $M \in \mathbb{R}^{k \times k}$ para $k = n + m$.

Para determinar la inversa $M^{-1} = \begin{bmatrix} X & Y \\ Z & W \end{bmatrix}$, planteamos el producto por bloques:

$$\begin{bmatrix} A & B \\ \mathbf{0} & C \end{bmatrix} \begin{bmatrix} X & Y \\ Z & W \end{bmatrix} = I_k = \begin{bmatrix} I_n & \mathbf{0} \\ \mathbf{0} & I_m \end{bmatrix},$$

para $X \in \mathbb{K}^{n \times n}$, $Y \in \mathbb{K}^{n \times m}$, $Z \in \mathbb{K}^{m \times n}$, $W \in \mathbb{K}^{m \times m}$. El sistema resultante es:

$$\begin{cases} AX + BZ = I_n \\ AY + BW = \mathbf{0} \\ CZ = \mathbf{0} \\ CW = I_m \end{cases} \Rightarrow \begin{cases} AX + BZ = I_n \\ AY + BW = \mathbf{0} \\ Z = \mathbf{0} \\ W = C^\top \end{cases} \Rightarrow \begin{cases} X = A^\top \\ Y = -A^\top B C^\top \\ Z = \mathbf{0} \\ W = C^\top \end{cases}.$$

De este modo, la inversa por bloques se reduce a:

$$M^{-1} = \begin{bmatrix} A^\top & -A^\top B C^\top \\ \mathbf{0} & C^\top \end{bmatrix} \in \mathbb{K}^{k \times k}.$$

Es fundamental advertir que $M \in \mathbb{K}^{k \times k}$ no es una matriz ortogonal ni una matriz triangular ordinaria; es una *matriz triangular por bloques* con bloques ortogonales en la diagonal, una propiedad completamente distinta.

Para visualizarlo con claridad, podemos considerar, por ejemplo, $n = m = 2$ y las matrices ortogonales $A = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}$ y $C = \begin{bmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix}$, junto con el bloque $B = \begin{bmatrix} 3 & 5 \\ 7 & 2 \end{bmatrix}$.

Al deshacer los bloques, la matriz global M se concreta en:

$$M = \begin{bmatrix} A & B \\ \mathbf{0} & C \end{bmatrix} = \begin{bmatrix} 0 & 1 & 3 & 5 \\ -1 & 0 & 7 & 2 \\ 0 & 0 & \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ 0 & 0 & -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix}.$$

La presencia de los valores $-1 \neq 0$, en la posición $(2, 1)$, y $-\frac{\sqrt{2}}{2} \neq 0$, en la posición $(4, 3)$, muestra que M no es triangular en el sentido ordinario del término, sino triangular por bloques. Tampoco es M una matriz ortogonal.

La triangularidad por bloques ortogonales preserva la eficiencia del cálculo de la inversa propia de las matrices triangulares y de las ortogonales. $\square$

Aplicación a la informática. La simplicidad con la que se invierten las matrices ortogonales no es solo un resultado teórico importante, sino uno de los pilares de la IA. Como se irá viendo a lo largo de la carrera, los algoritmos de IA procesan millones de transformaciones matriciales por segundo. Si estas matrices requirieran inversiones costosas, los sistemas colapsarían por inestabilidad numérica o falta de potencia de cálculo. $\square$

TEMA III

MATRICES Y TENSORES COMO APLICACIONES LINEALES O MULTILINEALES

1. LOS TENSORES COMO APLICACIONES

En el capítulo anterior hemos estudiado diversas operaciones con tensores, entre ellas la *contracción de índices*, operación que combina las componentes de uno o varios tensores para obtener un nuevo tensor de orden inferior.

Esta operación admite también otra interpretación de gran importancia: al considerar algunos de los tensores participantes como variables, podemos interpretar que un tensor determina una *aplicación* que asocia a cada tensor de entrada un tensor de salida. Es decir, un tensor, junto con una operación de contracción, determina una *transformación* entre espacios de tensores.

En esta asignatura nos centramos en un escenario particular, el más simple: estudiamos únicamente transformaciones entre espacios de vectores (es decir, entre espacios de tensores de orden 1). Incluso, dentro de ese escenario, casi siempre trabajaremos con transformaciones determinadas por matrices (tensores de orden 2).

Ejemplo 106. Si fijamos una matriz arbitraria $A \in \mathbb{R}^{n \times m}$ (tensor de orden 2), consideramos como variable un vector $\mathbf{x} \in \mathbb{R}^m$ y contraemos el segundo índice de la matriz A con el único de $\mathbf{x}$ (lo que, como sabemos, corresponde al producto de matrices), obtenemos una aplicación $f: \mathbb{R}^m \rightarrow \mathbb{R}^n$ mediante $f(\mathbf{x}) = A\mathbf{x}$.

Con la notación de variables dependiente–independiente y empleando subíndices, la misma aplicación se expresa como $y_i = \sum_{j=1}^m a_{ij}x_j$, en donde, como es costumbre en ocasiones (aunque no siempre), empleamos la letra y para las imágenes: $y = f(\mathbf{x})$.

Concretamos lo anterior en un ejemplo numérico: la matriz

$$A = \begin{bmatrix} 2 & 3 & 4 \\ -1 & 0 & 1 \end{bmatrix} \in \mathbb{R}^{2 \times 3}$$

determina la siguiente aplicación $f: \mathbb{R}^3 \rightarrow \mathbb{R}^2$ mediante multiplicación por la derecha

(contracción del segundo índice de A con el único índice del vector variable):

$$f(x_1, x_2, x_3) = \begin{bmatrix} 2 & 3 & 4 \\ -1 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 2x_1 + 3x_2 + 4x_3 \\ -x_1 + x_3 \end{bmatrix} = (2x_1 + 3x_2 + 4x_3, -x_1 + x_3),$$

lo que también puede describirse como $(y_1, y_2) = (2x_1 + 3x_2 + 4x_3, -x_1 + x_3)$. $\square$

Ejemplo 107. Sin contraemos simultáneamente el primer índice de una matriz $A \in \mathbb{R}^{n \times m}$ (tensor de orden 2) con el único de una variable $\mathbf{u} \in \mathbb{R}^n$ y el segundo índice de A con el único de $\mathbf{v} \in \mathbb{R}^m$ (multiplicación por la derecha y por la izquierda, respectivamente), obtenemos la aplicación $g: \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}$ dada $g(\mathbf{u}, \mathbf{v}) = \mathbf{u}^T A \mathbf{v}$.

Con la notación de variables dependiente–independiente y empleando subíndices, la misma aplicación se expresa como $y = \sum_{i=1}^n \sum_{j=1}^m a_{ij} u_i v_j$.

Veamos un caso numérico con la matriz $A \in \mathbb{R}^{2 \times 3}$ del ejemplo 106:

$$\begin{aligned} g(\mathbf{u}, \mathbf{v}) &= \mathbf{u}^T A \mathbf{v} = \begin{bmatrix} u_1 & u_2 \end{bmatrix} \begin{bmatrix} 2 & 3 & 4 \\ -1 & 0 & 1 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \\ v_3 \end{bmatrix} = \begin{bmatrix} u_1 & u_2 \end{bmatrix} \begin{bmatrix} 2v_1 + 3v_2 + 4v_3 \\ -v_1 + v_3 \end{bmatrix} \\ &= 2u_1 v_1 + 3u_1 v_2 + 4u_1 v_3 - u_2 v_1 + u_2 v_3, \end{aligned}$$

que es una aplicación de $\mathbb{R}^2 \times \mathbb{R}^3$ en $\mathbb{R}$. $\square$

Ejemplo 108. Aunque las cuentas a mano son aquí más farragosas que en los dos ejemplos anteriores, si contraemos los tres índices del tensor H de orden 3 de Levi-Civita (ejemplo 63) con los índices de tres variables vectoriales, $\mathbf{u}, \mathbf{v}, \mathbf{w} \in \mathbb{R}^3$, respectivamente, se obtiene la aplicación $h: \mathbb{R}^3 \times \mathbb{R}^3 \times \mathbb{R}^3 \rightarrow \mathbb{R}$ dada por

$$h(\mathbf{u}, \mathbf{v}, \mathbf{w}) = \sum_{i,j,k=1}^3 h_{ijk} u_i v_j w_k = u_1 v_2 w_3 - u_1 v_3 w_2 - u_2 v_1 w_3 + u_2 v_3 w_1 + u_3 v_1 w_2 - u_3 v_2 w_1,$$

expresión que probablemente se reconocerá como el determinante de la matriz

$$\begin{bmatrix} \mathbf{u} & \mathbf{v} & \mathbf{w} \end{bmatrix} = \begin{bmatrix} u_1 & v_1 & w_1 \\ u_2 & v_2 & w_2 \\ u_3 & v_3 & w_3 \end{bmatrix}.$$

Volveremos al determinante más adelante. $\square$

En este capítulo nos centraremos en las transformaciones entre espacios de vectores que desarrollan y especifican las ideas de los ejemplos 106, 107 y 108:

1. Aplicaciones $f: \mathbb{K}^m \rightarrow \mathbb{K}^n$ de la forma $f(\mathbf{x}) = A\mathbf{x}$, en donde $A \in \mathbb{K}^{n \times m}$.

Su propiedad fundamental es la **linealidad**, que se deduce inmediatamente de las propiedades del producto de matrices: para todos $\mathbf{u}, \mathbf{v} \in \mathbb{K}^m$, $\alpha, \beta \in \mathbb{K}$, se verifica

$$f(\alpha \mathbf{u} + \beta \mathbf{v}) = A(\alpha \mathbf{u} + \beta \mathbf{v}) = \alpha A\mathbf{u} + \beta A\mathbf{v} = \alpha f(\mathbf{u}) + \beta f(\mathbf{v}). \quad (18)$$

La linealidad se reconoce en la expresión en subíndices de f , porque cada componente y_i de $f(\mathbf{x})$ es una combinación lineal, $y_i = \sum_{j=1}^m a_{ij}x_j$, de las componentes x_j de $\mathbf{x}$ con las componentes a_{ij} de A como pesos.

2. Aplicaciones $g: \mathbb{K}^n \times \mathbb{K}^n \rightarrow \mathbb{K}$ que son el resultado de contraer los dos índices de una matriz cuadrada $A \in \mathbb{R}^{n \times n}$ (tensor de orden 2) con los índices de los 2 vectores variables $\mathbf{u}, \mathbf{v} \in \mathbb{K}^n$ para obtener $g(\mathbf{u}, \mathbf{v}) = \mathbf{u}^T A \mathbf{v}$.

Estas aplicaciones se expresan en la notación de índices como

$$g(\mathbf{u}, \mathbf{v}) = \mathbf{u}^T A \mathbf{v} = \sum_{i,j=1}^n a_{ij} u_i v_j \quad (19)$$

Su propiedad fundamental es la **bilinealidad**, que es la linealidad respecto de cada variable cuando se deja fija la otra.

Efectivamente, si fijamos uno de los vectores $\mathbf{u}, \mathbf{v}$, digamos $\mathbf{u}$, resulta una aplicación lineal $\mathbf{v} \in \mathbb{K}^n \rightarrow g(\mathbf{u}, \mathbf{v}) = (\mathbf{u}^T A) \mathbf{v} \in \mathbb{K}$, pues en la expresión (19) se observa que $g(\mathbf{u}, \mathbf{v})$ es una combinación lineal de las n componentes de $\mathbf{v}$, ya que las componentes de $\mathbf{u}$, al considerarse un vector fijo, serían constantes.

Estas aplicaciones se denominan **formas bilineales en $\mathbb{K}^n \times \mathbb{K}^n$** . En particular, las **formas bilineales simétricas en $\mathbb{K}^n \times \mathbb{K}^n$** son aquellas en las que la matriz A es simétrica (página 73), lo que equivale a decir que no se alteran cuando se permutan sus dos entradas. El mismo criterio se sigue para definir las **formas bilineales antisimétricas** (matriz A antisimétrica), aunque no las estudiaremos:

$$\begin{aligned} g(\mathbf{u}, \mathbf{v}) &= g(\mathbf{v}, \mathbf{u}), & (\text{simétrica}). \\ g(\mathbf{u}, \mathbf{v}) &= -g(\mathbf{v}, \mathbf{u}), & (\text{antisimétrica}). \end{aligned}$$

Aunque todas las definiciones de esta sección se aplican tanto cuando el campo de escalares considerado es $\mathbb{K} = \mathbb{R}$, como cuando es $\mathbb{K} = \mathbb{C}$, hay una modificación importante de la bilinealidad que tiene un sentido específico cuando $\mathbb{K} = \mathbb{C}$.

Decimos que una aplicación $g: \mathbb{K}^n \times \mathbb{K}^n \rightarrow \mathbb{K}$ es **sesquilineal** si existe una matriz $A \in \mathbb{K}^{n \times n}$ tal que $g(\mathbf{u}, \mathbf{v}) = \mathbf{u}^T A \mathbf{v}$ para todos $\mathbf{u}, \mathbf{v} \in \mathbb{K}^n$.

El prefijo «sesqui» proviene del latín clásico; se utilizaba para expresar «uno y medio» o «la unidad más su mitad».

Cuando $\mathbb{K} = \mathbb{R}$, los términos «bilineal» y «sesquilineal» coinciden y se emplea el primero. Cuando $\mathbb{K} = \mathbb{C}$, son dos conceptos totalmente diferentes: solamente la aplicación idénticamente nula es bilineal y sesquilineal simultáneamente en $\mathbb{C}$:

$$i g(\mathbf{u}, \mathbf{v}) = g(i\mathbf{u}, \mathbf{v}) = \bar{i} g(\mathbf{u}, \mathbf{v}) \implies 2i g(\mathbf{u}, \mathbf{v}) = 0 \implies g(\mathbf{u}, \mathbf{v}) = 0.$$

3. Aplicaciones $h: \mathbb{K}^n \times \cdots \times \mathbb{K}^n \rightarrow \mathbb{K}$ que son el resultado de contraer los n índices de tamaño n de un tensor $H \in \mathbb{K}^{n \times \cdots \times n}$ con los índices correspondientes de los n vectores variables $\mathbf{u}_1, \dots, \mathbf{u}_n \in \mathbb{K}^n$.

Es natural establecer la identificación $\mathbb{K}^n \times \cdots \times \mathbb{K}^n = \mathbb{K}^{n \times n}$, asociando a la n -tupla de vectores $(\mathbf{u}_1, \dots, \mathbf{u}_n)$ la matriz que tiene esos vectores como columnas, $U = [[\mathbf{u}_1, \dots, \mathbf{u}_n]]$, de manera que .

Su expresión con subíndices es un poco aparatosa, porque H tiene n ejes:

$$h(U) = h(\mathbf{u}_1, \dots, \mathbf{u}_n) = \sum_{j_1, j_2, \dots, j_n=1}^n h_{j_1 j_2 \dots j_n} u_{1j_1} u_{2j_2} \cdots u_{nj_n}. \quad (20)$$

Observemos que $h(\mathbf{e}_{k_1}, \mathbf{e}_{k_2}, \dots, \mathbf{e}_{k_n}) = h_{k_1 k_2 \dots k_n}$, pues $e_{kj} = (\mathbf{e}_k)_j = 0$, si $k \neq j$, $e_{kj} = (\mathbf{e}_k)_j = 1$, si $k = j$, y todos los sumandos de (20) se anulan, salvo el correspondiente a $j_1 = k_1, j_2 = k_2, \dots, j_n = k_n$.

Evitaremos, siempre que sea posible, emplear expresiones con tantos subíndices.

Una propiedad esencial de estas aplicaciones es la *multilinealidad*, que es la linealidad respecto de cada variable, cuando se consideran fijas las otras.

Efectivamente, si fijamos todos los vectores $\mathbf{u}_1, \dots, \mathbf{u}_n$ excepto uno de ellos, $\mathbf{u}_k$, resulta una aplicación lineal

$$\mathbf{u}_k \in \mathbb{K}^n \rightarrow h(\mathbf{u}_1, \dots, \mathbf{u}_k, \dots, \mathbf{u}_n) \in \mathbb{K},$$

pues en la expresión (20) se observa que $h(U)$ es una combinación lineal de las n componentes de $\mathbf{u}_k$, ya que las componentes de los otros vectores, al considerarse fijos, serían constantes.

Estas aplicaciones se denominan *formas multilineales en $\mathbb{K}^{n \times n}$* . En particular, las *formas multilineales antisimétricas en $\mathbb{K}^{n \times n}$* son aquellas en las que el tensor H es antisimétrico (página 73), lo que equivale a decir que cambian de signo cuando se permutan dos de las entradas. El mismo criterio se sigue para definir las *formas multilineales simétricas* (tensor H simétrico), aunque no las estudiaremos:

$$h(\mathbf{u}_1, \dots, \mathbf{u}_i, \dots, \mathbf{u}_j, \dots, \mathbf{u}_n) = -h(\mathbf{u}_1, \dots, \mathbf{u}_j, \dots, \mathbf{u}_i, \dots, \mathbf{u}_n), \quad (\text{antisimétrica}).$$

$$h(\mathbf{u}_1, \dots, \mathbf{u}_i, \dots, \mathbf{u}_j, \dots, \mathbf{u}_n) = h(\mathbf{u}_1, \dots, \mathbf{u}_j, \dots, \mathbf{u}_i, \dots, \mathbf{u}_n), \quad (\text{simétrica}).$$

En seguida veremos que, esencialmente, solo existe una forma multilinear antisimétrica en $\mathbb{K}^{n \times n}$, que es el determinante.

Vemos que el término *forma* se emplea cuando el espacio lineal final es precisamente el cuerpo de escalares $\mathbb{K}$, que es un espacio lineal de dimensión 1 sobre sí mismo.

Los conceptos que hemos ido introduciendo en esta sección se pueden establecer en un marco más general, el de los espacios vectoriales abstractos.

III.1: Aplicaciones lineales y multilineales

- Dados dos espacios vectoriales, X, Y , sobre el cuerpo de escalares $\mathbb{K}$, se dice que una aplicación $f: X \rightarrow Y$ es *lineal* si verifica:

$$f(\alpha \mathbf{u} + \beta \mathbf{v}) = \alpha f(\mathbf{u}) + \beta f(\mathbf{v}), \text{ para todos } \mathbf{u}, \mathbf{v} \in X, \alpha, \beta \in \mathbb{K}.$$

Cuando el espacio final es $Y = \mathbb{K}$, la aplicación f se denomina *forma lineal*.

- Dados $n + 1$ espacios vectoriales $X_1, \dots, X_n, Y$ sobre el cuerpo $\mathbb{K}$, se dice que una aplicación $f: X_1 \times \dots \times X_n \rightarrow Y$ es *multilineal* si es lineal respecto de cada variable cuando se consideran fijas las demás.

Cuando el espacio final es $Y = \mathbb{K}$ y los espacios iniciales son iguales, $X = X_1 = X_2 = \dots = X_n$, la aplicación f se denomina *forma multilineal*.

- Una forma multilineal $f: X \times \dots \times X \rightarrow Y$ es *simétrica* si verifica

$$f(\mathbf{u}_1, \dots, \mathbf{u}_i, \dots, \mathbf{u}_j, \dots, \mathbf{u}_n) = f(\mathbf{u}_1, \dots, \mathbf{u}_j, \dots, \mathbf{u}_i, \dots, \mathbf{u}_n)$$

para todos $\mathbf{u}_1, \dots, \mathbf{u}_n \in X, 1 \leq i < j \leq n$.

Una forma multilineal $f: X \times \dots \times X \rightarrow Y$ es *antisimétrica* si verifica

$$f(\mathbf{u}_1, \dots, \mathbf{u}_i, \dots, \mathbf{u}_j, \dots, \mathbf{u}_n) = -f(\mathbf{u}_1, \dots, \mathbf{u}_j, \dots, \mathbf{u}_i, \dots, \mathbf{u}_n)$$

para todos $\mathbf{u}_1, \dots, \mathbf{u}_n \in X, 1 \leq i < j \leq n$.

- Las aplicaciones lineales y multilineales entre espacios de funciones se suelen denominar también *operadores*.

Ejemplo 109. Entre las siguientes funciones de $\mathbb{R}$ en $\mathbb{R}$:

$$\begin{aligned} y = 3x + 1; \quad y = 1; \quad y = x^2; \quad y = 1 - x; \quad y = |x|; \quad y = 3x; \quad y = 0 \\ y = -x; \quad y = \cos x; \quad y = \sqrt{x^2}; \quad y = (x + 1)^5; \quad y = -4x; \quad y = \frac{1}{1+x^2}; \quad y = e^x, \end{aligned}$$

solo son lineales $y = 3x; y = 0; y = -x$ e $y = -4x$. Las funciones lineales de $\mathbb{R}$ en $\mathbb{R}$ son las de la forma $y = ax$ con $a \in \mathbb{R}$. □

Ejemplo 110. Sea V el subespacio de $\mathbb{R}^{\mathbb{R}}$ formado por las funciones polinómicas,

$$p(x) = a_n x^n + a_{n-1} x^{n-1} + \cdots + a_1 x + a_0.$$

Se trata de un subespacio de dimensión infinita, por que la familia $\{1, x, x^2, \dots, x^n, \dots\}$ tiene infinitos elementos y es linealmente independiente.

La aplicación $D: V \rightarrow V$ que a cada polinomio le asigna su derivada, $D(p) = p'$,

$$(D(p))(x) = p'(x) = na_n x^{n-1} + (n-1)a_{n-1} x^{n-2} + \cdots + a_1,$$

es un operador lineal, pues la derivada de una suma coincide la suma de las derivadas y las constantes salen fuera de la derivación:

$$(D(\alpha p + \beta q))(x) = (\alpha p + \beta q)'(x) = \alpha p'(x) + \beta q'(x) = (\alpha D(p) + \beta D(q))(x).$$

Por supuesto, ¡eso no significa que la derivada de un polinomio concreto sea una aplicación lineal de $\mathbb{R}$ en $\mathbb{R}$! Por ejemplo, si $p(x) = x^3$, entonces $(Dp)(x) = p'(x) = 3x^2$, pero $y = 3x^2$ no es una aplicación lineal de $\mathbb{R}$ en $\mathbb{R}$. $\square$

Ejemplo 111. Si V es el espacio de funciones polinómicas del ejemplo 110, la aplicación $f: V \rightarrow V$ definida por $(f(p))(x) = \int_0^x p(t) dt$ es un operador lineal, porque la integral de una suma es la suma de las integrales y las constantes salen fuera de la integral.

La aplicación $g: V \rightarrow \mathbb{R}$ definida por $g(p) = \int_0^3 p(t) dt$ es una forma lineal. $\square$

Ejemplo 112. La aplicación «adición» $f: \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$ definida por $f(x_1, x_2) = x_1 + x_2$, es una forma lineal (el espacio lineal inicial es $\mathbb{R} \times \mathbb{R} \equiv \mathbb{R}^2$), pero *no* es una forma bilineal. En efecto, si fijamos la primera variable $x_1 = \mu \neq 0$, por ejemplo, obtenemos una aplicación $h(x_2) = \mu + x_2$ que no es lineal. $\square$

Ejemplo 113. La aplicación «multiplicación» $g: \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$ definida por el producto de las variables, $g(x_1, x_2) = x_1 x_2$, es una forma bilineal, pero *no* es una forma lineal. $\square$

Aunque el cálculo del determinante es costoso y rara vez se realiza de forma directa en la práctica, se trata de un concepto teórico indispensable para entender las propiedades clave que vamos a estudiar en este capítulo. Por ese motivo, comenzamos por el final, por el tercer tipo de aplicaciones de la relación anterior.

2. EL DETERMINANTE

2.1. Definición y propiedades

Si una forma multilineal $h: \mathbb{K}^{n \times n} \rightarrow \mathbb{K}$ es antisimétrica, dado que el tensor de n ejes asociado H es también antisimétrico (págs. 71 y 73), al permutar los valores de los índices de la componente $h_{j_1 j_2 \dots j_n}$ de H , cambia únicamente su signo, no su valor absoluto.

En particular, $h_{j_1 j_2 \dots j_n} = 0$ cuando coinciden los valores de dos de los n índices, pues el cero es el único número igual a su opuesto. En caso contrario, si todos los índices toman valores diferentes, entonces $|h_{j_1 j_2 \dots j_n}| = |h_{1 2 \dots n}|$ y el signo de $h_{j_1 j_2 \dots j_n}$ solo depende de cómo estén reordenados sus índices.

En consecuencia, si $h, g: \mathbb{K}^{n \times n} \rightarrow \mathbb{K}$ son formas multilineales antisimétricas no idénticamente nulas, se tiene $g = \frac{g_{1 2 \dots n}}{h_{1 2 \dots n}} h$, es decir, salvo una constante multiplicativa, solo existe una forma multilineal antisimétrica en $\mathbb{K}^{n \times n}$.

Se denomina *determinante* a la única forma multilineal antisimétrica $\det: \mathbb{K}^{n \times n} \rightarrow \mathbb{K}$ que verifica $\det(I_n) = 1$.

El tensor de n ejes, $H \in \mathbb{K}^{n \times \dots \times n}$, asociado al determinante se denomina *tensor de Levi-Civita de orden n* y sus componentes son

$$h_{j_1 j_2 \dots j_n} = \det \begin{bmatrix} \mathbf{e}_{j_1} & \mathbf{e}_{j_2} & \dots & \mathbf{e}_{j_n} \end{bmatrix}. \quad (21)$$

En el ejemplo 63 ya se vio el tensor de Levi-Civita de orden 3.

La componente $h_{j_1 j_2 \dots j_n}$, cuando todos los índices toman valores diferentes, es el determinante de una matriz de permutación y se denomina *signatura* de esa permutación. Su valor, como veremos, solo puede ser 1 o -1 .

Aunque la definición de determinante que hemos dado es simple, su desarrollo suele enrevesarse por el exceso de subíndices (véanse las expresiones (20) y (21)):

$$\det(A) = \sum_{j_1, j_2, \dots, j_n=1}^n \det \begin{bmatrix} \mathbf{e}_{j_1} & \mathbf{e}_{j_2} & \dots & \mathbf{e}_{j_n} \end{bmatrix} a_{1j_1} a_{2j_2} \dots a_{nj_n}. \quad (22)$$

Abordamos las propiedades básicas del determinante intentando reducir esta notación.

- (a) Al multiplicar una matriz $A \in \mathbb{K}^{n \times n}$ por un escalar $\alpha \in \mathbb{K}$, se está multiplicando por α cada una de sus columnas, de manera que:

$$\begin{aligned} \det(\alpha A) &= \det \begin{bmatrix} \alpha \mathbf{a}_1 & \alpha \mathbf{a}_2 & \dots & \alpha \mathbf{a}_n \end{bmatrix} = \alpha \det \begin{bmatrix} \mathbf{a}_1 & \alpha \mathbf{a}_2 & \dots & \alpha \mathbf{a}_n \end{bmatrix} \\ &= \alpha^2 \det \begin{bmatrix} \mathbf{a}_1 & \mathbf{a}_2 & \alpha \mathbf{a}_3 & \dots & \alpha \mathbf{a}_n \end{bmatrix} = \alpha^n \det \begin{bmatrix} \mathbf{a}_1 & \mathbf{a}_2 & \dots & \mathbf{a}_n \end{bmatrix} = \alpha^n \det(A). \end{aligned}$$

- (b) Si $\det(A) \neq 0$, entonces la aplicación $\rho_A: \mathbb{K}^{n \times n} \rightarrow \mathbb{K}$ definida por

$$\rho_A(X) = \frac{1}{\det(A)} \det(AX) = \frac{1}{\det(A)} \det[A\mathbf{x}_1 \ A\mathbf{x}_2 \ \dots \ A\mathbf{x}_n]$$

es multilineal (si fijamos todas las $\mathbf{x}_j$ menos una, queda una aplicación lineal) y antisimétrica (pues el determinante lo es). Además, $\rho_A(I) = \frac{1}{\det(A)} \det(A) = 1$, luego $\rho_A = \det$ y $\det(AX) = \det(A) \det(X)$ para cualquier matriz $X \in \mathbb{K}^{n \times n}$.

Si $\det(A) = 0$, la forma multilineal antisimétrica $\sigma_A(X) = \det(AX)$ verifica $\sigma_A(I_n) = 0$, luego σ_A es idénticamente nula: $\det(AX) = 0$ para toda $X \in \mathbb{K}^{n \times n}$.

Por lo tanto, $\det(AB) = \det(A) \det(B)$ para todas las matrices $A, B \in \mathbb{K}^{n \times n}$.

- (c) Si permutamos dos columnas iguales, la matriz A se queda como estaba, pero su determinante debe cambiar de signo (por la antisimetría). El único número que no se altera al cambiarlo de signo es el cero. Por lo tanto, si A tiene dos columnas iguales, su determinante es nulo.

- (d) Si la primera columna de A es combinación lineal de las otras, entonces

$$\det \left[\sum_{j=2}^n \alpha_j \mathbf{u}_j \quad \mathbf{u}_2 \quad \dots \quad \mathbf{u}_n \right] = \sum_{j=2}^n \alpha_j \det [\mathbf{u}_j \quad \mathbf{u}_2 \quad \dots \quad \mathbf{u}_n] = 0,$$

porque la matriz de la derecha tiene la columna $\mathbf{u}_j$ repetida.

El razonamiento se puede aplicar a cualquier columna, no solo a la primera, luego $\det(A) = 0$ cuando las columnas de A son linealmente dependientes, pues en ese caso alguna columna sería combinación lineal de las otras.

Si las columnas de A son linealmente independientes, entonces A es invertible y

$$1 = \det(I_n) = \det(AA^{-1}) = \det(A) \det(A^{-1}),$$

por lo que $\det(A) \neq 0$ y $\det(A^{-1}) = \frac{1}{\det(A)}$.

En consecuencia, $\det(A) \neq 0$ si y solo si A es invertible, lo que, como sabemos, equivale a la independencia lineal de las columnas de A .

- (e) Si añadimos a la primera columna la combinación lineal $\mathbf{v} = \sum_{j=2}^n \alpha_j \mathbf{u}_j$:

$$\begin{aligned} \det [\mathbf{u}_1 + \mathbf{v} \quad \mathbf{u}_2 \quad \dots \quad \mathbf{u}_n] &= \det [\mathbf{u}_1 \quad \mathbf{u}_2 \quad \dots \quad \mathbf{u}_n] + \det [\mathbf{v} \quad \mathbf{u}_2 \quad \dots \quad \mathbf{u}_n] \\ &= \det [\mathbf{u}_1 \quad \mathbf{u}_2 \quad \dots \quad \mathbf{u}_n] + 0 = \det [\mathbf{u}_1 \quad \mathbf{u}_2 \quad \dots \quad \mathbf{u}_n]. \end{aligned}$$

De ahí se sigue que el determinante no se altera si se añade a una columna una combinación lineal de las demás.

(f) Gracias a (22) vemos que

$$\det(X^T) = \sum_{j_1, j_2, \dots, j_n=1}^n \det[\mathbf{e}_{j_1} \ \mathbf{e}_{j_2} \ \dots \ \mathbf{e}_{j_n}] x_{j_1 1} x_{j_2 2} \cdots x_{j_k k} \cdots x_{j_n n},$$

por lo que la aplicación $\tau: \mathbb{R}^{n \times n} \rightarrow \mathbb{K}$ dada por $\tau(X) = \det(X^T)$ es multilinear, antisimétrica y verifica $\tau(I_n) = \det(I_n^T) = \det(I_n) = 1$. Por lo tanto, $\tau = \det$, de manera que $\det(X^T) = \det(X)$ para toda matriz $X \in \mathbb{R}^{n \times n}$.

En consecuencia, todo lo afirmado para las columnas en los apartados anteriores es válido también para las filas.

III.2: Definición y propiedades del determinante

El *determinante* se define como la forma multilinear antisimétrica $\det: \mathbb{K}^{n \times n} \rightarrow \mathbb{K}$ que verifica $\det(I_n) = 1$.

El determinante, $\det: \mathbb{K}^{n \times n} \rightarrow \mathbb{K}$, es una *forma homogénea de grado n* :

$$\det(\alpha A) = \alpha^n \det(A), \text{ para todos } A \in \mathbb{K}^{n \times n}, \alpha \in \mathbb{K}.$$

El determinante del producto es el producto de los determinantes:

$$\det(AB) = \det(A) \det(B) \text{ para todas las matrices } A, B \in \mathbb{K}^{n \times n}.$$

El determinante de una matriz es igual al de su transpuesta: $\det(A^T) = \det(A)$.

Una matriz $A \in \mathbb{K}^{n \times n}$ es invertible si y solo si $\det(A) \neq 0$, en cuyo caso

$$\det(A^{-1}) = \frac{1}{\det(A)}.$$

El determinante cambia de signo si se permutan dos columnas y no se altera si se añade a una columna una combinación lineal de las demás. Lo anterior es también cierto para las filas.

Los determinantes de las submatrices principales, $A_k = (a_{ij})_{1 \leq i, j \leq k}$ de la matriz $A \in \mathbb{K}^{n \times m}$ se denominan *menores principales líderes* de A o, en nuestro contexto, simplemente *menores principales* de A (ver pág. 71).

 El determinante $\det: \mathbb{K}^{n \times n} \rightarrow \mathbb{K}$ no es una aplicación lineal. En general, el determinante no es aditivo, $\det(A + B) \neq \det(A) + \det(B)$. No obstante, algunas raras clases

de matrices verifican la aditividad $\det(A + B) = \det(A) + \det(B)$, por ejemplo, las matrices antisimétricas de tamaño n impar, pero eso es así porque tienen determinante nulo: $\det(A) = \det(A^T) = \det(-A) = (-1)^n \det(A) = -\det(A)$, luego $\det(A) = 0$. $\square$

La aplicación directa de la expresión (22) para el cálculo del determinantes de matrices de gran tamaño es poco eficiente computacionalmente, por lo que se prefiere emplear métodos de triangulación como los que se verán en Tema 4 (página 168).

Aplicación a la informática. La biblioteca NumPy de Phyton incorpora funciones para realizar operaciones de álgebra lineal. En particular, el determinante puede calcularse mediante la función `np.linalg.det`. Por ejemplo, el determinante de la matriz $A = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$ se calcula mediante el siguiente código:

```
import numpy as np
A = np.array([[2, 1], [1, 3]])
detA = np.linalg.det(A)
print(detA)
```

La salida obtenida es 5.0000000000000001. Es natural preguntarse por qué no sale el resultado exacto al operar en un sistema que maneja 52 cifras de significando, si los números 1, 2 y 3 se representan con 2 cifras significativas en base 2 y la operación es tan simple como $2 \times 3 - 1 \times 1 = 5$.

El motivo no es el redondeo en coma flotante de esas sencillas operaciones. Las bibliotecas científicas de Python están diseñadas para resolver sistemas masivos de dimensiones arbitrarias (1000×1000 o más). Por esta razón, el ejecutan algoritmos basados en transformaciones sistemáticas de la matriz (algoritmos que estudiaremos en el Tema 4). En el proceso, se hacen divisiones y ahí aparecen números que deben redondearse a la precisión de la máquina. Estos minúsculos errores se propagan y se acumulan ligeramente durante el proceso. El resultado final es una consecuencia inevitable de representar números reales con un número finitos de cifras. $\square$

2.2. Cálculo del determinante de matrices especiales

Observemos que en todos los sumandos de la expresión (22) aparecen posiciones tanto por encima de la diagonal principal, como por debajo de ella, excepto en el sumando con $j_k = k$ para todo k , que corresponde a la diagonal. Por lo tanto, el determinante de una matriz triangular es el producto de los elementos de su diagonal.

Ejemplo 114. Para calcular el determinante de la matriz triangular

$$A = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 6 & 2 & 0 & 0 \\ 9 & 8 & 3 & 0 \\ 3 & 5 & 2 & 1 \end{bmatrix},$$

basta multiplicar los elementos de la diagonal: $\det(A) = 1 \cdot 2 \cdot 3 \cdot 1 = 6$. $\square$

Podemos utilizar el mismo tipo de razonamiento que hemos empleado al deducir las propiedades básicas del determinante para calcular el de algunas matrices con una estructura especial.

Ejemplo 115. Si conocemos el determinante de $A \in \mathbb{K}^{k \times k}$, podemos calcular el de

$$B = \begin{bmatrix} A & \mathbf{0} \\ \mathbf{0} & I_{n-k} \end{bmatrix},$$

considerando la forma multilinear y alternada $\rho: \mathbb{K}^{k \times k} \rightarrow \mathbb{K}$ dada por

$$\rho(X) = \det \begin{bmatrix} X & \mathbf{0} \\ \mathbf{0} & I_{n-k} \end{bmatrix}.$$

Como $\rho(I_k) = \det(I_n) = 1$, se tiene $\rho = \det$, luego $\det(B) = \rho(A) = \det(A)$. $\square$

Ejemplo 116. Si conocemos los determinantes de $A \in \mathbb{K}^{k \times k}$ y de $B \in \mathbb{K}^{m \times m}$, podemos calcular el de la matriz diagonal por bloques

$$C = \begin{bmatrix} A & \mathbf{0} \\ \mathbf{0} & B \end{bmatrix}.$$

En efecto, como

$$C = \begin{bmatrix} A & \mathbf{0} \\ \mathbf{0} & B \end{bmatrix} = \begin{bmatrix} A & \mathbf{0} \\ \mathbf{0} & I_m \end{bmatrix} \begin{bmatrix} I_k & \mathbf{0} \\ \mathbf{0} & B \end{bmatrix},$$

podemos aplicar la propiedad las ideas del ejemplo 115 para concluir que

$$\det(C) = \det \begin{bmatrix} A & \mathbf{0} \\ \mathbf{0} & B \end{bmatrix} = \det \begin{bmatrix} A & \mathbf{0} \\ \mathbf{0} & I_m \end{bmatrix} \det \begin{bmatrix} I_k & \mathbf{0} \\ \mathbf{0} & B \end{bmatrix} = \det(A) \det(B).$$

$\square$

La estrategia del ejemplo 116 se puede aplicar con cualquier número de bloques, de manera que el determinante de una matriz diagonal por bloques es igual al producto de los determinantes de sus bloques:

$$\det \begin{bmatrix} A_1 & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & A_2 & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & A_k \end{bmatrix} = \det(A_1) \det(A_2) \cdots \det(A_k),$$

en donde $A_i \in \mathbb{K}^{n_i \times n_i}$ para $i = 1, \dots, k$, con $n_1 + n_2 + \dots + n_k = n$.

Ejemplo 117. Calculemos ahora el determinante de la matriz triangular por bloques

$$D = \begin{bmatrix} A & C \\ \mathbf{0} & B \end{bmatrix},$$

suponiendo que conocemos los determinantes de $A \in \mathbb{K}^{k \times k}$ y de $B \in \mathbb{K}^{m \times m}$.

Si A es invertible, D se factoriza como el producto de una matriz diagonal por bloques y otra unitriangular superior:

$$D = \begin{bmatrix} A & C \\ \mathbf{0} & B \end{bmatrix} = \begin{bmatrix} A & \mathbf{0} \\ \mathbf{0} & B \end{bmatrix} \begin{bmatrix} I_k & A^{-1}C \\ \mathbf{0} & I_m \end{bmatrix}.$$

Por lo tanto, $\det(D) = \det(AB) \cdot 1 = \det(A) \det(B)$.

Si A no es invertible, sus columnas son linealmente dependientes, por lo que también lo serán las correspondientes columnas de D . De esta manera, $\det(A) = 0$ y $\det(D) = 0$.

En todos los casos se verifica:

$$\det \begin{bmatrix} A & C \\ \mathbf{0} & B \end{bmatrix} = \det(A) \det(B),$$

lo que simplifica el cálculo del determinante de una matriz triangular por bloques. $\square$

Ejemplo 118. Calculamos el determinante de una matriz triangular superior por bloques:

$$\begin{aligned} \det \begin{bmatrix} 1 & 0 & 0 & 0 & 6 & 7 & 9 \\ 4 & 1 & 0 & 0 & 4 & 7 & 8 \\ 9 & 7 & 2 & 0 & 1 & -5 & 9 \\ 8 & 9 & 5 & 3 & 3 & 5 & 4 \\ 0 & 0 & 0 & 0 & 1 & 6 & 9 \\ 0 & 0 & 0 & 0 & 0 & -1 & 7 \\ 0 & 0 & 0 & 0 & 0 & 0 & 4 \end{bmatrix} &= \det \begin{bmatrix} 1 & 0 & 0 & 0 \\ 4 & 1 & 0 & 0 \\ 9 & 7 & 2 & 0 \\ 8 & 9 & 5 & 3 \end{bmatrix} \det \begin{bmatrix} 1 & 6 & 9 \\ 0 & -1 & 7 \\ 0 & 0 & 4 \end{bmatrix} \\ &= (1 \cdot 1 \cdot 2 \cdot 3)(1 \cdot (-1) \cdot 4) = -24 \end{aligned}$$

$\square$

Ejemplo 119. Para calcular el determinante de una matriz « 2×2 por bloques»:

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix},$$

en donde A y D son matrices cuadradas y A es invertible, multiplicamos las siguientes matrices triangulares y comprobamos que se obtiene nuestra matriz « 2×2 por bloques»:

$$\begin{bmatrix} I & \mathbf{0} \\ CA^{-1} & I \end{bmatrix} \begin{bmatrix} A & \mathbf{0} \\ \mathbf{0} & D - CA^{-1}B \end{bmatrix} \begin{bmatrix} I & A^{-1}B \\ \mathbf{0} & I \end{bmatrix} = \begin{bmatrix} A & \mathbf{0} \\ C & D - CA^{-1}B \end{bmatrix} \begin{bmatrix} I & A^{-1}B \\ \mathbf{0} & I \end{bmatrix}$$

$$= \begin{bmatrix} A & B \\ C & (CA^{-1}B) + (D - CA^{-1}B) \end{bmatrix} = \begin{bmatrix} A & B \\ C & D \end{bmatrix}.$$

Solo resta multiplicar los determinantes de esas tres matrices triangulares por bloques:

$$\det \begin{bmatrix} A & B \\ C & D \end{bmatrix} = 1 \cdot \det(A(D - CA^{-1}B)) \cdot 1 = \det(A) \det(D - CA^{-1}B).$$

Fórmula que resulta de gran utilidad. □

2.3. Interpretación geométrica del determinante

Hemos comentado ya cómo históricamente los vectores surgieron como segmentos orientados en el plano y en el espacio tridimensional de la geometría euclídea, que se corresponde con nuestro «espacio sensible» o intuitivo.


Hay que tener presente que la geometría es muchísimo más antigua que el álgebra. Hasta el siglo XIX, la base de todas las matemáticas era la geometría de Euclides. A partir de ella se definían las magnitudes, como la longitud, el área o el volumen; de hecho, del concepto de magnitud procede la propia noción de número real. Solo posteriormente se invirtió la estructura lógica, colocando en la base la teoría de conjuntos y el álgebra.

Hoy carece de sentido definir el concepto de área tal como se hace en las matemáticas escolares. Por otra parte, definir el concepto de área o el de volumen para conjuntos generales que no sean simplemente polígonos o poliedros es un problema muy difícil que no vamos a abordar en esta asignatura.

Si lo anterior se aplica al espacio tridimensional, con mucha más razón lo hacemos al considerar espacios de dimensiones muy altas en donde no existe (ni necesitamos) la intuición geométrica, ni disponemos de un espacio sensible.

Lo cierto es que las áreas, superficies y volúmenes de figuras que tengan bordes «simples» se definen algebraicamente. Por lo tanto, no se trata de hallar una fórmula para calcular áreas o volúmenes, sino de proporcionar una definición correcta, basada en el álgebra, de esos conceptos en cualquier dimensión.

Esta generalización de la noción de volumen no es una curiosidad matemática, sino una herramienta esencial en IA. En ciencia de datos, la información compleja se representa mediante espacios de muchas dimensiones donde las ideas geométricas habituales desaparecen (lo que a menudo dificulta procesar los datos de forma intuitiva). Comprender cómo se miden los volúmenes o las distancias de manera algebraica en estos entornos es lo que permite que los algoritmos analicen patrones, manejen grandes volúmenes de

Figura 17. Paralelogramo generado por las columnas de la matriz A .

información y aprendan a clasificar datos de forma eficiente, más allá de lo que nuestra imaginación tridimensional puede alcanzar.

Ejemplo 120. Tal y como se hace en la etapa escolar, concebimos un plano intuitivo como una hoja de papel que se extiende hasta el infinito. En esa hoja dibujamos dos rectas perpendiculares que nos sirven para introducir las coordenadas cartesianas de la enseñanza básica. Sobre esa hoja podemos dibujar segmentos, podemos también poner una flechita en uno de sus extremos, con lo que los consideramos orientados, y desplazarlos por el plano. Esa sería la noción de «vector» de la enseñanza elemental.

Las columnas $\mathbf{u} = (2, 1)$ y $\mathbf{v} = (1, 3)$ de la matriz $A = [\mathbf{u} \ \mathbf{v}]$, es decir,

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix},$$

pueden interpretarse como vectores del plano intuitivo: «colocados» en el punto $(0, 0)$ (recordemos que estamos exponiendo un ejemplo en términos escolares), determinan un paralelogramo (figura 17). Se puede calcular el área de ese paralelogramo restando las áreas de las regiones coloreadas del área del rectángulo de base $[0, 3]$ y altura $[0, 4]$:

$$\text{Área} = (3 \cdot 4) - \frac{2 \cdot 1}{2} - (1 \cdot 1) - \frac{1 \cdot 3}{2} - \frac{1 \cdot 2}{2} - (1 \cdot 1) - \frac{1 \cdot 3}{2} = 5,$$

lo que coincide con el valor del determinante: $\det(A) = 2 \cdot 3 - 1 \cdot 1 = 5$. $\square$

⚠ En matemáticas no hay unidades: las longitudes, las áreas y los volúmenes son números, por lo que se debe evitar a toda costa poner cosas como $5u$, $5u^2$ o $5u^3$. Las matemáticas

crean modelos abstractos que se interpretan de manera diferente en cada disciplina aplicada. Si el contexto es aplicado y no puramente matemático, se emplearán las unidades correctas, nunca la letra «u». Un área que matemáticamente es 5, puede corresponder a «5 m²», a «5 kWh», a «5 personas × mes», etc. En los dos últimos casos, por ejemplo, ¿a qué puede referirse la letra «u»? □

De la misma manera que un punto $p \in \mathbb{R}^n$ y un vector $\mathbf{u} \in \mathbb{R}^n$ determinan el segmento $P_1 = \{p + t\mathbf{u} : 0 \leq t \leq 1\}$, un punto y un par de vectores $\mathbf{u}_1, \mathbf{u}_2$ (que, colocados como columnas, forman una matriz $[\mathbf{u}_1 \ \mathbf{u}_2] \in \mathbb{R}^{n \times 2}$) determinan el paralelogramo $P_2 = \{p + t_1\mathbf{u}_1 + t_2\mathbf{u}_2 : 0 \leq t_1, t_2 \leq 1\}$ de $\mathbb{R}^n$. En general, un punto $p \in \mathbb{R}^n$ y una matriz $A = [\mathbf{u}_1 \ \dots \ \mathbf{u}_k] \in \mathbb{R}^{n \times k}$, determinan el *paralelepípedo k -dimensional* del espacio n -dimensional $P_k = \{p + t_1\mathbf{u}_1 + \dots + t_k\mathbf{u}_k : 0 \leq t_j \leq 1\}$.




Figura 18. Al segmento P_1 se le asigna un elemento de $\mathbb{R}^n \equiv \mathbb{R}^{n \times 1}$ (vector); al paralelogramo P_2 , una matriz de $\mathbb{R}^{n \times 2}$ (par de vectores); al paralelepípedo P_3 , una matriz de $\mathbb{R}^{n \times 3}$ (terna de vectores), etc.

Sabemos que la longitud de un segmento se define como el módulo del vector correspondiente. Para proporcionar una definición de medida k -dimensional, interpretamos que el volumen 1-dimensional es la longitud, el volumen 2-dimensional es el área, etc.

III.3: Volumen k -dimensional en $\mathbb{K}^n$

El *volumen k -dimensional* del paralelepípedo k -dimensional P de $\mathbb{K}^n$ asociado a la matriz $A \in \mathbb{K}^{n \times k}$ se define como $|P| = \sqrt{\det(A^\top A)}$.

Observemos que, en el caso particular de que sea $n = k$, se tiene

$$|P| = \sqrt{\det(A^\top A)} = \sqrt{\det(A^\top) \det A} = \sqrt{\det(A) \det(A)} = |\det A|.$$

Ejemplo 121. Si P es el paralelogramo de $\mathbb{R}^2$ de vértices $p_0 = (1, 3)$, $p_1 = (4, 5)$, $p_2 = (4, -1)$, $p_3 = (6, -2)$, entonces $\mathbf{u} = p_1 - p_0$, $\mathbf{v} = p_2 - p_0$, y su área es

$$|P| = \left| \det \begin{bmatrix} 4-1 & 4-1 \\ 5-3 & -1-3 \end{bmatrix} \right| = |-18| = 18.$$

□

Ejemplo 122. El volumen del paralelepípedo P de $\mathbb{R}^3$ con vértices $p_0 = (1, 3, -1)$, $p_1 = (4, 5, 6)$, $p_2 = (4, -1, 0)$, $p_3 = (1, 1, 1)$ en el que p_1, p_2 y p_3 están conectados con p_0 por aristas (no hace falta dar los otros cuatro vértices), es

$$|P| = \left| \det \begin{bmatrix} 4-1 & 4-1 & 1-1 \\ 5-3 & -1-3 & 1-3 \\ 6-(-1) & 0-(-1) & 1-(-1) \end{bmatrix} \right| = |-72| = 72.$$

□

Ejemplo 123. Calculemos el área del triángulo T de vértices $p_0 = (1, 2, 4)$, $p_1 = (3, 0, -1)$ y $p_2 = (6, 1, 4)$. El área, $|T|$, del triángulo es la mitad de la del paralelogramo de vértice p_0 y vectores $\mathbf{u} = p_1 - p_0 = (2, -2, -5)$, $\mathbf{v} = p_2 - p_0 = (5, -1, 0)$:

$$|T| = \frac{1}{2} \sqrt{\det \left(\begin{bmatrix} 2 & -2 & -5 \\ 5 & -1 & 0 \end{bmatrix} \begin{bmatrix} 2 & 5 \\ -2 & -1 \\ -5 & 0 \end{bmatrix} \right)} = \frac{1}{2} \sqrt{\det \left(\begin{bmatrix} 33 & 12 \\ 12 & 26 \end{bmatrix} \right)} = \frac{\sqrt{714}}{2}.$$

□

Ejemplo 124. No necesitamos la intuición geométrica para calcular medidas. Hallemos la medida 4-dimensional del paralelepípedo 4-dimensional $P \subset \mathbb{R}^6$ determinado por los

vectores $\mathbf{u}_j = (j, j^2, j^3, j^4, j^5, j^6)$ con $j = -2, -1, 1, 2$:

$$\begin{aligned}
 |P| &= \sqrt{\det \begin{bmatrix} -2 & 4 & -8 & 16 & -32 & 64 \\ -1 & 1 & -1 & 1 & -1 & 1 \\ 1 & 1 & 1 & 1 & 1 & 1 \\ 2 & 4 & 8 & 16 & 32 & 64 \end{bmatrix} \begin{bmatrix} -2 & -1 & 1 & 2 \\ 4 & 1 & 1 & 4 \\ -8 & -1 & 1 & 8 \\ 16 & 1 & 1 & 16 \\ -32 & -1 & 1 & 32 \\ 64 & 1 & 1 & 64 \end{bmatrix}} \\
 &= \sqrt{\det \begin{bmatrix} 5460 & 126 & 42 & 3276 \\ 126 & 6 & 0 & 42 \\ 42 & 0 & 6 & 126 \\ 3276 & 42 & 126 & 5460 \end{bmatrix}} = 12\,096.
 \end{aligned}$$

□

En el caso habitual de que $\mathbb{K} = \mathbb{R}$, la matriz $A^\top A$ de la definición III.3 está formada por productos escalares, así que basta conocer los ángulos y los módulos.

Ejemplo 125. Las tres aristas L_1, L_2 y L_3 que coinciden en un vértice de un tetraedro P miden $|L_1| = 2, |L_2| = 3, |L_3| = 4$ y forman ángulos $\widehat{L_1 L_2} = 60^\circ, \widehat{L_1 L_3} = 30^\circ, \widehat{L_2 L_3} = 45^\circ$. Calculemos el volumen del tetraedro P :

$$\begin{aligned}
 |P| &= \frac{1}{2} \sqrt{\det \left(\begin{bmatrix} \mathbf{u}_1^\top \\ \mathbf{u}_2^\top \\ \mathbf{u}_3^\top \end{bmatrix} \begin{bmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \mathbf{u}_3 \end{bmatrix} \right)} = \frac{1}{2} \sqrt{\det \begin{bmatrix} \mathbf{u}_1 \cdot \mathbf{u}_1 & \mathbf{u}_1 \cdot \mathbf{u}_2 & \mathbf{u}_1 \cdot \mathbf{u}_3 \\ \mathbf{u}_1 \cdot \mathbf{u}_2 & \mathbf{u}_2 \cdot \mathbf{u}_2 & \mathbf{u}_2 \cdot \mathbf{u}_3 \\ \mathbf{u}_1 \cdot \mathbf{u}_3 & \mathbf{u}_2 \cdot \mathbf{u}_3 & \mathbf{u}_3 \cdot \mathbf{u}_3 \end{bmatrix}} \\
 &= \frac{1}{2} \sqrt{\det \begin{bmatrix} 2^2 & 2 \times 3 \times \cos 60^\circ & 2 \times 4 \times \cos 30^\circ \\ 2 \times 3 \times \cos 60^\circ & 3^2 & 3 \times 4 \times \cos 45^\circ \\ 2 \times 4 \times \cos 30^\circ & 3 \times 4 \times \cos 45^\circ & 4^2 \end{bmatrix}} \\
 &= \frac{1}{2} \sqrt{\det \begin{bmatrix} 4 & 3 & 4\sqrt{3} \\ 3 & 9 & 6\sqrt{2} \\ 4\sqrt{3} & 6\sqrt{2} & 16 \end{bmatrix}} = 6\sqrt{\sqrt{6} - 2} \approx 4.022\,639\,772\,61.
 \end{aligned}$$

□

⚠ Mediante cortes y recomposiciones, aplicando III.3 reiteradamente, se pueden calcular las medidas de una infinidad de regiones. Sin embargo, no se pueden calcular las medidas de regiones que tengan sus bordes curvados; ni siquiera podemos definir con precisión qué entendemos por *longitud*, *área* o *volumen* cuando los objetos están *curvados*.

De hecho, tampoco podemos calcular el área de un círculo con la definición III.3, pues necesitamos aproximarlos mediante polígonos (un proceso de paso al límite). $\square$

3. APLICACIONES LINEALES ENTRE ESPACIOS DE VECTORES

3.1. Subespacios de una matriz

Se ha señalado ya que las lineales son las aplicaciones $f: \mathbb{K}^m \rightarrow \mathbb{K}^n$ de la forma $f(\mathbf{x}) = A\mathbf{x}$ para una cierta matriz $A \in \mathbb{K}^{n \times m}$.

El subespacio $\text{col}(A) \subset \mathbb{K}^n$ generado por la columnas de A se denomina *espacio imagen* o *espacio columna* de A y la dimensión de ese subespacio se denomina *rango* de A , esto es, $\text{rng } A = \dim(\text{col } A)$.

El rango $r = \text{rng } A$ es el tamaño de la mayor submatriz cuadrada de A con determinante no nulo. En efecto, de las propiedades del determinante se sigue que una familia de columnas de A es linealmente independiente si y solo si tiene determinante alguna submatriz cuadrada que intercepte a esas columnas y solo a esas.

Por lo tanto, como el determinante de una matriz es igual al de su traspuesta, se concluye que $\text{rng } A^\top = \text{rng } A$.

El subespacio $\text{col}(A^\top) \subset \mathbb{K}^n$ está generado por las conjugadas de las filas de A . Si A es real, $A \in \mathbb{R}^{n \times m}$, entonces, como la traspuesta conjugada, $A^\top$, es lo mismo que la traspuesta, A^T , el subespacio $\text{col}(A^\top) \subset \mathbb{R}^n$ está generado por las filas de A .

El subespacio $\ker A \subset \mathbb{K}^m$ formado por los vectores $\mathbf{u} \in \mathbb{K}^m$ tales que $A\mathbf{u} = \mathbf{0}$ se denomina *núcleo* o *espacio nulo* de A . En inglés «kernel» o «null space».

Sean $r = \text{rng } A$ y $\{\mathbf{f}_1, \mathbf{f}_2, \dots, \mathbf{f}_r\}$ una base ortonormal de $\text{col } A$, que ampliamos a una base ortonormal $\{\mathbf{f}_1, \mathbf{f}_2, \dots, \mathbf{f}_r, \mathbf{f}_{r+1}, \dots, \mathbf{f}_n\}$ de $\mathbb{K}^n$. Todo vector $\mathbf{u} \in \mathbb{K}^n$ se expresa como

$$\mathbf{u} = \sum_{j=1}^n (\mathbf{f}_j^\top \mathbf{u}) \mathbf{f}_j \implies \mathbf{u} = \mathbf{v} + \mathbf{w}, \text{ con } \mathbf{u} = \sum_{j=1}^r (\mathbf{f}_j^\top \mathbf{u}) \mathbf{f}_j, \quad \mathbf{v} = \sum_{j=r+1}^n (\mathbf{f}_j^\top \mathbf{u}) \mathbf{f}_j.$$

Claramente $\mathbf{u} \in \text{col } A$. Además, $\mathbf{v} \in \ker A^\top$, pues $\mathbf{f}_j^\top A = \mathbf{0}$ para $j = r+1, \dots, n$, al ser $\mathbf{f}_i \perp \mathbf{f}_j$ cuando $1 \leq i \leq r < j \leq n$, lo que implica $A^\top \mathbf{f}_j = (\mathbf{f}_j^\top A)^\top = \mathbf{0}$. Por lo tanto, $\text{col } A \oplus \ker A^\top = \mathbb{K}^n$, con $\text{col } A \perp \ker A^\top$.

Se obtiene el mismo resultado reemplazando A por $A^\top$ y así se demuestra el a veces llamado *teorema fundamental del álgebra lineal*, un nombre realmente exagerado.

III.4: «Teorema fundamental del álgebra lineal»

Toda matriz $A \in \mathbb{K}^{n \times m}$ verifica

$$\text{col } A \oplus \ker A^\top = \mathbb{K}^n, \text{ con } \text{col } A \perp \ker A^\top$$

$$\text{col } A^\top \oplus \ker A = \mathbb{K}^m, \text{ con } \text{col } A^\top \perp \ker A.$$

Además, si el rango de $A \in \mathbb{K}^{n \times m}$ es $\text{rng } A = r$:

$$\text{col } A \subset \mathbb{K}^n \text{ tiene dimensión } r,$$

$$\ker(A^\top) \subset \mathbb{K}^n \text{ tiene dimensión } n - r,$$

$$\text{col}(A^\top) \subset \mathbb{K}^m \text{ tiene dimensión } r,$$

$$\ker A \subset \mathbb{K}^m \text{ tiene dimensión } m - r.$$

3.2. Núcleo generalizado

Al multiplicar reiteradamente por sí misma una matriz singular $B \in \mathbb{K}^{n \times n}$ se obtiene una sucesión creciente de subespacios, $\ker B \subset \ker B^2 \subset \cdots \subset \ker B^n$, pues

$$\mathbf{u} \in \ker B^k \implies B^k \mathbf{u} = \mathbf{0} \implies B^{k+1} \mathbf{u} = B^k \mathbf{0} = \mathbf{0} \implies \mathbf{u} \in \ker B^{k+1}.$$

Como las dimensiones de estos núcleos no pueden superar la dimensión n del espacio $\mathbb{K}^n$, existirá exactamente una potencia $p \in \{1, \dots, n\}$ tal que $\ker B^{p-1} \subsetneq \ker B^p = \ker B^{p+1}$. El subespacio $\ker B^p$ se denomina **núcleo generalizado** de la matriz B .

Ejemplo 126. Calculemos la cadena de núcleos para la matriz

$$B = \begin{bmatrix} -3 & -3 & 0 & 0 \\ 1 & 1 & -1 & 0 \\ 4 & 4 & 2 & 0 \\ 0 & -3 & 0 & -3 \end{bmatrix}.$$

Multiplicamos reiteradamente por B y resolvemos el sistema que determina el núcleo, hallando una familia de generadores de ese subespacio:

$$\ker B = \left\{ \mathbf{u} : \begin{bmatrix} -3 & -3 & 0 & 0 \\ 1 & 1 & -1 & 0 \\ 4 & 4 & 2 & 0 \\ 0 & -3 & 0 & -3 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ u_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \right\} = \left\langle \begin{bmatrix} 1 \\ -1 \\ 0 \\ 1 \end{bmatrix} \right\rangle.$$

$$\begin{aligned}\ker B^2 &= \left\{ \mathbf{u} : \begin{bmatrix} 6 & 6 & 3 & 0 \\ -6 & -6 & -3 & 0 \\ 0 & 0 & 0 & 0 \\ -3 & 6 & 3 & 9 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ u_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \right\} = \left\langle \begin{bmatrix} 1 \\ -1 \\ 0 \\ 1 \end{bmatrix}, \begin{bmatrix} 0 \\ -1 \\ 2 \\ 0 \end{bmatrix} \right\rangle. \\ \ker B^3 &= \left\{ \mathbf{u} : \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 27 & 0 & 0 & -27 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ u_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \right\} = \left\langle \begin{bmatrix} 1 \\ -1 \\ 0 \\ 1 \end{bmatrix}, \begin{bmatrix} 0 \\ -1 \\ 2 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \end{bmatrix} \right\rangle. \\ \ker B^4 &= \left\{ \mathbf{u} : \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ -81 & 0 & 0 & 81 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ u_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \right\} = \left\langle \begin{bmatrix} 1 \\ -1 \\ 0 \\ 1 \end{bmatrix}, \begin{bmatrix} 0 \\ -1 \\ 2 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \end{bmatrix} \right\rangle.\end{aligned}$$

Comprobamos que la dimensión de los núcleos va aumentando hasta llegar $\ker B^3$ y, a partir de ahí, se estabiliza. Por lo tanto, $p = 3$ y el núcleo generalizado de la matriz B es $\ker B^3$, subespacio que tiene por base a la familia $\{(1, -1, 0, 1), (0, -1, 2, 0), (1, 0, 0, 1)\}$. Solo el primero de estos vectores está en el núcleo ordinario de B . $\square$

3.3. Autovalores y autovectores

Se dice que un vector no nulo $\mathbf{u} \in \mathbb{C}^n$ es un *autovector* con *autovalor* $\lambda \in \mathbb{C}^n$ de una matriz cuadrada $A \in \mathbb{C}^{n \times n}$ si $A\mathbf{u} = \lambda\mathbf{u}$, o lo que es equivalente, si $\mathbf{u}$ pertenece al subespacio $\ker(\lambda I - A)$, que se denomina *autoespacio* correspondiente al autovalor λ .

 Una matriz real puede tener tanto autovalores como autovectores complejos. $\square$

Si una matriz real $A \in \mathbb{R}^{n \times n}$ tiene un autovalor complejo λ , entonces su conjugado $\bar{\lambda}$ también es autovalor de A pues

$$\ker(\lambda I - A) \neq \mathbf{0} \iff \ker(\overline{\lambda I - A}) \neq \mathbf{0}$$

siendo $\ker(\overline{\lambda I - A}) = \ker(\bar{\lambda} \bar{I} - \bar{A}) = \ker(\bar{\lambda} I - A)$.

Ejemplo 127. El vector $\mathbf{u} = (i, 1) \in \mathbb{C}^2$ es un autovector de la matriz

$$A = \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix} \in \mathbb{R}^{2 \times 2},$$

correspondiente al autovalor $\lambda = 1 + i$, pues

$$A\mathbf{u} = \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} i \\ 1 \end{bmatrix} = \begin{bmatrix} -1 + i \\ 1 + i \end{bmatrix} = (1 + i) \begin{bmatrix} i \\ 1 \end{bmatrix} = \lambda\mathbf{u}.$$

El vector $\bar{\mathbf{u}} = (-i, 1) \in \mathbb{C}^2$ es un autovector de A correspondiente al autovalor $\bar{\lambda} = 1 - i$,

$$A\bar{\mathbf{u}} = \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} -i \\ 1 \end{bmatrix} = \begin{bmatrix} -1 - i \\ 1 - i \end{bmatrix} = (1 - i) \begin{bmatrix} -i \\ 1 \end{bmatrix} = \bar{\lambda}\bar{\mathbf{u}}.$$

□

Claramente, la condición necesaria y suficiente para que un $\lambda_0 \in \mathbb{C}$ sea autovalor de A (para algún autovector $\mathbf{u}$) es que la matriz $\lambda_0 I - A$ sea singular, esto es, que $\lambda = \lambda_0$ sea solución de la ecuación polinómica $\det(\lambda I - A) = 0$.

El polinomio mónico $P_A(\lambda) = \det(\lambda I - A)$ se denomina *polinomio característico* de la matriz A y la ecuación $P_A(\lambda) = 0$, *ecuación característica* de la matriz A .

Gracias al Teorema Fundamental del Álgebra, podemos asegurar que toda matriz cuadrada tiene algún autovalor, de lo donde se deduce la existencia de

Ejemplo 128. Hallemos los autovalores y los autovectores correspondientes de la matriz:

$$A = \begin{bmatrix} 9 & -1 & -5 \\ 2 & 2 & -2 \\ 7 & -3 & -3 \end{bmatrix}.$$

El polinomio característico de A es:

$$P_A(\lambda) = \det(\lambda I - A) = \det \begin{bmatrix} \lambda - 9 & 1 & 5 \\ -2 & \lambda - 2 & 2 \\ -7 & 3 & \lambda + 3 \end{bmatrix} = \lambda^3 - 8\lambda^2 + 16\lambda.$$

Las soluciones de la ecuación característica, $\lambda^3 - 8\lambda^2 + 16\lambda = 0$, se calculan fácilmente porque el ejemplo está «preparado»:

$$\lambda^3 - 8\lambda^2 + 16\lambda = 0 \iff \lambda = 0 \text{ o } \lambda^2 - 8\lambda + 16 = 0 \iff \lambda = 0 \text{ o } \lambda = \frac{8 \pm \sqrt{8^2 - 64}}{2} = 4.$$

La matriz A tiene dos autovalores, $\lambda_1 = 0$ y $\lambda_2 = 4$, con multiplicidades $m_1 = 1$ y $m_2 = 2$, respectivamente. Por lo tanto, $P(\lambda) = \lambda(\lambda - 4)^2$.

El autoespacio $E_1 = \ker(\lambda_1 I - A)$ viene dado por las ecuaciones:

$$(\lambda_1 I - A)\mathbf{u} = \mathbf{0} \iff \begin{bmatrix} -9 & 1 & 5 \\ -2 & -2 & 2 \\ -7 & 3 & 3 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \iff \begin{cases} u_1 = 3t \\ u_2 = 2t \\ u_3 = 5t \end{cases}, \text{ para } t \in \mathbb{R}.$$

El autoespacio E_1 tiene dimensión 1 y está generado por el autovector $\mathbf{u}_1 = (3, 2, 5)$ o por cualquier otro proporcional a él.

El autoespacio $E_2 = \ker(\lambda_2 I - A)$ viene dado por las ecuaciones:

$$(\lambda_2 I - A) \mathbf{u} = \mathbf{0} \iff \begin{bmatrix} -5 & 1 & 5 \\ -2 & 2 & 2 \\ -7 & 3 & 7 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \iff \begin{cases} u_1 = t \\ u_2 = 0 \\ u_3 = t \end{cases}, \text{ para } t \in \mathbb{R}.$$

El autoespacio E_2 tiene dimensión 1, aunque la multiplicidad de $\lambda_2 = 4$ sea $m_2 = 2$, y está generado por el autovalor $\mathbf{u}_1 = (1, 0, 1)$. $\square$

Veamos cuatro importantes propiedades del polinomio característico y los autovalores.

En primer lugar: el polinomio característico no se altera por cambios de bases, es decir, si W es una matriz invertible, se verifica $P_{WAW^{-1}} = P_A$. En efecto:

$$\begin{aligned} P_{WAW^{-1}}(\lambda) &= \det(\lambda I - WAW^{-1}) = \det(W(\lambda I - A)W^{-1}) \\ &= \det(W) \det(\lambda I - A) \det(W^{-1}) = \det(\lambda I - A) = P_A(\lambda). \end{aligned}$$

En segundo lugar, veamos que la multiplicidad de un autovalor λ en el polinomio característico P_A es precisamente la dimensión del núcleo generalizado de la matriz $\lambda I - A$ (pág. 137), que se denomina *autoespacio generalizado*, y a sus elementos, *autovectores generalizados*, correspondiente al autovalor λ .

Razonemos primero suponiendo que $\lambda = 0$ es un autovalor de A . Completamos una base de $\mathbb{K}^n$ a partir de una base $\mathbf{w}_1, \dots, \mathbf{w}_p$ del núcleo generalizado $\ker_\infty A$, con la que formamos una matriz $W = [[\mathbf{w}_1, \dots, \mathbf{w}_p, \mathbf{w}_{p+1}, \dots, \mathbf{w}_n]]$. Como $A\mathbf{w} \in \ker_\infty A$ para todo $\mathbf{w} \in \ker_\infty A$, la matriz $C = W^{-1}AW$, que tiene el mismo polinomio característico que A , debe ser triangular superior con bloque $C_{11} \in \mathbb{K}^{p \times p}$, de forma que

$$\begin{aligned} C = W^{-1}AW &= \begin{bmatrix} C_{11} & C_{12} \\ \mathbf{0} & C_{22} \end{bmatrix} \implies \alpha I_n - C = \begin{bmatrix} \alpha I_p - C_{11} & -C_{12} \\ \mathbf{0} & \alpha I_{n-p} - C_{22} \end{bmatrix} \\ \implies P_C(\alpha) &= \det(\alpha I_n - C) = \det(\alpha I_p - C_{11}) \det(\alpha I_{n-p} - C_{22}) = P_{C_{11}}(\alpha) P_{C_{22}}(\alpha). \end{aligned}$$

Por otra parte, como las p primeras columnas de W están en $\ker A^p$, se tiene

$$\begin{bmatrix} \mathbf{0} & M_{12} \\ \mathbf{0} & M_{22} \end{bmatrix} = W^{-1}A^pW = C^p = \begin{bmatrix} C_{11}^p & M_{12} \\ \mathbf{0} & C_{22}^p \end{bmatrix} \implies C_{11}^p = \mathbf{0}.$$

Así, el único autovalor de C_{11} es 0, es decir, $P_{C_{11}}(\alpha) = \alpha^p$, mientras que $P_{C_{22}}(0) \neq 0$, pues $\mathbf{w}_k \notin \ker_\infty A$ para $k > p$. Por lo tanto, $P_C(\alpha) = \alpha^p P_{C_{22}}(\alpha)$ y la multiplicidad de la raíz $\alpha = 0$ es precisamente p , la dimensión de $\ker_\infty(A)$.

Para extender nuestro razonamiento a cualquier autovalor λ de A no necesariamente nulo, aplicamos lo anterior a la matriz $A' = A - \lambda I$, que tiene autovalor nulo, pues $A'\mathbf{u} = \mathbf{0}$ para todo autovector $\mathbf{u}$ de A de autovalor λ .

Ejemplo 129. Calculemos el polinomio característico de la siguiente matriz

$$A = \begin{bmatrix} 8 & 3 & 0 & 0 \\ -1 & 4 & 1 & 0 \\ -4 & -4 & 3 & 0 \\ 0 & 3 & 0 & 8 \end{bmatrix} \rightarrow P_A(\lambda) = \det(\lambda I - A) = \det \begin{bmatrix} \lambda - 8 & -3 & 0 & 0 \\ 1 & \lambda - 4 & -1 & 0 \\ 4 & 4 & \lambda - 3 & 0 \\ 0 & -3 & 0 & \lambda - 8 \end{bmatrix}$$

$$= (\lambda - 8) \det \begin{bmatrix} \lambda - 8 & -3 & 0 \\ 1 & \lambda - 4 & -1 \\ 4 & 4 & \lambda - 3 \end{bmatrix} = (\lambda - 8)(\lambda - 5)^3.$$

El autovalor $\lambda = 8$ tiene multiplicidad 1, luego su autoespacio debe tener necesariamente dimensión 1, que es, en este caso, la dimensión del núcleo generalizado. En efecto:

$$\ker(8I - A) = \left\{ \mathbf{u} : \begin{bmatrix} 0 & -3 & 0 & 0 \\ 1 & 4 & -1 & 0 \\ 4 & 4 & 5 & 0 \\ 0 & -3 & 0 & 0 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ u_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \right\} = \langle (0, 0, 0, 1) \rangle.$$

$$\ker(8I - A)^2 = \left\{ \mathbf{u} : \begin{bmatrix} -3 & -12 & 3 & 0 \\ 0 & 9 & -9 & 0 \\ 24 & 24 & 21 & 0 \\ -3 & -12 & 3 & 0 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ u_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \right\} = \langle (0, 0, 0, 1) \rangle.$$

Comprobamos que la multiplicidad del autovalor $\lambda = 8$ coincide con la dimensión del núcleo generalizado $\ker_\infty(8I - A) = \ker(8I - A)$, es decir, del autoespacio generalizado correspondiente al autovalor $\lambda = 8$.

La matriz $5I - 8A$ es precisamente la matriz B del ejemplo 126:

$$5I - 8A = \begin{bmatrix} -3 & -3 & 0 & 0 \\ 1 & 1 & -1 & 0 \\ 4 & 4 & 2 & 0 \\ 0 & -3 & 0 & -3 \end{bmatrix}.$$

Según se vio entonces, el núcleo generalizado de esta matriz tiene dimensión 3, lo que coincide con la multiplicidad del autovalor $\lambda = 5$ de A . $\square$

La tercera propiedad que vamos a razonar es la descomposición del espacio global en suma directa de autoespacios generalizados:

$$\ker_\infty(\lambda_1 I - A) \oplus \cdots \oplus \ker_\infty(\lambda_p I - A) = \mathbb{K}^n. \quad (23)$$

en donde $\lambda_1, \dots, \lambda_p$ son todos los autovalores distintos de A , si bien, gracias a la propiedad anterior, basta comprobar que $\ker_\infty(\lambda_j I - A) \cap \ker_\infty(\lambda_i I - A) = \{0\}$ si $\lambda_i \neq \lambda_j$.

Efectivamente, si $\mathbf{v} \in \ker_{\infty}(\lambda_j I - A) \cap \ker_{\infty}(\lambda_i I - A) = \{\mathbf{0}\}$, existen sendos exponentes q y r para los que $\mathbf{w} = (\lambda_i I - A)^r \mathbf{v}$ es un autovalor de A y $(\lambda_j I - A)^q \mathbf{v} = \mathbf{0}$. Como las matrices I , A y sus potencias conmutan:

$$(\lambda_j I - A)^q \mathbf{w} = (\lambda_j I - A)^q (\lambda_i I - A)^r \mathbf{v} = (\lambda_i I - A)^r (\lambda_j I - A)^q \mathbf{v} = (\lambda_i I - A)^r \mathbf{0} = \mathbf{0},$$

pero, como $\mathbf{w}$ es un autovector correspondiente a λ_i ,

$$\begin{aligned} (\lambda_j I - A)\mathbf{w} &= \lambda_j \mathbf{w} - A\mathbf{w} = \lambda_j \mathbf{w} - \lambda_i \mathbf{w} = (\lambda_j - \lambda_i)\mathbf{w} \\ \implies \mathbf{0} &= (\lambda_j I - A)^q \mathbf{w} = (\lambda_j I - A)^{q-1} (\lambda_j - \lambda_i)\mathbf{w} = \dots = (\lambda_j - \lambda_i)^q \mathbf{w} \implies \mathbf{w} = \mathbf{0}. \end{aligned}$$

En cuanto a la cuarta propiedad, como las matrices I , A y sus potencias conmutan, se opera con ellas como si fueran números (salvo para dividir). Si sustituimos la matriz A en su propio polinomio característico $P_A(\lambda) = (\lambda - \lambda_1)^{m_1} \dots (\lambda - \lambda_p)^{m_p}$, obtenemos $P_A(A) = (A - \lambda_1 I)^{m_1} \dots (A - \lambda_p I)^{m_p} \in \mathbb{K}^{n \times n}$, en donde los p factores conmutan, de manera que, poniendo a la derecha el factor adecuado en cada caso, se comprueba que $P_A(A)\mathbf{w} = \mathbf{0}$ para todo autovector generalizado $\mathbf{w}$.

Gracias a (23), podemos formar una base de $\mathbb{K}^n$ con autovectores generalizados, de forma que la matriz $P_A(A)$ debe ser nula, $P_A(A) = \mathbf{0}$, es decir, toda matriz cuadrada anula su propio polinomio característico (*teorema de Cayley-Hamilton*).

Ejemplo 130. Comprobemos que la siguiente matriz anula su polinomio característico

$$A = \begin{bmatrix} 1 & 0 & 2 \\ 1 & 4 & 3 \\ 2 & 1 & 3 \end{bmatrix}.$$

$$P_A(\lambda) = \det(\lambda I - A) = \det \begin{bmatrix} \lambda - 1 & 0 & -2 \\ -1 & \lambda - 4 & -3 \\ -2 & -1 & \lambda - 3 \end{bmatrix} = \lambda^3 - 8\lambda^2 + 12\lambda + 5.$$

$$P_A(A) = A^3 - 8A^2 + 12A + 5I.$$

$$A^2 = AA = \begin{bmatrix} 5 & 2 & 8 \\ 11 & 19 & 23 \\ 9 & 7 & 16 \end{bmatrix} \quad ; \quad A^3 = A^2 A = \begin{bmatrix} 5 & 2 & 8 \\ 11 & 19 & 23 \\ 9 & 7 & 16 \end{bmatrix} \begin{bmatrix} 1 & 0 & 2 \\ 1 & 4 & 3 \\ 2 & 1 & 3 \end{bmatrix} = \begin{bmatrix} 23 & 16 & 40 \\ 76 & 99 & 148 \\ 48 & 44 & 87 \end{bmatrix}$$

$$\begin{aligned} P_A(A) &= \begin{bmatrix} 23 & 16 & 40 \\ 76 & 99 & 148 \\ 48 & 44 & 87 \end{bmatrix} - 8 \begin{bmatrix} 5 & 2 & 8 \\ 11 & 19 & 23 \\ 9 & 7 & 16 \end{bmatrix} + 12 \begin{bmatrix} 1 & 0 & 2 \\ 1 & 4 & 3 \\ 2 & 1 & 3 \end{bmatrix} + 5 \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \\ &= \begin{bmatrix} 23 & 16 & 40 \\ 76 & 99 & 148 \\ 48 & 44 & 87 \end{bmatrix} - \begin{bmatrix} 40 & 16 & 64 \\ 88 & 152 & 184 \\ 72 & 56 & 128 \end{bmatrix} + \begin{bmatrix} 12 & 0 & 24 \\ 12 & 48 & 36 \\ 24 & 12 & 36 \end{bmatrix} + \begin{bmatrix} 5 & 0 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & 5 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}. \end{aligned}$$

Hemos comprobado que $P_A(A) = \mathbf{0}$ sin factorizar el polinomio característico. □

III.5: Autovalores y autovectores

Se dice que $\lambda \in \mathbb{C}$ es un *autovalor* de $A \in \mathbb{C}^{n \times n}$ si $\ker(\lambda I - A) \neq \{\mathbf{0}\}$, en cuyo caso, denominamos *autoespacio* a $\ker(\lambda I - A)$, *autoespacio generalizado* a $\ker_\infty(\lambda I - A)$, *autovectores* a los elementos del primero y *autovectores generalizados* a los del segundo, todo referido al autovalor λ .

Si una matriz real $A \in \mathbb{R}^{n \times n}$ tiene un autovalor complejo, entonces su conjugado también es autovalor de A .

Los autovalores de una matriz $A \in \mathbb{C}^{n \times n}$ son las raíces de su *polinomio característico* $P_A(\lambda) = \det(\lambda I - A)$, por lo que

$$P_A(\lambda) = (\lambda - \lambda_1)^{m_1} \dots (\lambda - \lambda_p)^{m_p},$$

en donde $\lambda_1, \dots, \lambda_p$ son los distintos autovalores de A , de manera que la suma de las multiplicidades $m_1, \dots, m_p$ es igual a n . En particular:

$$\det(A) = (-1)^n P_A(0) = \lambda_1^{m_1} \lambda_2^{m_2} \dots \lambda_p^{m_p}.$$

El polinomio característico no se altera por cambios de bases, es decir, si W es una matriz invertible, se verifica $P_{WAW^{-1}} = P_A$.

La multiplicidad m_j del autovalor λ_j es igual a $\dim(\ker_\infty(\lambda_j I - A))$; además:

$$\ker_\infty(\lambda_1 I - A) \oplus \dots \oplus \ker_\infty(\lambda_p I - A) = \mathbb{K}^n.$$

Toda matriz $A \in \mathbb{C}^{n \times n}$ anula su propio polinomio característico: $P_A(A) = \mathbf{0}$.

Para profundizar. Hemos visto que la dimensión del autoespacio generalizado $E = \ker_\infty(\lambda I - A)$ coincide con la multiplicidad del autovalor λ en el polinomio característico.

La dimensión del autoespacio $\ker(\lambda I - A) \subset E$ se denomina habitualmente *multiplicidad geométrica* de λ . Cuando se adopta esta terminología, a la multiplicidad de λ en el polinomio característico se la suele denominar *multiplicidad algebraica*.

Por criterio didáctico, en este texto optamos por no emplear dicha distinción. Por una parte, el concepto de multiplicidad de la raíz de un polinomio es general y previo al cálculo de autovalores, por lo que resulta más sencillo mantener una terminología uniforme. Por otra parte, dado que tanto la dimensión del autoespacio como la del autoespacio gene-

ralizado admiten lecturas tanto geométricas como algebraicas, prescindir de la dicotomía «geométrica/algebraica» ayuda a simplificar la presentación.

Así pues, la «multiplicidad» de una raíz λ_i de un polinomio P se refiere aquí al sentido habitual: el exponente m_i en la factorización $P(\lambda) = (\lambda - \lambda_1)^{m_1} \cdots (\lambda - \lambda_p)^{m_p}$, donde $\lambda_1, \dots, \lambda_p$ son las distintas raíces del polinomio P . Véase el Teorema Fundamental del Álgebra en el Tema I, página 53. $\square$

Notación y terminología. Es conveniente señalar que en la literatura matemática en español se utilizan con frecuencia las denominaciones *valor propio*, *vector propio* y *espacio propio*, en vez de *autovalor*, *autovector* y *autoespacio*.

Estos conceptos provienen históricamente del alemán, donde el prefijo *eigen-* se traduce como «propio» o «característico» (de ahí los vocablos originales *Eigenwert* y *Eigenvektor*, acuñados por David Hilbert). Aunque la variante «propio» transmite de forma más explícita la idea geométrica subyacente, hemos optado por la variante con el prefijo «auto-» debido a su mayor concisión y comodidad al expresarse en una sola palabra.

Cabe destacar que en la literatura científica en inglés se ha adoptado directamente el prefijo alemán, siendo la terminología estándar *eigenvalue*, *eigenvector* y *eigenspace*. Este uso en inglés es dominante y prácticamente universal en las áreas de álgebra lineal aplicada, ciencia de datos y aprendizaje automático. $\square$

4. FORMAS BILINEALES Y FORMAS CUADRÁTICAS

4.1. Formas bilineales

Hemos visto en el apartado 2.1, página 121, que las formas multilineales cuyo espacio inicial tiene solo dos ejes se denominan bilineales y corresponden a multiplicar la matriz asociada desde la izquierda y la derecha por las variables.

Es decir, la forma bilineal determinada por la matriz $A \in \mathbb{K}^{n \times n}$ es

$$g: \mathbb{K}^n \times \mathbb{K}^n \rightarrow \mathbb{K}, \quad ; \quad g(\mathbf{u}, \mathbf{v}) = \mathbf{u}^T A \mathbf{v} = \sum_{i,j=1}^n a_{ij} u_i v_j.$$

Recíprocamente, la identificación general de las componentes de una matriz (cuadro II.3) permite obtener la matriz A asociada a una forma bilineal $g: \mathbb{K}^n \times \mathbb{K}^n \rightarrow \mathbb{K}$ cuando A no venga dada explícitamente: $a_{ij} = g(\mathbf{e}_i, \mathbf{e}_j)$, para $i = 1, \dots, n$; $j = 1, \dots, m$.

Ejemplo 131. La forma bilineal $b(\mathbf{x}, \mathbf{y}) = \mathbf{x}^T B \mathbf{y}$ cuya matriz asociada es

$$B = \begin{bmatrix} 2 & 1 \\ 5 & 3 \end{bmatrix}$$

se expresa en forma polinómica o «analítica» como

$$\begin{aligned} b(\mathbf{x}, \mathbf{y}) &= \mathbf{x}^T B \mathbf{y} = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 5 & 3 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2y_1 + y_2 \\ 5y_1 + 3y_2 \end{bmatrix} \\ &= 2x_1y_1 + x_1y_2 + 5x_2y_1 + 3x_2y_2. \end{aligned}$$

Se obtiene, como vemos, un polinomio de cuatro variables en el que los sumandos $b_{ij}x_iy_j$ tienen todos grado 2. Si lo que nos dan es el polinomio b , entonces la matriz B se obtiene de forma trivial como $b_{ij} = b(\mathbf{e}_i, \mathbf{e}_j)$:

$$b_{11} = b(\mathbf{e}_1, \mathbf{e}_1) = [2x_1y_1 + x_1y_2 + 5x_2y_1 + 3x_2y_2]_{x_1=1, x_2=0, y_1=1, y_2=0} = 2,$$

$$b_{12} = b(\mathbf{e}_1, \mathbf{e}_2) = [2x_1y_1 + x_1y_2 + 5x_2y_1 + 3x_2y_2]_{x_1=1, x_2=0, y_1=0, y_2=1} = 1,$$

$$b_{21} = b(\mathbf{e}_2, \mathbf{e}_1) = [2x_1y_1 + x_1y_2 + 5x_2y_1 + 3x_2y_2]_{x_1=0, x_2=1, y_1=1, y_2=0} = 5,$$

$$b_{22} = b(\mathbf{e}_2, \mathbf{e}_2) = [2x_1y_1 + x_1y_2 + 5x_2y_1 + 3x_2y_2]_{x_1=0, x_2=1, y_1=0, y_2=1} = 3,$$

coeficientes que, obviamente, coinciden con los de la forma polinómica. $\square$

Notación y terminología. Antiguamente, y todavía hoy en otros contextos, las formas bilineales se expresaban como polinomios de varias variables. Estos polinomios reciben el nombre, de manera misteriosa, de «expresión analítica» de la forma correspondiente.

En el ámbito de la inteligencia artificial, estas expresiones carecen prácticamente de interés porque, al tratarse de espacios de alta dimensión, se obtendrían polinomios con miles de variables y sumandos: objetos imposibles de manipular o de imaginar sin marearse. Por ello, en nuestro contexto del álgebra aplicada a la IA, las formas bilineales solo pueden concebirse de forma matricial.

La excepción radica en los ejemplos y ejercicios académicos, donde los polinomios se usan solo como herramientas didácticas, sin utilidad práctica. $\square$

Si la matriz A es simétrica, entonces la forma bilineal asociada g también lo es

$$g(\mathbf{u}, \mathbf{v}) = \mathbf{u}^T A \mathbf{v} = (\mathbf{u}^T A \mathbf{v})^T = \mathbf{v}^T A^T \mathbf{u} = \mathbf{v}^T A \mathbf{u} = g(\mathbf{v}, \mathbf{u}).$$

Obsérvese que $\mathbf{u}^T A \mathbf{v}$ es un escalar, por lo que $\mathbf{u}^T A \mathbf{v} = (\mathbf{u}^T A \mathbf{v})^T$. Recíprocamente, si $g(\mathbf{u}, \mathbf{v}) = \mathbf{u}^T A \mathbf{v}$ es una forma simétrica, entonces A es una matriz simétrica:

$$\begin{aligned} g(\mathbf{u}, \mathbf{v}) &= g(\mathbf{v}, \mathbf{u}), \text{ para todos } \mathbf{u}, \mathbf{v} \in \mathbb{K}^n \iff \mathbf{v}^T A^T \mathbf{u} = \mathbf{v}^T A \mathbf{u}, \text{ para todos } \mathbf{u}, \mathbf{v} \in \mathbb{K}^n \\ &\iff A^T = A. \end{aligned}$$

De la misma manera se comprueba que una forma bilineal es antisimétrica si y solo si su matriz asociada es antisimétrica.

Modificando el razonamiento anterior en un detalle, sustituir A^T por $A^\top$, se comprueba que una forma sesquilineal g es *hermítica* (lo que es decir, $g(\mathbf{u}, \mathbf{v}) = \overline{g(\mathbf{v}, \mathbf{u})}$) si y solo si la matriz A es *hermítica* ($A^\top = A$) y que una forma sesquilineal g es *antihermítica* (es decir, $g(\mathbf{u}, \mathbf{v}) = -\overline{g(\mathbf{v}, \mathbf{u})}$) si y solo si la matriz A es *antihermítica* ($A^\top = -A$, pág. 73).

⚠ Los términos «simétrica» y «hermítica» coinciden cuando el cuerpo de escalares es $\mathbb{R}$, de la misma manera que «antisimétrica» y «antihermítica». Lo mismo ocurre con «bilineal» y «sesquilineal». Por supuesto, al fijar el campo de escalares en $\mathbb{R}$, se emplean preferentemente los términos tradicionales como «simétrica» y «bilineal», en lugar de la terminología general. Sin embargo, cuando $\mathbb{K}$ puede representar tanto $\mathbb{R}$ como $\mathbb{C}$, o trabajamos explícitamente sobre los complejos, los conceptos difieren por completo. Hay que tener mucho cuidado para no cruzar los términos: por ejemplo, no existe ninguna forma sesquilineal no nula que sea simétrica, ya que el concepto adecuado y natural para una forma sesquilineal es el de forma «hermítica», no «simétrica». □

Ejemplo 132. Consideremos las siguientes matrices

$$A = \begin{bmatrix} -2 & -5 & 4 \\ 9 & 6 & 6 \\ -4 & 0 & 10 \end{bmatrix}; B = \begin{bmatrix} 1+i & 2 & 2+i \\ 2 & 4 & 3 \\ 2+i & 3 & 5 \end{bmatrix}; C = \begin{bmatrix} 6 & 2 & 2-i \\ 2 & 4 & 3 \\ 2+i & 3 & 5 \end{bmatrix}.$$

La matriz A no es simétrica ni antisimétrica, mientras B es simétrica, pero no hermítica. Por su parte, C es hermítica, pero no simétrica. □

En general, una matriz no tiene por qué ser hermítica o antihermítica, aunque siempre se puede descomponer como suma de su *parte hermítica* y de su *parte antihermítica*.

$$A = \frac{A + A^\top}{2} + \frac{A - A^\top}{2},$$

$$A_+ = \frac{A^\top + A}{2} = \left(\frac{A + A^\top}{2} \right)^\top \implies A_+ \text{ es hermítica (simétrica, si es real),}$$

$$A_- = \frac{A^\top - A}{2} = - \left(\frac{A^\top - A}{2} \right)^\top \implies A_- \text{ es antihermítica (antisimétrica, si es real).}$$

Ejemplo 133. La siguiente matriz no es simétrica ni antisimétrica.

$$A = \begin{bmatrix} 5 & 0 & 12 \\ 2i & -2 & i \\ -6 & -i & 2 \end{bmatrix},$$

pero se puede descomponer en suma de una simétrica y otra antisimétrica:

$$\frac{A + A^T}{2} = \begin{bmatrix} 5 & i & 3 \\ i & -2 & 0 \\ 3 & 0 & 2 \end{bmatrix} \text{ (simétrica)}; \quad \frac{A - A^T}{2} = \begin{bmatrix} 0 & -i & 9 \\ i & 0 & i \\ -9 & -i & 0 \end{bmatrix} \text{ (antisimétrica)}$$

$$\frac{A + A^T}{2} + \frac{A - A^T}{2} = \begin{bmatrix} 5 & i & 3 \\ i & -2 & 0 \\ 3 & 0 & 2 \end{bmatrix} + \begin{bmatrix} 0 & -i & 9 \\ i & 0 & i \\ -9 & -i & 0 \end{bmatrix} = \begin{bmatrix} 5 & 0 & 12 \\ 2i & -2 & i \\ -6 & -i & 2 \end{bmatrix} = A.$$

La matriz A tampoco es hermítica ni antihermítica, pero se puede descomponer en suma de una hermítica y otra antihermítica:

$$A_+ = \frac{A + A^\top}{2} = \begin{bmatrix} 5 & -i & 3 \\ i & -2 & i \\ 3 & -i & 2 \end{bmatrix} \text{ (hermítica)}; \quad A_- = \frac{A - A^\top}{2} = \begin{bmatrix} 0 & i & 9 \\ i & 0 & 0 \\ -9 & 0 & 0 \end{bmatrix} \text{ (antihermítica)}$$

$$A_+ + A_- = \begin{bmatrix} 5 & -i & 3 \\ i & -2 & i \\ 3 & -i & 2 \end{bmatrix} + \begin{bmatrix} 0 & i & 9 \\ i & 0 & 0 \\ -9 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 5 & 0 & 12 \\ 2i & -2 & i \\ -6 & -i & 2 \end{bmatrix} = A.$$

□

4.2. Formas cuadráticas

Una forma cuadrática es el resultado de multiplicar una matriz hermítica $A \in \mathbb{K}^{n \times n}$ por la misma variable desde la izquierda y la derecha:

$$f(\mathbf{u}) = \mathbf{u}^\top A \mathbf{u}.$$

Recordemos que «hermítica» es lo mismo que «simétrica» cuando $\mathbb{K} = \mathbb{R}$ y observemos que $f(\mathbf{u})$ es un escalar, por lo que su conjugado $\overline{f(\mathbf{u})}$ verifica

$$\overline{f(\mathbf{u})} = (f(\mathbf{u}))^\top = (\mathbf{u}^\top A \mathbf{u})^\top = \mathbf{u}^\top A^\top \mathbf{u} = \mathbf{u}^\top A \mathbf{u} = f(\mathbf{u}) \implies f(\mathbf{u}) \in \mathbb{R}.$$

De ahí que f esté valorada en $\mathbb{R}$ aunque $\mathbb{K} = \mathbb{C}$, es decir, $f: \mathbb{K}^n \rightarrow \mathbb{R}$.

Para profundizar. Una matriz real $B \in \mathbb{R}^{n \times n}$ siempre define una forma cuadrática $f: \mathbb{R}^n \rightarrow \mathbb{R}$ mediante $f(\mathbf{u}) = \mathbf{u}^\top B \mathbf{u}$, aunque B no sea simétrica. Para comprobarlo, basta separar las partes simétrica y antisimétrica de B :

$$\begin{aligned} f(\mathbf{u}) &= \mathbf{u}^\top B \mathbf{u} = \mathbf{u}^\top \left(\frac{B+B^\top}{2} + \frac{B-B^\top}{4} + \frac{B-B^\top}{4} \right) \mathbf{u} \\ &= \mathbf{u}^\top \left(\frac{B+B^\top}{2} \right) \mathbf{u} + \mathbf{u}^\top \left(\frac{B-B^\top}{4} \right) \mathbf{u} + \left(\mathbf{u}^\top \left(\frac{B-B^\top}{4} \right) \mathbf{u} \right)^\top \\ &= \mathbf{u}^\top \left(\frac{B+B^\top}{2} \right) \mathbf{u} + \mathbf{u}^\top \left(\frac{B-B^\top}{4} \right) \mathbf{u} + \mathbf{u}^\top \left(\frac{B^\top-B}{4} \right) \mathbf{u} = \mathbf{u}^\top \left(\frac{B+B^\top}{2} \right) \mathbf{u}, \end{aligned}$$

por lo que $f(\mathbf{u})$ se puede expresar como $f(\mathbf{u}) = \mathbf{u}^\top A \mathbf{u}$ con $A = \frac{B+B^\top}{2}$ simétrica. □

Ejemplo 134. La aplicación $f: \mathbb{R}^3 \rightarrow \mathbb{R}$ definida por

$$f(\mathbf{x}) = [x_1 \ x_2 \ x_3] \begin{bmatrix} 3 & 3 & -2 \\ 1 & 9 & 12 \\ 10 & -2 & 8 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = 3x_1^2 + 4x_1x_2 + 8x_1x_3 + 9x_2^2 + 10x_2x_3 + 8x_3^2$$

es una forma cuadrática, aunque la matriz

$$B = \begin{bmatrix} 3 & 3 & -2 \\ 1 & 9 & 12 \\ 10 & -2 & 8 \end{bmatrix}$$

no sea simétrica. Comprobamos que efectivamente es una forma cuadrática al obtener la misma aplicación tras sustituir B por su parte *simétrica* $\frac{B+B^\top}{2}$:

$$f(\mathbf{x}) = [x_1 \ x_2 \ x_3] \begin{bmatrix} 3 & 2 & 4 \\ 2 & 9 & 5 \\ 4 & 5 & 8 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = 3x_1^2 + 4x_1x_2 + 8x_1x_3 + 9x_2^2 + 10x_2x_3 + 8x_3^2.$$

□

Se ha señalado ya que la expresión de las formas cuadráticas mediante polinomios carece prácticamente de interés en las ciencias de la computación, debido a la alta dimensionalidad de los espacios que intervienen. No obstante, únicamente con fines didácticos, podemos emplear la siguiente identidad para obtener la matriz simétrica A asociada a una forma cuadrática facilitada mediante un polinomio $f(\mathbf{x})$:

$$\begin{aligned} f(\mathbf{u} + \mathbf{v}) - f(\mathbf{u}) - f(\mathbf{v}) &= (\mathbf{u}^\top + \mathbf{v}^\top)A(\mathbf{u} + \mathbf{v}) - \mathbf{u}^\top A\mathbf{u} - \mathbf{v}^\top A\mathbf{v} \\ &= \mathbf{v}^\top A\mathbf{u} + \mathbf{u}^\top A\mathbf{v} = 2\mathbf{u}^\top A\mathbf{v} \\ \implies a_{ij} &= \mathbf{e}_i^\top A\mathbf{e}_j = \frac{f(\mathbf{e}_i + \mathbf{e}_j) - f(\mathbf{e}_i) - f(\mathbf{e}_j)}{2}. \end{aligned}$$

Ejemplo 135. Si nos facilitan una forma cuadrática mediante el polinomio

$$f(\mathbf{x}) = f(x_1, x_2, x_3) = 3x_1^2 + 4x_1x_2 + 8x_1x_3 + 9x_2^2 + 10x_2x_3 + 8x_3^2,$$

podemos calcular la matriz simétrica A asociada a f de forma sencilla:

$$\begin{aligned} a_{11} &= \frac{f(\mathbf{e}_1 + \mathbf{e}_1) - f(\mathbf{e}_1) - f(\mathbf{e}_1)}{2} = \frac{f(2,0,0) - 2f(1,0,0)}{2} = \frac{3 \cdot 2^2 - 2 \cdot 3 \cdot 1^2}{2} = 3. \\ a_{12} &= \frac{f(\mathbf{e}_1 + \mathbf{e}_2) - f(\mathbf{e}_1) - f(\mathbf{e}_2)}{2} = \frac{f(1,1,0) - f(1,0,0) - f(0,1,0)}{2} = \frac{16 - 3 - 9}{2} = 2. \\ a_{13} &= \frac{f(\mathbf{e}_1 + \mathbf{e}_3) - f(\mathbf{e}_1) - f(\mathbf{e}_3)}{2} = \frac{f(1,0,1) - f(1,0,0) - f(0,0,1)}{2} = 4. \\ a_{22} &= \frac{f(0,2,0) - 2f(0,1,0)}{2} = 9. \\ a_{23} &= \frac{f(0,1,1) - f(0,1,0) - f(0,0,1)}{2} = 5. \end{aligned}$$

$$a_{33} = \frac{f(0,0,2) - 2f(0,0,1)}{2} = 8.$$

La matriz simétrica asociada a la forma $f(\mathbf{x})$ es

$$A = \begin{bmatrix} 3 & 2 & 4 \\ 2 & 9 & 5 \\ 4 & 5 & 8 \end{bmatrix}.$$

Compárese con el ejemplo 134. □

4.3. El producto escalar como forma cuadrática

Se dice que una matriz hermítica $A \in \mathbb{K}^{n \times n}$ es *semidefinida positiva* si la forma cuadrática asociada toma valores no negativos y se dice que es *definida positiva* si esos valores son estrictamente positivos para todo vector no nulo:

A es semidefinida positiva si y solo si $\mathbf{x}^\top A \mathbf{x} \geq 0$, para todo $\mathbf{x} \in \mathbb{K}^n$.

A es definida positiva si y solo si $\mathbf{x}^\top A \mathbf{x} > 0$, para todo $\mathbf{x} \in \mathbb{K}^n \setminus \{\mathbf{0}\}$.

Una matriz definida positiva A es invertible (un elemento $\mathbf{u}$ de su núcleo verifica $\mathbf{x}^\top A \mathbf{x} = 0$) y su inversa A^{-1} también es definida positiva. En efecto, para $\mathbf{x} = A\mathbf{v} \neq \mathbf{0}$:

$$\mathbf{x}^\top A^{-1} \mathbf{x} = (A\mathbf{v})^\top A^{-1} (A\mathbf{v}) = \mathbf{v}^\top A^\top A^{-1} A \mathbf{v} = \mathbf{v}^\top A^\top \mathbf{v} = \mathbf{v}^\top A \mathbf{v} > 0.$$

De manera lógica, se dice que la matriz A es *definida negativa* o *semidefinida negativa* si su opuesta, $-A$, es definida o semidefinida positiva, respectivamente. Las matrices hermíticas que no entran en ninguna de estas cuatro categorías se denominan *indefinidas*.

La forma asociada a una matriz recibe el adjetivo correspondiente: definida positiva, definida negativa, semidefinida positiva, semidefinida negativa o indefinida.

Ejemplo 136. La matriz

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$$

es semidefinida positiva pues

$$\mathbf{x}^\top A \mathbf{x} = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = x_1^2 + 4x_1x_2 + 4x_2^2 = (x_1 + 2x_2)^2 \geq 0,$$

pero no es definida positiva, porque

$$\begin{bmatrix} 2 & -1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 2 \\ -1 \end{bmatrix} = 0, \text{ con } (2, -1) \neq (0, 0).$$

Es decir, no se cumple $\mathbf{x}^\top A \mathbf{x} > 0$ para todo $\mathbf{x} \in \mathbb{R}^2 \setminus \{\mathbf{0}\}$. □

Ejemplo 137. La matriz

$$A = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \\ 1 & 3 & 6 \end{bmatrix}$$

es definida positiva pues

$$\begin{aligned} \mathbf{x}^\top A \mathbf{x} &= \begin{bmatrix} x_1 & x_2 & x_3 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \\ 1 & 3 & 6 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} \\ &= x_1^2 + 2x_1x_2 + 2x_1x_3 + 2x_2^2 + 6x_2x_3 + 6x_3^2 \\ &= (x_1 + x_2 + x_3)^2 + (x_2 + 2x_3)^2 + x_3^2 > 0, \end{aligned}$$

para todo $(x_1, x_2, x_3) \neq (0, 0, 0)$. Este agrupamiento de los cuadrados es fácil de comprobar expandiendo la expresión, pero es difícil formar los cuadrados sin calcular antes los autovalores y los autovectores de la matriz. $\square$

Si $B \in \mathbb{K}^{m \times n}$ es una matriz arbitraria, entonces $A = B^\top B \in \mathbb{K}^{n \times n}$ es hermítica y semidefinida positiva. En efecto, $A^\top = (B^\top B)^\top = B^\top B = A$ y, por otro lado,

$$\mathbf{x}^\top A \mathbf{x} = \mathbf{x}^\top (B^\top B) \mathbf{x} = (\mathbf{x}^\top B^\top)(B \mathbf{x}) = (B \mathbf{x})^\top (B \mathbf{x}) = \|B \mathbf{x}\|^2 \geq 0.$$

Este razonamiento muestra también que si $B \in \mathbb{K}^{n \times m}$ tiene núcleo nulo, $\ker B = \{\mathbf{0}\}$, entonces $A = B^\top B$ es definida positiva. Observemos que los núcleos de A y B coinciden:

$$\mathbf{u} \in \ker A \iff B \mathbf{u} \in \ker B^\top \iff B \mathbf{u} \in \ker(B^\top) \cap \text{col}(B) = \{\mathbf{0}\} \iff \mathbf{u} \in \ker B.$$

Véase la sección III.4. También coinciden los rangos de A y B :

$$\begin{aligned} \text{rng } B &= \text{rng } B^\top = \dim \text{col}(B^\top) = m - \dim \ker(B) = m - \dim \ker(A) \\ &= m - (m - \dim \text{col}(A^\top)) = \dim \text{col}(A^\top) = \dim \text{col } A = \text{rng } A. \end{aligned}$$

$\triangle$ De momento, solo hemos razonado una implicación: si $A = B^\top B$, entonces A es hermítica semidefinida positiva, pero el recíproco también es cierto: si A es hermítica semidefinida positiva, entonces existe una matriz B tal que $A = B^\top B$. Ningún resultado de este manual se queda sin justificar; este lo veremos más adelante (cuadro V.6). $\square$

En el apartado 5.1 del Tema II presentamos el producto escalar

$$(\mathbf{u}, \mathbf{v}) \in \mathbb{K}^n \times \mathbb{K}^n \rightarrow \mathbf{u}^\top \mathbf{v}.$$

Se trata de la forma sesquilineal definida positiva asociada a la matriz identidad $I_n \in \mathbb{K}^n$ (pues $\mathbf{u}^\top I_n \mathbf{v} = \mathbf{u}^\top \mathbf{v}$), matriz que es claramente hermítica (simétrica) definida positiva.

Cualquier otra forma sesquilineal definida positiva de $\mathbb{K}^n$ se puede interpretar como un cambio de coordenadas del producto escalar canónico $\mathbf{u}^\top \mathbf{v}$. En efecto, si $A \in \mathbb{K}^{n \times n}$ es

hermítica definida positiva, debe ser invertible, es decir, tener núcleo nulo, $\ker A = \{\mathbf{0}\}$, por lo que (según se verá en el Tema V) existirá una matriz $B \in \mathbb{K}^{n \times n}$ también invertible tal que $A = B^\top B$. Por lo tanto, si ponemos $\tilde{\mathbf{u}} = B\mathbf{u}$, $\tilde{\mathbf{v}} = B\mathbf{v}$, se tiene

$$\mathbf{u}^\top A \mathbf{v} = \mathbf{u}^\top B^\top B \mathbf{v} = (B\mathbf{u})^\top (B\mathbf{v}) = \tilde{\mathbf{u}}^\top \tilde{\mathbf{v}},$$

en donde las tuplas $\tilde{\mathbf{u}}$ y $\tilde{\mathbf{v}}$ se interpretan respectivamente como las coordenadas de los vectores $\mathbf{u}$ y $\mathbf{v}$ respecto de base formada por las columnas de B^{-1} .

Notación y terminología. En general, las formas sesquilineales definidas positivas en un espacio vectorial arbitrario se denominan *productos escalares* o *productos internos*. Esta terminología se emplea especialmente cuando el campo de escalares es $\mathbb{R}$, en cuyo caso «sesquilineal» es lo mismo que «bilineal». Si el campo de escalares es $\mathbb{C}$, se suele emplear *producto hermítico* o *producto interno hermítico*. $\square$

TEMA IV

PROCESOS DE TRIANGULACIÓN

1. MATRICES TRIANGULARES

Las matrices trapezoidales, y especialmente las triangulares, gozan de ciertas propiedades deseables para la simplificación de procedimientos complicados.

En primer lugar, el determinante de una matriz triangular $U \in \mathbb{K}^{n \times n}$ se calcula simplemente multiplicando los elementos de su diagonal: $\det U = u_{11} u_{12} \dots u_{nn}$. Además, cuando este determinante es distinto de cero, una matriz triangular se invierte de forma sencilla, como vimos en el Tema II (página 13) para una matriz triangular superior:

$$U^{-1} = \begin{bmatrix} \frac{1}{u_{11}} & b_{12} & b_{13} & \dots & b_{1n} \\ 0 & \frac{1}{u_{22}} & b_{23} & \dots & b_{2n} \\ 0 & 0 & \frac{1}{u_{33}} & \dots & b_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & \frac{1}{u_{nn}} \end{bmatrix},$$

en donde los términos superiores b_{ij} (con $i < j$) vienen dados por la relación recurrente:

$$b_{ij} = -\frac{1}{u_{ii}} \sum_{k=i+1}^j u_{ik} b_{kj}.$$

Por otra parte, las únicas matrices triangulares normales son las matrices diagonales.

Razonémoslo con una matriz triangular superior U (si fuera inferior, la traspondríamos). La única posición que puede ser distinta de cero en la primera columna es u_{11} . Dado que en una matriz normal el módulo de la primera columna debe coincidir con el de la primera fila (véase el apartado 3.6 del Tema II), todas las demás entradas de la primera fila deben ser cero. Repitiendo sucesivamente esta misma deducción fila por fila y columna por columna de arriba abajo, se concluye que todos los elementos situados fuera de la diagonal principal deben ser nulos.

2. FACTORIZACIÓN PLU

2.1. Sistemas de ecuaciones lineales en forma matricial

El estudio de los sistemas de ecuaciones lineales constituye uno de los fundamentos del álgebra lineal y, por extensión, de la ingeniería en inteligencia artificial. Es probable que en la enseñanza secundaria se hayan abordado estos sistemas mediante la manipulación individual de ecuaciones y variables (habitualmente denotadas como x, y, z).

En esta asignatura, transformaremos este punto de vista. Los sistemas de ecuaciones lineales se tratarán exclusivamente como ecuaciones matriciales. Este cambio no es meramente estético o notacional; la representación matricial nos permite compactar grandes volúmenes de información, generalizar algoritmos a un número arbitrario de dimensiones y operar con estructuras de datos complejas de forma eficiente, sentando las bases para el cálculo computacional.

Para ilustrar esta transición, consideremos un sistema de ecuaciones lineales en su formato tradicional:

$$\begin{cases} 2x_1 - 3x_2 + x_3 = 5, \\ 4x_1 - 5x_3 = -2, \\ -x_1 + 6x_2 + 2x_3 = 0. \end{cases}$$

En esta asignatura, el sistema se presenta como la ecuación matricial $Ax = b$ de la siguiente forma:

$$\begin{bmatrix} 2 & -3 & 1 \\ 4 & 0 & -5 \\ -1 & 6 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 5 \\ -2 \\ 0 \end{bmatrix},$$

en donde la matriz de coeficientes,

$$A = \begin{bmatrix} 2 & -3 & 1 \\ 4 & 0 & -5 \\ -1 & 6 & 2 \end{bmatrix},$$

el vector de incógnitas,

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix},$$

y el vector de términos independientes,

$$\mathbf{b} = \begin{bmatrix} 5 \\ -2 \\ 0 \end{bmatrix},$$

actúan como bloques.

A partir de este momento, el objeto de estudio dejará de ser la ecuación individual para pasar a ser la estructura y las propiedades de estas matrices.

Por ejemplo, si A es una matriz cuadrada invertible, la solución del sistema $A\mathbf{x} = \mathbf{b}$ es $\mathbf{x} = A^{-1}\mathbf{b}$. Esta expresión «cerrada» de la solución es extremadamente útil para guiar los razonamientos teóricos; sin embargo, no resulta eficiente desde el punto de vista computacional ya que, como se ha señalado anteriormente, la inversión explícita de matrices es un proceso con un alto coste algorítmico.

Notación y terminología. En este contexto no se suelen poner los vectores en negrita. Como señalamos en su momento, es un disparate pretender que el uso de tipografía negrita o el del trazo fino sean preceptivos para denotar vectores: la tipografía negrita sirve para recordar al lector que el objeto tiene componentes, sobre todo cuando puede haber confusión, pero no todo lo que tiene componentes va en negrita. $\square$

Conviene observar que $\mathbf{x} = (x_1, x_2, \dots, x_m) \in \mathbb{K}^m$ es solución de $A\mathbf{x} = \mathbf{b}$, para $A \in \mathbb{K}^{n \times m}$, $\mathbf{b} \in \mathbb{K}^n$, si y solo si $\mathbf{x}' = (x_1, x_2, \dots, x_n, -1) \in \mathbb{K}^{m+1}$ es solución de $C\mathbf{x}' = 0$, en donde $C \in \mathbb{K}^{n \times (m+1)}$ es la matriz por bloques $C = [[A, \mathbf{b}]]$ (*matriz ampliada* del sistema), por lo que, en principio, bastaría estudiar los *sistemas homogéneos* (aquellos que tienen término independiente nulo):

$$\begin{bmatrix} 2 & -3 & 1 & 5 \\ 4 & 0 & -5 & -2 \\ -1 & 6 & 2 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ -1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

No obstante, en muchas ocasiones interesa estudiar una misma matriz de coeficientes A con diferente vector de términos independientes $\mathbf{b}$, por lo que las exposiciones teóricas suelen tratar por separado a las matrices A y $\mathbf{b}$.

La resolución manual de sistemas de baja dimensión carece de interés práctico, pero es necesario realizarla en unos cuantos casos, para comprender completamente el funcionamiento de los algoritmos.

2.2. El método de Gauss

El procedimiento tradicional para resolver un sistema lineal $A\mathbf{x} = \mathbf{b}$, en donde $A \in \mathbb{K}^{n \times m}$ y $\mathbf{b} \in \mathbb{K}^n$, es el *método de Gauss*, que revisamos en su versión matricial. El método consta de dos etapas: escalonamiento y sustitución hacia atrás.

En el proceso de *escalonamiento* se va transformando en varios pasos la matriz ampliada $C = [[A, \mathbf{b}]]$, hasta convertirla en una matriz escalonada. En cada paso, se reordenan las filas, si es necesario, y se anulan las posiciones por debajo del pivote. Recordemos que el *pivote* de una fila de una matriz es la primera posición no nula de esa fila (página 81).

Cada uno de esos pasos se puede expresar matricialmente multiplicando desde la izquierda nuestra matriz por $E_j P_j$, en donde P_j es una matriz de permutación que deja fijas las filas superiores (véase (11) en el Tema II)

$$P_j = \begin{bmatrix} I_j & \mathbf{0} \\ \mathbf{0} & Q_j \end{bmatrix}$$

y E_j es una matriz unitriangular por bloques concentrada en la columna j , matriz que representa una combinación lineal de filas (véase (12) en el Tema II).

Así, la matriz escalonada con la que finaliza el proceso es de la forma $U = MC$ con

$$M = (E_m P_m) \cdots (E_j P_j) \cdots (E_1 P_1). \quad (24)$$

El *proceso de sustitución* hacia atrás en el sistema escalonado $U\mathbf{x}' = \mathbf{0}$ es similar al que vimos en la página 101 en el contexto del cálculo de la matriz inversa, solo que entonces se trataba del caso particular de una matriz triangular invertible, y aquí tendríamos una matriz escalonada $U = MC$ (alta, ancha, triangular invertible o no invertible).



Se debe consultar en este momento el epígrafe *Método de Gauss o de eliminación gaussiana* en la sección 1.4 del manual [1], páginas 38 a 44, donde se describe con detalle el método completo, hasta la matriz escalonada, y se proporcionan ejemplos.

Las operaciones elementales del método de Gauss no alteran los rangos de las submatrices de C , lo que permite clasificar los sistemas de ecuaciones por el número de sus soluciones a partir de los rangos de la matriz de coeficientes A y de la matriz ampliada C .

1. Si el rango de la matriz de coeficientes es menor que el de la ampliada, el sistema es *incompatible* (no tiene soluciones). Si los rangos son iguales, el sistema es *compatible* (tiene solución).

En efecto, si los rangos son distintos en la forma escalonada es porque tenemos una ecuación del tipo $0 = 1$ al final.

Por supuesto, lo anterior puede razonarse fácilmente sin necesidad de escalonar la matriz: el sistema $A\mathbf{x} = \mathbf{b}$ es compatible si y solo si $\mathbf{b} \in \text{col } A$, con lo que, al añadir $\mathbf{b}$ al subespacio $\text{col } A$, no aumenta su rango.

2. Si los rangos de las matrices de coeficientes y ampliada coinciden con el número de incógnitas m (número de columnas de A), entonces el sistema es *compatible determinado*: tiene una única solución, que es un vector de $\mathbb{K}^m$.

En este caso, la forma escalonada de A es trapezoidal alta o triangular, por lo que la sustitución hacia atrás da una única solución.

3. Si el rango r de la matriz de coeficientes coincide con el de la ampliada y es menor que el número de incógnitas m (número de columnas de A), entonces el sistema es *compatible indeterminado*, lo que significa que tiene infinitas soluciones que forman un subespacio afín de dimensión $m - r$.

Efectivamente, en este caso la forma escalonada de A es trapezoidal ancha, por lo que las últimas $m - r$ incógnitas quedan libres.

Este resultado se conoce como *teorema de Rouché-Frobenius*. Aunque es fundamental en los desarrollos teóricos, su utilidad en la práctica computacional es limitada. Debido a los errores de redondeo inherentes a la aritmética de punto flotante, resulta difícil determinar si un valor numérico es un cero exacto o un artefacto del cálculo, lo que vuelve inestable determinar el rango exacto de una matriz por métodos directos.

Método de Gauss y factorización

En nuestro contexto, interesa contemplar el método de Gauss como un proceso de factorización de la matriz C (factorizar una matriz consiste en expresarla como producto de otras). El método concluye, como hemos visto, con la matriz escalonada $U = MC$, de donde $C = M^{-1}U$. Hemos comentado anteriormente que la inversión de matrices implica, en general, un alto coste computacional. Sin embargo, nuestro caso es muy particular, como vemos a continuación. De (24) se sigue que

$$C = M^{-1}U = P_1^{-1}E_1^{-1}P_2^{-1} \cdots E_{m-1}^{-1}P_m^{-1}E_m^{-1}U. \quad (25)$$

En primer lugar, recordemos que las matrices de permutación P_j son ortogonales, por lo que su inversa no es nada más que su traspuesta, que resulta ser otra matriz de permutación (ver la sección 6.4 del Tema II). Como las matrices unitriangulares por bloques E_j

se invierten simplemente cambiando el signo del bloque (véase el ejemplo 93), el coste computacional de las inversiones de (25) es prácticamente nulo.

En segundo lugar, observamos que, si bien las matrices que aparecen en la cadena de productos (25) no necesariamente conmutan, las propiedades de las matrices unitriangulares por bloques permiten *reordenarlas*, en un cierto sentido. Efectivamente, si $j \leq k$, multiplicando por bloques como en (8):

$$E_j^{-1}P_k^{-1} = \begin{bmatrix} I_j & \mathbf{0} \\ A & I_{n-j} \end{bmatrix} \begin{bmatrix} I_j & \mathbf{0} \\ \mathbf{0} & Q \end{bmatrix} = \begin{bmatrix} I_j & \mathbf{0} \\ \mathbf{0} & Q \end{bmatrix} \begin{bmatrix} I_j & \mathbf{0} \\ Q^\top A & I_{n-j} \end{bmatrix} = P_k^{-1} \hat{E}_j^{-1}.$$

De esta manera, podemos llevar todas las matrices de permutación a la izquierda del miembro derecho de (25):

$$C = M^{-1}U = P_1^{-1}P_2^{-1} \dots P_m^{-1} \hat{E}_1^{-1} \hat{E}_2^{-1} \dots \hat{E}_m^{-1}U = PLU, \quad (26)$$

en donde

$$P = P_1^{-1}P_2^{-1} \dots P_m^{-1}$$

es una matriz de permutación y

$$L = \hat{E}_1^{-1} \hat{E}_2^{-1} \dots \hat{E}_m^{-1}$$

es una matriz unitriangular inferior. Recordemos que el producto de las matrices unitriangulares E_j^{-1} no requiere cálculos: basta agregar los bloques, de manera que las posiciones por debajo de la diagonal de L están ocupadas por los coeficientes de las combinaciones lineales representadas por las matrices E_j (véase la expresión (10) del Tema II).

Como nuestro enfoque está estrictamente dirigido al álgebra matricial, aportamos cuatro ejemplos complementarios a los de la referencia [1], enfatizando en ellos la cadena de matrices de transformación.

Ejemplo 138. Queremos resolver el sistema $Ax = b$ mediante eliminación de Gauss usando matrices de transformación elemental por la izquierda, en donde:

$$A = \begin{bmatrix} 1 & 2 & 1 & 1 & 0 \\ 2 & 4 & 2 & 1 & 1 \\ 1 & 2 & 2 & 1 & 2 \\ 1 & 1 & 1 & 1 & 0 \end{bmatrix} ; \quad b = \begin{bmatrix} 1 \\ 2 \\ 5 \\ 3 \end{bmatrix}$$

Trabajaremos de forma compacta con la matriz ampliada $C = [[A, b]]$.

$$C = [A \quad b] = \begin{bmatrix} 1 & 2 & 1 & 1 & 0 & 1 \\ 2 & 4 & 2 & 1 & 1 & 2 \\ 1 & 2 & 2 & 1 & 2 & 5 \\ 1 & 1 & 1 & 1 & 0 & 3 \end{bmatrix}$$

Claramente, $\mathbf{x}' = (x_1, x_2, x_3, x_4, x_5, -1)$ es solución de $C\mathbf{x}' = \mathbf{0}$ si y solamente si $\mathbf{x} = (x_1, x_2, x_3, x_4, x_5)$ es solución de $A\mathbf{x} = \mathbf{b}$.

Como la posición $(1, 1)$ es distinta de cero, no necesitamos permutar las filas en este paso, por lo que P_1 es la identidad, $P_1 = I$.

A continuación, eliminamos los elementos bajo la posición $(1, 1)$ empleando la matriz unitriangular inferior E_1 , que ejecuta en un solo paso las combinaciones lineales necesarias (véase (12) en el Tema II):

$$E_1C = \begin{bmatrix} 1 & 0 & 0 & 0 \\ -2 & 1 & 0 & 0 \\ -1 & 0 & 1 & 0 \\ -1 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & 1 & 1 & 0 & 1 \\ 2 & 4 & 2 & 1 & 1 & 2 \\ 1 & 2 & 2 & 1 & 2 & 5 \\ 1 & 1 & 1 & 1 & 0 & 3 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 1 & 1 & 0 & 1 \\ 0 & 0 & 0 & -1 & 1 & 0 \\ 0 & 0 & 1 & 0 & 2 & 4 \\ 0 & -1 & 0 & 0 & 0 & 2 \end{bmatrix}$$

Observemos que E_1 es la matriz unitriangular inferior 4×4 concentrada en la primera columna, con bloque

$$\begin{bmatrix} -2 \\ -1 \\ -1 \end{bmatrix} \in \mathbb{R}^{3 \times 1}.$$

Como tenemos un cero en la posición $(2, 2)$, permutamos las filas segunda y cuarta mediante la correspondiente matriz de permutación P_2 :

$$P_2E_1C = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 2 & 1 & 1 & 0 & 1 \\ 0 & 0 & 0 & -1 & 1 & 0 \\ 0 & 0 & 1 & 0 & 2 & 4 \\ 0 & -1 & 0 & 0 & 0 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 1 & 1 & 0 & 1 \\ 0 & -1 & 0 & 0 & 0 & 2 \\ 0 & 0 & 1 & 0 & 2 & 4 \\ 0 & 0 & 0 & -1 & 1 & 0 \end{bmatrix}.$$

La matriz obtenida ya es escalonada superior, por lo que el método ha alcanzado su objetivo con $E_2 = P_3 = E_3 = I$ y $U = E_3P_3E_2P_2E_1P_1C = P_2E_1C$ escalonada superior.

El sistema $A\mathbf{x} = \mathbf{b}$ es compatible indeterminado (tiene infinitas soluciones), permitiendo parametrizar el sistema en función de x_5 . Poniendo $x_5 = \lambda$, el proceso de sustitución hacia atrás nos da la expresión paramétrica de espacio de soluciones:

$$-x_4 + \lambda = 0 \implies x_4 = \lambda$$

$$x_3 + 2\lambda = 4 \implies x_3 = 4 - 2\lambda$$

$$-x_2 = 2 \implies x_2 = -2$$

$$x_1 + 2(-2) + (4 - 2\lambda) + \lambda = 1 \implies x_1 - 4 + 4 - \lambda = 1 \implies x_1 = 1 + \lambda.$$

Es decir, las infinitas soluciones forma un subespacio afín de $\mathbb{R}^5$:

$$\begin{cases} x_1 = 1 + \lambda \\ x_2 = -2 \\ x_3 = 4 - 2\lambda \\ x_4 = \lambda \\ x_5 = \lambda, \end{cases}$$

para $\lambda \in \mathbb{R}$. Pero más que las soluciones, nos interesa profundizar en el algoritmo expresado en forma matricial.

Agrupando la secuencia $M = E_3 P_3 E_2 P_2 E_1 P_1 = P_2 E_1$, el proceso completo queda condensado de forma puramente matricial en la expresión $U\mathbf{x} = \mathbf{0}$, en donde $U = MC$ es escalonada superior, lo que ha facilitado la sustitución hacia atrás.

Gracias a la expresión (8) del Tema II, aplicada a

$$Q = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix},$$

podemos *reordenar* la matriz de permutación y de la de combinación:

$$M = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ -2 & 1 & 0 & 0 \\ -1 & 0 & 1 & 0 \\ -1 & 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ -1 & 1 & 0 & 0 \\ -1 & 0 & 1 & 0 \\ -2 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix}.$$

Ahora bien, sabemos que las matrices de permutación y las unitriangulares con bloque se invierten muy fácilmente. En efecto, las matrices de permutación son ortogonales, por lo que su inversa es su traspuesta, mientras que las unitriangulares con bloque se invierten simplemente cambiando el signo del bloque (véase el ejemplo 93). En consecuencia,

$$C = M^{-1}U = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 2 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & 1 & 1 & 0 & 1 \\ 0 & -1 & 0 & 0 & 0 & 2 \\ 0 & 0 & 1 & 0 & 2 & 4 \\ 0 & 0 & 0 & -1 & 1 & 0 \end{bmatrix}.$$

Independientemente de lo que represente la matriz C (sea la matriz ampliada o la de coeficientes de un sistema o una matriz de cualquier otro proceso), lo que realmente hace el método de Gauss es factorizar C en la forma $C = PLU$, en donde P es una matriz de permutación, L es unitriangular inferior y U es escalonada superior (REF). $\square$

Ejemplo 139. Aplicamos ahora el método de Gauss empleando matrices de transforma-

ción elemental por la izquierda al sistema $A\mathbf{x} = \mathbf{b}$, en donde:

$$A = \begin{bmatrix} 0 & 2 & 1 \\ 1 & -2 & 0 \\ 3 & 0 & 2 \\ 1 & 1 & 1 \end{bmatrix} \quad ; \quad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 5 \\ 3 \end{bmatrix}$$

La matriz ampliada es

$$C = [A \quad \mathbf{b}] = \begin{bmatrix} 0 & 2 & 1 & 1 \\ 1 & -2 & 0 & 2 \\ 3 & 0 & 2 & 5 \\ 1 & 1 & 1 & 3 \end{bmatrix}$$

Como tenemos un cero en la posición pivote $(1, 1)$, permutamos las dos primeras filas mediante la correspondiente matriz de permutación P_1 :

$$P_1 C = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 0 & 2 & 1 & 1 \\ 1 & -2 & 0 & 2 \\ 3 & 0 & 2 & 5 \\ 1 & 1 & 1 & 3 \end{bmatrix} = \begin{bmatrix} 1 & -2 & 0 & 2 \\ 0 & 2 & 1 & 1 \\ 3 & 0 & 2 & 5 \\ 1 & 1 & 1 & 3 \end{bmatrix}$$

A continuación, eliminamos los elementos bajo el primer pivote empleando la matriz triangular inferior E_1 , que ejecuta en un solo paso las combinaciones lineales necesarias:

$$E_1 P_1 C = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ -3 & 0 & 1 & 0 \\ -1 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & -2 & 0 & 2 \\ 0 & 2 & 1 & 1 \\ 3 & 0 & 2 & 5 \\ 1 & 1 & 1 & 3 \end{bmatrix} = \begin{bmatrix} 1 & -2 & 0 & 2 \\ 0 & 2 & 1 & 1 \\ 0 & 6 & 2 & -1 \\ 0 & 3 & 1 & 1 \end{bmatrix}$$

Como la posición $(2, 2)$ no es nula, no hace falta permutar las filas en este paso, por lo que $P_2 = I$. Seguidamente, reducimos las posiciones $(3, 2)$ y $(4, 2)$ de la segunda columna mediante la matriz unitriangular E_2 :

$$E_2 P_2 E_1 P_1 C = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & -3 & 1 & 0 \\ 0 & -\frac{3}{2} & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & -2 & 0 & 2 \\ 0 & 2 & 1 & 1 \\ 0 & 6 & 2 & -1 \\ 0 & 3 & 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & -2 & 0 & 2 \\ 0 & 2 & 1 & 1 \\ 0 & 0 & -1 & -4 \\ 0 & 0 & -\frac{1}{2} & -\frac{1}{2} \end{bmatrix}.$$

Al ser la posición $(3, 3)$ no nula, la correspondiente matriz de permutación es $P_3 = I$. Por último, logramos la estructura escalonada con la matriz unitriangular E_3 , que anula la posición $(4, 3)$:

$$U = E_3 P_3 E_2 P_2 E_1 P_1 C = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & -\frac{1}{2} & 1 \end{bmatrix} \begin{bmatrix} 1 & -2 & 0 & 2 \\ 0 & 2 & 1 & 1 \\ 0 & 0 & -1 & -4 \\ 0 & 0 & -\frac{1}{2} & -\frac{1}{2} \end{bmatrix} = \begin{bmatrix} 1 & -2 & 0 & 2 \\ 0 & 2 & 1 & 1 \\ 0 & 0 & -1 & -4 \\ 0 & 0 & 0 & \frac{3}{2} \end{bmatrix}.$$

El sistema $Ax = b$ es incompatible (no tiene solución) porque la única solución del sistema ampliado $Cx' = 0$ es la nula, $x' = 0$, cuando debe ser $x'_4 = -1 \neq 0$.

Como antes, nos interesa la forma matricial $Ux' = 0$, con $U = MC$ escalonada superior y $M = E_3P_3E_2P_2E_1P_1 = E_3E_2E_1P_1$, de manera que $C = M^{-1}U$ con

$$\begin{aligned} M^{-1} &= P_1^{-1}E_1^{-1}E_2^{-1}E_3^{-1} \\ &= \begin{bmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 3 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 3 & 1 & 0 \\ 0 & \frac{3}{2} & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & \frac{1}{2} & 1 \end{bmatrix} \\ &= \begin{bmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 3 & 3 & 1 & 0 \\ 1 & \frac{3}{2} & \frac{1}{2} & 1 \end{bmatrix} = PL \implies C = PLU. \end{aligned}$$

Recordemos que las matrices de permutación son ortogonales, por lo que su inversa no es nada más que su traspuesta, mientras que las unitriangulares con bloque se invierten simplemente cambiando el signo del bloque (véase el ejemplo 93). Obsérvese también que el producto de las tres matrices unitriangulares no requiere cálculos: basta agregar los bloques (véase la expresión (10) del Tema II).

Una vez más, lo que ha hecho el método de Gauss es factorizar la matriz C en la forma $C = PLU$, en donde P es una matriz de permutación, U es escalonada superior y L es una matriz unitriangular inferior que tiene en sus posiciones precisamente los coeficientes de las combinaciones lineales. $\square$

Ejemplo 140. Resolvemos ahora el sistema $Ax = b$, en donde:

$$A = \begin{bmatrix} 0 & 2 & 1 \\ 1 & -2 & 0 \\ 3 & 0 & 2 \\ 1 & 1 & 1 \end{bmatrix} ; \quad b = \begin{bmatrix} 5 \\ -1 \\ 11 \\ 6 \end{bmatrix} ; \quad C = [A \quad b] = \begin{bmatrix} 0 & 2 & 1 & 5 \\ 1 & -2 & 0 & -1 \\ 3 & 0 & 2 & 11 \\ 1 & 1 & 1 & 6 \end{bmatrix}.$$

La matriz A de los coeficientes es la misma que la del ejemplo 147, por lo que las matrices de transformación son las mismas:

$$E_3E_2E_1P_1C = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ -3 & -3 & 1 & 0 \\ 0 & \frac{1}{2} & -\frac{1}{2} & 1 \end{bmatrix} \begin{bmatrix} 0 & 2 & 1 & 5 \\ 1 & -2 & 0 & -1 \\ 3 & 0 & 2 & 11 \\ 1 & 1 & 1 & 6 \end{bmatrix} = \begin{bmatrix} 1 & -2 & 0 & -1 \\ 0 & 2 & 1 & 5 \\ 0 & 0 & -1 & -1 \\ 0 & 0 & 0 & 0 \end{bmatrix}.$$

Resolvemos hacia atrás en

$$\begin{bmatrix} 1 & -2 & 0 & -1 \\ 0 & 2 & 1 & 5 \\ 0 & 0 & -1 & -1 \\ 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ -1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix},$$

lo que equivale a:

$$\begin{bmatrix} 1 & -2 & 0 \\ 0 & 2 & 1 \\ 0 & 0 & -1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} -1 \\ 5 \\ -1 \end{bmatrix}.$$

De la tercera ecuación:

$$-x_3 + 1 = 0 \implies x_3 = 1$$

Sustituyendo en la segunda ecuación:

$$2x_2 + 1(1) - 5 = 0 \implies 2x_2 - 4 = 0 \implies x_2 = 2$$

Sustituyendo en la primera ecuación:

$$x_1 - 4 + 1 = 0 \implies x_1 = 3$$

La única solución del sistema es: $x_1 = 3$, $x_2 = 2$, $x_3 = 1$. □

Ejemplo 141. En esta ocasión, resolvemos el sistema $Ax = b$, en donde:

$$A = \begin{bmatrix} 0 & 2 & 1 \\ 1 & -2 & 0 \\ 3 & 0 & 3 \\ 1 & 1 & \frac{3}{2} \end{bmatrix}; \quad b = \begin{bmatrix} 5 \\ -1 \\ 12 \\ \frac{13}{2} \end{bmatrix}; \quad C = \begin{bmatrix} 0 & 2 & 1 & 5 \\ 1 & -2 & 0 & -1 \\ 3 & 0 & 3 & 12 \\ 1 & 1 & \frac{3}{2} & \frac{13}{2} \end{bmatrix}$$

Aunque la matriz A de los coeficientes no es exactamente la misma que la del ejemplo 147, sirven las mismas matrices de transformación:

$$E_3 E_2 E_1 P_1 C = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ -3 & -3 & 1 & 0 \\ 0 & \frac{1}{2} & -\frac{1}{2} & 1 \end{bmatrix} \begin{bmatrix} 0 & 2 & 1 & 5 \\ 1 & -2 & 0 & -1 \\ 3 & 0 & 3 & 12 \\ 1 & 1 & \frac{3}{2} & \frac{13}{2} \end{bmatrix} = \begin{bmatrix} 1 & -2 & 0 & -1 \\ 0 & 2 & 1 & 5 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}.$$

Resolvemos hacia atrás en

$$\begin{bmatrix} 1 & -2 & 0 & -1 \\ 0 & 2 & 1 & 5 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ -1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}.$$

De la segunda ecuación:

$$2x_2 + x_3 - 5 = 0 \implies x_2 = \frac{5 - x_3}{2}.$$

Sustituyendo en la primera ecuación:

$$x_1 - 2 \left(\frac{5 - x_3}{2} \right) + 1 = 0 \implies x_1 = 4 - x_3.$$

El sistema tiene infinitas soluciones, que forman un subespacio afín de dimensión 1 que se describe en forma paramétrica mediante

$$\begin{cases} x_1 = 4 - \lambda \\ x_2 = \frac{5}{2} - \frac{1}{2} \lambda \\ x_3 = \lambda, \end{cases}$$

para $\lambda \in \mathbb{R}$.

□

2.3. Factorización PLU

Hasta hace unas décadas, el método de Gauss con escalonamiento desempeñaba un papel fundamental en la enseñanza del álgebra lineal elemental, tanto desde el punto de vista teórico (al proporcionar una clasificación clara de los sistemas lineales según el número de sus soluciones) como por su utilidad para resolver a mano sistemas de baja dimensión.

Sin embargo, el papel del escalonamiento como instrumento teórico de clasificación puede reemplazarse con ventaja por otros procedimientos que veremos, mientras que el empeño en llegar hasta una matriz totalmente escalonada implica ciertas desventajas desde el punto de vista computacional.

Por una parte, la estructura escalonada final no está establecida *a priori*, por lo que no se pueden «reservar» las posiciones por encima de la diagonal que quedarán finalmente ocupadas por ceros. Tampoco están prefijadas las posiciones de los pivotes, pues, esas posiciones pueden quedar fuera de la diagonal. La búsqueda de esas posiciones pivote introduce condicionales dinámicos («si este valor es cero, haz esto; si no, aquello») que impiden procesar datos de forma masiva y uniforme.

Además, en la práctica, la comprobación exacta de ceros es inviable por los errores de redondeo propios de la aritmética de precisión simple, al tiempo que la falta de un patrón de operaciones fijo dificulta el procesamiento de grandes bloques de datos en paralelo.

Por estas razones, el estándar computacional real ha dejado atrás el escalonamiento estricto para factorizar la matriz original en la forma PLU , en donde, como antes, P es una matriz de permutación y L es una matriz unitriangular inferior, pero U es simplemente una matriz trapezoidal superior. El objetivo aquí no es forzar a U a llegar a la forma escalonada perfecta, sino simplemente asegurar que sea trapezoidal superior, de manera

que las posiciones pivote siempre queden en la diagonal y se eviten los condicionales dinámicos necesarios para comprobar si una posición es o no nula.

Esta diferencia, que a primera vista parece menor, ahorra comprobaciones complejas y permite ejecutar algoritmos con un patrón de acceso a memoria fijo y altamente optimizado. Sorprendentemente, al resolver el sistema mediante la sustitución hacia atrás, trabajar con una matriz trapezoidal superior ofrece las mismas ventajas matemáticas que una forma escalonada, pero sin haber pagado el alto coste computacional de construirla.

Para un perfil orientado a la inteligencia artificial, entender este matiz es fundamental: no buscamos la forma que parezca más limpia en la pizarra, sino la estructura que equilibre la estabilidad numérica con el máximo rendimiento de los equipos.

Es probable que si el escalonamiento sigue ocupando un papel central en muchos cursos y textos de álgebra lineal elemental, se deba a ese «obstinado conservadurismo de la tradición académica» que, como bien se ha denunciado, congela los planes de estudio mucho después de haber sobrevivido a su importancia histórica.

Los ejemplos 138 a 141 están formulados de manera que la forma trapezoidal resulte escalonada sin más cálculo, porque nos interesa poco el escalonamiento. En el siguiente ejemplo simple vemos la diferencia entre buscar la forma trapezoidal y la escalonada. Dejamos al lector los detalles de las operaciones.

Ejemplo 142. Apliquemos el método de Gauss hasta el escalonamiento a la matriz

$$C = \begin{bmatrix} 1 & 2 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 1 & -1 \end{bmatrix}.$$

Etapla 1: pivote en la posición (1, 1), aunque no hay que hacer nada:

$$P_1 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \quad E_1 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \quad C_1 = \begin{bmatrix} 1 & 2 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 1 & -1 \end{bmatrix}.$$

Etapla 2: pivote en la posición (2, 3), fuera de la diagonal:

$$P_2 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \quad E_2 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & -1 & 0 & 1 \end{bmatrix}, \quad C_2 = \begin{bmatrix} 1 & 2 & 0 & 0 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & -3 \end{bmatrix}.$$

Etapa 3: pivote en la posición (3, 4), fuera de la diagonal:

$$P_3 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \quad E_3 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 3 & 1 \end{bmatrix}, \quad U = \begin{bmatrix} 1 & 2 & 0 & 0 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix}.$$

La factorización obtenida es:

$$C = PLU = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & -3 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & 0 & 0 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix}.$$

Repetimos el procedimiento, pero sin buscar el escalonamiento, solamente queremos llegar a una matriz trapecoidal superior.

Etapa 1: pivote en la posición (1, 1), en la diagonal, aunque no hay que hacer nada:

$$P_1 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \quad E_1 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \quad C_1 = \begin{bmatrix} 1 & 2 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 1 & -1 \end{bmatrix}.$$

Etapa 2: pivote en la posición (2, 2), en la diagonal, aunque no hay que hacer nada:

$$P_2 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \quad E_2 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \quad C_2 = \begin{bmatrix} 1 & 2 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 1 & -1 \end{bmatrix}.$$

Etapa 3: pivote en la posición (3, 3), en la diagonal:

$$P_3 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \quad E_3 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & -1 & 1 \end{bmatrix}, \quad U = \begin{bmatrix} 1 & 2 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & -3 \end{bmatrix}.$$

La factorización obtenida es:

$$C = PLU = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & -3 \end{bmatrix}.$$

□

Podemos preguntarnos si realmente es imprescindible la matriz de permutación P , es decir, si podemos garantizar que cualquier matriz C admita una factorización de la forma $C = LU$ con L unitriangular superior y U trapezoidal superior. La respuesta es negativa, como se muestra en el siguiente ejemplo.

Ejemplo 143. Apliquemos el método de Gauss para factorizar la matriz:

$$C = \begin{bmatrix} 0 & 1 & 2 \\ 1 & 2 & 1 \\ 2 & 1 & 0 \end{bmatrix}$$

Etapla 1:

$$P_1 = \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \quad E_1 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ -2 & 0 & 1 \end{bmatrix}, \quad C_1 = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 1 & 2 \\ 0 & -3 & -2 \end{bmatrix}.$$

Etapla 2:

$$P_2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \quad E_2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 3 & 1 \end{bmatrix}, \quad U = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 1 & 2 \\ 0 & 0 & 4 \end{bmatrix}.$$

Factorización $C = PLU$:

$$\begin{bmatrix} 0 & 1 & 2 \\ 1 & 2 & 1 \\ 2 & 1 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 2 & -3 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & 1 \\ 0 & 1 & 2 \\ 0 & 0 & 4 \end{bmatrix}.$$

Comprobamos por contradicción que no existe una factorización $C = LU$:

$$\begin{bmatrix} 0 & 1 & 2 \\ 1 & 2 & 1 \\ 2 & 1 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ l_{21} & 1 & 0 \\ l_{31} & l_{32} & 1 \end{bmatrix} \begin{bmatrix} u_{11} & u_{12} & u_{13} \\ 0 & u_{22} & u_{23} \\ 0 & 0 & u_{33} \end{bmatrix}$$

$$\Rightarrow \begin{cases} \text{posición } (1, 1) \text{ de } C : & 0 = u_{11} \\ \text{posición } (2, 1) \text{ de } C : & 1 = l_{21}u_{11} = 0. \end{cases}$$

Por lo tanto, si suponemos $C = LU$, llegamos a la conclusión absurda $1 = 0$, luego no existe tal factorización. $\square$

No es difícil dar con la condición necesaria y suficiente para que una matriz cuadrada no singular $C = C_0$ admita una factorización $C = LU$. La permutación es necesaria en la etapa j si y solo si las posiciones (i, j) de C_{j-1} , con $i \leq j$, son todas nulas, lo cual ocurre cuando el menor principal $j \times j$ de C_{j-1} es nulo y ese menor es nulo precisamente cuando lo es el menor principal $j \times j$ de C .

Por lo tanto, una matriz cuadrada no singular admite una factorización LU si y solo si todos sus menores principales son no nulos (véase III.2 en la página 127). En este caso, la matriz trapezoidal U resulta ser escalonada, pues no tiene ceros en la diagonal. En particular, las matrices definidas (positivas o negativas) admiten factorización LU.

Si la matriz cuadrada C es singular, puede admitir una factorización LU aunque tenga otros menores principales nulos, como ocurría en el ejemplo 142.

Observemos también que en el ejemplo 143 el menor 1×1 de $C = C_0$ es el determinante de la submatriz principal correspondiente a la posición $(1, 1)$, que es nula.

IV.1: Resumen: factorización o descomposición PLU

1. Toda matriz C se puede factorizar como $C = PLU$, en donde P es una matriz de permutación, L es unitriangular inferior y U es escalonada superior.

El procedimiento de escalonamiento es computacionalmente poco adecuado y tampoco es imprescindible para razonar la clasificación de los sistemas según el número de sus soluciones.

2. El estándar computacional no requiere que la matriz U sea escalonada, sino simplemente trapezoidal superior, para conseguir algoritmos eficientes.

Por lo tanto, el término *descomposición PLU* se refiere a la factorización de una matriz arbitraria C en la forma $C = PLU$, en donde P es una matriz de permutación, L es unitriangular inferior y U es trapezoidal superior, no necesariamente escalonada.

3. No todas las matrices, ni siquiera las cuadradas, admiten una descomposición de la forma $C = LU$, con L unitriangular inferior y U , trapezoidal superior.

Una matriz cuadrada no singular C admite una *descomposición LU*, en la forma $C = LU$, si solo si carece de menores principales nulos, en cuyo caso, la factorización es única y la matriz trapezoidal U resulta ser escalonada.

4. El determinante de una matriz cuadrada C que no tenga menores principales nulos se calcula multiplicando los elementos de la diagonal de U en su descomposición LU:

$$\det(C) = \det(LU) = \det(L) \det(U) = 1 \cdot \det(U) = u_{11}u_{22} \dots u_{nn}.$$

En otro caso, se puede emplear la descomposición PLU:

$$\det(C) = \det(P) \det(U) = \pm u_{11}u_{22} \dots u_{nn}.$$

Para profundizar. Se ha presentado la versión general de la factorización PLU, pero, como la descomposición suele adaptarse según el tipo de matriz, conviene prestar atención a las características concretas de los factores L y U .

Por ejemplo, al aplicar la factorización a una matriz $C \in \mathbb{K}^{n \times m}$ con $m < n$ (más filas que columnas), se obtiene una matriz unitriangular inferior $L \in \mathbb{K}^{n \times n}$ y una matriz trapezoidal superior $U \in \mathbb{K}^{n \times m}$ cuyas últimas $n - m$ filas son nulas:

$$P^\top C = LU = \begin{bmatrix} L_1 & L_2 \end{bmatrix} \begin{bmatrix} U_1 \\ \mathbf{0} \end{bmatrix} = L_1 U_1,$$

en donde $L_1 \in \mathbb{K}^{n \times m}$, $L_2 \in \mathbb{K}^{n \times (n-m)}$ y $U_1 \in \mathbb{K}^{m \times m}$. Obsérvese cómo disminuye el tamaño de los factores al no intervenir el bloque L_2 .

Por esta razón, la descomposición reducida de C suele representarse directamente mediante una matriz $L \in \mathbb{K}^{n \times m}$ trapezoidal inferior (con unos en la diagonal) y una matriz $U \in \mathbb{K}^{m \times m}$ triangular superior cuadrada. $\square$

Aplicación a la informática. Aunque algebraicamente toda matriz admite una descomposición de la forma $C = PLU$, en la práctica computacional es muy frecuente recurrir a una factorización con pivoteo completo $C = PLUP'$, donde P' es una matriz de permutación que reordena las columnas de C . Esta reordenación responde a dos motivos.

En primer lugar, permite preservar la dispersión (*sparsity*): una matriz es *dispersa* cuando la inmensa mayoría de sus elementos son ceros (algo muy común en el procesamiento de grafos, redes neuronales y grandes volúmenes de datos en IA). Al calcular los factores L y U , pueden aparecer valores distintos de cero en posiciones donde antes había ceros, un fenómeno conocido como *relleno* (*fill-in*). La elección adecuada de P' reordena las columnas para minimizar este relleno, ahorrando memoria y tiempo de cálculo.

En segundo lugar, proporciona mayor estabilidad numérica y facilita la detección del rango, ya que el pivoteo por columnas ayuda a seleccionar como pivote el mayor valor absoluto disponible en toda la submatriz restante (y no solo en la columna actual). Esto previene errores de redondeo y facilita la identificación de las columnas linealmente dependientes en matrices de rango deficiente. $\square$

3. FACTORIZACIÓN QR

3.1. Ortogonalización de Gram-Schmidt y factorización QR

Así como la reducción de Gauss corresponde matricialmente a la factorización PLU, el método de ortogonalización de Gram-Schmidt (véase 6.1 en el Tema II) se asocia también a una descomposición matricial.

Efectivamente, este procedimiento geométrico admite una interpretación matricial directa cuando se aplica a la familia de las columnas $\mathbf{c}_1, \dots, \mathbf{c}_m \in \mathbb{K}^n$ de una matriz arbitraria $C \in \mathbb{K}^{n \times m}$, completándola con los elementos de la base canónica: $\mathbf{c}_{m+1} = \mathbf{e}_1, \dots, \mathbf{c}_{m+n} = \mathbf{e}_n$.

En la etapa $j = 1, \dots, n$, tendremos:

$$\mathbf{u} = \mathbf{c}_j - \sum_{k=1}^{j-1} (\mathbf{f}_k^\top \mathbf{c}_j) \mathbf{f}_k \implies \begin{cases} \text{si } \mathbf{u} \neq \mathbf{0}, \text{ resulta } \mathbf{u} = (\mathbf{f}_j^\top \mathbf{c}_j) \mathbf{f}_j, \text{ para } \mathbf{f}_j = \frac{\mathbf{u}}{\|\mathbf{u}\|}. \\ \text{si } \mathbf{u} = \mathbf{0}, \text{ resulta } \mathbf{c}_j = \sum_{k=1}^j (\mathbf{f}_k^\top \mathbf{c}_j) \mathbf{f}_k, \text{ para } \mathbf{f}_j = \mathbf{0}. \end{cases}$$

Como sabemos, el procedimiento concluye cuando conseguimos n vectores no nulos $\mathbf{f}_{k_1}, \mathbf{f}_{k_2}, \dots, \mathbf{f}_{k_n}$, que forman una base ortonormal de $\mathbb{K}^n$ (hemos excluido los $\mathbf{f}_k$ nulos).

Denotando $\mathbf{q}_t = \mathbf{f}_{k_t}$, para $t = 1, \dots, n$ (observemos que $k_t \geq t$), tenemos

$$\mathbf{c}_j = \sum_{k=1}^j (\mathbf{f}_k^\top \mathbf{c}_j) \mathbf{f}_k = \sum_{t=1}^n (\mathbf{f}_{k_t}^\top \mathbf{c}_j) \mathbf{f}_{k_t} = \sum_{t=1}^n r_{tj} \mathbf{q}_t \implies c_{ij} = \sum_{t=1}^n q_{it} r_{tj},$$

en donde, $r_{tj} = \mathbf{q}_t^\top \mathbf{c}_j$ para $1 \leq t \leq n, 1 \leq j \leq m$. En particular, $r_{tj} = 0$ cuando $k_t > j$ y sabemos que $k_t \geq t$, de manera que $r_{tj} = 0$ cuando $t > j$.

Así, hemos obtenido una factorización $C = QR$, con $Q = (q_{ij}) \in \mathbb{K}^{n \times n}$ ortogonal y $R = (r_{ij}) \in \mathbb{K}^{n \times m}$, trapezoidal superior, con el mismo rango que C . Esta descomposición se denomina **factorización QR** (completa).

Ejemplo 144. Desarrollamos el procedimiento expuesto con una matriz $C \in \mathbb{R}^{5 \times 3}$:

$$C = \begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 2 \\ 0 & 2 & 2 \\ 2 & 1 & 3 \\ 1 & 0 & 1 \end{bmatrix} = [\mathbf{c}_1 \quad \mathbf{c}_2 \quad \mathbf{c}_3] \quad ; \quad I_5 = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix} = [\mathbf{c}_4 \quad \mathbf{c}_5 \quad \mathbf{c}_6 \quad \mathbf{c}_7 \quad \mathbf{c}_8]$$

Etapla 1,

$$\mathbf{u} = \mathbf{c}_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \\ 2 \\ 1 \end{bmatrix}, \quad \|\mathbf{u}\| = \sqrt{7} \implies \mathbf{q}_1 = \mathbf{f}_1 = \frac{1}{\sqrt{7}} \begin{bmatrix} 1 \\ 1 \\ 0 \\ 2 \\ 1 \end{bmatrix}, \quad r_{11} = \mathbf{q}_1^\top \mathbf{c}_1 = \sqrt{7}$$

Etapa 2

$$\mathbf{u} = \mathbf{c}_2 - (\mathbf{f}_1^\top \mathbf{c}_2) \mathbf{f}_1 = \begin{bmatrix} -3/7 \\ 4/7 \\ 2 \\ 1/7 \\ -3/7 \end{bmatrix}, \quad \|\mathbf{u}\| = \frac{\sqrt{231}}{7} \implies \mathbf{q}_2 = \mathbf{f}_2 = \frac{1}{\sqrt{231}} \begin{bmatrix} -3 \\ 4 \\ 14 \\ 1 \\ -3 \end{bmatrix}$$

$$r_{22} = \mathbf{q}_2^\top \mathbf{c}_2 = \frac{\sqrt{231}}{7}, \quad r_{23} = \mathbf{q}_2^\top \mathbf{c}_3 = \frac{\sqrt{231}}{7}$$

Etapa 3

$$\mathbf{u} = \mathbf{c}_3 - (\mathbf{f}_1^\top \mathbf{c}_3) \mathbf{f}_1 - (\mathbf{f}_2^\top \mathbf{c}_3) \mathbf{f}_2 = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \implies \mathbf{f}_3 = \mathbf{0}$$

Etapa 4

$$\mathbf{u} = \mathbf{c}_4 - \sum_{k=1}^3 (\mathbf{f}_k^\top \mathbf{c}_4) \mathbf{f}_k = \begin{bmatrix} 9/11 \\ -1/11 \\ 2/11 \\ -3/11 \\ -2/11 \end{bmatrix}, \implies \mathbf{q}_3 = \mathbf{f}_4 = \frac{1}{\sqrt{11}} \begin{bmatrix} 3 \\ -1/3 \\ 2/3 \\ -1 \\ -2/3 \end{bmatrix}$$

$$r_{33} = \mathbf{q}_3^\top \mathbf{c}_3 = 0$$

Etapa 5

$$\mathbf{u} = \mathbf{c}_5 - \sum_{k=1}^4 (\mathbf{f}_k^\top \mathbf{c}_5) \mathbf{f}_k = \begin{bmatrix} 0 \\ 7/9 \\ -2/9 \\ -1/3 \\ -1/9 \end{bmatrix} \implies \mathbf{q}_4 = \mathbf{f}_5 = \frac{1}{\sqrt{7}} \begin{bmatrix} 0 \\ 7/3 \\ -2/3 \\ -1 \\ -1/3 \end{bmatrix}$$

Etapa 6

$$\mathbf{u} = \mathbf{c}_6 - \sum_{k=1}^5 (\mathbf{f}_k^\top \mathbf{c}_6) \mathbf{f}_k = \begin{bmatrix} 0 \\ 0 \\ 1/21 \\ -2/21 \\ 4/21 \end{bmatrix} \Rightarrow \mathbf{q}_5 = \mathbf{f}_6 = \frac{1}{\sqrt{21}} \begin{bmatrix} 0 \\ 0 \\ 1 \\ -2 \\ 4 \end{bmatrix}.$$

Los cinco vectores ortonormales, $\mathbf{q}_t = \mathbf{f}_{k_t}$, donde $k_1 = 1, k_2 = 2, k_3 = 4, k_4 = 5$ y $k_5 = 6$, proporcionan la descomposición $C = QR$:

$$\begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 2 \\ 0 & 2 & 2 \\ 2 & 1 & 3 \\ 1 & 0 & 1 \end{bmatrix} = \begin{bmatrix} \frac{1}{\sqrt{7}} & \frac{-3}{\sqrt{231}} & \frac{3}{\sqrt{11}} & 0 & 0 \\ \frac{1}{\sqrt{7}} & \frac{4}{\sqrt{231}} & \frac{-1}{3\sqrt{11}} & \frac{\sqrt{7}}{3} & 0 \\ 0 & \frac{14}{\sqrt{231}} & \frac{2}{3\sqrt{11}} & \frac{-2}{3\sqrt{7}} & \frac{1}{\sqrt{21}} \\ \frac{2}{\sqrt{7}} & \frac{1}{\sqrt{231}} & \frac{-1}{\sqrt{11}} & \frac{-1}{\sqrt{7}} & \frac{-2}{\sqrt{21}} \\ \frac{1}{\sqrt{7}} & \frac{-3}{\sqrt{231}} & \frac{-2}{3\sqrt{11}} & \frac{-1}{3\sqrt{7}} & \frac{4}{\sqrt{21}} \end{bmatrix} \begin{bmatrix} \sqrt{7} & \frac{3}{\sqrt{7}} & \frac{10}{\sqrt{7}} \\ 0 & \frac{\sqrt{231}}{7} & \frac{\sqrt{231}}{7} \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

□

Cuando $C \in \mathbb{K}^{n \times m}$ es alta (más filas que columnas, $m < n$), la matriz trapezoidal superior U es trapezoidal superior alta (tiene filas de ceros en la parte inferior), por lo que la factorización $C = QR$ se puede representar en bloques como

$$C = QR = [Q_1 \quad Q_2] \begin{bmatrix} R_1 \\ \mathbf{0} \end{bmatrix} = Q_1 R_1,$$

en donde $Q_1 \in \mathbb{K}^{n \times m}$ verifica $Q_1^\top Q_1 = I_m$ y $R_1 \in \mathbb{K}^{m \times m}$ es triangular superior.

La descomposición $C = Q_1 R_1$ se denomina *descomposición QR reducida o delgada*.

La misma idea se puede aplicar a cualquier matriz $C \in \mathbb{K}^{n \times m}$ de rango $r < n$:

$$C = QR = [Q_1 \quad Q_2] \begin{bmatrix} R_1 \\ \mathbf{0} \end{bmatrix} = Q_1 R_1,$$

en donde $Q_1 \in \mathbb{K}^{n \times r}$ verifica $Q_1^\top Q_1 = I_r$ y $R_1 \in \mathbb{K}^{r \times m}$ es trapezoidal superior con rango completo r . Esta versión de la factorización QR se denomina *factorización QR de rango*.

Obsérvese que las columnas de la matriz $Q_2 \in \mathbb{K}^{n \times (n-r)}$ forman una base ortonormal del subespacio $(\text{col } C)^\perp = \ker(C^\top)$.

Si C tiene rango máximo igual a n y se requiere que las posiciones de la diagonal de R_1 sean positivas, entonces la factorización QR reducida o de rango (coinciden, en este caso) es única (no existen otras dos matrices de esas características cuyo producto sea C).

Ejemplo 145. La descomposición QR reducida de la matriz C del ejemplo 144 es:

$$\begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 2 \\ 0 & 2 & 2 \\ 2 & 1 & 3 \\ 1 & 0 & 1 \end{bmatrix} = \begin{bmatrix} \frac{1}{\sqrt{7}} & \frac{-3}{\sqrt{231}} & \frac{3}{\sqrt{11}} \\ \frac{1}{\sqrt{7}} & \frac{4}{\sqrt{231}} & \frac{-1}{3\sqrt{11}} \\ 0 & \frac{14}{\sqrt{231}} & \frac{2}{3\sqrt{11}} \\ \frac{2}{\sqrt{7}} & \frac{1}{\sqrt{231}} & \frac{-1}{\sqrt{11}} \\ \frac{1}{\sqrt{7}} & \frac{-3}{\sqrt{231}} & \frac{-2}{3\sqrt{11}} \end{bmatrix} \begin{bmatrix} \sqrt{7} & \frac{3}{\sqrt{7}} & \frac{10}{\sqrt{7}} \\ 0 & \frac{\sqrt{231}}{7} & \frac{\sqrt{231}}{7} \\ 0 & 0 & 0 \end{bmatrix}.$$

Si atendemos al rango, y no solo al formato de C , se «reduce» más la descomposición, obteniéndose la factorización QR de rango:

$$\begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 2 \\ 0 & 2 & 2 \\ 2 & 1 & 3 \\ 1 & 0 & 1 \end{bmatrix} = \begin{bmatrix} \frac{1}{\sqrt{7}} & \frac{-3}{\sqrt{231}} \\ \frac{1}{\sqrt{7}} & \frac{4}{\sqrt{231}} \\ 0 & \frac{14}{\sqrt{231}} \\ \frac{2}{\sqrt{7}} & \frac{1}{\sqrt{231}} \\ \frac{1}{\sqrt{7}} & \frac{-3}{\sqrt{231}} \end{bmatrix} \begin{bmatrix} \sqrt{7} & \frac{3}{\sqrt{7}} & \frac{10}{\sqrt{7}} \\ 0 & \frac{\sqrt{231}}{7} & \frac{\sqrt{231}}{7} \end{bmatrix}.$$

□

En ocasiones se denomina *factorización o descomposición LQ* de una matriz C a la factorización QR de su traspuesta

$$C^T = QR \implies C = R^T Q^T = LQ^T,$$

en donde L es trapezoidal inferior y Q^T es ortogonal. En general, la descomposición LQ se puede obtener operando desde la derecha, por filas.

Ejemplo 146. Proporcionamos las descomposiciones QR completa y LQ reducida de una matriz ancha C de formato 3×5 :

$$\begin{aligned} C &= \begin{bmatrix} 1 & 2 & 5 & 4 & 7 \\ 2 & 10 & 7 & 8 & 11 \\ 2 & -2 & 4 & 8 & 8 \end{bmatrix} \\ C &= \begin{bmatrix} \frac{1}{3} & 0 & \frac{2}{3}\sqrt{2} \\ \frac{2}{3} & \frac{1}{2}\sqrt{2} & -\frac{1}{6}\sqrt{2} \\ \frac{2}{3} & -\frac{1}{2}\sqrt{2} & -\frac{1}{6}\sqrt{2} \end{bmatrix} \begin{bmatrix} 3 & 6 & 9 & 12 & 15 \\ 0 & 6\sqrt{2} & \frac{3}{2}\sqrt{2} & 0 & \frac{3}{2}\sqrt{2} \\ 0 & 0 & \frac{3}{2}\sqrt{2} & 0 & \frac{3}{2}\sqrt{2} \end{bmatrix} \\ C &= \begin{bmatrix} \sqrt{95} & 0 & 0 \\ \frac{166\sqrt{95}}{95} & \frac{3\sqrt{48070}}{95} & 0 \\ \frac{106\sqrt{95}}{95} & -\frac{336\sqrt{48070}}{24035} & \frac{18\sqrt{4807}}{253} \end{bmatrix} \begin{bmatrix} \frac{\sqrt{95}}{95} & \frac{2\sqrt{95}}{95} & \frac{\sqrt{95}}{19} & \frac{4\sqrt{95}}{95} & \frac{7\sqrt{95}}{95} \\ \frac{4\sqrt{48070}}{24035} & \frac{103\sqrt{48070}}{24035} & \frac{-\sqrt{48070}}{874} & \frac{16\sqrt{48070}}{24035} & \frac{-39\sqrt{48070}}{48070} \\ \frac{14\sqrt{4807}}{4807} & \frac{-\sqrt{4807}}{253} & \frac{-3\sqrt{4807}}{437} & \frac{56\sqrt{4807}}{4807} & \frac{-5\sqrt{4807}}{4807} \end{bmatrix} \end{aligned}$$



3.2. Aspectos computacionales de la factorización QR

Cuando se trabaja con matrices de gran tamaño y con aritmética de punto flotante, el objetivo deja de ser solo la validez teórica y pasa a ser la estabilidad frente a errores de redondeo y la eficiencia en memoria y tiempo de ejecución.

Aunque algebraicamente perfecto, el método de Gram-Schmidt es numéricamente inestable. La pérdida de ortogonalidad entre las columnas de Q se expande rápidamente debido a errores de cancelación cuando las columnas de C están casi alineadas.

Para garantizar la estabilidad numérica, las librerías especializadas no emplean Gram-Schmidt, sino diferentes tipos de transformaciones ortogonales, como los reflectores de Householder o las rotaciones de Givens, técnicas que no estudiaremos aquí. Estos métodos se pueden combinar con permutaciones de columnas, lo que da lugar a factorizaciones del tipo $C = QRP$, para ciertas matrices de permutación P .

De esta manera, normalmente es preferible la factorización QR frente a la descomposición PLU, no porque la primera requiera menos trabajo (de hecho, la factorización QR mediante Householder realiza aproximadamente el doble de operaciones flotantes que PLU), sino porque la robustez numérica y la reducción de la propagación de errores compensan el coste computacional adicional.

La excepción suele presentarse en el caso de las matrices dispersas, circunstancia en la que puede ser preferible una descomposición del tipo $C = PLUP'$.

IV.2: Resumen: factorización o descomposición QR

1. Toda matriz C se puede factorizar como $C = QR$, en donde Q es una matriz ortogonal y R es trapezoidal superior, con el mismo formato y rango que C . Esta descomposición se denomina *factorización QR* (completa).
2. Una matriz alta C (más filas que columnas), admite una descomposición *QR reducida* $C = Q_1 R_1$, en la que Q_1 es una matriz del mismo formato que C con las columnas ortonormales y R_1 es una matriz triangular superior.
3. Toda matriz $C \in \mathbb{K}^{n \times m}$ admite una descomposición *QR de rango*, de la forma $C = Q_1 R_1$, en la que r es el rango de C , mientras que $Q_1 \in \mathbb{K}^{n \times r}$ verifica $Q_1^\top Q_1 = I_r$ y $R_1 \in \mathbb{K}^{r \times m}$ es trapezoidal superior con rango r .

Si $r < n$ y $Q_2 \in \mathbb{K}^{n \times (n-r)}$ verifica $Q = [Q_1 \ Q_2]$, entonces las columnas de Q_2 forman una base ortonormal del subespacio $(\text{col } C)^\perp = \ker(C^\top)$.

Si $r = n$ y se requiere que las posiciones de la diagonal de R_1 sean positivas, entonces la factorización QR de rango, que coincide con la completa, es única (no existen otras dos matrices Q_1 y R_1 de esas características cuyo producto sea C).

4. Al aplicar la factorización QR a la traspuesta de C , se obtiene una descomposición $C = LQ$, en la que L es trapezoidal inferior y Q es ortogonal.
5. El método de Gram-Schmidt, de gran importancia teórica, tiene una limitada utilidad computacional. Las librerías especializadas emplean otros procedimientos para conseguir la factorización QR, como los reflectores de Householder o las rotaciones de Givens.
6. Normalmente, es preferible la factorización QR frente a la descomposición PLU, pues, aunque la primera requiere más operaciones que la segunda, es numéricamente más robusta. Hay excepciones, como lo son algunos casos de matrices dispersas.

3.3. Sistemas de ecuaciones y factorización QR

La resolución de un sistema de ecuaciones puede enfocarse a través de la proyección del vector de términos independientes sobre el espacio columna de la matriz de coeficientes: dados $A \in \mathbb{K}^{n \times m}$ y $\mathbf{b} \in \mathbb{K}^n$, como $\mathbb{K}^n = \text{col } A \oplus \ker A^\top$ (pág. 137), resulta

$$A\mathbf{x} = \text{proj}_{\text{col}(A)}(\mathbf{b}) \iff A^\top A\mathbf{x} = A^\top \mathbf{b}. \quad (27)$$

Cuando se considera como una ecuación matricial con incógnita $\mathbf{x} \in \mathbb{K}^m$, la igualdad de la derecha de (27) se denomina *ecuación normal* para la matriz A y el vector $\mathbf{b}$; si se considera, más bien, como un sistema de ecuaciones con incógnitas x_i , se le suele denominar sistema de *ecuaciones normales*.

Se puede reducir el tamaño de la ecuación normal aplicando una factorización QR de rango a la matriz $A^\top \in \mathbb{K}^{m \times n}$. Consideremos $A^\top = Q_1 R_1$, donde $Q_1 \in \mathbb{K}^{m \times r}$ verifica $Q_1^\top Q_1 = I_r$ y $R_1 \in \mathbb{K}^{r \times n}$ es trapezoidal superior con rango $r = \text{rng}(A)$.

$$\begin{aligned} A^\top A\mathbf{x} = A^\top \mathbf{b} &\iff Q_1 R_1 (Q_1 R_1)^\top \mathbf{x} = Q_1 R_1 \mathbf{b} \iff R_1 (Q_1 R_1)^\top \mathbf{x} = R_1 \mathbf{b} \\ &\iff R_1 R_1^\top Q_1^\top \mathbf{x} = R_1 \mathbf{b} \iff Q_1^\top \mathbf{x} = (R_1 R_1^\top)^{-1} R_1 \mathbf{b} \end{aligned}$$

$$\Longleftrightarrow \mathbf{x} = Q_1(R_1 R_1^\top)^{-1} R_1 \mathbf{b}.$$

El proceso anterior ha sido posible porque la matriz $R_1 R_1^\top \in \mathbb{K}^{r \times r}$ tiene rango r , por lo que es invertible (se trata de una matriz simétrica definida positiva). Observemos que la matriz completa $A^\top A \in \mathbb{K}^{m \times m}$ no tiene por qué ser invertible. En consecuencia,

$$A\mathbf{x} = \text{proj}_{\text{col } A}(\mathbf{b}) \Longleftrightarrow \mathbf{x} = Q_1(R_1 R_1^\top)^{-1} R_1 \mathbf{b}. \quad (28)$$

Esta expresión fundamental nos permite reproducir el razonamiento del teorema de Rouché-Frobenius (página 157) sin necesidad de recurrir al escalonamiento y obtener, además, soluciones cerradas en todos los casos:

1. Si $r = \text{rng}(A) < \text{rng}([A, \mathbf{b}])$, entonces $\mathbf{b} \notin \text{col } A$, luego el sistema $A\mathbf{x} = \mathbf{b}$ es incompatible (no tiene solución) y (28) nos da un $\mathbf{x} \in \mathbb{K}^m$ para el que $A\mathbf{x}$ minimiza la distancia de $\mathbf{b}$ al subespacio $\text{col } A$. Se trata del ajuste de A a $\mathbf{b}$ por *mínimos cuadrados*. Si $r = m$, el ajuste $\mathbf{x} = Q_1(R_1 R_1^\top)^{-1} R_1 \mathbf{b}$ es único.

Si $r < m$, hay infinitos «ajustes»

$$\mathbf{x} = Q_1(R_1 R_1^\top)^{-1} R_1 \mathbf{b} + Q_2 \mathbf{u},$$

en donde $\mathbf{u} \in \mathbb{K}^{m-r}$ es un vector de parámetros y $Q_2 \in \mathbb{K}^{m \times (m-r)}$ verifica $Q = [[Q_1, Q_2]]$ para la matriz ortogonal Q de la descomposición QR completa de $A^\top$.

Se trata de un caso patológico para el ajuste por mínimos cuadrados, pues indicaría la existencia de variables linealmente dependientes.

2. Si $r = \text{rng}(A) = \text{rng}([A, \mathbf{b}]) = m$, entonces $\mathbf{b} \in \text{col } A$ (el sistema $A\mathbf{x} = \mathbf{b}$ es compatible) y la factorización QR de rango coincide con la QR completa, de manera que $Q_1 = Q$, $R_1 = R$ y el sistema es compatible determinado, es decir, tiene una única solución:

$$\mathbf{x} = Q(R R^\top)^{-1} R \mathbf{b}.$$

3. Si $r = \text{rng}(A) = \text{rng}([A, \mathbf{b}]) < m$, entonces $\mathbf{b} \in \text{col } A$ (el sistema $A\mathbf{x} = \mathbf{b}$ es compatible) y la factorización QR de rango nos da el subespacio afín de las soluciones del sistema compatible indeterminado:

$$\mathbf{x} = Q_1(R_1 R_1^\top)^{-1} R_1 \mathbf{b} + Q_2 \mathbf{u},$$

en donde $\mathbf{u} \in \mathbb{K}^{m-r}$ es un vector de parámetros y $Q_2 \in \mathbb{K}^{m \times (m-r)}$ verifica $Q = [[Q_1, Q_2]]$ para la matriz ortogonal Q de la descomposición QR completa de $A^\top$.

Ejemplo 147. Aplicamos la factorización QR al sistema $A\mathbf{x} = \mathbf{b}$ del ejemplo 147:

$$A = \begin{bmatrix} 0 & 2 & 1 \\ 1 & -2 & 0 \\ 3 & 0 & 2 \\ 1 & 1 & 1 \end{bmatrix} \quad ; \quad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 5 \\ 3 \end{bmatrix}$$

La descomposición QR completa de $A^\top$ es:

$$\begin{bmatrix} 0 & 1 & 3 & 1 \\ 2 & -2 & 0 & 1 \\ 1 & 0 & 2 & 1 \end{bmatrix} = \begin{bmatrix} 0 & \frac{\sqrt{5}}{3} & \frac{2}{3} \\ \frac{2}{\sqrt{5}} & -\frac{2}{3\sqrt{5}} & \frac{1}{3} \\ \frac{1}{\sqrt{5}} & \frac{4}{3\sqrt{5}} & -\frac{2}{3} \end{bmatrix} \begin{bmatrix} \sqrt{5} & -\frac{4}{\sqrt{5}} & \frac{2}{\sqrt{5}} & \frac{3}{\sqrt{5}} \\ 0 & \frac{3}{\sqrt{5}} & \frac{23}{3\sqrt{5}} & \frac{7}{3\sqrt{5}} \\ 0 & 0 & \frac{2}{3} & \frac{1}{3} \end{bmatrix}.$$

Vemos que el rango de A es $m = 3$, por lo que la factorización coincide con la de rango y se comprueba que

$$\mathbf{x} = Q(RR^\top)^{-1}R\mathbf{b} = \begin{bmatrix} \frac{1}{2} \\ -\frac{1}{2} \\ 2 \end{bmatrix}.$$

□

Para profundizar. Hemos visto en el Tema II (pág. 114) que la matriz cuadrada $A^\top A \in \mathbb{K}^{m \times m}$ es invertible si y solo si el rango de $A \in \mathbb{K}^{n \times m}$ es igual m , es decir, si y solo si las columnas de A son linealmente independientes.

Gracias a (27), comprobamos de nuevo que el sistema $A\mathbf{x} = \mathbf{b}$ es compatible determinado si y solo si $\text{rng}(A) = \text{rng}([A, \mathbf{b}]) = m$, en cuyo caso, ahora tenemos una expresión cerrada para su única solución

$$\mathbf{x} = (A^\top A)^{-1}A^\top \mathbf{b}, \quad (29)$$

que, por supuesto, coincide con la proporcionada por (28) para el caso general.

En particular, si A es una matriz cuadrada, (29) resulta ser la expresión ya conocida $\mathbf{x} = A^{-1}\mathbf{b}$, pues $(A^\top A)^{-1}A^\top = A^{-1}(A^\top)^{-1}A^\top = A^{-1}$.

Cuando las columnas de A son linealmente independientes (véanse (27) y (29)):

$$\text{proj}_{\text{col } A}(\mathbf{b}) = A\mathbf{x} = A(A^\top A)^{-1}A^\top \mathbf{b},$$

precisamente como obtuvimos en la expresión (17) del Tema II. □

Aplicación a la informática. El ajuste por mínimos cuadrados representa en la ingeniería para la IA un puente entre el álgebra lineal teórica y el aprendizaje automático práctico, que se tratará con profundidad en otras asignaturas.

Aunque históricamente nace como la solución geométrica óptima para proyectar datos sobre subespacios en problemas superdeterminados (encontrando el punto de mínima distancia mediante la norma euclídea), su verdadero alcance en la IA moderna va mucho más allá: constituye el motor matemático de la regresión lineal básica y el fundamento conceptual de casi todas las funciones de pérdida empleadas en el entrenamiento de redes neuronales.

Comprender cómo minimizar la suma de errores al cuadrado mediante ecuaciones normales o descomposiciones matriciales no solo nos permite resolver problemas estadísticos clásicos, sino que sienta las bases algebraicas para entender la optimización en espacios de alta dimensión, el ajuste de modelos predictivos o el tratamiento de ruido en sistemas autónomos. $\square$

Ejemplo 148. Se desea ajustar un plano $z = p_1x + p_2y + p_3$ a un conjunto de $n = 6$ mediciones tridimensionales (x, y, z) , encontrando el vector $\mathbf{x} = (p_1, p_2, p_3)$ que minimiza el error cuadrático (distancia euclídea) mediante la factorización de la traspuesta $A^\top = QR$ correspondiente al sistema incompatible sobredeterminado $A\mathbf{x} = \mathbf{b}$.

Consideremos las mediciones siguientes, así como su presentación matricial:

$$\begin{array}{ccc|ccc}
 x_i & y_i & z_i & & & \\
 \hline
 1 & 0 & 7 & & & \\
 0 & 1 & 4 & & & \\
 1 & 1 & 5 & \rightarrow & A = & \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 1 & 1 \\ -1 & 0 & 1 \\ 0 & -1 & 1 \\ 0 & 0 & 1 \end{bmatrix}, & \mathbf{b} = & \begin{bmatrix} 7 \\ 4 \\ 5 \\ 3 \\ 6 \\ 0 \end{bmatrix} \\
 -1 & 0 & 3 & & & \\
 0 & -1 & 6 & & & \\
 0 & 0 & 0 & & & \\
 \hline
 \end{array}$$

La tercera columna de unos de A se incluye para formalizar el término independiente p_3 del ajuste mediante un plano afín $z = p_1x + p_2y + p_3$. Es como si hiciéramos un ajuste lineal $z = p_1x + p_2y + p_3s$ y la variable s tomara el valor constante $s = 1$.

Como la matriz A es de rango máximo, $\text{rng}(A) = m = 3$, la factorización QR completa $A^\top = QR$ coincide con la de rango:

$$Q = \begin{bmatrix} \frac{1}{\sqrt{3}} & 0 & 0 \\ \frac{1}{2\sqrt{3}} & \frac{\sqrt{3}}{2} & 0 \\ \frac{1}{2\sqrt{3}} & -\frac{1}{2\sqrt{3}} & \frac{1}{\sqrt{2}} \end{bmatrix}, \quad R = \begin{bmatrix} \sqrt{3} & \frac{1}{2\sqrt{3}} & \frac{3}{2\sqrt{3}} & 0 & \frac{1}{2\sqrt{3}} & \frac{1}{2\sqrt{3}} \\ 0 & \frac{\sqrt{3}}{2} & \frac{\sqrt{3}}{2} & 0 & -\frac{\sqrt{3}}{2} & 0 \\ 0 & 0 & \frac{1}{\sqrt{2}} & \sqrt{2} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$$

El valor del ajuste $\mathbf{x} = (p_1, p_2, p_3) = Q(RR^\top)^{-1}R\mathbf{b}$ es

$$\mathbf{x} = \begin{bmatrix} p_1 \\ p_2 \\ p_3 \end{bmatrix} = \begin{bmatrix} 2 \\ -1 \\ 4 \end{bmatrix}$$

Este vector determina la ecuación del plano ajustado $z = 2x - y + 4$, que minimiza la suma de los cuadrados de las distancias verticales de las 6 mediciones respecto al plano.

Si las dos primeras columnas de A hubieran sido linealmente dependientes (proporcionales), la nube de puntos de la tabla estaría alineada en una recta de $\mathbb{R}^3$, por lo que habría infinitos planos (todos los del haz por esa recta) que servirían de ajuste. Este sería el caso patológico que antes comentábamos:

$$\mathbf{x} = Q_1(R_1 R_1^\top)^{-1} R_1 \mathbf{b} + Q_2 u,$$

en donde $u \in \mathbb{R}$ sería un parámetro y $Q_2 \in \mathbb{R}^{3 \times 1}$ verificaría $Q = [[Q_1, Q_2]]$ para la descomposición QR de rango de $A^\top$. $\square$

4. FACTORIZACIÓN TRIANGULAR DE SCHUR

Vamos a demostrar que cualquier matriz cuadrada admite una *triangulación ortogonal*.

IV.3: Factorización triangular de Schur

Toda matriz cuadrada $A \in \mathbb{C}^{n \times n}$ se puede factorizar en la forma $A = QUQ^\top$, en donde $Q \in \mathbb{C}^{n \times n}$ es ortogonal y $U \in \mathbb{C}^{n \times n}$ es triangular superior con los autovalores de A en la diagonal, de manera que los polinomios característicos de A y U son idénticos.

Si $A \in \mathbb{R}^{n \times n}$ solo tiene autovalores reales, entonces Q se puede escoger en $\mathbb{R}^{n \times n}$.

Razonemos por inducción sobre el tamaño n de la matriz. En el caso $n = 1$ la propiedad es evidente, porque las matrices 1×1 son los escalares. Supongamos que la propiedad es cierta para matrices de tamaño $n - 1$. Para probarla para las matrices A de tamaño n , escogemos uno de sus autovalores λ y completamos una matriz ortonormal $Q_1 = [[\mathbf{u}, Q'_1]] \in \mathbb{C}^{n \times n}$ a partir un autovector unitario $\mathbf{u}$ correspondiente a λ :

$$Q_1^\top A Q_1 = Q_1^\top A \begin{bmatrix} \mathbf{u} & Q'_1 \end{bmatrix} = Q_1^\top \begin{bmatrix} A\mathbf{u} & A Q'_1 \end{bmatrix} = \begin{bmatrix} \mathbf{u}^\top \\ Q_1'^\top \end{bmatrix} \begin{bmatrix} \lambda \mathbf{u} & A Q'_1 \end{bmatrix} = \begin{bmatrix} \lambda & \mathbf{u}^\top A Q'_1 \\ \mathbf{0} & Q_1'^\top A Q'_1 \end{bmatrix}.$$

Como $Q_1'^\top A Q'_1$ es de tamaño $n - 1$, la hipótesis de inducción asegura la existencia de una matriz triangular superior U_1 y una ortogonal Q'_2 tales que $Q_1'^\top A Q'_1 = Q_2'^\top U_1 Q'_2$. Poniendo $Q_2 = [[1, \mathbf{0}], [\mathbf{0}, Q'_2]]$, $Q = Q_2 Q_1^\top$, resulta

$$\begin{aligned} Q A Q^\top &= \begin{bmatrix} 1 & \mathbf{0} \\ \mathbf{0} & Q'_2 \end{bmatrix} \begin{bmatrix} \lambda & \mathbf{u}^\top A Q'_1 \\ \mathbf{0} & Q_1'^\top A Q'_1 \end{bmatrix} \begin{bmatrix} 1 & \mathbf{0} \\ \mathbf{0} & Q_2'^\top \end{bmatrix} = \begin{bmatrix} \lambda & \mathbf{u}^\top A Q'_1 Q_2'^\top \\ \mathbf{0} & Q_2'^\top Q_1'^\top A Q'_1 Q_2'^\top \end{bmatrix} \\ &= \begin{bmatrix} \lambda & \mathbf{u}^\top A Q'_1 Q_2'^\top \\ \mathbf{0} & U_1 \end{bmatrix} = U \implies A = Q^\top U Q. \end{aligned}$$

Ejemplo 149. La factorización de Schur de la matriz del ejemplo 128 es:

$$\begin{bmatrix} 9 & -1 & -5 \\ 2 & 2 & -2 \\ 7 & -3 & -3 \end{bmatrix} = \begin{bmatrix} \frac{2}{3} & -\frac{1}{\sqrt{5}} & \frac{4}{3\sqrt{5}} \\ \frac{1}{3} & \frac{2}{\sqrt{5}} & \frac{2}{3\sqrt{5}} \\ \frac{2}{3} & 0 & -\frac{\sqrt{5}}{3} \end{bmatrix} \begin{bmatrix} 4 & 15 & -1 \\ 0 & 2 & -2\sqrt{5} \\ 0 & 0 & 2 \end{bmatrix} \begin{bmatrix} \frac{2}{3} & \frac{1}{3} & \frac{2}{3} \\ -\frac{1}{\sqrt{5}} & \frac{2}{\sqrt{5}} & 0 \\ \frac{4}{3\sqrt{5}} & \frac{2}{3\sqrt{5}} & -\frac{\sqrt{5}}{3} \end{bmatrix}.$$

Obsérvense los autovalores $\lambda = 4$, $\lambda = 2$, en la diagonal de la matriz triangular, repetidos según su multiplicidad en el polinomio característico. $\square$

Ejemplo 150. La factorización triangular de Schur de la matriz

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ -1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & -1 & 0 \end{bmatrix}$$

es

$$A = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & 0 & \frac{i}{\sqrt{2}} \\ \frac{i}{\sqrt{2}} & 0 & 0 & \frac{1}{\sqrt{2}} \\ 0 & \frac{1}{\sqrt{2}} & \frac{i}{\sqrt{2}} & 0 \\ 0 & \frac{i}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \end{bmatrix} \begin{bmatrix} i & 0 & \frac{1}{2} & -\frac{i}{2} \\ 0 & i & \frac{i}{2} & \frac{1}{2} \\ 0 & 0 & -i & 0 \\ 0 & 0 & 0 & -i \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{i}{\sqrt{2}} & 0 & 0 \\ 0 & 0 & \frac{1}{\sqrt{2}} & -\frac{i}{\sqrt{2}} \\ 0 & 0 & -\frac{i}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{i}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 & 0 \end{bmatrix}.$$

Compruébese que el polinomio característico de A es $P_A(\lambda) = (\lambda^2 + 1)^2$. $\square$

Resolver directamente la ecuación característica para hallar los autovalores es un proceso computacionalmente inestable y muy sensible a errores de redondeo. Las librerías numéricas actuales aplican iterativamente factorizaciones **QR** para aproximar esos autovalores y generar la estructura triangular de la factorización de Schur de forma numéricamente robusta.

TEMA V

PROCESOS DE DIAGONALIZACIÓN

1. DIAGONALIZACIÓN

En el capítulo anterior comprobamos cómo las factorizaciones PLU, QR y de Schur permiten descomponer matrices complejas en bloques triangulares u ortogonales más fáciles de operar, optimizando la resolución de sistemas de ecuaciones y los ajustes por mínimos cuadrados.

Sin embargo, en el núcleo de la IA a menudo no basta con simplificar: necesitamos comprender cómo opera una transformación lineal a lo largo de sus direcciones fundamentales. Aquí es donde entran en juego los procesos de diagonalización.

En este capítulo empleamos el término *diagonalización* en un sentido muy general: una factorización de la forma $A = W\Lambda V$, en la que Λ es una matriz diagonal-rectangular del mismo formato que A , que puede no ser cuadrada, mientras que V y W son matrices cuadradas invertibles.

Las matrices W y V pueden entenderse como cambios de bases, de manera que, cuando tienen el mismo formato $n \times n$, serían cambios de base en el mismo espacio $\mathbb{R}^n$.

En particular, si $V = W^{-1}$, la matriz Λ representaría la expresión de la aplicación lineal $\mathbf{x} \rightarrow A\mathbf{x}$ al cambiar las coordenadas mediante la matriz V :

$$\mathbf{x} \in \mathbb{R}^n \xrightarrow{\text{cambio}} \mathbf{x}' = V\mathbf{x} \xrightarrow{\text{aplicación lineal } \Lambda} \Lambda\mathbf{x}' \xrightarrow{\text{cambio}} W\Lambda\mathbf{x}' = W\Lambda V\mathbf{x} = A\mathbf{x} \in \mathbb{R}^n.$$

Se trata de una *diagonalización por similitud*, pues se dice que dos matrices A y B son *similares* si existe una matriz invertible W tal que $A = WBW^{-1}$.

 La relación de similitud se denomina también de *semejanza*, término que presenta inconvenientes didácticos, pues una *semejanza geométrica* corresponde a una matriz de la forma $W = \alpha Q$, con $\alpha \in \mathbb{R}$ y Q ortogonal. Aunque dicha matriz es invertible, no toda matriz invertible corresponde a una semejanza geométrica. Hay que prestar atención porque, en inglés, el término «similarity» se refiere tanto a lo que hemos llamado «similitud» como a la «semejanza» geométrica. □

Otro caso especialmente importante se da cuando A es una matriz hermítica (en par-

ticular, cuando $\mathbb{K} = \mathbb{R}$ y A es real simétrica) y $V = W^\top$, de manera que la matriz Λ representaría la expresión de la forma hermítica (bilineal, cuando $\mathbb{K} = \mathbb{R}$) dada por $\mathbf{x}, \mathbf{y} \in \mathbb{K}^n \rightarrow \mathbf{x}^\top A \mathbf{y} \in \mathbb{K}$ respecto del cambio determinado por la matriz V :

$$\mathbf{x}, \mathbf{y} \in \mathbb{K}^n \xrightarrow{\text{cambio}} \mathbf{x}' = V\mathbf{x}, \mathbf{y}' = V\mathbf{y} \xrightarrow{\Lambda \text{ como forma}} \mathbf{x}'^\top \Lambda \mathbf{y}' = \mathbf{x}^\top A \mathbf{y} \in \mathbb{K}.$$

Se trata de una *diagonalización por congruencia*, pues se dice que dos matrices A y B son *congruentes* si existe una matriz invertible W tal que $A = WBW^\top$.

⚠ Si W es ortogonal y $V = W^\top$, entonces, como $W^{-1} = W^\top$, una factorización del tipo $A = W\Lambda V$ sería tanto diagonalización por similitud como por congruencia. Se trata de la circunstancia más favorable: la *diagonalización ortogonal*. $\square$

Los escenarios de más interés son los siguientes:

- I) V y W triangulares. Son factorizaciones de tipo *LDU*, extensiones de la factorización LU ordinaria y basadas, por lo tanto, en la eliminación gaussiana. Es una descomposición más interesante cuando $W = V^\top$ o $W = V^T$, lo que da lugar a diagonalizaciones por congruencia del tipo *LDLT* para matrices hermíticas y simétricas, en particular, de *Cholesky (LLT)* si la matriz es semidefinida positiva.
- II) $V = W^{-1}$ ortogonal. Es el escenario central: la *diagonalización ortogonal* de una matriz normal como $A = Q\Lambda Q^\top$ con Q ortogonal, que se obtiene mediante la factorización de Schur. Es relevante el caso particular de que A sea hermítica y, especialmente, cuando A es real simétrica.
- III) $V = W^{-1}$. Es una extensión del escenario II, en el que se renuncia a pedir la ortogonalidad de los factores de transformación, pero se mantiene su igualdad. Se trata de la *diagonalización por similitud* de una matriz cuadrada diagonalizable (no todas lo son, como veremos).

Una versión aún más debilitada se aplica a cualquier matriz cuadrada, conformándose con que Λ sea diagonal por bloques, no necesariamente diagonal, aunque sus bloques sean *casi* diagonales (*forma de Jordan*).

Pese a su gran valor teórico, la diagonalización por similitud de matrices que no sean normales resulta poco interesante desde el punto de vista computacional, porque pequeñas variaciones o errores de redondeo en los datos iniciales pueden provocar errores gigantescos al calcular la inversa W^{-1} .

- IV) V y W ortogonales. Es una extensión del escenario II, en el que se renuncia a pedir la igualdad de los factores de transformación, a cambio de conseguir una gran

generalidad: todas las matrices admiten la denominada *descomposición en valores singulares (SVD)*. Se trata, sin duda, de la herramienta fundamental del álgebra lineal en IA. El correcto desempeño computacional está garantizado por el empleo de factores de transformación ortogonales.

2. FACTORIZACIÓN LDU

Al aplicar la factorización LU a una matriz $A \in \mathbb{K}^{n \times m}$ cuyos menores principales sean no nulos, obtenemos una descomposición $A = LV$, en donde $L \in \mathbb{K}^{n \times n}$ es unitriangular inferior y $V \in \mathbb{K}^{n \times m}$ es trapezoidal superior. La matriz V no puede tener elementos nulos en la diagonal, pues, si $v_{rr} = 0$, entonces:

$$\begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} = \begin{bmatrix} L_{11} & \mathbf{0} \\ L_{21} & L_{22} \end{bmatrix} \begin{bmatrix} V_{11} & V_{12} \\ V_{21} & V_{22} \end{bmatrix} \Rightarrow A_{11} = L_{11}V_{11} \Rightarrow \det A_{11} = \det V_{11} = 0,$$

en donde $A_{11}, L_{11}, V_{11} = (v_{ij})_{1 \leq i, j \leq r} \in \mathbb{K}^{r \times r}$.

Si $D \in \mathbb{K}^{n \times n}$ es la matriz diagonal $D = (\text{diag}(v_{11}, v_{22}, \dots, v_{nn}))^{-1}$, se obtiene la factorización $A = LDU$, en donde $L \in \mathbb{K}^{n \times n}$ es unitriangular inferior, $D \in \mathbb{K}^{n \times n}$ es diagonal y $U = D^{-1}V \in \mathbb{K}^{n \times m}$ es trapezoidal superior con unos en la diagonal principal.

Esta descomposición se denomina *factorización LDU*. Tal y como está definida arriba, no es una diagonalización en el sentido que hemos dado a ese término (página 181), pues la matriz U no es necesariamente cuadrada. En realidad, bastaría reescribir la expresión, poniendo $W = L$ y escogiendo Λ y V como sigue.

Si $m > n$, las matrices D y U «crecen»:

$$\Lambda = \begin{bmatrix} D & \mathbf{0} \end{bmatrix} \in \mathbb{K}^{n \times m}; V = \begin{bmatrix} U_1 & U_2 \\ \mathbf{0} & I_{m-n} \end{bmatrix} \in \mathbb{K}^{m \times m}, U = \begin{bmatrix} U_1 & U_2 \end{bmatrix} \Rightarrow DU = \Lambda V.$$

Si $m < n$, las matrices D y U se «recortan»:

$$W = L; D = \begin{bmatrix} \Lambda & D' \end{bmatrix}, \Lambda \in \mathbb{K}^{n \times m}; U = \begin{bmatrix} V \\ \mathbf{0} \end{bmatrix}, V \in \mathbb{K}^{m \times m} \Rightarrow DU = \Lambda V.$$

Ejemplo 151. Aplicamos el procedimiento anterior a la siguiente matriz:

$$\begin{aligned} A = \begin{bmatrix} 1 & 0 & 2 & 1 \\ 1 & 2 & 1 & 3 \\ 2 & 1 & 0 & 4 \end{bmatrix} &= \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 2 & \frac{1}{2} & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 2 & 1 \\ 0 & 2 & -1 & 2 \\ 0 & 0 & -\frac{7}{2} & 1 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 2 & \frac{1}{2} & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & -\frac{7}{2} \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 \\ 0 & 0 & -\frac{7}{2} & 0 \end{bmatrix}^{-1} \begin{bmatrix} 1 & 0 & 2 & 1 \\ 0 & 2 & -1 & 2 \\ 0 & 0 & -\frac{7}{2} & 1 \end{bmatrix} \end{aligned}$$

$$\begin{aligned}
&= \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 2 & \frac{1}{2} & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & -\frac{7}{2} \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & \frac{1}{2} & 0 \\ 0 & 0 & -\frac{2}{7} \end{bmatrix} \begin{bmatrix} 1 & 0 & 2 & 1 \\ 0 & 2 & -1 & 2 \\ 0 & 0 & -\frac{7}{2} & 1 \end{bmatrix} \\
&= \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 2 & \frac{1}{2} & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & -\frac{7}{2} \end{bmatrix} \begin{bmatrix} 1 & 0 & 2 & 1 \\ 0 & 1 & -\frac{1}{2} & 1 \\ 0 & 0 & 1 & -\frac{2}{7} \end{bmatrix} = LDU. \\
A = \begin{bmatrix} 1 & 0 & 2 & 1 \\ 1 & 2 & 1 & 3 \\ 2 & 1 & 0 & 4 \end{bmatrix} &= \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 2 & \frac{1}{2} & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 \\ 0 & 0 & -\frac{7}{2} & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 2 & 1 \\ 0 & 1 & -\frac{1}{2} & 1 \\ 0 & 0 & 1 & -\frac{2}{7} \\ 0 & 0 & 0 & 1 \end{bmatrix} = WAV.
\end{aligned}$$

□

El caso particular más interesante se da cuando $A \in \mathbb{K}^{n \times n}$ es una matriz cuadrada invertible que admite una factorización $A = LDU$ como la anterior: L y U unitriangulares y D diagonal, todas invertibles. Como hemos señalado, esta factorización existe, por ejemplo, cuando la matriz cuadrada A carece de menores principales nulos.

En estas circunstancias, la factorización LDU es única. En efecto, si existieran otras matrices L', D', U' de las mismas características que verificaran $LDU = L'D'U'$, se tendría $L'^{-1}LD = D'U'U^{-1}$. El miembro izquierdo de esta última igualdad es una matriz triangular inferior, mientras que el derecho es triangular superior, de manera que ambos deben ser, en realidad, matrices diagonales, por lo que $L'^{-1}L$ y $U'U^{-1}$ deben ser también diagonales. La unitriangularidad de los factores implica $L'^{-1}L = I$ y $U'U^{-1} = I$, de donde $L = L', U = U', D = D'$.

Si, además, la matriz A es simétrica, entonces $A = A^T = U^T D^T L^T$, lo que implica $L = U^T$ y la factorización LDU se presenta, en este caso, como $A = LDL^T$.

En algunos manuales, este caso de LDU se denomina *factorización LDLT*. De forma análoga, si $A \in \mathbb{C}^{n \times n}$ es hermítica, $A = A^\top = U^\top D^\top L^\top$, lo que implica $L = U^\top$, $D = D^\top$ y la factorización LDU se presenta como $A = LDL^\top$ con $D \in \mathbb{R}^{n \times n}$.

Ejemplo 152. Aplicamos transformaciones LDU a dos matrices simétricas y a una hermítica no simétrica:

$$\begin{aligned}
A = \begin{bmatrix} 1 & 0 & 2 \\ 0 & 5 & 3 \\ 2 & 3 & 0 \end{bmatrix} &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 2 & \frac{3}{5} & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 2 \\ 0 & 5 & 3 \\ 0 & 0 & -\frac{29}{5} \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 2 & \frac{3}{5} & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & -\frac{29}{5} \end{bmatrix} \begin{bmatrix} 1 & 0 & 2 \\ 0 & 1 & \frac{3}{5} \\ 0 & 0 & 1 \end{bmatrix}. \\
B = \begin{bmatrix} 1+i & 0 & 2i \\ 0 & 5 & 3 \\ 2i & 3 & 0 \end{bmatrix} &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 1+i & \frac{3}{5} & 1 \end{bmatrix} \begin{bmatrix} 1+i & 0 & 2i \\ 0 & 5 & 3 \\ 0 & 0 & \frac{1}{5} - 2i \end{bmatrix}
\end{aligned}$$

$$\begin{aligned}
 &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 1+i & \frac{3}{5} & 1 \end{bmatrix} \begin{bmatrix} 1+i & 0 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & \frac{1}{5} - 2i \end{bmatrix} \begin{bmatrix} 1 & 0 & 1+i \\ 0 & 1 & \frac{3}{5} \\ 0 & 0 & 1 \end{bmatrix} \\
 C &= \begin{bmatrix} 1 & 0 & -2i \\ 0 & 5 & 3+i \\ 2i & 3-i & 0 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 2i & \frac{3}{5} - \frac{1}{5}i & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & -2i \\ 0 & 5 & 3+i \\ 0 & 0 & -6 \end{bmatrix} \\
 &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 2i & \frac{3}{5} - \frac{1}{5}i & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & -6 \end{bmatrix} \begin{bmatrix} 1 & 0 & -2i \\ 0 & 1 & \frac{3}{5} + \frac{1}{5}i \\ 0 & 0 & 1 \end{bmatrix}.
 \end{aligned}$$

Obsérvese que A es simétrica real (y, por lo tanto, hermítica) $A^\top = A^T = A$, mientras que B es simétrica, $B^T = B$, pero no hermítica, $B^\top \neq B$. Por último, la matriz C es hermítica, $C^\top = C$, pero no simétrica, $C^T \neq C$. $\square$

Para terminar esta sección, observemos que, si A es hermítica y semidefinida positiva, la matriz $D = \text{diag}(d_{11}, \dots, d_{nn})$ tiene números reales no negativos en su diagonal, de los que se puede extraer la raíz cuadrada. Poniendo $D^{1/2} = \text{diag}(\sqrt{d_{11}}, \dots, \sqrt{d_{nn}})$ y $L' = LD^{1/2}$, se tiene

$$A = LDL^\top = LD^{1/2}D^{1/2}L^\top = L'L'^\top.$$

Por lo tanto, toda matriz hermítica semidefinida positiva se factoriza como $A = LL^\top$, con L triangular inferior (*descomposición de Cholesky o LLT*).

Ejemplo 153. Veamos tres descomposiciones Cholesky:

$$A = \begin{bmatrix} 4 & 2 & -2 & 4 \\ 2 & 10 & 1 & 5 \\ -2 & 1 & 6 & -1 \\ 4 & 5 & -1 & 15 \end{bmatrix} = \begin{bmatrix} 2 & 0 & 0 & 0 \\ 1 & 3 & 0 & 0 \\ -1 & 1 & 2 & 0 \\ 2 & 1 & 0 & 3 \end{bmatrix} \begin{bmatrix} 2 & 1 & -1 & 2 \\ 0 & 3 & 1 & 1 \\ 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 3 \end{bmatrix} = LL^\top.$$

$$B = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & -2 \\ 0 & -2 & 5 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ -\frac{1}{2}\sqrt{2} & \frac{1}{2}\sqrt{2} & 0 \\ \sqrt{2} & -\sqrt{2} & 1 \end{bmatrix} \begin{bmatrix} 0 & -\frac{1}{2}\sqrt{2} & \sqrt{2} \\ 0 & \frac{1}{2}\sqrt{2} & -\sqrt{2} \\ 0 & 0 & 1 \end{bmatrix} = LL^\top$$

$$B = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & -2 \\ 0 & -2 & 5 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ -\frac{1}{2} & \frac{\sqrt{3}}{2} & 0 \\ 1 & -\sqrt{3} & 1 \end{bmatrix} \begin{bmatrix} 0 & -\frac{1}{2} & 1 \\ 0 & \frac{\sqrt{3}}{2} & -\sqrt{3} \\ 0 & 0 & 1 \end{bmatrix} = L'L'^\top.$$

La matriz B admite distintas factorizaciones LLT; no es definida positiva, solo es semidefinida positiva. $\square$

3. DIAGONALIZACIÓN ORTOGONAL

3.1. Teorema espectral

Si una matriz $A \in \mathbb{C}^{n \times n}$ admite una diagonalización ortogonal, $A = Q\Lambda Q^\top$, con Λ diagonal y Q ortogonal, entonces A es normal, pues

$$AA^\top = (Q\Lambda Q^\top)(Q\Lambda^\top Q^\top) = Q\Lambda\Lambda^\top Q^\top = Q\Lambda^\top\Lambda Q^\top = (Q\Lambda^\top Q^\top)(Q\Lambda Q^\top) = A^\top A.$$

Recíprocamente, si aplicamos la factorización de Schur a una matriz normal A (véase el apartado 4 del Tema 4):

$$\left. \begin{aligned} Q^\top AA^\top Q &= Q^\top (QUQ^\top)(QU^\top Q^\top)Q = UU^\top \\ Q^\top A^\top AQ &= Q^\top (QU^\top Q^\top)(QUQ^\top)Q = U^\top U \end{aligned} \right\} \implies UU^\top = U^\top U.$$

Como U es triangular y normal, tiene que ser diagonal, $U = \Lambda$ (véase el apartado 3.6 del Tema II), con lo que A admite una diagonalización ortogonal $A = Q\Lambda Q^\top$.

Como $AQ = Q\Lambda$, cada columna $\mathbf{q}_i$ de Q es un autovector de A con autovalor λ_i , en donde $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$, pues $A\mathbf{q}_i = \lambda_i \mathbf{q}_i$.

Resumimos estos resultados, recordando las propiedades de la factorización de Schur.

V.1: Teorema espectral para matrices normales ($A^\top A = AA^\top$)

Una matriz A admite una diagonalización ortogonal, $A = Q\Lambda Q^\top$, con Q ortogonal y Λ diagonal, si y solo si A es normal, $A^\top A = AA^\top$.

Cada columna $\mathbf{q}_i$ de la matriz Q es un autovector de A con autovalor λ_i , en donde $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$, y cada autovalor λ_i aparece en la diagonal de Λ tantas veces como indica su multiplicidad en el polinomio característico de A .

Las matrices normales más importantes son las hermíticas ($A^\top = A$), en particular, las matrices reales simétricas. La matriz diagonal Λ obtenida al diagonalizar una matriz hermítica A siempre es real, lo sea o no A :

$$\Lambda = Q^\top A Q = Q^\top A^\top Q = (Q^\top A Q)^\top = \Lambda^\top = \bar{\Lambda} \implies \Lambda \in \mathbb{R}^{n \times n}.$$

Entre las hermíticas, las más interesantes son las matrices semidefinidas positivas. Si $A = Q\Lambda Q^\top$ es una diagonalización ortogonal de una matriz hermítica, claramente se verificará $\mathbf{u}^\top A \mathbf{u} \geq 0$ para todo $\mathbf{u} \in \mathbb{K}^n$, si y solo si $\mathbf{v}^\top \Lambda \mathbf{v} \geq 0$, para todo $\mathbf{v} \in \mathbb{K}^n$ (basta

poner $\mathbf{v} = Q^\top \mathbf{u}$), lo cual ocurre si y solo si los elementos de la diagonal de Λ (autovalores de A) son no negativos. Un razonamiento similar funciona cuando A es definida positiva.

Podemos definir la **raíz cuadrada** de una matriz hermítica semidefinida positiva A :

$$A^{1/2} = Q \operatorname{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_n}) Q^\top, \quad (30)$$

en donde $\Lambda = \operatorname{diag}(\lambda_1, \dots, \lambda_n)$ en la diagonalización ortogonal $A = Q\Lambda Q^\top$.

Tal y como se espera de una raíz cuadrada, se verifica $(A^{1/2})^2 = A$:

$$\begin{aligned} (A^{1/2})^2 &= (Q \operatorname{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_n}) Q^\top)(Q \operatorname{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_n}) Q^\top) \\ &= Q(\operatorname{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_n})^2 Q^\top = Q \operatorname{diag}(\lambda_1, \dots, \lambda_n) Q^\top = A. \end{aligned}$$

Por otra parte, $X = A^{1/2}$ es la única matriz hermítica definida positiva que cumple $X^2 = A$, pues, si hubiera dos de tales matrices X e Y , como las dos tendrían los mismos autovectores que A , ambas compartirían la matriz Q en sendas diagonalizaciones ortogonales, $X = QDQ^\top$, $Y = QD'Q^\top$, de donde $D^2 = QX^2Q^\top = QY^2Q^\top = D'^2$, lo que implica $D = D'$ y, en consecuencia, $X = Y$.

V.2: Teorema espectral para matrices hermíticas ($A^\top = A$)

Todos los autovalores de una matriz hermítica A son reales, es decir, $\Lambda \in \mathbb{R}^{n \times n}$ en todas las diagonalizaciones ortogonales $A = Q\Lambda Q^\top$.

En particular, si $A \in \mathbb{R}^{n \times n}$ es simétrica, $A^\top = A$, la matriz Q se puede escoger también en $\mathbb{R}^{n \times n}$.

Una matriz hermítica es definida positiva (respectivamente, semidefinida positiva) si y solo si todos sus autovalores son positivos (respectivamente, no negativos).

La raíz cuadrada $A^{1/2}$ de una matriz hermítica semidefinida positiva A definida en (30) es la única matriz hermítica semidefinida positiva X que verifica $X^2 = A$.

Ejemplo 154. Veamos cómo se puede obtener la diagonalización ortogonal de la matriz normal A del ejemplo 87. Un ejercicio de este tipo puede servir para aclarar la estructura de la diagonalización ortogonal, pero tiene muy poca utilidad práctica fuera del entorno académico, pues los algoritmos que se emplean en la realidad son diferentes.

El polinomio característico de A es $P_A(\lambda) = (\lambda - 3)(\lambda^2 - 2\lambda + 5)$ y sus autovalores

son $\lambda_1 = 3, \lambda_2 = 1 + 2i, \lambda_3 = 1 - 2i$, con autoespacios:

$$E_1 = \ker(\lambda_1 I - A) = \left\{ \mathbf{u} : \begin{bmatrix} 0 & 0 & 0 \\ 0 & 2 & 2 \\ 0 & -2 & 2 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \right\} = \langle (1, 0, 0) \rangle.$$

$$E_2 = \ker(\lambda_2 I - A) = \left\{ \mathbf{u} : \begin{bmatrix} -2 + 2i & 0 & 0 \\ 0 & 2i & 2 \\ 0 & -2 & 2i \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \right\} = \langle (0, 1, -i) \rangle.$$

$$E_3 = \ker(\lambda_3 I - A) = \left\{ \mathbf{u} : \begin{bmatrix} -2 - 2i & 0 & 0 \\ 0 & -2i & 2 \\ 0 & -2 & -2i \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \right\} = \langle (0, 1, i) \rangle.$$

Los tres autoespacios tienen dimensión 1 y son ortogonales entre sí (como hemos visto, siempre lo son, si la matriz original es normal). Normalizamos un generador de cada autoespacio, $\mathbf{q}_1 = (1, 0, 0)$, $\mathbf{q}_2 = (0, \frac{1}{\sqrt{2}}, \frac{-i}{\sqrt{2}})$, $\mathbf{q}_3 = (0, \frac{1}{\sqrt{2}}, \frac{i}{\sqrt{2}})$, formamos con ellos la matriz ortogonal $Q = [\mathbf{q}_1 \ \mathbf{q}_2 \ \mathbf{q}_3]$ y obtenemos así la diagonalización ortogonal:

$$A = \begin{bmatrix} 3 & 0 & 0 \\ 0 & 1 & -2 \\ 0 & 2 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ 0 & -\frac{i}{\sqrt{2}} & \frac{i}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} 3 & 0 & 0 \\ 0 & 1 + 2i & 0 \\ 0 & 0 & 1 - 2i \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & \frac{1}{\sqrt{2}} & \frac{i}{\sqrt{2}} \\ 0 & \frac{1}{\sqrt{2}} & -\frac{i}{\sqrt{2}} \end{bmatrix} = Q \Lambda Q^\top.$$

Se trata de una diagonalización en $\mathbb{C}$ de una matriz normal real $A \in \mathbb{R}^{3 \times 3}$. No podemos conseguir una diagonalización en $\mathbb{R}$, porque A tiene autovalores complejos (A es normal, pero no simétrica). $\square$

Ejemplo 155. Diagonalicemos ortogonalmente la siguiente matriz real simétrica:

$$A = \begin{bmatrix} 3 & 0 & 0 \\ 0 & 1 & 2 \\ 0 & 2 & 1 \end{bmatrix}.$$

El polinomio característico de A es $P_A(\lambda) = (\lambda - 3)(\lambda^2 - 2\lambda - 3) = (\lambda - 3)^2(\lambda + 1)$ y sus autovalores son reales: $\lambda_1 = 3$, con multiplicidad 2, y $\lambda_2 = -1$, con multiplicidad 1. Los autoespacios correspondientes son:

$$E_1 = \ker(\lambda_1 I - A) = \left\{ \mathbf{u} : \begin{bmatrix} 0 & 0 & 0 \\ 0 & 2 & -2 \\ 0 & -2 & 2 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \right\} = \langle (1, 0, 0), (0, 1, 1) \rangle.$$

$$E_2 = \ker(\lambda_2 I - A) = \left\{ \mathbf{u} : \begin{bmatrix} -4 & 0 & 0 \\ 0 & -2 & -2 \\ 0 & -2 & -2 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \right\} = \langle (0, 1, -1) \rangle.$$

Los autoespacios E_1 y E_2 tienen dimensiones 2 y 1, respectivamente, y son ortogonales entre sí. Al escoger los generadores de E_1 hemos formado una base ortogonal de E_1 , lo que siempre se puede conseguir por el algoritmo de Gram-Schmidt. Normalizamos los generadores, $\mathbf{q}_1 = (1, 0, 0)$, $\mathbf{q}_2 = (0, \frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}})$, $\mathbf{q}_3 = (0, \frac{1}{\sqrt{2}}, \frac{-1}{\sqrt{2}})$, formamos con ellos la matriz ortogonal $Q = [\mathbf{q}_1 \ \mathbf{q}_2 \ \mathbf{q}_3]$ y obtenemos la diagonalización ortogonal:

$$A = \begin{bmatrix} 3 & 0 & 0 \\ 0 & 1 & 2 \\ 0 & 2 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ 0 & \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} 3 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & -1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ 0 & \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix} = Q\Lambda Q^\top.$$

Como cabía esperar, hemos obtenido una diagonalización en $\mathbb{R}$, pues la matriz real A no solo es normal, es simétrica. $\square$

Ejemplo 156. Hallemos la raíz cuadrada de la siguiente matriz simétrica semidefinida positiva (en el proceso comprobaremos que efectivamente lo es):

$$A = \begin{bmatrix} 294 & -282 & -12 \\ -282 & 294 & -12 \\ -12 & -12 & 24 \end{bmatrix}.$$

Diagonalizamos ortogonalmente la matriz A :

$$A = \begin{bmatrix} \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{3}} & -\frac{2}{\sqrt{6}} & 0 \end{bmatrix} \begin{bmatrix} 0 & 0 & 0 \\ 0 & 36 & 0 \\ 0 & 0 & 576 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{6}} & 0 \end{bmatrix}.$$

Extraemos la raíz cuadrada de la matriz diagonal y deshacemos la factorización:

$$A^{1/2} = \begin{bmatrix} \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{3}} & -\frac{2}{\sqrt{6}} & 0 \end{bmatrix} \begin{bmatrix} 0 & 0 & 0 \\ 0 & 6 & 0 \\ 0 & 0 & 24 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{6}} & 0 \end{bmatrix} = \begin{bmatrix} 13 & -11 & -2 \\ -11 & 13 & -2 \\ -2 & -2 & 4 \end{bmatrix}.$$

Compruébese que, efectivamente, $A^{1/2}A^{1/2} = A$. $\square$

3.2. Ley de inercia de Sylvester

Ya hemos señalado que la ortogonal es un caso particular de diagonalización por congruencia (también es un caso de diagonalización por similitud, pues $W^\top = W^{-1}$).

Aunque no todas las diagonalizaciones por congruencia $A = V\Lambda V^\top$ de una matriz hermítica A sean ortogonales, pues V es aquí una matriz invertible, no necesariamente ortogonal, lo cierto que A admitirá también una diagonalización ortogonal $A = Q\Lambda_A Q^\top$, de manera que $\Lambda_A = M\Lambda M^\top$, donde $M = Q^\top V$.

Las matrices reales Λ y Λ_A son diagonalizaciones por congruencia de la misma matriz A , pero, como Λ_A lo es ortogonalmente, debe tener en su diagonal los autovalores de A , algo que, en general, no cumplirá Λ . Veamos que la relación entre Λ_A y Λ es más sutil.

Decimos que dos matrices hermíticas A y B del mismo formato tienen la *misma signatura* si admiten sendas diagonalizaciones ortogonales de la forma $A = Q_A \Lambda_A Q_A^\top$, $B = Q_B \Lambda_+ \Lambda_A Q_B^\top$ con Λ_+ definida positiva. En términos más coloquiales: A y B tienen la misma signatura si tienen el mismo número de autovalores positivos y el mismo número de autovalores negativos, contando las multiplicidades.

Comencemos demostrando que si $RDR^\top$ es diagonal, con R triangular invertible y D diagonal real, entonces D y $RDR^\top$ tiene la misma signatura. Lo hacemos para R triangular inferior (se hace igual si es superior): suponemos que la propiedad es cierta para matrices de tamaño menor que el de D y razonamos por inducción con $z \in \mathbb{K}$, $d \in \mathbb{R}$:

$$RDR^\top = \begin{bmatrix} R_1 & \mathbf{0} \\ \mathbf{r}^\top & z \end{bmatrix} \begin{bmatrix} D_1 & \mathbf{0} \\ \mathbf{0} & d \end{bmatrix} \begin{bmatrix} R_1^\top & \mathbf{r} \\ \mathbf{0} & \bar{z} \end{bmatrix} = \begin{bmatrix} R_1 D_1 R_1^\top & R_1 D_1 \mathbf{r} \\ \mathbf{r}^\top D_1 R_1^\top & \mathbf{r}^\top D_1 \mathbf{r} + |z|^2 d \end{bmatrix}.$$

Ahora bien, como $RDR^\top$ es diagonal, se tiene $R_1 D_1 \mathbf{r} = \mathbf{0}$, es decir, $D_1 \mathbf{r} = \mathbf{0}$, pues R_1 es singular. Al tener $R_1 D_1 R_1^\top$ la misma signatura que D_1 por la hipótesis de inducción, concluimos que D y $RDR^\top$ tienen también la misma signatura, pues:

$$D = \begin{bmatrix} D_1 & \mathbf{0} \\ \mathbf{0} & d \end{bmatrix} \quad ; \quad RDR^\top = \begin{bmatrix} R_1 D_1 R_1^\top & \mathbf{0} \\ \mathbf{0} & |z|^2 d \end{bmatrix}.$$

Retomemos nuestro razonamiento con $\Lambda_A = M \Lambda M^\top$. Podemos conseguir una factorización PLU de la matriz M , de manera que $M = PLU$ con $U \Lambda U^\top$ diagonal. Como P es una matriz de permutación, la matriz $P^\top \Lambda_A P$ es diagonal y:

$$P^\top \Lambda_A P = P^\top M \Lambda M^\top P = L(U \Lambda U^\top) L^\top.$$

Aplicando dos veces el resultado parcial anterior para matrices triangulares y diagonales, deducimos que Λ y $P^\top \Lambda_A P$ tienen la misma signatura y, como $P^\top \Lambda_A P$ y Λ_A tienen incluso el mismo polinomio característico (ya que $P^\top$ es la inversa de P), concluimos que Λ y Λ_A tienen la misma signatura y, por lo tanto, Λ y A también tienen la misma signatura.

Como toda matriz hermítica puede diagonalizarse ortogonalmente, hemos demostrado que la congruencia de matrices hermíticas implica la igualdad de las signaturas.

El recíproco también es cierto: si A y B tienen la misma signatura, entonces de las correspondientes diagonalizaciones, $A = Q_A \Lambda_A Q_A^\top$, $B = Q_B \Lambda_+ \Lambda_A Q_B^\top$, se sigue:

$$B = Q_B \Lambda_+ \Lambda_A Q_B^\top = Q_B \Lambda_+^{1/2} \Lambda_A \Lambda_+^{1/2} Q_B^\top = Q_B \Lambda_+^{1/2} (Q_A^\top A Q_A) \Lambda_+^{1/2} Q_B^\top = M A M^\top, \\ \text{para } M = Q_B \Lambda_+^{1/2} Q_A^\top.$$

V.3: Ley de inercia de Sylvester

Dos matrices hermíticas son congruentes si y solo si tienen la misma signatura.

Es decir, dos matrices hermíticas, A y B , tienen el mismo formato, el mismo número de autovalores positivos y el mismo número de autovalores negativos (contando la multiplicidad) si y solo si existe una matriz invertible M tal que $B = MAM^T$.

En consecuencia, si $A = M\Lambda M^T$ y $A = M'\Lambda'M'^T$ son dos diagonalizaciones por congruencia de una misma matriz hermítica A , entonces las matrices diagonales Λ y Λ' son congruentes, por lo que tienen el mismo número de elementos positivos y el mismo número de elementos negativos.

Ejemplo 157. Comparemos dos diagonalizaciones por congruencia de la siguiente matriz real simétrica:

$$A = \begin{bmatrix} 1 & -1 & 0 & 2 \\ -1 & 1 & 2 & 0 \\ 0 & 2 & 1 & -1 \\ 2 & 0 & -1 & 1 \end{bmatrix}.$$

Mediante reducción de Gauss, obtenemos una diagonalización del tipo LDLT:

$$A = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 2 & 1 & 0 & 0 \\ -2 & 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & -4 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 1 & 2 & -2 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & -1 \\ 0 & 0 & 0 & 1 \end{bmatrix}.$$

Ahora, diagonalizamos ortogonalmente la matriz A :

$$A = \begin{bmatrix} -\frac{1}{2} & \frac{1}{2} & -\frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} \\ -\frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} \\ \frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} & \frac{1}{2} \end{bmatrix} \begin{bmatrix} -2 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 4 \end{bmatrix} \begin{bmatrix} -\frac{1}{2} & \frac{1}{2} & -\frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} \\ -\frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} \\ \frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} & \frac{1}{2} \end{bmatrix}.$$

Vemos que las matrices diagonales son diferentes, pero ambas tienen la misma signatura: dos elementos positivos y uno negativo.

La diagonalización ortogonal proporciona, como sabemos, los autovalores de A , que

pueden calcularse directamente a partir de su ecuación característica:

$$P_A(\lambda) = 0 \iff \det(\lambda I - A) = 0 \iff \det \begin{bmatrix} \lambda - 1 & 1 & 0 & -2 \\ 1 & \lambda - 1 & -2 & 0 \\ 0 & -2 & \lambda - 1 & 1 \\ -2 & 0 & 1 & \lambda - 1 \end{bmatrix} = 0$$

$$\iff \lambda^4 - 4\lambda^3 - 4\lambda^2 + 16\lambda = 0 \iff \lambda(\lambda - 2)(\lambda + 2)(\lambda - 4) = 0,$$

de manera que los autovalores son $\lambda = -2$, $\lambda = 0$, $\lambda = 2$ y $\lambda = 4$. $\square$

Nota 7. Aunque teóricamente existen infinitas matrices que diagonalizan una matriz real simétrica por congruencia, en IA solo interesa la diagonalización ortogonal. Las matrices ortogonales garantizan la estabilidad y conservan la geometría de los datos. $\square$

3.3. Matrices definidas y semidefinidas

El tedioso método de agrupar cuadrados para clasificar una forma cuadrática que vimos en los ejemplos 136 y 137 del Tema III resulta impracticable, salvo en dimensiones muy bajas. La diagonalización ortogonal (V.2) nos ofrece un criterio más práctico.

Si $A = Q^T \Lambda Q$ es una diagonalización ortogonal de una matriz hermítica $A \in \mathbb{K}^{n \times n}$ definida positiva (pág. 149), todos sus autovalores λ_i son positivos, pues $\lambda_i \leq 0$ implicaría $(Q\mathbf{e}_i)^T A (Q\mathbf{e}_i) = \mathbf{e}_i^T \Lambda \mathbf{e}_i = \lambda_i \leq 0$, lo cual no es posible si A es definida positiva.

Recíprocamente, si todos los autovalores λ_i de A son positivos, entonces

$$\mathbf{x}^T A \mathbf{x} = (Q^T \mathbf{u})^T (Q^T \Lambda Q) (Q^T \mathbf{u}) = \mathbf{u}^T Q Q^T \Lambda Q Q^T \mathbf{u} = \mathbf{u}^T \Lambda \mathbf{u} = \sum_{i,j=1}^n \lambda_i u_i^2 > 0,$$

para todo $\mathbf{x} = Q^T \mathbf{u} \neq \mathbf{0}$, luego A es definida positiva. El mismo argumento funciona para semidefinitud positiva.

V.4: Caracterización de la definitud mediante autovalores

Una matriz hermítica $A \in \mathbb{K}^{n \times n}$ es definida positiva si y solo si todos sus autovalores son positivos. Por lo tanto, el determinante de una matriz hermítica definida positiva es positivo.

Una matriz hermítica $A \in \mathbb{K}^{n \times n}$ es semidefinida positiva si y solo si todos sus autovalores son no negativos. Por lo tanto, el determinante de una matriz hermítica semidefinida positiva es no negativo.

La caracterización de la definitud positiva mediante autovalores sugiere que tal vez no sea imprescindible calcular todos los autovalores, sino que pudiera bastar con calcular los menores principales. Efectivamente, es así.

V.5: Criterio de Sylvester

Una matriz hermítica $A \in \mathbb{K}^{n \times n}$ es definida positiva si y solo si todos sus menores principales son positivos:

$$\det \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1k} \\ a_{21} & a_{22} & \dots & a_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{k2} & \dots & a_{kk} \end{bmatrix} > 0, \text{ para todo } k = 1, 2, \dots, n.$$

Ejemplo 158. Dada la matriz simétrica A :

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & 3 \\ 0 & 3 & 7 \end{bmatrix},$$

calculamos los menores principales:

$$\Delta_1 = \det [a_{11}] = \det [2] = 2 > 0,$$

$$\Delta_2 = \det \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} = \det \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} = 3 > 0,$$

$$\Delta_3 = \det \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = \det \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & 3 \\ 0 & 3 & 7 \end{bmatrix} = 3 > 0.$$

Como todos los menores principales son positivos, A es definida positiva. □

Ejemplo 159. Dada la matriz simétrica A :

$$A = \begin{bmatrix} 1 & -1 & 0 & 2 \\ -1 & 1 & 2 & 0 \\ 0 & 2 & 1 & -1 \\ 2 & 0 & -1 & 1 \end{bmatrix},$$

calculamos los menores principales:

$$\Delta_1 = \det [a_{11}] = \det [1] = 1 > 0,$$

$$\Delta_2 = \det \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} = \det \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix} = 0 \geq 0.$$

$$\Delta_3 = \det \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = \det \begin{bmatrix} 1 & -1 & 0 \\ -1 & 1 & 2 \\ 0 & 2 & 1 \end{bmatrix} = -5 < 0.$$

Como el menor Δ_3 es negativo, A no es definida positiva.

La matriz A tampoco es semidefinida positiva, por cierto, porque tiene un autovalor negativo (ejemplo 157), pero esto no se deduce del criterio de Sylvester. $\square$

Vamos a justificar el criterio de Sylvester razonando por inducción sobre el tamaño n de la matriz. El criterio es evidentemente cierto para $n = 1$, pues una matriz hermítica 1×1 es un número real (un escalar igual a su conjugado). Supongamos que el criterio de Sylvester es cierto para matrices de tamaño menor que n y demostrémoslo para matrices hermíticas A de tamaño n , matrices que podemos escribir por bloques como

$$A = \begin{bmatrix} C & \mathbf{w} \\ \mathbf{w}^\top & a \end{bmatrix}, \text{ con } a \in \mathbb{K}, \mathbf{w} \in \mathbb{K}^n \text{ y } C \in \mathbb{K}^{(n-1) \times (n-1)}, \text{ hermítica.}$$

Si suponemos que A es definida positiva, entonces C también debe serlo, pues

$$\mathbf{x}^\top C \mathbf{x} = \begin{bmatrix} \mathbf{x} & 0 \end{bmatrix} \begin{bmatrix} C & \mathbf{w} \\ \mathbf{w}^\top & a \end{bmatrix} \begin{bmatrix} \mathbf{x} \\ 0 \end{bmatrix} > 0, \text{ para } \mathbf{x} \neq \mathbf{0}.$$

Por el mismo motivo, todas las submatrices principales de C son definidas positivas. Por la hipótesis de inducción, son positivos sus menores principales, que coinciden con los de A de tamaño menor que n . El de tamaño n también lo es, pues el determinante de toda matriz definida positiva resulta positivo por ser el producto de sus autovalores.

Recíprocamente, supongamos ahora que todos los menores principales de A son positivos. Claramente, también lo son los de C , luego la hipótesis de inducción implica que C es definida positiva. Si aplicamos un cambio de base $\mathbf{x} = R\mathbf{u}$, con la matriz invertible

$$R = \begin{bmatrix} I & -C^{-1}\mathbf{w} \\ \mathbf{0} & 1 \end{bmatrix},$$

resulta

$$\begin{aligned} \mathbf{x}^\top A \mathbf{x} &= \mathbf{u}^\top R^\top A R \mathbf{u} = \mathbf{u}^\top \begin{bmatrix} I & 0 \\ -\mathbf{w}^\top C^{-1} & I \end{bmatrix} \begin{bmatrix} C & \mathbf{w} \\ \mathbf{w}^\top & a \end{bmatrix} \begin{bmatrix} I & -C^{-1}\mathbf{w} \\ 0 & I \end{bmatrix} \mathbf{u} \\ &= \mathbf{u}^\top \begin{bmatrix} C & \mathbf{w} \\ 0 & a - \mathbf{w}^\top C^{-1}\mathbf{w} \end{bmatrix} \begin{bmatrix} I & -C^{-1}\mathbf{w} \\ 0 & I \end{bmatrix} \mathbf{u} \\ &= \mathbf{u}^\top \begin{bmatrix} C & 0 \\ 0 & a - \mathbf{w}^\top C^{-1}\mathbf{w} \end{bmatrix} \mathbf{u} = \mathbf{u}^\top \begin{bmatrix} C & 0 \\ 0 & \frac{\det(A)}{\det(C)} \end{bmatrix} \mathbf{u} > 0, \end{aligned}$$

pues C es definida positiva y los determinantes de A y C son positivos (se ha aplicado la fórmula del determinante de una matriz « 2×2 por bloques» del ejemplo 119). En con-

secuencia, A es definida positiva y así concluye la demostración del criterio de Sylvester.

Ejemplo 160. Dada la matriz simétrica A :

$$A = \begin{bmatrix} 0 & 0 & -1 \\ 0 & -1 & 0 \\ -1 & 0 & 0 \end{bmatrix},$$

calculamos los menores principales:

$$\Delta_1 = \det [a_{11}] = \det [0] = 0 \geq 0,$$

$$\Delta_2 = \det \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} = \det \begin{bmatrix} 0 & 0 \\ 0 & -1 \end{bmatrix} = 0 \geq 0,$$

$$\Delta_3 = \det \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = \det \begin{bmatrix} 0 & 0 & -1 \\ 0 & -1 & 0 \\ -1 & 0 & 0 \end{bmatrix} = 1 > 0.$$

La matriz A no es definida positiva, porque tiene menores principales nulos. Aunque todos los menores principales son no negativos, A no es semidefinida positiva, ya que posee autovalores negativos (sus autovalores son -1 , -1 y 1). $\square$

 Por analogía con los autovalores, podría pensarse que el criterio de Sylvester se extiende a matrices semidefinidas positivas cambiando las desigualdades estrictas por no estrictas, pero esto es falso, como muestra el ejemplo anterior. Su verdadero equivalente exige permutar filas y columnas para aislar las anulaciones, de modo que no basta con la no negatividad de los menores principales, sino que deben serlo todas las submatrices de tamaño $n - 1$. Al ser poco útil en la práctica (hay $2^n - 1$ submatrices de ese tamaño) la semidefinitud positiva se suele detectar mediante autovalores. $\square$

Finalmente, podemos combinar los resultados sobre matrices hermíticas semidefinidas positivas que obtuvimos en el Tema III (página 150) con la factorización de Cholesky, para obtener una tercera caracterización de definitud de una matriz.

V.6: Caracterización de la definitud mediante factorización

Una matriz $A \in \mathbb{K}^{n \times n}$ es hermítica semidefinida positiva si y solo si existe $B \in \mathbb{K}^{n \times n}$ tal que $A = B^\top B$. En ese caso, A y B tienen el mismo núcleo y rango.

Una matriz $A \in \mathbb{K}^{n \times n}$ es hermítica definida positiva si y solo si existe una matriz invertible $B \in \mathbb{K}^{n \times n}$ tal que $A = B^\top B$.

⚠ Una matriz es definida negativa si y solo si su opuesta es definida positiva, Así que, la manera lógica de aplicar los criterios anteriores para detectar la definitud negativa es aplicarlos, cuando sea posible, a la matriz opuesta $-A$. $\square$

4. DIAGONALIZACIÓN POR SIMILITUD

4.1. Matrices diagonalizables

Hemos comentado en varias ocasiones que la diagonalización ortogonal lo es tanto por congruencia como por similitud, pues los factores ortogonales en $A = Q\Lambda Q^\top$ verifican $Q^\top = Q^{-1}$ (véase la página 181). También sabemos que las matrices normales ($A^\top A = AA^\top$) son las únicas que pueden diagonalizarse ortogonalmente (véase el resultado V.1). En este apartado veremos que entre las matrices cuadradas que no son normales hay algunas que se pueden diagonalizar por similitud y otras que no.

Ejemplo 161. La matriz

$$A = \begin{bmatrix} 4 & -1 \\ 2 & 1 \end{bmatrix}$$

no es normal, pues

$$AA^\top - A^\top A = \begin{bmatrix} 17 & 7 \\ 7 & 5 \end{bmatrix} - \begin{bmatrix} 20 & -2 \\ -2 & 2 \end{bmatrix} \neq \mathbf{0},$$

pero se puede diagonalizar: compruébese la siguiente igualdad:

$$\begin{bmatrix} 4 & -1 \\ 2 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 2 & 1 \end{bmatrix}^{-1}$$

$\square$

Si escribimos la expresión $A = W\Lambda W^{-1}$ de una diagonalización por similitud en la forma $AW = W\Lambda$, vemos cuál es la condición necesaria y suficiente para que una matriz se pueda diagonalizar por similitud: las columnas de la matriz $W = [[\mathbf{w}_1, \dots, \mathbf{w}_n]]$ deben ser autovectores linealmente independientes de A , cuyos autovalores asociados estarán en la posición correspondiente en $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$. En efecto:

$$A\mathbf{w}_i = AW\mathbf{e}_i = W\Lambda\mathbf{e}_i = \lambda_i W\mathbf{e}_i = \lambda_i \mathbf{w}_i.$$

Para que sea posible formar una base con autovectores (elementos del autoespacio correspondiente a cada autovalor), la dimensión de cada autoespacio debe coincidir con la multiplicidad del correspondiente autovalor en el polinomio característico, pues la suma

de las multiplicidades de los autovalores coincide con la dimensión n del espacio total (Teorema Fundamental del Álgebra).

Ejemplo 162. El polinomio característico de la matriz

$$A = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 0 \\ 1 & 1 & 2 \end{bmatrix}$$

es

$$P_A(\lambda) = \det(\lambda I - A) = \det \begin{bmatrix} \lambda - 1 & -1 & 0 \\ 0 & \lambda - 1 & 0 \\ -1 & -1 & \lambda - 2 \end{bmatrix} = (\lambda - 2)(\lambda - 1)^2.$$

Los autovalores de A son $\lambda_1 = 2$, con multiplicidad 1, y $\lambda_2 = 1$, con multiplicidad 2. Los correspondientes autoespacios son:

$$E_1 = \ker(\lambda_1 I - A) = \left\{ \mathbf{u} : \begin{bmatrix} 1 & -1 & 0 \\ 0 & 1 & 0 \\ -1 & -1 & 0 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \right\} = \langle (0, 0, 1) \rangle.$$

$$E_2 = \ker(\lambda_2 I - A) = \left\{ \mathbf{u} : \begin{bmatrix} 0 & -1 & 0 \\ 0 & 0 & 0 \\ -1 & -1 & -1 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \right\} = \langle (1, 0, -1) \rangle.$$

Vemos que E_2 tiene dimensión 1, aunque la multiplicidad de λ_2 es 2. Es imposible formar una base de $\mathbb{R}^3$ con autovectores (como mucho podemos conseguir dos linealmente independientes, pero no tres). La matriz A no es diagonalizable. $\square$

No debemos olvidar que el Teorema Fundamental del Álgebra es verdadero en el campo complejo, pero no en el campo real (por ejemplo, el polinomio $P(x) = x^2 + 1$ no tiene raíces reales). Por eso, una matriz real puede ser diagonalizable en $\mathbb{C}$, pero no en $\mathbb{R}$.

Ejemplo 163. El polinomio característico de la matriz

$$A = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$$

es $P_A(\lambda) = \lambda^2 + 1$, de manera que los autovalores de A son $\lambda_1 = i$, y $\lambda_2 = -i$, ambos con multiplicidad 1 y autoespacios respectivos:

$$E_1 = \ker(\lambda_1 I - A) = \left\{ \mathbf{u} : \begin{bmatrix} i & 1 \\ -1 & i \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \right\} = \langle (1, -i) \rangle.$$

$$E_2 = \ker(\lambda_2 I - A) = \left\{ \mathbf{u} : \begin{bmatrix} -i & 1 \\ -1 & -i \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \right\} = \langle (1, i) \rangle.$$

Como la dimensión de cada autoespacio iguala a la multiplicidad del correspondiente autovalor, tenemos una base de $\mathbb{C}^n$ formada por autovectores de A , lo que equivale a afirmar que A es diagonalizable en $\mathbb{C}$:

$$A = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ i & -i \end{bmatrix} \begin{bmatrix} -i & 0 \\ 0 & i \end{bmatrix} \begin{bmatrix} 1 & 1 \\ i & -i \end{bmatrix}^{-1}.$$

En efecto,

$$\begin{bmatrix} 1 & 1 \\ i & -i \end{bmatrix} \begin{bmatrix} -i & 0 \\ 0 & i \end{bmatrix} \begin{bmatrix} 1 & 1 \\ i & -i \end{bmatrix}^{-1} = \begin{bmatrix} -i & i \\ 1 & 1 \end{bmatrix} \begin{bmatrix} \frac{1}{2} & -\frac{i}{2} \\ \frac{1}{2} & \frac{i}{2} \end{bmatrix} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} = A.$$

Sin embargo, A no es diagonalizable en $\mathbb{R}$, porque tiene autovalores complejos. Para que una matriz sea diagonalizable en $\mathbb{R}$, todos los autovalores deben ser reales y las dimensiones de los autoespacios correspondientes deben igualar a las multiplicidades de los correspondientes autovalores. $\square$

V.7: Matrices diagonalizables por similitud

Una matriz cuadrada $A \in \mathbb{K}^{n \times n}$ es diagonalizable en $\mathbb{K}$ por similitud si y solo si los autovectores de A generan todo $\mathbb{K}^n$.

La condición necesaria y suficiente para que los autovectores de A generen todo $\mathbb{K}^n$ (lo que permite formar una base autovectores de $\mathbb{K}^n$) es que la dimensión de cada autoespacio $E_i = \ker(\lambda_i I - A) \subset \mathbb{K}^n$ coincida con la multiplicidad del autovalor λ_i en el polinomio característico de A .

En una diagonalización $A = W\Lambda W^{-1}$, cada columna $\mathbf{w}_i$ de W es un autovector de A de autovalor λ_i y la matriz $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ contiene a esos autovalores repetidos según su multiplicidad en el polinomio característico de A .

4.2. Forma canónica de Jordan

Hemos visto que no todas las matrices cuadradas se pueden diagonalizar por similitud: se necesita que sus autovectores generen todo el espacio, algo que no siempre ocurre, aunque sabemos que siempre se puede formar una base de todo el espacio con autovectores generalizados (véase la sección 3.3 del Tema III).

El procedimiento de «cuasidiagonalización» de una matriz arbitraria $A \in \mathbb{C}^{n \times n}$ mediante autovectores generalizados consiste en escoger una base adecuada $\mathbf{v}_1, \dots, \mathbf{v}_q$ del

subespacio generado por los autovectores de A que se pueda completar asignando a cada autovector $\mathbf{v}_k$ una cadena de autovectores generalizados $\mathbf{u}_k^1, \mathbf{u}_k^2, \dots, \mathbf{u}_k^{n_k}$ tales que $(A - \lambda_k I)\mathbf{u}_k^j = \mathbf{u}_k^{j-1}$, para $\mathbf{u}_k^1 = \mathbf{v}_k$, en donde λ_k es el autovalor correspondiente a $\mathbf{v}_k$, de manera que las columnas de la siguiente matriz forman una base de $\mathbb{C}^n$:

$$W = [\mathbf{u}_1^1 \quad \mathbf{u}_1^2 \quad \dots \quad \mathbf{u}_1^{n_1} \quad \mathbf{u}_2^1 \quad \mathbf{u}_2^2 \quad \dots \quad \mathbf{u}_2^{n_2} \quad \dots \quad \mathbf{u}_k^1 \quad \mathbf{u}_k^2 \quad \dots \quad \mathbf{u}_k^{n_k}],$$

en donde $n_1 + n_2 + \dots + n_k = n$. Las cadenas se construyen así para conseguir que:

$$A\mathbf{u}_k^1 = A\mathbf{v}_k = \lambda_k \mathbf{v}_k = \lambda_k \mathbf{u}_k^1,$$

$$A\mathbf{u}_k^j = \lambda_k \mathbf{u}_k^j + (A - \lambda_k I)\mathbf{u}_k^j = \lambda_k \mathbf{u}_k^j + \mathbf{u}_k^{j-1}, \text{ para } j = 2, \dots, n_k.$$

De esta manera, la matriz $A \in \mathbb{C}^{n \times n}$ se factoriza de la forma $A = WJW^{-1}$, donde $J \in \mathbb{C}^{n \times n}$ es una matriz *diagonal por bloques* (pág. 75) con q bloques:

$$J = \begin{bmatrix} J_1 & \mathbf{0} & \mathbf{0} & \dots & \mathbf{0} \\ \mathbf{0} & J_2 & \mathbf{0} & \dots & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & J_3 & \ddots & \vdots \\ \vdots & \vdots & \ddots & \ddots & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \dots & \mathbf{0} & J_q \end{bmatrix} \in \mathbb{C}^{n \times n}, \quad (31)$$

en donde J_k es el *bloque de Jordan* de tamaño n_k asociado al autovector $\mathbf{v}_k$:

$$J_k = \begin{bmatrix} \lambda_k & 1 & 0 & \dots & 0 \\ 0 & \lambda_k & 1 & \dots & 0 \\ 0 & 0 & \lambda_k & \ddots & \vdots \\ \vdots & \vdots & \ddots & \ddots & 1 \\ 0 & 0 & \dots & 0 & \lambda_k \end{bmatrix} \in \mathbb{C}^{n_k \times n_k}. \quad (32)$$

La diagonalización por bloques (31)–(32) se denomina *forma canónica de Jordan* de la matriz A y es única salvo la reordenación de los bloques.

La diagonalización por similitud ordinaria corresponde al caso particular en el que $q = n$ (base de autovectores de $\mathbb{C}^n$), con lo que todos los bloques tienen el formato 1×1 .

⚠ No es cierto, de forma general, que a cada autovalor le corresponda un solo bloque. El autovalor λ_i del bloque J_i (el correspondiente al autovector $\mathbf{v}_i$) puede ser el mismo que el autovalor λ_j del bloque J_j ; esto es, $\lambda_i = \lambda_j$ siendo $i \neq j$. En ese caso, los bloques correspondientes pueden ser bien distintos ($n_i \neq n_j$) o bien iguales ($n_i = n_j$, bloques repetidos). La suma de los tamaños de todos los bloques asociados a un mismo autovalor nos dará la dimensión del correspondiente autoespacio generalizado. $\square$

Ejemplo 164. Calculemos la forma canónica de Jordan de la matriz:

$$A = \begin{bmatrix} 6 & -1 & 1 & -2 \\ 0 & 5 & -3 & 3 \\ 1 & -1 & 3 & 1 \\ 1 & -1 & 1 & 3 \end{bmatrix}$$

El polinomio característico es

$$P(\lambda) = \det(\lambda I - A) = (\lambda - 5)^3(\lambda - 2) = 0.$$

Como $\lambda = 2$ tiene multiplicidad 1, su autoespacio generalizado $\ker_{\infty}(2I - A)$ tiene también dimensión 1, con lo que coincide con su autoespacio $\ker(2I - A)$:

$$\ker(2I - A) = \left\{ \mathbf{u} : \begin{bmatrix} -4 & 1 & -1 & 2 \\ 0 & -3 & 3 & -3 \\ -1 & 1 & -1 & -1 \\ -1 & 1 & -1 & -1 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ u_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \right\} = \left\langle \begin{bmatrix} 0 \\ 1 \\ 1 \\ 0 \end{bmatrix} \right\rangle.$$

Ya tenemos $\mathbf{u}_1^1 = \mathbf{v}_1 = (0, 1, 1, 0)$, con $n_1 = 1$.

Como $\lambda = 5$ tiene multiplicidad 3, su autoespacio generalizado $\ker_{\infty}(5I - A)$ tiene también dimensión 3:

$$\ker(5I - A) = \left\{ \mathbf{u} : \begin{bmatrix} -1 & 1 & -1 & 2 \\ 0 & 0 & 3 & -3 \\ -1 & 1 & 2 & -1 \\ -1 & 1 & -1 & 2 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ u_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \right\} = \left\langle \begin{bmatrix} 1 \\ 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 1 \\ 1 \end{bmatrix} \right\rangle.$$

$$\ker(5I - A)^2 = \left\{ \mathbf{u} : \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 9 & -9 \\ 0 & 0 & 9 & -9 \\ 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ u_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \right\} = \left\langle \begin{bmatrix} 1 \\ 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 1 \\ 1 \end{bmatrix} \right\rangle.$$

Formamos la cadena $\mathbf{u}_2^2 = (0, 0, 1, 1)$, $\mathbf{u}_2^1 = \mathbf{v}_2 = (A - 5I)\mathbf{u}_2^2 = (-1, 0, -1, -1)$, de longitud 2 y la cadena $\mathbf{u}_3^1 = \mathbf{v}_3 = (1, 1, 0, 0)$ de longitud 1. Así, obtenemos las matrices

$$W = \begin{bmatrix} 0 & -1 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & -1 & 1 & 0 \\ 0 & -1 & 1 & 0 \end{bmatrix} ; \quad J = \begin{bmatrix} 2 & 0 & 0 & 0 \\ 0 & 5 & 1 & 0 \\ 0 & 0 & 5 & 0 \\ 0 & 0 & 0 & 5 \end{bmatrix}$$

que verifican $A = WJW^{-1}$. Obsérvese que la matriz diagonal por bloques J tiene 3 bloques (la dimensión del subespacio generado por los autovalores de A es 3):

$$J_1 = [2], \quad J_2 = \begin{bmatrix} 5 & 1 \\ 0 & 5 \end{bmatrix} \text{ y } J_3 = [5].$$

Los bloques J_2 y J_3 corresponden al autovalor $\lambda = 5$. La suma de los tamaños de estos dos bloques es $n_2 + n_3 = 2 + 1 = 3$, lo que coincide con la multiplicidad del autovalor $\lambda = 5$ y con la dimensión del autoespacio generalizado del autovalor $\lambda = 5$. $\square$

Aplicación a la informática. Calcular a mano la forma canónica de Jordan apenas tiene interés práctico; su valor es fundamentalmente didáctico al trabajar ejemplos sencillos.

En la práctica, las librerías numéricas como SymPy en Python incorporan funciones específicas (como `Matrix.jordan_form()`) para obtenerla simbólicamente.

Conviene señalar, no obstante, que la forma de Jordan es una herramienta de carácter eminentemente teórico. El cálculo numérico con matrices no ortogonales es sumamente inestable y sensible a pequeños errores de redondeo, por lo que en el ámbito computacional se prefieren alternativas estables como la descomposición de Schur. $\square$



Consulte la sección 4.4 *Matrices de Jordan* en el libro *Álgebra para ingenieros* [1], páginas 160 a 168, en particular, los ejemplos resueltos.

5. DESCOMPOSICIÓN EN VALORES SINGULARES (SVD)

Si $A \in \mathbb{K}^{n \times m}$ tiene rango r , la matriz $B = A^\top A \in \mathbb{K}^{m \times m}$, que tiene el mismo rango r , admite una diagonalización ortogonal $B = V\Lambda V^\top$, con $\Lambda \in \mathbb{K}^{m \times m}$ diagonal semidefinida positiva y $V \in \mathbb{K}^{m \times m}$ ortogonal, que se puede descomponer en bloques, $V = [V_r \ V_{m-r}]$, con $V_r \in \mathbb{K}^{m \times r}$ y $\Lambda_r \in \mathbb{K}^{r \times r}$ diagonal definida positiva, como sigue

$$B = V\Lambda V^\top = [V_r \ V_{m-r}] \begin{bmatrix} \Lambda_r & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} \begin{bmatrix} V_r^\top \\ V_{m-r}^\top \end{bmatrix} = V_r \Lambda_r V_r^\top.$$

La matriz rectangular $W_r = AV_r \Sigma_r^{-1} \in \mathbb{K}^{n \times r}$, en donde $\Sigma_r = \Lambda_r^{1/2} \in \mathbb{K}^{r \times r}$, tiene sus columnas ortonormales, pues

$$W_r^\top W_r = (\Sigma_r^{-1} V_r^\top A^\top)(A V_r \Sigma_r^{-1}) = \Sigma_r^{-1} V_r^\top B V_r \Sigma_r^{-1} = \Sigma_r^{-1} \Lambda_r \Sigma_r^{-1} = I_r,$$

luego, podemos ampliarla hasta una matriz ortogonal $W = [W_r \ W_{n-r}] \in \mathbb{K}^{n \times n}$.

Si denotamos por Σ a la matriz diagonal-rectangular, del mismo formato que A ,

$$\Sigma = \begin{bmatrix} \Sigma_r & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} \in \mathbb{K}^{n \times m}$$

tenemos

$$\begin{aligned} W\Sigma V^\top &= \begin{bmatrix} W_r & W_{n-r} \end{bmatrix} \begin{bmatrix} \Sigma_r & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} \begin{bmatrix} V_r^\top \\ V_{m-r}^\top \end{bmatrix} = W_r \Sigma_r V_r^\top \\ &= (AV_r \Sigma_r^{-1}) \Lambda_r^{1/2} V_r^\top = AV_r (\Lambda_r^{1/2})^{-1} \Lambda_r^{1/2} V_r^\top = AV_r V_r^\top = A. \end{aligned}$$

Las componentes σ_i de la matriz $\Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r)$ se denominan *valores singulares* de A y son las raíces cuadradas de los autovalores positivos de $A^\top A$, es decir $\sigma_i = \sqrt{\lambda_i}$.

V.8: Descomposición en valores singulares

Toda matriz $A \in \mathbb{K}^{n \times m}$ admite una *descomposición en valores singulares (SVD compacta)* $A = W_r \Sigma_r V_r^\top$, en donde $r = \text{rng } A$, $W_r \in \mathbb{K}^{n \times r}$ y $V_r \in \mathbb{K}^{m \times r}$ verifican $W_r^\top W_r = V_r^\top V_r = I_r$ y $\Sigma_r \in \mathbb{K}^{r \times r}$ es diagonal, $\Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r)$, con $\sigma_i > 0$, para todo $i = 1, \dots, r$ (*valores singulares* de A).

La matriz $A \in \mathbb{K}^{n \times m}$ admite también una *descomposición en valores singulares (SVD completa)* $A = W \Sigma V^\top$, en donde $W \in \mathbb{K}^{n \times n}$ y $V \in \mathbb{K}^{m \times m}$ ortogonales y

$$\Sigma = \begin{bmatrix} \Sigma_r & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} \in \mathbb{K}^{n \times m}.$$

Los valores singulares se suelen escoger en orden decreciente $\sigma_1 \geq \sigma_2 \geq \dots \sigma_r > 0$, para asegurar, de esa manera, la unicidad de las matrices Σ o Σ_r (según la SVD que se aplique). Las matrices de transformación, ya sean W y V o W_r y V_r , no son únicas, porque las bases de vectores se pueden completar de maneras diferentes.

Las columnas de W_r se denominan *vectores singulares por la izquierda* de A , mientras que las de V_r son los *vectores singulares por la derecha* de A . Estos nombre se aplican, en ocasiones, a las correspondientes columnas de las matrices completas W y V .

Ejemplo 165. Aplicamos a la matriz

$$A = \begin{bmatrix} \sqrt{2} & \sqrt{2} & -1 \\ \sqrt{2} & \sqrt{2} & 1 \\ 0 & 0 & 1 \\ \sqrt{2} & \sqrt{2} & 0 \end{bmatrix}$$

los pasos que nos han llevado a deducir la existencia la descomposición en valores singula-

res para una matriz arbitraria. Dejamos para el lector la comprobación de las operaciones.

$$B = A^T A = \begin{bmatrix} 6 & 6 & 0 \\ 6 & 6 & 0 \\ 0 & 0 & 3 \end{bmatrix}.$$

$$B = \begin{bmatrix} \frac{\sqrt{2}}{2} & 0 & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & 0 & -\frac{\sqrt{2}}{2} \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 12 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} & 0 \\ 0 & 0 & 1 \\ \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} & 0 \end{bmatrix} \text{ (diagonalización ortogonal).}$$

$$V = \begin{bmatrix} \frac{\sqrt{2}}{2} & 0 & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & 0 & -\frac{\sqrt{2}}{2} \\ 0 & 1 & 0 \end{bmatrix} ; \quad r = 2 ; \quad V_r = \begin{bmatrix} \frac{\sqrt{2}}{2} & 0 \\ \frac{\sqrt{2}}{2} & 0 \\ 0 & 1 \end{bmatrix}.$$

$$\Lambda = \begin{bmatrix} 12 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 0 \end{bmatrix} ; \Lambda_r = \begin{bmatrix} 12 & 0 \\ 0 & 3 \end{bmatrix} ; \Sigma_r = \begin{bmatrix} \sqrt{12} & 0 \\ 0 & \sqrt{3} \end{bmatrix} ; \Sigma = \begin{bmatrix} \sqrt{12} & 0 & 0 \\ 0 & \sqrt{3} & 0 \\ 0 & 0 & 0 \end{bmatrix}.$$

$$W_r = AV_r \Sigma_r^{-1} = \begin{bmatrix} \sqrt{2} & \sqrt{2} & -1 \\ \sqrt{2} & \sqrt{2} & 1 \\ 0 & 0 & 1 \\ \sqrt{2} & \sqrt{2} & 0 \end{bmatrix} \begin{bmatrix} \frac{\sqrt{2}}{2} & 0 \\ \frac{\sqrt{2}}{2} & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \frac{1}{6}\sqrt{3} & 0 \\ 0 & \frac{\sqrt{3}}{3} \end{bmatrix} = \begin{bmatrix} \frac{\sqrt{3}}{3} & -\frac{\sqrt{3}}{3} \\ \frac{\sqrt{3}}{3} & \frac{\sqrt{3}}{3} \\ 0 & \frac{\sqrt{3}}{3} \\ \frac{\sqrt{3}}{3} & 0 \end{bmatrix}.$$

$$W = \begin{bmatrix} \frac{\sqrt{3}}{3} & -\frac{\sqrt{3}}{3} & \sqrt{\frac{1}{3}} & 0 \\ \frac{\sqrt{3}}{3} & \frac{\sqrt{3}}{3} & 0 & \frac{\sqrt{3}}{3} \\ 0 & \frac{\sqrt{3}}{3} & \sqrt{\frac{1}{3}} & -\frac{\sqrt{3}}{3} \\ \frac{\sqrt{3}}{3} & 0 & -\sqrt{\frac{1}{3}} & -\frac{\sqrt{3}}{3} \end{bmatrix} \text{ (se completa por Gram-Schmidt).}$$

Así, obtenemos las descomposiciones SVD compacta y completa

$$A = W_r \Sigma_r V_r^T = \begin{bmatrix} \frac{\sqrt{3}}{3} & -\frac{\sqrt{3}}{3} \\ \frac{\sqrt{3}}{3} & \frac{\sqrt{3}}{3} \\ 0 & \frac{\sqrt{3}}{3} \\ \frac{\sqrt{3}}{3} & 0 \end{bmatrix} \begin{bmatrix} \sqrt{12} & 0 \\ 0 & \sqrt{3} \end{bmatrix} \begin{bmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ 0 & 0 & 1 \end{bmatrix} \text{ SVD compacta}$$

$$A = W\Sigma V^\top = \begin{bmatrix} \frac{\sqrt{3}}{3} & -\frac{\sqrt{3}}{3} & \sqrt{\frac{1}{3}} & 0 \\ \frac{\sqrt{3}}{3} & \frac{\sqrt{3}}{3} & 0 & \frac{\sqrt{3}}{3} \\ 0 & \frac{\sqrt{3}}{3} & \sqrt{\frac{1}{3}} & -\frac{\sqrt{3}}{3} \\ \frac{\sqrt{3}}{3} & 0 & -\sqrt{\frac{1}{3}} & -\frac{\sqrt{3}}{3} \end{bmatrix} \begin{bmatrix} \sqrt{12} & 0 & 0 \\ 0 & \sqrt{3} & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} & 0 \\ 0 & 0 & 1 \\ \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} & 0 \end{bmatrix} \quad \text{SVD completa}$$

Hay que tener en cuenta que librerías informáticas no calculan la SVD de esta manera; en su lugar, reducen directamente la matriz original a una forma simplificada de solo dos diagonales y luego aplican métodos iterativos para extraer los valores singulares. $\square$

La descomposición en valores singulares permite definir la *pseudoinversa de Moore–Penrose* de una matriz $A \in \mathbb{K}^{n \times m}$: si $A = W_r \Sigma_r V_r^\top$ es la SVD compacta de A , entonces

$$A^\dagger = V_r \Sigma_r^{-1} W_r^\top \in \mathbb{K}^{m \times n}$$

Aunque la matriz $P = AA^\dagger \in \mathbb{K}^{n \times n}$ no tiene por qué ser la identidad,

$$P = AA^\dagger = (W_r \Sigma_r V_r^\top)(V_r \Sigma_r^{-1} W_r^\top) = W_r \Sigma_r \Sigma_r^{-1} W_r^\top = W_r W_r^\top,$$

sí es hermítica e *idempotente* (esto es, $P^2 = P$) y deja invariante el subespacio $\text{col } A$:

$$P^\top = (W_r W_r^\top)^\top = W_r W_r^\top = P.$$

$$P^2 = (W_r W_r^\top)^2 = (W_r W_r^\top)(W_r W_r^\top) = W_r I_r W_r^\top = W_r W_r^\top = P.$$

$$PA = AA^\dagger A = (W_r W_r^\top)(W_r \Sigma_r V_r^\top) = W_r \Sigma_r V_r^\top = A. \quad (33)$$

Por lo tanto, P proporciona la proyección ortogonal sobre el subespacio $\text{col } A$. En efecto, como $\text{col } A \oplus \ker A^\top = \mathbb{K}^n$, todo vector $\mathbf{u} \in \mathbb{K}^n$ se descompone como $\mathbf{u} = \mathbf{u}_1 + \mathbf{u}_2$, con $\mathbf{u}_1 \in \text{col } A$ y $\mathbf{u}_2 \in \ker A^\top$. Gracias a la expresión (33), vemos $P\mathbf{u}_1 = \mathbf{u}_1$, mientras que $P\mathbf{u}_2 = PP\mathbf{u}_2 = PP^\top \mathbf{u}_2 = P\mathbf{0} = \mathbf{0}$, de manera que $P\mathbf{u} = P\mathbf{u}_1 + P\mathbf{u}_2 = \mathbf{u}_1$.

La pseudoinversa proporciona siempre una solución $\mathbf{x} = A^\dagger \mathbf{b}$ para las ecuaciones normales $A^\top A \mathbf{x} = A^\top \mathbf{b}$ (pág. 175), pues $A^\top A A^\dagger = A^\top P = (PA)^\top = A^\top$, luego

- Si $A\mathbf{x} = \mathbf{b}$ es un sistema compatible determinado, $\mathbf{x} = A^\dagger \mathbf{b}$ es su única solución.
- Si $A\mathbf{x} = \mathbf{b}$ es compatible indeterminado, entonces $\mathbf{x} = A^\dagger \mathbf{b}$ es una de sus soluciones.
- Si $A\mathbf{x} = \mathbf{b}$ es un sistema incompatible, entonces $\mathbf{x} = A^\dagger \mathbf{b}$ proporciona un ajuste por mínimos cuadrados (página 176).

En realidad, ya nos habíamos encontrado con la pseudoinversa (sin nombrarla) en temas anteriores: la expresión (17) del Tema II nos daba la pseudoinversa

$$A^\dagger = (A^\top A)^{-1} A^\top, \quad (34)$$

en el caso particular de que $\text{rng } A = m$.

Análogamente, si $\text{rng } A = n$, como $(A^\top)^\dagger = (A^\dagger)^\top$, podemos aplicar (34) a $A^\top$:

$$A^\dagger = ((A^\top)^\dagger)^\top = ((AA^\top)^{-1}A)^\top = A^\top(AA^\top)^{-1}.$$

Si A es cuadrada invertible, se verifican las condiciones anteriores, luego $A^\dagger = A^{-1}$.

Ejemplo 166. Calculamos la pseudoinversa de la matriz A del ejemplo 165:

$$A = \begin{bmatrix} \sqrt{2} & \sqrt{2} & -1 \\ \sqrt{2} & \sqrt{2} & 1 \\ 0 & 0 & 1 \\ \sqrt{2} & \sqrt{2} & 0 \end{bmatrix} = W_r \Sigma_r V_r^\top = \begin{bmatrix} \frac{\sqrt{3}}{3} & -\frac{\sqrt{3}}{3} \\ \frac{\sqrt{3}}{3} & \frac{\sqrt{3}}{3} \\ 0 & \frac{\sqrt{3}}{3} \\ \frac{\sqrt{3}}{3} & 0 \end{bmatrix} \begin{bmatrix} \sqrt{12} & 0 \\ 0 & \sqrt{3} \end{bmatrix} \begin{bmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

A partir de esta SVD compacta, la pseudoinversa $A^\dagger = V_r \Sigma_r^{-1} W_r^\top$ se calcula como

$$A^\dagger = \begin{bmatrix} \frac{\sqrt{2}}{2} & 0 \\ \frac{\sqrt{2}}{2} & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{12}} & 0 \\ 0 & \frac{1}{\sqrt{3}} \end{bmatrix} \begin{bmatrix} \frac{\sqrt{3}}{3} & \frac{\sqrt{3}}{3} & 0 & \frac{\sqrt{3}}{3} \\ -\frac{\sqrt{3}}{3} & \frac{\sqrt{3}}{3} & \frac{\sqrt{3}}{3} & 0 \end{bmatrix} = \begin{bmatrix} \frac{\sqrt{2}}{12} & \frac{\sqrt{2}}{12} & 0 & \frac{\sqrt{2}}{12} \\ \frac{\sqrt{2}}{12} & \frac{\sqrt{2}}{12} & 0 & \frac{\sqrt{2}}{12} \\ -\frac{1}{3} & \frac{1}{3} & \frac{1}{3} & 0 \end{bmatrix},$$

una matriz con el mismo formato que $A^\top$. □

Aplicación a la informática. Como ya se ha señalado, la SVD no es solo un resultado teórico importante, sino una de las herramientas del álgebra lineal más utilizadas en la IA moderna. A lo largo de los próximos cursos, esta descomposición probablemente aparecerá en varios ámbitos.

Por una parte, sabemos que los datos reales (imágenes, textos o datos numéricos) se representan en espacios de miles o millones de dimensiones, aunque la información relevante suele concentrarse en unas pocas direcciones principales. La SVD permite identificarlas al conservar únicamente los valores singulares más grandes, obteniendo así aproximaciones de bajo rango de las matrices. Este principio permite comprimir datos y constituye la base matemática del análisis de componentes principales (PCA), fundamental para procesar grandes volúmenes de información eficientemente.

Por ejemplo, la SVD permite transformar matrices de coocurrencia de datos (como la frecuencia con la que aparecen ciertas palabras juntas en un texto) en un espacio de menor dimensión. En cierta manera, la cercanía «geométrica» refleja la similitud semántica. Este mecanismo, conocido históricamente como análisis semántico latente (LSA), es el antecedente directo de los espacios de *embedding* que utilizan los modelos de lenguaje actuales.

Por último, hay que tener en cuenta la estabilidad numérica y computacional. En IA es frecuente encontrar sistemas de ecuaciones o problemas de mínimos cuadrados en los que las matrices involucradas no se pueden invertir eficientemente. La pseudoinversa de Moore-Penrose, calculada a través de la SVD, ofrece una solución numéricamente estable para estos problemas.

□

TABLA DE MATRICES

$\mathbb{K}$		$\mathbb{C}$	$\mathbb{R}$
Formulación general. Válida para $\mathbb{K} = \mathbb{R}$ o $\mathbb{K} = \mathbb{C}$		Caso particular $\mathbb{K} = \mathbb{C}$. Menos frecuente	Caso particular $\mathbb{K} = \mathbb{R}$. Más frecuente
$\overline{A}$	Conjugada. Cambiar $i \rightsquigarrow -i$	Uso frecuente	$\overline{A} = A$
A^T	Transpuesta. $(a_{ij}) \rightarrow (a_{ji})$	Uso muy poco frecuente	$A^\top = A^T$ Empleamos $A^\top$
$A^\top$	Transpuesta conjugada. $A^\top = (\overline{A})^T = \overline{A^T}$	Uso frecuente	
$A^\top A = AA^\top$	Matriz normal	Tiene diagonalización ortogonal	Tiene diagonalización ortogonal
$A^T = A$	Matriz simétrica	Uso muy poco frecuente	Simétrica = hermítica
$A^\top = A$	Matriz hermítica	Uso frecuente	Se emplea simétrica
$A^\top A = AA^\top = I$	Matriz ortogonal/unitaria	Matriz unitaria	Matriz ortogonal
$\mathbf{u}^T A \mathbf{u}$	Forma bilineal	Uso muy poco frecuente	Bilineal = sesquilineal Se emplea bilineal $\mathbf{u}^\top A \mathbf{u}$
$\mathbf{u}^\top A \mathbf{u}$	Forma sesquilineal	Uso frecuente	

ÍNDICE ALFABÉTICO DE TÉRMINOS

Apilamiento, 70
Aplicación, 21, 119
 lineal, 121, 123
Argumento de un número complejo, 46
Autoespacio, 138
 generalizado, 140
Autovalor, 138
Autovector, 138
 generalizado, 140

Base, 58
 cambio de, 103
 canónica de $\mathbb{K}^I$, 59
 canónica de $\mathcal{F}(I)$, 59
 de $\mathbb{K}^n$, 103
 ordenada, 58
 ordenada de $\mathbb{K}^n$, 103
 ortogonal, 108
 ortonormal, 108
Base de un sistema de numeración posicional, 26
Biyectiva, función, 21

Cambio de base en $\mathbb{K}^n$, 103
Cholesky, descomposición LLT, 182, 185
Cifras significativas (c.s.), 34
Coeficientes de una combinación lineal, 57
Colección, 16
Combinación lineal, 57
 de subconjuntos, 57
 trivial, 57
Complemento ortogonal: $V^\perp$, 112
Componentes, 22

- de un tensor, 66
- Concatenación, 70
- Conjugado de un número complejo, 44
- Conjunto, 16
 - acotado, 31
 - cerrado por una operación, 22
 - de las partes: $\wp(X)$, 17
 - finito, 25
 - indexado, 22
 - infinito, 25
 - no numerable, 37
 - numerable, 25
 - ordenado, 20
 - potencia: $\wp(X)$, 17
 - vacío: $\emptyset$, 16
- Conjuntos
 - ortogonales: $A \perp B$, 112
- Cota, 20
- Covector, 68
- Cuerpo, 31
 - de escalares, 42
 - de los números complejos, 41
 - de los números racionales, 30
 - ordenado, 31
- Dependiente, linealmente, 58
- Desarrollo eventualmente periódico, 33
- Desarrollo finito en una base b , 34
- Descomposición
 - de Schur, 179
 - LDLT, 182, 184
 - LDU, 183
 - en valores singulares, SVD, 183, 202
 - LLT o de Cholesky, 182, 185
 - ortogonal, 112
 - PLU, 168
 - QR, 170, 174
 - de rango, 172
 - delgada, 172

- reducida, 172
- Desigualdad
 - de Cauchy-Schwartz, 106
 - triangular, 108
- Despliegue de un tensor, 73
- Determinación principal del argumento, 47
- Determinante, 125, 127
 - cálculo mediante PLU, 168
- Diagonal principal, 74
- Diagonalización, 181
 - ortogonal, 182
 - ortogonal, 182, 186
 - por congruencia, 182
 - por similitud, 181, 182
- Dimensión, 61
 - finita, 61
 - infinita, 61
- Distancia euclídea en $\mathbb{R}^n$, 109
- Domino de una función, 21
- Ecuación característico, 139
- Ecuación normal, 175
- Ecuaciones normales, 175
- Eigenspace = autoespacio, 144
- Eigenvalue = autovalor, 144
- Eigenvector = autovector, 144
- Eje o índice
 - de un tensor, 66
 - degenerado, 66
- Elemento, 16
 - cero: $\mathbf{0}$, 58
 - nulo: $\mathbf{0}$, 58
- Elementos
 - básicos de $\mathbb{R}^I$, 59
- Escalar, 42
- Escalonamiento, 156
- Espacio
 - columna = espacio imagen, 136
 - imagen = espacio columna, 136

- lineal, 57, 82
 - abstracto, 63
- lineal libre sobre un conjunto, 59
- métrico, 109
- nulo = núcleo, 136
- vectorial, 82
 - abstracto, 63
- vectorial = espacio lineal, 57, 63

Fórmula de Euler, 48

Fórmula de Moivre, 49

Factorización

- de Schur, 179
- LDLT, 182, 184
- LDU, 183
- LLT o de Cholesky, 182, 185
- PLU, 168
- QR, 170, 174
 - de rango, 172
 - delgada, 172
 - reducida, 172

Familia, 22

- ortogonal, 108
- ortonormal, 108

Forma, 123

- bilineal, 121
 - antisimétrica, 121
 - simétrica, 121
- definida negativa, 149
- definida positiva, 149
- indefinida, 149
- lineal, 123
- multilineal, 122, 123
 - antisimétrica, 122, 123
 - simétrica, 122, 123
- semidefinida negativa, 149
- semidefinida positiva, 149
- sesquilineal, 121
 - antisimétrica, 121

hermitica, 146
 simétrica, 121
 Forma binómica de un número complejo, 42
 Forma de Jordan, 182
 Forma exponencial de un número complejo, 48
 Forma trigonométrica de un número complejo, 46
 Formato, 66
 Función, 21
 biyectiva, 21
 inyectiva, 21
 Gauss, método, 156
 Gauss-Jordan, método, 102
 Homogénea de grado n , 127
 Homogeneidad absoluta del módulo, 105
 Identidad de Euler, 48
 Imagen de un subconjunto, 21
 Imagen inversa de un subconjunto, 21
 Independiente, linealmente, 58
 Índice o eje de un tensor, 66
 Índices, 23
 Inversa
 matriz, 98
 por la derecha, 98
 por la izquierda, 98
 Inyectiva, función, 21
 Jordan, forma de, 182
 Ley de inercia de Sylvester, 189, 191
 Linealmente
 dependiente, 58
 independiente, 58
 Llaves (notación), 16
 Longitud o tamaño de un índice, 66
 Mínimos cuadrados, 176
 Método

- de Gauss, 156
- de Gauss-Jordan, 102
- Métrica, 109
- Módulo
 - de un número complejo, 45
 - de un vector, 105
- Mantisa: denominación poco adecuada para el *significando*, 35
- Matriz, 66
 - alta, 74
 - ampliada de un sistema, 155
 - ancha, 74
 - antihermítica: $A^T = -A$. Si A es una matriz real, es lo mismo que antisimétrica, 73
 - antisimétrica: $A^T = -A$, 73
 - columna, 68
 - congruente, 182
 - cuadrada, 74
 - de cambio de coordenadas, 103
 - de coeficientes de un sistema, 155
 - de permutación, 77, 116
 - de transformación elemental, 99
 - de unos: **1**, 75
 - definida negativa, 149, 192
 - definida positiva, 149, 192
 - diagonal, 75
 - diagonal por bloques, 75, 130
 - diagonal-rectangular, 76
 - dispersa, 169
 - escalonada, 80
 - fila, 68
 - hermítica: $A^T = A$. Si A es una matriz real, es lo mismo que simétrica, 73, 146
 - idempotente: $P^2 = P$, 204
 - identidad, 76
 - indefinida, 149, 192
 - inversa, 98
 - invertible, 98
 - no singular, 98
 - normal, 96
 - normal triangular = matriz diagonal, 153

- nula de formato $n \times m$: , 75
- ortogonal, 115
- por bloques, 70
- por cajas, 70
- rectangular, 74
- regular, 98
- semejante = similar, 181
- semidefinida negativa, 149, 192
- semidefinida positiva, 149, 192
- simétrica: $A^T = A$, 73
- similar, 181
- singular, 98
- transpuesta conjugada: $A^\top$. Si A es real, $A^\top = A^T$, 71
- transpuesta: A^T , 71
- trapezoidal, 79
 - inferior, 80
 - superior, 79
- triangular, 78, 153
 - inferior, 78
 - por bloques, 117
 - superior, 78
- unitaria, 115
- unitriangular, 78
 - con bloque A , 78
 - concentrada, 78
 - por bloques, 78
- Menor principal, 127
- Menor principal líder = menor principal, en nuestro contexto, 127
- Multiplicidad, 143
 - algebraica, 143
 - geométrica, 143
- Multiplicidad de una raíz de un polinomio, 53
- Núcleo
 - generalizado, 137
- Núcleo de una matriz = espacio nulo, 136
- Número, 26
 - complejo, 41
 - imaginario puro, 42

- entero, 25
- irracional, 37
- natural, 24
- racional, 30
 - exacto en base b , 34
- real, 36
- representable, 38
- Norma L_p , 109
- Notación
 - científica, 35
 - de coma flotante, 35
- Operación, 22
 - p -aria, 22
 - binaria, 22
- Ortogonal
 - base, 108
 - descomposición, 112
 - familia, 108
 - suma directa, 113
- Ortogonales
 - conjuntos: $A \perp B$, 112
 - vectores, 107
- Ortonormal
 - base, 108
 - familia, 108
- Par ordenado, 19
- Paralelepípedo k -dimensional, 133
- Parte
 - antihermítica, 146
 - antisimétrica, 146
 - hermítica, 146
 - imaginaria de un número complejo, 42
 - real de un número complejo, 42
 - simétrica, 146
- Pesos de una combinación lineal, 57
- Pivote, 80
- Pivote; fila, 100

Polinomio característico, 139

Potencia n -ésima de un número complejo, 49

Producto

cartesiano de conjuntos, $\times$, 19

de Hadamard, 62

de matrices, 84

escalar de vectores, 104, 150

vectorial de $\mathbb{R}^3$, 89

propiedades, 107

Producto interno = producto escalar, 151

Proyección ortogonal sobre un subespacio, 113, 204

Raíz n -ésima de un número complejo, 50

Raíz cuadrada de un matriz hermítica semidefinida positiva, 187

Raíz de un polinomio, 51

Rango, 136

Recorrido de una función, 21

Redondeo, 39

al par más cercano, 39

Reduced Row Echelon Form (RREF), 81

REF: Row Echelon Form, 80

Regresión linal, 176

Relación, 20

de orden parcial, 20

de orden total = relación de orden, 20

Rouché-Fröbenius, teorema de, 157

Row Echelon Form (REF), 80

RREF: Reduced Row Echelon Form, 81, 102

Semejanza = similitud, 181

Signatura, 190

Signatura de una permutación, 125

Significando y exponente, 35

Sistema

compatible, 156

determinado, 157

indeterminado, 157

homogéneo, 155

incompatible, 156

Sistema de numeración, 26
 posicional , 26
 Sistema de numeración binario, 27
 Sistema de numeración decimal, 27
 Sistema hexadecimal, 27
 Sistema octal, 27
 Subconjunto de un conjunto, 17
 Subespacio
 afín, 58
 generado por un conjunto, 58
 lineal, 58
 propio, 59
 propio = autoespacio, 144
 Submatriz principal líder, 71
 Suma
 de Einstein, 89
 de subconjuntos, 57
 de subespacios, 62
 directa de subespacios: $U \oplus V$, 62
 Sustitución hacia atrás, 101, 156
 Sylvester, ley de inercia de, 189, 191

 Término independiente de un sistema, 155
 Tamaño o longitud de un índice, 66
 Tensor, 66
 antisimétrico, 73
 cuadrado, 73
 de Levi-Civita, 73, 89, 120, 125
 simétrico, 73
 Teorema
 de Cayley-Hamilton, 142
 de inercia de Sylvester, 189, 191
 de la base, 61
 de Rouché-Frobenius, 157, 176
 espectral para matrices hermíticas, 187
 espectral para matrices normales, 186
 Fundamental del Álgebra (TFA), 53
 Transformación, 119
 Transposición de ejes, 71

Transpuesta

conjugada: $A^\top$. Si A es real, $A^\top = A^T$, 71

hermítica: transpuesta-conjugada, 72

matriz A^T , 71

Tupla: $(a_1, a_2, \dots, a_n)$, 19

Unidad imaginaria, 41

Unitario, vector, 105

Universo, 18

Vacío, conjunto: $\emptyset$, 16

Valor

propio = autovalor, 144

singular (SVD), 202

Valor absoluto, 32

Variable

libre, 23

muda o ligada, 23

Vector, 66, 68, 82

propio = autovector, 144

singular (SVD), 202

unitario, 105

Vectores

ortogonales, 107

Volumen k -dimensional, 134

LISTA DE SÍMBOLOS

- (a, b) : par ordenado, 19
 A^{-1} : matriz inversa, 98
 $A^{1/2}$, para A hermítica semidefinida positiva, 187
 Y^X : conjunto de las aplicaciones $f: X \rightarrow Y$, 21
 $\mathbb{N}_n = \{1, 2, \dots, n\}$, 65
 δ_{ij} : delta de Kronecker, 59
 $\det$: determinante, 127
 $\text{dom } f$: dominio de la función f , 21
 $\emptyset$: conjunto vacío, 16
 $\setminus$: complemento relativo. No confundir $A \setminus B$ con $A - B$, 17
 $\subset$ o $\subseteq$: contenido, 17
 $\{\dots\}$: llaves, 17
 $\in$: pertenece, 16
 $\notin$: no pertenece, 16
 $\langle B \rangle$: subespacio generado por B , 58
 $\mathbb{N}$: Números naturales, 24
 $\mathbb{Z}$: Números enteros, 25
 $\mathbf{0}$: elemento cero de $\mathbb{K}^I$, 58
 $\mathbf{0}$: elemento nulo de $\mathbb{K}^I$, 58
 $\mathbf{1}$: matriz de unos, 75
 $\mathbf{e}_j$: elementos básicos de $\mathbb{K}^I$, 59
 $\text{Im}(z)$: Parte imaginaria del complejo z , 42
 $\text{Re}(z)$: Parte real del complejo z , 42
 $\bar{z}$: Conjugado de un número complejo, 44
 $\text{Arg}(z)$: Argumento de un número complejo, 46
 $\times$: producto cartesiano., 19
 $\times$: producto vectorial en $\mathbb{R}^3$, 89
 $\wp(X)$: potencia de X o conjunto de las partes de X , 17
 $f: X \rightarrowtail Y$: función de un subconjunto de X en Y ; es decir, $\text{dom } f \subset X$, 21
 $f: X \rightarrow Y$: función de X en Y ; es decir, $\text{dom } f = X$, 21
 $f(A)$: imagen de $A \subset X$; es $f(A) = \{f(x) : x \in A\}$, 21
 $f^{-1}(B)$: imagen inversa de $B \subset Y$; es $f^{-1}(B) = \{x \in \text{dom } f : f(x) \in B\}$, 21

i : unidad imaginaria. También se emplea j , 41

$n_1 \times n_2 \times \cdots \times n_m \equiv \mathbb{N}_{n_1} \times \mathbb{N}_{n_2} \times \cdots \times \mathbb{N}_{n_m}$, 65

IEE 754: estándar técnico, 35

$U \oplus V$: suma directa de subespacios, 62

$A \perp B$: conjuntos ortogonales, 112

$V^\perp$: complemento ortogonal al subespacio V , 112

$\mathbb{C}$: cuerpo de los números complejos, 41

$\mathbb{Q}$: cuerpo de los números racionales, 30

$\mathbb{R}$: cuerpo de los números reales, 36

`einsum`, 89

$\ker A$: núcleo de A , 136

$\text{col}(A)$: espacio columna, 136

PLU, 168

LDLT, 182, 184

LDU, 182, 183

LLT, 182, 185

LU, 168

$A^H = A^\top = \overline{A^T}$, 72

A^T : matriz transpuesta. Si A es real, $A^T = A^\top$, 71

$A^\top$: matriz transpuesta conjugada. Si A es real, $A^\top = A^T$, 71

$|x|$: Valor absoluto de un número real x , 32

$|z|$: Módulo de un número complejo z , 45

$\|\mathbf{u}\|$: módulo de un vector $\mathbf{u}$, 105, 109

$\|\mathbf{u}\|_p$: norma L_p en $\mathbb{R}^n$, 109

$\perp$: ortogonal, 107

$\mathbb{Q}_{b,n}$: racionales exactos con menos de $n + 1$ cifras significativas en base b , 35

QR: factorización o descomposición, 170

$\text{rng}(A)$: rango de A , 136

SVD: descomposición en valores singulares, 183, 202

TFA: Teorema Fundamental del Álgebra, 53

$\mathbb{Z}_b$, 34

BIBLIOGRAFÍA

- [1] A. M. Díaz Hernández, E. Hernández García y L. Tejero Escribano. *Álgebra para ingenieros*. 1.^a ed. UNED, 2012. ISBN: 9788492948246. Disponible en abierto en el curso virtual.
- [2] P. R. Halmos. *Naive Set Theory*. Undergraduate Texts in Mathematics. Springer-Verlag, 2000. ISBN: 978-0-387-90092-6.